

Aspectos destacados

Selección y concatenación de descriptores heterogéneos para la clasificación de texturas

Carlos Ayala, Joaquín Delgado

- Se comparan cinco estrategias de representación bajo las mismas particiones externas.
- La concatenación y la selección ofrecen beneficios que dependen del dataset.
- Se presentan Friedman, Iman–Davenport, Friedman alineado, Quade y valores p ajustados con Holm.
- Se evalúan 22 descriptores en seis datasets con SVM lineal y ResMLP.

Selección y concatenación de descriptores heterogéneos para la clasificación de texturas*

Carlos Ayala^{a,*}, Joaquín Delgado^{a,1}

^aUniversidad Nacional de Asunción, Facultad Politécnica (UNA-FP), Campus Universitario, San Lorenzo, Central, Paraguay

ARTICLE INFO

Keywords:

clasificación de texturas
concatenación de descriptores
selección de bloques de características
Greedy Forward Selection
fusión de representaciones

Abstract

Este trabajo evalúa la concatenación de descriptores heterogéneos para clasificar texturas. Se comparan cinco estrategias: Individual, Completa, Top- k , Greedy Forward Selection (GFS) y Homogénea. La biblioteca común reúne 22 descriptores, incluidos RGB N-gramas + SVD y BEiT_{v2}-B, sobre DTD, FMD, CURET, Outex, Soil y KTH-TIPS2-b con SVM lineal y ResMLP. La selección se realiza dentro del entrenamiento y el desempeño se mide mediante macro-F1 y exactitud en 94 condiciones externas. Friedman, Iman-Davenport y Quade detectan diferencias globales para ambos clasificadores, mientras Friedman alineado no rechaza. Tras ajustar con Holm los diez pares basados en Friedman dentro de cada clasificador, GFS supera a Individual con ResMLP; ningún par resulta significativo con SVM. La adición de BEiT_{v2} a la concatenación completa produce cambios pequeños y dependientes del dominio, sin diferencia global significativa frente a la biblioteca de 21 bloques. Los resultados respaldan elegir la composición y el costo dimensional según el dominio, sin afirmar superioridad universal de una estrategia.

1. Introducción

La clasificación de texturas depende de señales locales, distribuciones espaciales y respuestas en frecuencia que cambian con el dominio, la escala, la iluminación y el punto de vista [1–3]. Ninguna representación captura necesariamente todas esas variaciones. Los descriptores clásicos resumen propiedades diseñadas, como microestructuras, coocurrencias y gradientes [4–6]; las redes convolucionales, los Transformers y los modelos autosupervisados producen características aprendidas con arquitecturas y objetivos de preentrenamiento diferentes [7–11]. Esta diversidad crea una oportunidad para combinar representaciones, pero también introduce redundancia, escalas incompatibles y un aumento considerable de dimensionalidad.

La concatenación conserva la información de varios extractores y delega al clasificador la decisión sobre sus coordenadas. Agregaciones locales, Fisher vectors, bancos de filtros profundos y capas de codificación aprendida han mostrado que combinar respuestas puede mejorar el reconocimiento de texturas [2, 12, 13]. Sin embargo, una mejora de la representación conjunta no demuestra que todos sus bloques sean necesarios ni que la complementariedad explique por sí sola el resultado. El mismo efecto puede aparecer al aumentar la dimensión o al reunir descriptores que ya son fuertes de manera individual.

Las arquitecturas de fusión y las combinaciones de representaciones motivan distinguir tres factores en la evaluación: calidad individual, cantidad de variables y composición del subconjunto. La distinción adquiere especial importancia en una biblioteca que reúne descriptores clásicos, CNN, Transformers y representaciones autosupervisadas o multimodales. La pregunta de estudio es *cómo cambian el desempeño externo y la dimensionalidad al concatenar descriptores, frente a seleccionar uno individual, y qué aporta elegir la composición de esa concatenación*.

Para responder esta pregunta se evaluaron 22 descriptores sobre DTD, FMD, CURET, Outex, Soil y KTH-TIPS2-b con SVM lineal y ResMLP. El mismo protocolo anidado compara cinco estrategias: Individual, Completa, Top- k , GFS y Homogénea. La comparación considera macro-F1 y exactitud, junto

* Borrador de trabajo de Tesis de Grado, Facultad Politécnica, Universidad Nacional de Asunción (UNA-FP). Documento preparado para revisión con el tutor; el bloque experimental primario ha finalizado y permanece sujeto a revisión académica.

* Autor de correspondencia

✉ carlos.ayala@est.fpuna.edu.py (C. Ayala); joaquin.delgado@est.fpuna.edu.py (J. Delgado)

¹ Ambos autores contribuyeron al diseño y ejecución del estudio. Tutor: Prof. José Vázquez.

con la dimensión de las representaciones. Se completaron 47 condiciones externas por clasificador; cada una incluye las cinco estrategias sobre la misma biblioteca de 22 descriptores.

El trabajo aporta una comparación reproducible de estrategias de concatenación bajo particiones comunes, una evaluación no paramétrica entre datasets y una comparación del desempeño y la dimensionalidad de los subconjuntos seleccionados. GFS y Top- k son procedimientos para elegir qué bloques concatenar dentro de esta comparación. El propósito es caracterizar las ganancias y los costos observados de combinar bloques, sin introducir un nuevo algoritmo de selección. La evidencia se interpreta atendiendo tanto a las diferencias observadas como a la incertidumbre estadística.

El resto del artículo se organiza de la siguiente manera. La segunda sección revisa brevemente por qué combinar representaciones heterogéneas puede mejorar la clasificación de texturas. La tercera describe el método de concatenación y selección de descriptores. La cuarta presenta los datasets, los clasificadores, el protocolo anidado, el análisis estadístico y los resultados experimentales. La quinta discute la complementariedad, el costo dimensional y las amenazas a la validez. Finalmente, la sexta sección concluye.

2. Trabajos relacionados

2.1. Complementariedad entre representaciones de textura

Los descriptores de textura resumen señales distintas de una misma imagen: microestructuras (LBP), coocurrencias, orientación de gradientes y patrones en frecuencia [4–6, 14]. Las representaciones aprendidas introducen sesgos adicionales derivados de arquitecturas convolucionales, Transformers y objetivos de preentrenamiento supervisado, autosupervisado o multimodal [7–11, 15–18]. Por ello, ningún extractor debe suponerse universalmente suficiente: vectores con distinto origen pueden contener información redundante, pero también señales complementarias aprovechables por un clasificador conjunto. Esta complementariedad, y no la comparación aislada entre arquitecturas, motiva la composición de bloques del presente estudio.

2.2. Concatenación y selección de bloques

La fusión de características combina información antes de la decisión final del clasificador. Una estrategia directa consiste en concatenar los vectores extraídos de una misma imagen. A diferencia de la fusión de decisiones, esta operación conserva explícitamente las coordenadas de cada representación y permite entrenar un único clasificador sobre el espacio conjunto. Su sencillez constituye una ventaja experimental: permite estudiar el efecto de combinar descriptores sin introducir un módulo de fusión altamente parametrizado. No obstante, el vector resultante crece con cada extractor incorporado y puede acumular escalas incompatibles, variables redundantes y dimensiones poco informativas.

Los Fisher vectors mostraron que la agregación de descriptores locales puede producir representaciones de alto rendimiento [12]; en texturas, los bancos de filtros profundos combinaron activaciones convolucionales con agregación estadística [2] y DeepTEN integró una capa de codificación residual dentro de una arquitectura profunda [13]. Estos antecedentes muestran que reunir señales distintas puede mejorar la representación, pero no determinan si todos los componentes son necesarios cuando la biblioteca contiene extractores heterogéneos y congelados.

Los antecedentes citados motivan evaluar si una búsqueda secuencial supera a reunir los descriptores individualmente más fuertes bajo el mismo número de bloques. Por ello, este estudio compara esas políticas bajo las mismas particiones y separa la selección de la evaluación externa, como recomiendan los diseños wrapper y la evaluación anidada [19, 20]. El foco no está en proponer otro extractor ni en atribuir el resultado a una arquitectura particular, sino en evaluar la *concatenación de descriptores como problema de selección de bloques*, comparando su desempeño externo y dimensionalidad. Igualar el número de bloques no iguala las dimensiones ni permite aislar causalmente la complementariedad.

Dos estudios recientes permiten contextualizar el bloque BEiT_v2. Neshov et al. concatenan representaciones de capas internas y finales de arquitecturas preentrenadas y entrenan una MLP; informan que la agregación multicapas de BEiT_v2 mejora varios benchmarks de textura, aunque el efecto depende de la arquitectura [21]. Scabini et al. comparan 25 variantes Transformer como extractores congelados y encuentran que BEiT_v2-B/16 obtiene el mejor promedio entre sus modelos evaluados [22]. El presente trabajo difiere de ambos: BEiT_v2 constituye uno de 22 bloques candidatos y se estudia dentro de políticas de concatenación

y selección con evaluación anidada, no como único backbone ni como arquitectura ajustada de extremo a extremo.

3. Método de concatenación y selección de descriptores

3.1. Representación conjunta y pregunta de estudio

El estudio evalúa la concatenación como un problema de selección de bloques. Cada extractor transforma una imagen x_i en un vector $\mathbf{z}_{ij} \in \mathbb{R}^{d_j}$, donde j identifica el descriptor y d_j su dimensionalidad. Para un subconjunto S de extractores, la representación conjunta se define como

$$\mathbf{z}_{i,S} = \left\| \frac{\mathbf{z}_{ij}}{\max(\|\mathbf{z}_{ij}\|_2, 10^{-12})} \right\|, \quad (1)$$

donde $\|$ denota concatenación. La normalización L_2 se aplica por descriptor y por muestra antes de unir los bloques, para evitar que la escala de un extractor determine por sí sola la contribución al clasificador.

La Figura 1 muestra cómo una misma imagen produce representaciones diferentes. Un descriptor resume patrones, relaciones entre intensidades o activaciones aprendidas en un vector. Después de normalizar cada bloque, se conserva un descriptor individual o se concatenan los bloques seleccionados. La dimensión conjunta es $d_S = \sum_{j \in S} d_j$.




Figura 1: Extracción y concatenación de descriptores. La misma imagen de DTD se representa mediante cinco ejemplos: patrones locales (LBP), respuestas de filtros (Gabor), coocurrencias (GLCM), una red convolucional (ResNet) y secuencias RGB (N-gramas). Las transformaciones internas se muestran esquemáticamente; no representan mapas de importancia por píxel. Cada rama produce un bloque normalizado que puede utilizarse individualmente o concatenarse con otros. El ejemplo de tres bloques ilustra la unión de coordenadas; cada política determina el subconjunto admisible.

3.2. Estrategias comparadas

Las cinco estrategias responden a decisiones sobre la representación que recibe el clasificador. Individual establece el desempeño de un solo bloque; Completa evalúa la unión de toda la biblioteca; Top- k y GFS eligen subconjuntos; Homogénea restringe la procedencia de los bloques a una familia. Se utilizan las mismas denominaciones en método, resultados y estadística:

1. **Individual:** descriptor con mayor macro-F1 medio en validación interna.
2. **Completa:** concatenación de todos los bloques de la biblioteca evaluada.
3. **Top- k :** concatenación de los k descriptores mejor posicionados por su macro-F1 individual interno; k se toma del subconjunto GFS de la misma condición.
4. **GFS:** subconjunto devuelto por la selección secuencial de bloques.
5. **Homogénea:** mejor resultado interno de GFS restringido a una familia, con un límite de bloques no mayor que el subconjunto GFS heterogéneo.

Top- k controla la composición bajo el mismo número de bloques que GFS, aunque las dimensiones pueden diferir. No constituye una política independiente de elección de k . Homogénea permite estudiar el efecto de restringir la biblioteca a una familia. Todos los comparadores se seleccionan antes de evaluar el test. Los controles aleatorios y las variantes de presupuesto se conservan como análisis auxiliares en los materiales del proyecto.

3.3. Espacio de descriptores

La biblioteca contiene 22 descriptores, agrupados según el tipo de representación. Cada uno constituye un bloque candidato sujeto al mismo criterio de selección. Las Tablas 1 y 2 identifican la parametrización, los checkpoints y la dimensionalidad de cada bloque. Las redes preentrenadas se ejecutaron en modo evaluación y sin ajuste de pesos. En los modelos cargados mediante `timm` se eliminó la capa clasificadora (`num_classes=0`) y se aplicó el preprocesamiento asociado al checkpoint. Para ViT, DeiT, Swin, MAE y SigLIP se utilizó la salida *pooler* cuando estaba disponible y, en caso contrario, el token de clasificación. Todas las imágenes se convirtieron a RGB.

Los descriptores clásicos se basan en operadores LBP, Gabor, GLCM y HOG [4–6, 14, 23]. Las CNN corresponden a VGG16, ResNet, DenseNet, EfficientNet y ConvNeXt V2 [7, 8, 24–26]. El grupo Transformer incluye ViT, DeiT, Swin y EVA-02 [9, 10, 27, 28]; las representaciones con preentrenamiento autosupervisado o multimodal se basan en DINOv2, MAE, SigLIP y BEiT v2 [11, 16, 18, 29].

Tabla 1

Seis descriptores basados en patrones, filtros, gradientes y conteos incluidos en la biblioteca. Cada fila constituye un bloque completo.

Descriptor	Parametrización	Salida	Dim.
LBP	multiescala $(P, R) = (8, 1), (16, 2), (24, 3)$; mapeo uniforme invariante a rotación (<code>riu2</code>)	histogramas normalizados	54
LBP-rot	$P = 8, R = 1$; ocho rotaciones; códigos limitados a $[0, 10]$	histogramas 10×8	80
Gabor	cuatro frecuencias 0,1–0,8; seis orientaciones	media y desv. de respuesta real	48
GLCM	256 niveles; distancias 1–3; cuatro ángulos; seis propiedades	promedios sobre ángulos	18
HOG	nueve orientaciones; celda 16^2 ; bloque 2^2 ; norma L2-Hys	vector HOG	1.764
N-gramas	ventana vertical 2×1 ; cuantización RGB por 12; 8.192 bins; SVD	vector normalizado	256

Los descriptores clásicos se calcularon en escala de grises con la implementación de `scikit-image`: LBP, LBP-rot, Gabor y GLCM sobre imágenes redimensionadas a 256×256 , y HOG sobre 128×128 . LBP-rot designa la implementación propia registrada como `dr1bp` en los archivos experimentales: aplica LBP con mapeo `ror` a ocho rotaciones y concatena diez bins por rotación en el intervalo $[0, 10]$. Los códigos

Tabla 2

Dieciséis representaciones aprendidas congeladas incluidas en la biblioteca. “Preclas.” designa la salida inmediatamente anterior al clasificador del backbone.

Familia	Descriptor	Checkpoint	Salida	Dim.
CNN	VGG16	vgg16.tv_in1k	preclas.	4.096
	ResNet-50	resnet50.a1_in1k	preclas.	2.048
	ResNet-101	resnet101.a1_in1k	preclas.	2.048
	DenseNet-121	densenet121.tv_in1k	preclas.	1.024
	EfficientNet-B0	efficientnet_b0.ra_in1k	preclas.	1.280
	ConvNeXt V2-T	convnextv2_tiny.fcmae_ft_in22k_in1k	preclas.	768
Transformer	ViT-B/16	google/vit-base-patch16-224	pooler/CLS	768
	DeiT-S	facebook/deit-small-patch16-224	pooler/CLS	384
	Swin-T	microsoft/swin-tiny-patch4-window7-224	pooler	768
	EVA-02 base	eva02_base_patch14_224	preclas.	768
Autosup./multimodal	DINOv2-S	vit_small_patch14_dinov2.lvd142m	preclas.	384
	DINOv2-B	vit_base_patch14_dinov2.lvd142m	preclas.	768
	DINOv2-L	vit_large_patch14_dinov2.lvd142m	preclas.	1.024
	MAE-B	facebook/vit-mae-base	pooler/CLS	768
	SigLIP-B	google/siglip-base-patch16-224	pooler/CLS	768
	BEiTv2-B	beitv2_base_patch16_224. in1k_ft_in22k_in1k	preclas.	768

fuera de ese intervalo se descartan; por tanto, es un histograma restringido, no una reproducción del DRLBP de Mehta y Egiazarian [14]. BEiTv2-B utiliza la salida final preclasificador de 768 dimensiones; las imágenes se redimensionan y recortan a 224×224 con la normalización asociada al checkpoint. Los 22 vectores concatenados suman 20.652 dimensiones. Las características fijas y los conteos por imagen se almacenaron junto con etiquetas, orden de muestras y hashes de procedencia; las transformaciones aprendidas se ajustaron dentro de cada partición de entrenamiento. El estudio evalúa la selección y concatenación de bloques con extractores de imagen congelados y transformaciones ajustadas dentro del entrenamiento; no compara estrategias de *fine-tuning*.

RGB Pixel N-grams [30] utiliza ventanas verticales de 2×1 píxeles con paso 1 sobre la imagen RGB en su resolución original. Cada canal se cuantiza mediante $q(v) = \lfloor v/12 \rfloor$; los seis valores se codifican en base 22, recorriendo las dos posiciones de R, G y B. Los conteos se agrupan por el resto del código dividido por 8.192 y se comprimen mediante TruncatedSVD aleatorizado (256 componentes, cinco iteraciones y semilla de la condición). SVD se ajusta exclusivamente con el entrenamiento de cada partición interna y se reajusta sobre el entrenamiento externo para la evaluación final. El vector se normaliza con L_2 antes de concatenarlo. Esta parametrización comprimida se identifica como N-gramas + SVD y constituye una familia propia para la selección Homogénea.

3.4. Greedy Forward Selection

GFS se utiliza como un método *wrapper*: los subconjuntos se valoran mediante el propio clasificador y exclusivamente dentro de la validación interna, como requieren los diseños de selección que separan búsqueda y evaluación externa [19, 20]. La búsqueda comienza con un conjunto vacío. En el paso t , evalúa cada descriptor aún no seleccionado al añadirlo al subconjunto vigente y elige el candidato con mayor macro-F1 medio en la validación interna:

$$j_t = \arg \max_{j \notin S_{t-1}} \widehat{F}_{1,\text{inner}}(S_{t-1} \cup \{j\}), \quad S_t = S_{t-1} \cup \{j_t\}. \quad (2)$$

La búsqueda se limita a $k \leq 8$. Se detiene cuando la mejora respecto del paso anterior es menor que 0,001 durante dos pasos consecutivos, pero devuelve el mejor paso histórico, no necesariamente el último. Los empates se resuelven de forma determinista mediante el nombre del extractor. Todas las evaluaciones candidatas utilizan únicamente muestras pertenecientes al entrenamiento externo.

La Figura 2 representa el mecanismo general de GFS. En cada ronda se comparan únicamente los bloques aún disponibles dentro de los folds internos; el bloque elegido se incorpora al subconjunto y el test externo permanece fuera de esa decisión.




Figura 2: Mecanismo de Greedy Forward Selection sobre bloques completos. En cada paso se elige el bloque que maximiza el macro-F1 medio de la validación interna; el test externo se utiliza únicamente tras cerrar el subconjunto.

La Tabla 3 concentra los parámetros de búsqueda, comunes a ambos clasificadores.

Tabla 3

Configuración de la selección GFS en el flujo general.

Elemento	Configuración
Unidad de selección	Bloque completo generado por un extractor
Candidatos	22 bloques
Criterio interno	Macro-F1 medio en cuatro folds estratificados y agrupados
Presupuesto	Hasta $k = 8$ bloques
Parada	Dos mejoras consecutivas menores que 0,001; se devuelve el mejor paso histórico
Empates	Nombre del extractor, en orden determinista
Información excluida	Test externo y sus etiquetas durante toda la selección

4. Resultados experimentales

4.1. Conjuntos de datos y control de integridad

Antes del análisis se construyó un manifiesto por dataset y se verificaron etiquetas, orden de muestras, dimensiones, valores finitos y grupos de dependencia. Se utilizaron DTD, FMD, CURET, Outex, Soil y KTH-TIPS2-b. Sus particiones se describen a continuación; los seis datasets integran el análisis estadístico principal.

DTD contiene 5.640 imágenes de texturas en condiciones no controladas y proporciona diez particiones oficiales de entrenamiento, validación y prueba [1]. En cada partición se unieron entrenamiento y validación para ejecutar la selección interna, mientras que el test oficial se reservó para una única evaluación. Los duplicados byte-idénticos que cruzaban roles fueron retirados del conjunto de entrenamiento, conservando intacta la evaluación.

FMD reúne 1.000 fotografías de diez categorías de materiales [31]. Las características fijas y los conteos por imagen se obtuvieron desde las imágenes oficiales en un orden canónico. Cada imagen presentó un hash único y se utilizó como unidad de agrupación. La evaluación externa empleó cinco folds estratificados y agrupados, repetidos con semillas 42, 123 y 2026.

Outex contiene 1.360 BMP RGB de 128×128 píxeles, organizados en 68 clases balanceadas. La auditoría verificó archivos legibles, IDs continuos 000000–001359, ausencia de duplicados y la partición oficial de 680 imágenes de entrenamiento y 680 de prueba, con diez muestras de cada clase en cada lado [32]. Todos los bloques respetan el orden de las 1.360 muestras del manifiesto oficial. Este es el único conjunto Outex utilizado en los resultados del artículo.

Para CURET se utilizó la distribución gris recortada de 61 materiales, con 92 condiciones compartidas por clase [33]. Cada condición constituye un grupo para impedir que la misma configuración de adquisición aparezca a ambos lados de una partición. Se definieron dos mitades complementarias deterministas de 46 condiciones: A para selección y entrenamiento con B como test, y la dirección inversa. Esta asignación reproduce de manera transparente el tamaño 46/46 publicado, pero no se presenta como el split histórico exacto. Debido a que las dos direcciones son complementarias y dependientes, sus resultados se interpretarán descriptivamente.

Soil se recuperó de la versión 1 archivada del repositorio *Comprehensive Soil Classification Datasets* de ai4a-lab. Se conservaron sólo las imágenes originales, se eliminaron 49 duplicados exactos y se definieron grupos conservadores a partir de las familias de nombres. El manifiesto final contiene 1.140 imágenes de siete clases y 962 grupos. La evaluación usa cinco folds estratificados y agrupados, repetidos con las semillas 42, 123 y 2026.

KTH-TIPS2-b contiene 4.752 imágenes RGB de 200×200 píxeles, correspondientes a 11 materiales y cuatro muestras físicas por material [34]. Se emplea el protocolo de cuatro particiones usado por RADAM: en cada una, tres muestras físicas por clase quedan en entrenamiento y la restante en prueba. El manifiesto conserva el hash de cada archivo y usa la muestra física como grupo, por lo que ninguna muestra aparece en ambos lados de una partición.

4.2. Clasificadores

Se emplearon dos clasificadores con sesgos diferentes. La SVM lineal se implementa con `LinearSVC` de `scikit-learn`: $C = 1$, ponderación balanceada por clase, pérdida *squared hinge*, regularización L_2 , esquema uno-contra-el-resto, tolerancia 10^{-4} y un máximo de 10.000 iteraciones.

Se denomina ResMLP a la MLP residual implementada para este estudio sobre vectores de características; no es una reproducción del modelo de imágenes del mismo nombre [35]. Proyecta la entrada a 256 unidades y aplica tres bloques residuales, normalización de capa, activaciones GELU, *dropout* de 0,1 y una salida multiclase. Se entrena con entropía cruzada y AdamW, tasa de aprendizaje 10^{-3} , decaimiento de pesos 10^{-4} , lotes de 256 muestras y un máximo de 100 épocas. La parada se basa en la pérdida media de entrenamiento: tras diez épocas sin una disminución mayor que 10^{-4} , se detiene y restaura el mejor estado registrado. No utiliza el test ni una validación adicional para elegir la época. Las semillas se fijan para NumPy y PyTorch; cuando está disponible, la red se ejecuta en GPU.

4.3. Configuración experimental y protocolo anidado

La selección interna utiliza cuatro folds estratificados y agrupados. En DTD se ejecuta dentro de la unión *train+val* de cada split oficial; en FMD y Soil dentro del entrenamiento de cada uno de sus 15 folds externos; y en CURET dentro de la mitad de 46 condiciones asignada al entrenamiento. En Outex y KTH-TIPS2-b, las cinco estrategias restringen los cuatro folds internos al entrenamiento definido por su partición oficial. Después de seleccionar el subconjunto y los comparadores, cada modelo se ajusta con todo el entrenamiento externo y se evalúa una sola vez en el test correspondiente. Se verifica programáticamente que ningún grupo aparezca en entrenamiento y prueba.

4.4. Análisis estadístico

El análisis sigue la presentación de rankings, pruebas globales y comparaciones por pares del trabajo sobre RGB Pixel N-grams [30]. Se ejecutan CONTROLTEST y MULTIPLETEST de SCI2S por separado para SVM y ResMLP. Cada matriz contiene seis datasets y cinco estrategias; las condiciones externas se promedian dentro de cada dataset. Se reportan Friedman, Iman–Davenport, Friedman alineado y Quade. Los valores p de los diez pares basados en los rangos de Friedman se ajustan con Holm dentro de cada clasificador. La familia de comparaciones y el nivel nominal $\alpha = 0,05$ son explícitos; no se afirma control simultáneo del error sobre todos los análisis auxiliares. Las comparaciones por pares se interpretan tras el

rechazo del Friedman clásico correspondiente y las conclusiones globales también consideran la discrepancia con Friedman alineado.

Como sensibilidad a la aproximación de rangos con sólo seis bloques, se reporta Wilcoxon exacto bilateral para Completa frente a Individual. La comparación entre SVM y ResMLP bajo Completa y el efecto incremental de Completa-22 frente a Completa-21 también son bilaterales y se emparejan por dataset. Estos contrastes se definieron durante la revisión de resultados y se interpretan como exploratorios; no constituyen hipótesis preregistradas. La ausencia de significancia no implica equivalencia. Wilcoxon requiere diferencias independientes entre bloques y una distribución simétrica bajo la hipótesis nula.

La exactitud es la proporción de imágenes clasificadas correctamente. Macro-F1 promedia el F1 de las C clases con igual peso: $\text{macro-F1} = C^{-1} \sum_{c=1}^C 2TP_c / (2TP_c + FP_c + FN_c)$, donde TP_c , FP_c y FN_c son los verdaderos positivos, falsos positivos y falsos negativos de la clase c . Esta media evita que la contribución de una clase dependa directamente de su número de muestras.

Macro-F1 es la métrica primaria. Para cada contraste se promedian las condiciones externas dentro de cada dataset y clasificador, manteniendo SVM y ResMLP separados. Así, cada prueba usa seis bloques emparejados, uno por dataset. No se tratan las particiones repetidas como problemas independientes. Se adopta $\alpha = 0,05$.

La exactitud se reporta como métrica descriptiva secundaria sobre las mismas condiciones. La media y la desviación estándar entre particiones describen la variación observada, pero no convierten las particiones dependientes en réplicas independientes. La ausencia de significancia no demuestra equivalencia entre estrategias.

4.5. Resultados principales: desempeño y descriptor individual

La Tabla 4 compara las cinco estrategias con la biblioteca de 22 descriptores. Individual corresponde a una política de selección interna: el descriptor elegido puede cambiar entre particiones. La Tabla 5 presenta la exactitud bajo el mismo protocolo.

Tabla 4

Macro-F1 externo de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial.

Dataset	Clasif.	Individual	Completa	Top- k	GFS	Homogénea
DTD	SVM	0,8426	0,8639	0,8700	0,8703	0,8604
DTD	ResMLP	0,8373	0,8620	0,8643	0,8639	0,8611
FMD	SVM	0,9726	0,9647	0,9820	0,9766	0,9789
FMD	ResMLP	0,9690	0,9564	0,9740	0,9783	0,9773
CUReT	SVM	0,9948	0,9989	0,9989	0,9988	0,9989
CUReT	ResMLP	0,9971	0,9991	0,9984	0,9986	0,9982
Outex	SVM	0,9066	0,9656	0,9426	0,9589	0,9307
Outex	ResMLP	0,9476	0,9416	0,9652	0,9715	0,9306
Soil	SVM	0,8578	0,8816	0,8776	0,8671	0,8670
Soil	ResMLP	0,8533	0,8649	0,8685	0,8691	0,8629
KTH-TIPS2-b	SVM	0,9396	0,9601	0,9400	0,9052	0,9271
KTH-TIPS2-b	ResMLP	0,9061	0,9487	0,9322	0,9201	0,9127

Tabla 5

Exactitud externa de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial.

Dataset	Clasif.	Individual	Completa	Top- <i>k</i>	GFS	Homogénea
DTD	SVM	0,8448	0,8654	0,8714	0,8716	0,8621
DTD	ResMLP	0,8382	0,8635	0,8652	0,8651	0,8626
FMD	SVM	0,9727	0,9647	0,9820	0,9767	0,9790
FMD	ResMLP	0,9690	0,9563	0,9740	0,9783	0,9773
CUReT	SVM	0,9948	0,9989	0,9989	0,9988	0,9989
CUReT	ResMLP	0,9971	0,9991	0,9984	0,9986	0,9982
Outex	SVM	0,9103	0,9662	0,9441	0,9603	0,9324
Outex	ResMLP	0,9485	0,9456	0,9662	0,9721	0,9338
Soil	SVM	0,9044	0,9281	0,9225	0,9152	0,9126
Soil	ResMLP	0,9044	0,9184	0,9181	0,9170	0,9135
KTH-TIPS2-b	SVM	0,9415	0,9609	0,9419	0,9112	0,9293
KTH-TIPS2-b	ResMLP	0,9099	0,9499	0,9346	0,9219	0,9165

Tabla 6

Dimensión media de las representaciones usadas en la evaluación externa con 22 descriptores.

Dataset	Clasif.	Individual	Completa	Top- <i>k</i>	GFS	Homogénea
DTD	SVM	819,2	20652,0	4480,0	5390,4	2496,0
DTD	ResMLP	768,0	20652,0	4211,2	4626,4	2598,4
FMD	SVM	768,0	20652,0	2969,6	2687,5	2338,1
FMD	ResMLP	768,0	20652,0	3404,8	3077,5	2218,7
CUReT	SVM	1024,0	20652,0	3328,0	4402,0	2944,0
CUReT	ResMLP	704,0	20652,0	2176,0	2880,0	1856,0
Outex	SVM	1024,0	20652,0	7808,0	6784,0	3712,0
Outex	ResMLP	256,0	20652,0	6016,0	3346,0	2176,0
Soil	SVM	768,0	20652,0	4898,1	3709,9	2184,5
Soil	ResMLP	768,0	20652,0	5529,6	4415,6	2235,7
KTH-TIPS2-b	SVM	832,0	20652,0	1280,0	960,0	960,0
KTH-TIPS2-b	ResMLP	672,0	20652,0	1600,0	1440,0	928,0

Completa tiene siempre 20.652 coordenadas; las otras estrategias pueden elegir subconjuntos distintos entre particiones.

Tabla 7

Descriptor Individual seleccionado mediante validación interna. La frecuencia indica en cuántas condiciones externas fue elegido.

Dataset	Clasif.	Descriptor (frecuencia)
DTD	SVM	SigLIP-B (8/10); DINOv2-L (2/10)
DTD	ResMLP	SigLIP-B (10/10)
FMD	SVM	SigLIP-B (15/15)
FMD	ResMLP	SigLIP-B (15/15)
CUReT	SVM	DINOv2-L (2/2)
CUReT	ResMLP	DINOv2-S (1/2); DINOv2-L (1/2)
Outex	SVM	DINOv2-L (1/1)
Outex	ResMLP	RGB N-gramas + SVD (1/1)
Soil	SVM	EVA-02 base (8/15); SigLIP-B (7/15)
Soil	ResMLP	SigLIP-B (6/15); EVA-02 base (4/15); BEiTv2-B (3/15); ConvNeXt V2-T (1/15); MAE-B (1/15)
KTH-TIPS2-b	SVM	BEiTv2-B (2/4); DINOv2-L (1/4); ViT-B/16 (1/4)
KTH-TIPS2-b	ResMLP	Swin-T (1/4); BEiTv2-B (1/4); DINOv2-S (1/4); ViT-B/16 (1/4)

El método con mayor macro-F1 medio depende del dataset y del clasificador. GFS obtiene el máximo en DTD con SVM, FMD con ResMLP, Outex con ResMLP y Soil con ResMLP; Top- k lo hace en DTD con ResMLP y FMD con SVM. Completa alcanza el máximo en CUReT con ResMLP, Outex con SVM, Soil con SVM y KTH-TIPS2-b con ambos clasificadores; en CUReT con SVM empata descriptivamente con Top- k . Esta comparación de medias no implica por sí sola significancia de cada diferencia.

4.6. Aporte de BEiTv2 y comparación externa

La Tabla 8 aísla el cambio descriptivo de añadir el bloque final de BEiTv2 a Completa-21. Con SVM, Completa-22 mejora en DTD, FMD, Soil y KTH-TIPS2-b, permanece prácticamente igual en CUReT y disminuye en Outex. Con ResMLP mejora en DTD, FMD, Soil y KTH-TIPS2-b, y disminuye en CUReT y Outex. Promediado por dataset, el cambio es +0,0010 con SVM y -0,0006 con ResMLP. Wilcoxon exacto bilateral sobre seis diferencias no rechaza en SVM ($p = 0,3125$) ni en ResMLP ($p = 0,5625$). Por tanto, BEiTv2 aporta información útil en algunos dominios, pero añadirlo indiscriminadamente a la concatenación completa no produce una mejora global demostrable.

Tabla 8

Efecto pareado de añadir BEiTv2-B a la concatenación completa: macro-F1 con 21 y 22 bloques sobre las mismas condiciones externas.

Dataset	Clasif.	Completa-21	Completa-22	Δ
DTD	SVM	0,8629	0,8639	0,0009
DTD	ResMLP	0,8608	0,8620	0,0012
FMD	SVM	0,9644	0,9647	0,0003
FMD	ResMLP	0,9518	0,9564	0,0046
CUReT	SVM	0,9989	0,9989	0,0000
CUReT	ResMLP	0,9993	0,9991	-0,0002
Outex	SVM	0,9674	0,9656	-0,0018
Outex	ResMLP	0,9537	0,9416	-0,0121
Soil	SVM	0,8789	0,8816	0,0027
Soil	ResMLP	0,8643	0,8649	0,0006
KTH-TIPS2-b	SVM	0,9563	0,9601	0,0038
KTH-TIPS2-b	ResMLP	0,9464	0,9487	0,0023

Las diferencias son descriptivas por dataset. El contraste global exploratorio usa Wilcoxon exacto bilateral sobre seis medias emparejadas por clasificador.

La Tabla 9 contrasta descriptivamente el mayor *promedio externo por configuración* del presente estudio con los resultados BEiTv2 publicados por Neshov et al. [21] y Scabini et al. [22]. Se promedian primero las particiones externas de cada combinación de estrategia y clasificador; no se toma el mejor resultado de una partición aislada. Frente a Neshov et al., este trabajo presenta mayor exactitud media en DTD y FMD, pero

menor en KTH-TIPS2-b. Frente a Scabini et al., presenta valores mayores en los cuatro datasets compartidos. El máximo entre configuraciones propias se identificó después de observar sus tests externos: esta tabla sirve para contextualizar magnitudes, no para elegir un modelo ni demostrar superioridad. Además, los protocolos, clasificadores y formas de agregación son distintos.

El Soil de Neshov et al. no se incluye entre los datasets directamente compartidos: utilizan un corpus con 829 imágenes originales, aumento del entrenamiento y un test fijo de 178 imágenes, mientras que aquí se evalúan 1.140 imágenes originales tras depuración mediante validación cruzada agrupada. Nuestro mejor promedio de exactitud es 0,9281 y el 0,9450 publicado corresponde a otra variante del corpus y otro protocolo; la diferencia numérica no constituye una comparación de desempeño válida.

Tabla 9

Comparación descriptiva de exactitud media con BEiTv2 en los datasets compartidos. Este trabajo muestra el mayor promedio externo entre sus configuraciones; los otros valores proceden de Neshov et al. y Scabini et al.

Dataset	Este trabajo	Neshov et al.	Scabini et al.
DTD	0,8716	0,8200	0,7910
FMD	0,9820	0,9670	0,9090
Outex	0,9721	—	0,9160
KTH-TIPS2-b	0,9609	0,9680	0,9370

El mayor promedio del presente trabajo se identificó tras observar los tests externos, por lo que la tabla es sólo contextual. Los protocolos, clasificadores y agregaciones difieren; Scabini et al. promedian KNN, LDA y SVM. Soil se excluye porque el corpus y la partición de Neshov et al. son distintos.

Antes de promover BEiTv2-B a la biblioteca común se realizó una ablación en KTH-TIPS2-b. La Tabla 10 compara Completa-21 con la capa final y con la concatenación de cuatro capas internas de BEiTv2 sobre las mismas cuatro particiones. La variante final mejoró descriptivamente a Completa-21 con ambos clasificadores; la variante multicapas no mejoró con ResMLP y multiplicó por cuatro la dimensión del bloque. Este resultado negativo motivó conservar únicamente la capa final de 768 dimensiones en el análisis principal de 22 bloques.

Tabla 10

Ablación externa en KTH-TIPS2-b con el protocolo de tres muestras físicas para entrenamiento y una para prueba. BEiTv2 se agrega como bloque 22 a Completa-21; la dispersión es la desviación estándar entre las cuatro particiones.

Clasif.	Representación	Macro-F1	Exactitud	Δ F1 vs. 21	Dim.
SVM	Completa-21	$0,9563 \pm 0,0122$	$0,9571 \pm 0,0116$	0,0000	19884
SVM	Completa-21 + BEiTv2 final	$0,9601 \pm 0,0088$	$0,9609 \pm 0,0083$	0,0038	20652
SVM	Completa-21 + BEiTv2 multicapas	$0,9597 \pm 0,0080$	$0,9604 \pm 0,0076$	0,0034	22956
ResMLP	Completa-21	$0,9464 \pm 0,0259$	$0,9476 \pm 0,0246$	0,0000	19884
ResMLP	Completa-21 + BEiTv2 final	$0,9520 \pm 0,0301$	$0,9531 \pm 0,0287$	0,0056	20652
ResMLP	Completa-21 + BEiTv2 multicapas	$0,9455 \pm 0,0282$	$0,9472 \pm 0,0270$	-0,0010	22956

En esta ablación exploratoria separada, agregar la capa final eleva el macro-F1 de Completa-21 en 0,0038 con SVM y 0,0056 con ResMLP; la matriz principal de la Tabla 8, ejecutada posteriormente con el flujo confirmatorio común, es la fuente autoritativa para la comparación multibase. La variante multicapas aporta 0,0034 con SVM, pero cambia -0,0010 con ResMLP. Con sólo cuatro particiones, los contrastes exactos unilaterales de la ablación frente a Completa-21 no alcanzan $\alpha = 0,05$ (capa final: $p = 0,1250$ con SVM y $p = 0,1875$ con ResMLP).

La Tabla 6 permite contrastar el desempeño con el tamaño de la representación. La dimensión de Completa es siempre 20.652; los subconjuntos seleccionados son menores y su dimensión puede variar entre folds. La disminución corresponde al vector usado por el clasificador y no implica una reducción proporcional de latencia o memoria de extremo a extremo. Todas las tablas muestran medias; en Outex, al existir un único split oficial, la media coincide con el valor observado.

4.7. Contrastes por clasificador

La Tabla 11 resume los rankings por clasificador; la Tabla 12 presenta todas las pruebas globales producidas por CONTROLTEST. Con SVM rechazan Friedman ($p = 0,0289$), Iman–Davenport ($p = 0,0139$) y Quade ($p = 0,0349$), mientras Friedman alineado no rechaza ($p = 0,2860$). Con ResMLP ocurre el mismo patrón: $p = 0,0110$, $p = 0,0025$, $p = 0,0210$ y $p = 0,2883$, respectivamente. El rechazo del Friedman clásico predefinido justifica examinar sus pares dentro de cada clasificador, pero la discrepancia entre pruebas globales obliga a una interpretación prudente.

Tabla 11

Rankings medios de macro-F1 según Friedman, Friedman alineado y Quade con 22 descriptores. Seis datasets por clasificador; menor ranking indica mejor desempeño relativo dentro de cada prueba.

Clasif.	Estrategia	Friedman	F. alineado	Quade
SVM	Individual	4,500	23,000	4,429
SVM	Completa	2,000	10,000	1,762
SVM	Top- k	2,000	9,833	2,190
SVM	GFS	3,000	15,000	2,857
SVM	Homogénea	3,500	19,667	3,762
ResMLP	Individual	4,500	24,167	4,381
ResMLP	Completa	2,833	15,333	2,857
ResMLP	Top- k	2,167	8,833	2,000
ResMLP	GFS	1,667	10,500	1,810
ResMLP	Homogénea	3,833	18,667	3,952

Tabla 12

Pruebas globales por clasificador sobre cinco estrategias y seis datasets con la biblioteca de 22 descriptores. Nivel nominal $\alpha = 0,05$.

Clasif.	Prueba	p	Decisión
SVM	Friedman	0,0289	Rechazo
SVM	Iman–Davenport	0,0139	Rechazo
SVM	Friedman alineado	0,2860	No rechazo
SVM	Quade	0,0349	Rechazo
ResMLP	Friedman	0,0110	Rechazo
ResMLP	Iman–Davenport	0,0025	Rechazo
ResMLP	Friedman alineado	0,2883	No rechazo
ResMLP	Quade	0,0210	Rechazo

En SVM, Completa y Top- k comparten el mejor ranking de Friedman; sus comparaciones frente a Individual quedan en $p_{\text{Holm}} = 0,0617$ y no alcanzan el nivel nominal. Con ResMLP, GFS obtiene el mejor ranking y su comparación frente a Individual permanece significativa tras Holm ($p_{\text{Holm}} = 0,0191$). Ningún otro par alcanza 0,05. Estos valores proceden de la tabla de valores ajustados de MULTIPLETEST, no de los umbrales secuenciales de rechazo.

Tabla 13

Comparaciones por pares basadas en rangos de Friedman. Holm corrige los diez pares dentro de cada clasificador.

Clasif.	Comparación	p sin ajustar	p Holm
SVM	Individual vs. Top- k	0,0062	0,0617
SVM	Individual vs. Completa	0,0062	0,0617
SVM	Individual vs. GFS	0,1003	0,8028
SVM	Top- k vs. Homogénea	0,1003	0,8028
SVM	Completa vs. Homogénea	0,1003	0,8028
SVM	Individual vs. Homogénea	0,2733	1,0000
SVM	Top- k vs. GFS	0,2733	1,0000
SVM	Completa vs. GFS	0,2733	1,0000
SVM	GFS vs. Homogénea	0,5839	1,0000
SVM	Completa vs. Top- k	1,0000	1,0000
ResMLP	Individual vs. GFS	0,0019	0,0191
ResMLP	Individual vs. Top- k	0,0106	0,0953
ResMLP	GFS vs. Homogénea	0,0176	0,1410
ResMLP	Individual vs. Completa	0,0679	0,4752
ResMLP	Top- k vs. Homogénea	0,0679	0,4752
ResMLP	Completa vs. GFS	0,2012	1,0000
ResMLP	Completa vs. Homogénea	0,2733	1,0000
ResMLP	Individual vs. Homogénea	0,4652	1,0000
ResMLP	Completa vs. Top- k	0,4652	1,0000
ResMLP	Top- k vs. GFS	0,5839	1,0000

La mejora media de Completa sobre Individual con SVM es de 0,0201 en macro-F1, con cinco victorias y una derrota entre datasets. Wilcoxon exacto bilateral arroja $p = 0,0938$ (Tabla 14). Con ResMLP, la mejora media es 0,0104, con cuatro victorias y dos derrotas, y Wilcoxon da $p = 0,4375$. Ambas diferencias se interpretan descriptivamente por el número reducido de datasets y porque no alcanzan el nivel nominal.

Tabla 14

Sensibilidad: Completa menos Individual mediante Wilcoxon exacto bilateral sobre seis datasets. V indica datasets con diferencia positiva y W la menor suma de rangos.

Clasif.	Δ medio	V/6	W	p
SVM	0,0201	5/6	2	0,0938
ResMLP	0,0104	4/6	6	0,4375

Para Completa, la diferencia media ResMLP menos SVM es $-0,0104$: SVM obtiene mayor macro-F1 en cinco de seis datasets. Wilcoxon exacto bilateral ($W = 1$, $p = 0,0625$, sin ajuste) no permite declarar un clasificador globalmente superior; tampoco demuestra equivalencia.

5. Discusión

La comparación muestra que concatenar descriptores puede mejorar el desempeño respecto de elegir un único bloque, pero el beneficio depende de la composición y del dominio. Completa resulta competitiva en CURET, Outex con SVM, Soil con SVM y KTH-TIPS2-b; GFS o Top- k obtienen el máximo en DTD, FMD, Outex con ResMLP y Soil con ResMLP. Seleccionar bloques ofrece una alternativa de menor dimensión, cuyo resultado depende de su composición. Este patrón es compatible con distintas combinaciones de información complementaria y redundante; el diseño no mide directamente esa redundancia ni identifica un mecanismo causal.

Tres de las cuatro pruebas globales detectan diferencias entre estrategias con ambos clasificadores; Friedman alineado no rechaza. El ajuste de Holm sobre los pares del Friedman clásico muestra que la evidencia localizada se concentra en GFS frente a Individual con ResMLP; Completa frente a Individual no alcanza significancia con ninguno de los dos clasificadores. La discrepancia entre pruebas globales y los

pocos pares significativos es compatible con el bajo número de datasets, sus distintas ponderaciones y la corrección de diez comparaciones. No se demuestra un mecanismo causal de complementariedad.

El bloque BEiTv2 tampoco produce un efecto uniforme. Mejora descriptivamente la concatenación completa en cuatro de seis datasets por clasificador, pero el promedio es cercano a cero y los contrastes pareados no rechazan. En Outex, BEiTv2 reduce especialmente Completa con ResMLP, mientras GFS alcanza el máximo al seleccionar una composición menor que sí incluye BEiTv2. Por tanto, un descriptor fuerte de manera aislada puede aportar dentro de ciertos subconjuntos sin beneficiar la concatenación exhaustiva.

5.1. Limitaciones

GFS es una búsqueda local y no garantiza el subconjunto óptimo. Top- k hereda su presupuesto de bloques, por lo que compara composiciones bajo un k compartido. Individual se elige internamente y no representa al descriptor con mejor resultado a posteriori en el test. Las particiones de DTD y FMD reutilizan imágenes, CURET presenta dos direcciones complementarias y Outex tiene una sola partición. El número de datasets limita la precisión y la generalización de la inferencia multibase. No se realizó un cálculo de tamaño muestral a priori ni se presentan intervalos de confianza de generalización a nuevos datasets. Las desviaciones entre particiones describen la variabilidad observada; no estiman esa incertidumbre tratando folds dependientes como réplicas independientes. La comparación con trabajos publicados es descriptiva porque difieren los clasificadores, la agregación, el ajuste de hiperparámetros y, en algunos casos, la forma de resumir las particiones.

Los descriptores clásicos se calcularon sobre escala de grises, mientras las redes y RGB Pixel N-grams utilizan RGB; en CURET las imágenes de origen son grises. Además, los corpus de preentrenamiento de los modelos podrían solaparse con imágenes de los benchmarks; ese solapamiento no fue auditado. El agrupamiento de conteos y la reducción de dimensión pueden perder información. El histograma restringido de LBP-rot también descarta códigos; la comparación incluye esa implementación específica y no permite extraer conclusiones sobre el DRLBP original. Los resultados dependen de la parametrización especificada. No se dispone de mediciones homogéneas de latencia y memoria para atribuir ahorro de cómputo a la reducción dimensional.

Los ensayos preliminares con PCA no cubren la matriz completa de datasets, estrategias, clasificadores y particiones bajo el protocolo confirmatorio común. Por esa razón no se mezclan con los resultados principales ni se utilizan para sostener conclusiones; se conservan únicamente como material exploratorio reproducible del proyecto.

6. Conclusión

Este trabajo estudió la concatenación de descriptores como una elección entre representaciones individuales, completas y seleccionadas. La evaluación completa reunió 22 descriptores, seis datasets y dos clasificadores bajo un protocolo que separa selección interna y evaluación externa. Las cinco estrategias se compararon mediante macro-F1 y exactitud, con Friedman, Iman-Davenport, Friedman alineado y Quade, además de comparaciones de Friedman ajustadas con Holm por separado para cada clasificador.

Los resultados muestran beneficios descriptivos de combinar representaciones y reducciones dimensionales al seleccionar subconjuntos. Ninguna estrategia obtiene el mayor desempeño en todos los dominios. Friedman, Iman-Davenport y Quade rechazan la igualdad de estrategias con ambos clasificadores, pero Friedman alineado no; después de Holm sobre los pares de Friedman, GFS supera a Individual con ResMLP, mientras ningún par resulta significativo con SVM. Completa mejora descriptivamente a Individual en cinco de seis datasets con SVM y cuatro de seis con ResMLP, pero Wilcoxon bilateral no establece superioridad. Tampoco se establece un clasificador globalmente superior bajo Completa. Añadir BEiTv2 a la concatenación completa genera mejoras y pérdidas según el dominio, sin efecto global significativo frente a Completa-21.

La elección de una representación debe considerar el desempeño externo y la dimensionalidad bajo un protocolo común. Como siguientes pasos se plantea ampliar la diversidad de datasets, estudiar el efecto de la normalización y medir de forma homogénea el costo de extracción y clasificación.

A. Trazabilidad de resultados

Las tablas principales provienen de 94 condiciones externas completas de la biblioteca de 22 bloques: 47 con SVM y 47 con ResMLP, cada una con Individual, Completa, Top- k , GFS y Homogénea (470 resultados). La matriz fue validada sin claves duplicadas ni métricas obligatorias no finitas. Los CSV de procedencia, las entradas y salidas de SCI2S, los checkpoints y las tablas derivadas se conservan junto con sus hashes. El archivo fuente auditado de Outex tiene SHA-256 8d8c6b9d55dccc6302d3a1afb07eb55caedc622649e1c669a79ecde1bccbc642; de él se verificaron 1.360 BMP RGB legibles, 68 clases, ausencia de duplicados y la partición oficial 680/680.

Los controles aleatorios y los análisis auxiliares se conservan en los materiales del proyecto con sus configuraciones respectivas. El archivo `results/primary22_beitv2/nonparametric/validation.json` registra las claves externas emparejadas de Completa-21 y Completa-22, los hashes SHA-256 de los CSV fuente y el hash de las 470 filas canónicas. La Tabla 9 se genera a partir de promedios por dataset, estrategia y clasificador, antes de identificar el mayor de ellos.

Disponibilidad de datos y código

Los datasets utilizados son de acceso público y permanecen sujetos a las condiciones de sus respectivos distribuidores. El repositorio del proyecto contiene el código, los manifiestos, las salidas por partición, los resultados estadísticos y los hashes necesarios para auditar las tablas; los datasets originales y los embeddings se obtienen o regeneran según sus respectivas condiciones de uso. El material público está versionado en Git, aunque este borrador todavía no identifica un depósito archivado con DOI o una versión inmutable independiente del repositorio.

Declaración ética

Los experimentos utilizan colecciones públicas de imágenes de texturas y no incorporan reclutamiento de participantes. La declaración ética final queda pendiente de confirmación por los autores.

Conflicto de intereses

Declaración pendiente de confirmación por los autores antes del envío.

Financiación

Información pendiente de confirmación por los autores antes del envío.

Declaración sobre asistencia de herramientas de IA

Se utilizaron herramientas de inteligencia artificial para apoyar la programación, la organización de resultados y la estructuración, redacción y revisión del manuscrito. La comprobación y aprobación final del contenido corresponden a los autores antes de su envío.

CRedit authorship contribution statement

Carlos Ayala: Conceptualización, Metodología, Software, Experimentación, Análisis formal, Redacción – borrador original. **Joaquín Delgado:** Conceptualización, Metodología, Software, Experimentación, Análisis formal, Redacción – revisión y edición.

Referencias

- [1] Mircea Cimpoi, Subhansu Maji, Iasonas Kokkinos, Sammy Mohamed, and Andrea Vedaldi. Describing textures in the wild. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3606–3613, 06 2014. doi: 10.1109/CVPR.2014.461.

- [2] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, and Andrea Vedaldi. Deep filter banks for texture recognition, description, and segmentation. *International Journal of Computer Vision (IJCV)*, 118(1):65–94, 01 2016. doi: 10.1007/s11263-015-0872-3.
- [3] Li Liu, Jie Chen, Paul Fieguth, Guoying Zhao, Rama Chellappa, and Matti Pietikäinen. From BoW to CNN: Two decades of texture representation for texture classification. *International Journal of Computer Vision (IJCV)*, 127:74–109, 2019. doi: 10.1007/s11263-018-1125-z.
- [4] Timo Ojala, Matti Pietikäinen, and Topi Mäenpää. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 24(7):971–987, 07 2002. doi: 10.1109/TPAMI.2002.1017623.
- [5] Robert M. Haralick. Statistical and structural approaches to texture. *Proceedings of the IEEE*, 67(5):786–804, 05 1979. doi: 10.1109/PROC.1979.11328.
- [6] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893. IEEE, 06 2005. doi: 10.1109/CVPR.2005.177.
- [7] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 06 2016. doi: 10.1109/CVPR.2016.90.
- [8] Mingxing Tan and Quoc Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 6105–6114. PMLR, 06 2019. URL <https://proceedings.mlr.press/v97/tan19a.html>.
- [9] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 05 2021. URL <https://openreview.net/forum?id=YicbFdNTTy>. International Conference on Learning Representations (ICLR).
- [10] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 10012–10022, 10 2021. doi: 10.1109/ICCV48922.2021.00986.
- [11] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research (TMLR)*, 07 2024. URL <https://arxiv.org/abs/2304.07193>.
- [12] Jorge Sánchez, Florent Perronnin, Thomas Mensink, and Jakob Verbeek. Image classification with the fisher vector: Theory and practice. *International Journal of Computer Vision (IJCV)*, 105(3):222–245, 12 2013. doi: 10.1007/s11263-013-0636-x.
- [13] Hang Zhang, Jia Xue, and Kristin Dana. Deep TEN: Texture encoding network. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2896–2905. IEEE, 07 2017. doi: 10.1109/CVPR.2017.309.
- [14] Rakesh Mehta and Karen Egiazarian. Dominant rotated local binary patterns (DRLBP) for texture classification. *Pattern Recognition Letters*, 71:16–22, 02 2016. doi: 10.1016/j.patrec.2015.11.019.
- [15] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 9650–9660, 10 2021. doi: 10.1109/ICCV48922.2021.00951.
- [16] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16000–16009. IEEE, 06 2022. doi: 10.1109/CVPR52688.2022.01553.
- [17] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763. PMLR, 07 2021. URL <https://proceedings.mlr.press/v139/radford21a.html>.
- [18] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 11941–11952. IEEE, 10 2023. doi: 10.1109/ICCV51070.2023.01100.
- [19] Ron Kohavi and George H. John. Wrappers for feature subset selection. *Artificial Intelligence*, 97(1–2):273–324, 1997. doi: 10.1016/S0004-3702(97)00043-X.
- [20] Isabelle Guyon and André Elisseeff. An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182, 2003. URL <https://www.jmlr.org/papers/v3/guyon03a.html>.
- [21] Nikolay Neshov, Krasimir Tonchev, Ivaylo Bozhilov, Radostina Petkova, and Agata Manolova. Improving texture recognition via multi-layer feature aggregation from pre-trained vision architectures. *Electronics*, 14(23):4779, 2025. doi: 10.3390/electronics14234779.
- [22] Leonardo Scabini, Arthur Sacilotti, Kamil M. Zielinski, Lucas C. Ribas, Bernard De Baets, and Odemir M. Bruno. A comparative survey of vision transformers for feature extraction in texture analysis. *Journal of Imaging*, 11(9):304, 2025. doi: 10.3390/jimaging11090304.
- [23] Anil K. Jain and Farshid Farrokhnia. Unsupervised texture segmentation using Gabor filters. *Pattern Recognition*, 24(12):1167–1186, 1991. doi: 10.1016/0031-3203(91)90143-S.

- [24] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition, 2015. URL <https://arxiv.org/abs/1409.1556>. International Conference on Learning Representations (ICLR).
- [25] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2261–2269. IEEE, 07 2017. doi: 10.1109/CVPR.2017.243. URL https://openaccess.thecvf.com/content_cvpr_2017/html/Huang_Densely_Connected_Convolutional_CVPR_2017_paper.html.
- [26] Sanghyun Woo, Shoubhik Debnath, Ronghang Hu, Xinlei Chen, Zhuang Liu, In So Kweon, and Saining Xie. Convnext v2: Co-designing and scaling convnets with masked autoencoders. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16133–16142, 06 2023. doi: 10.1109/CVPR52729.2023.01548.
- [27] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 10347–10357. PMLR, 07 2021. URL <https://proceedings.mlr.press/v139/touvron21a.html>.
- [28] Yuxin Fang, Quan Sun, Xinggang Wang, Tiejun Huang, Xinlong Wang, and Yue Cao. Eva-02: A visual representation for neon genesis. *Image and Vision Computing*, 149:105171, 09 2024. doi: 10.1016/j.imavis.2024.105171.
- [29] Zhiliang Peng, Li Dong, Hangbo Bao, Qixiang Ye, and Furu Wei. Beit v2: Masked image modeling with vector-quantized visual tokenizers. *arXiv preprint arXiv:2208.06366*, 2022. doi: 10.48550/arXiv.2208.06366.
- [30] Fátima Belén Paiva Pavón, María Cristina Orué Gil, José Luis Vázquez Noguera, Helena Gómez-Adorno, and Valentín Calzada-Ledesma. Rgb pixel n-grams: A texture descriptor. *Signal Processing: Image Communication*, 118:117028, 2023. doi: 10.1016/j.image.2023.117028.
- [31] Lavanya Sharan, Ce Liu, Ruth Rosenholtz, and Edward H. Adelson. Recognizing materials using perceptually inspired features. *International Journal of Computer Vision (IJCV)*, 103(3):348–371, 07 2013. doi: 10.1007/s11263-013-0609-0.
- [32] Timo Ojala, Topi Mäenpää, Matti Pietikäinen, Jaakko Viertola, Juha Kyllönen, and Sami Huovinen. Outex—new framework for empirical evaluation of texture analysis algorithms. In *Proceedings of the 16th International Conference on Pattern Recognition*, volume 1, pages 701–706. IEEE, 2002. doi: 10.1109/ICPR.2002.1044854.
- [33] Manik Varma and Andrew Zisserman. Texture classification: Are filter banks necessary? In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 2, pages 691–698. IEEE, 2003. URL <https://www.robots.ox.ac.uk/~vgg/publications/2003/Varma03/varma03.pdf>.
- [34] P. Mallikarjuna, Mario Fritz, Eric Hayman, Barbara Caputo, and Jan-Olof Eklundh. Kth-tips and kth-tips2: Two databases for the evaluation of texture classification algorithms. In *Swedish Symposium on Image Analysis*, 03 2005.
- [35] Hugo Touvron, Piotr Bojanowski, Mathilde Caron, Matthieu Cord, Alaaeldin El-Nouby, Edouard Grave, Gautier Izacard, Armand Joulin, Gabriel Synnaeve, Jakob Verbeek, and Hervé Jégou. ResMLP: Feedforward networks for image classification with data-efficient training. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 45(4):5314–5321, 04 2023. doi: 10.1109/TPAMI.2022.3206148.