Concatenación sistemática y fusión adaptativa costo-consciente de descriptores visuales para clasificación de texturas

De la selección anidada de bloques a la adquisición secuencial guiada por incertidumbre

Carlos Ayala **Joaquín Delgado**

Tutor: Prof. José Vázquez

Universidad Nacional de Asunción
Facultad Politécnica

Octubre 2026

Estructura de la Presentación

Parte I: Fundamentos y Concatenación Estática

1. **Motivación y Problema:** Diversidad textural frente al costo de extracción.
2. **Preguntas y Aportes:** Del análisis estático a la inferencia condicional.
3. **Biblioteca de 22 Descriptores:** 6 clásicos + 16 profundos/fundacionales (20.652 dims).
4. **Protocolo Anidado y Fase 1:** Evaluación en 6 conjuntos con Linear SVM y ResMLP.

Parte II: Cascada Adaptativa Costo-Consciente

5. **Arquitectura FSC-Tex:** Regla de decisión por margen $m(x)$ y umbral prospectivo τ.
6. **Evaluación en 27 Condiciones:** Desempeño macro-F1 por dataset y pruebas de Demšar.
7. **Validación Física en GPU (RTX 4060):** 612 inferencias pareadas en los 6 datasets.
8. **Discusión, Límites y Conclusiones.**

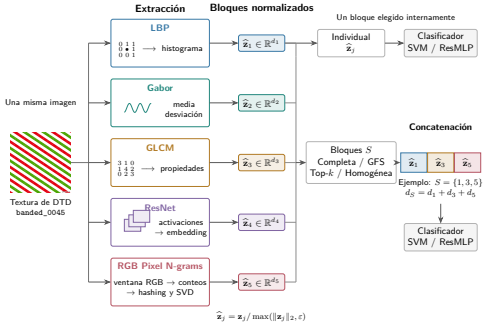
1. Motivación y Problema de Investigación

Naturaleza heterogénea de las texturas visuales

- Ningún descriptor aislado captura simultáneamente microestructuras locales, periodicidad espectral y semántica global de materiales.
- Combinar operadores clásicos (LBP, Gabor, GLCM, HOG, N-gramas) con CNNs, ViTs y modelos fundacionales (DINOv2, SigLIP, BEiT-v2) eleva la capacidad discriminativa.

El cuello de botella operativo de la concatenación estática

- **Saturación dimensional:** las ganancias de exactitud muestran rendimientos decrecientes tras pocos bloques de alto orden.
- **Costo fijo invariable:** extraer 22 modelos (20.652



Extracción heterogénea y normalización L_2 por bloque antes de la unión conjunta.

2. Preguntas de Estudio y Aportes del Trabajo

Preguntas de Investigación

1. **Fase 1 (Estática):** *¿En qué medida y a qué costo dimensional la concatenación estática de bloques supera la selección del mejor descriptor individual, y cuál es el impacto de la política de composición del subconjunto?*
2. **Fase 2 (Dinámica):** *¿Es posible aproximar estrechamente la calidad predictiva de la concatenación densa reduciendo sustancialmente el tiempo de inferencia mediante una regla adaptativa de adquisición secuencial guiada por incertidumbre?*

Aportes Verificables de la Tesis

- **Aporte 1:** Evaluación anidada sin fuga de 5 estrategias estáticas sobre **22 descriptores (20.652 dims)** y **6 datasets** con dos clasificadores (Linear SVM y ResMLP), desagregando la inferencia estadística por clasificador.
- **Aporte 2:** Formulación y evaluación en **27 condiciones canónicas** de la **Cascada Adaptativa Costo-Consciente** (2 etapas guiadas por margen OOF).
- **Aporte 3: Benchmark físico pareado en GPU (NVIDIA RTX 4060)** sobre los **6 datasets** (204 imágenes estratificadas $\times$ 3 repeticiones aleatorizadas = **612 mediciones pareadas**): **69,0%**

3. Espacio de Representación: Biblioteca de 22 Descriptores

Table 1: 6 Descriptores Clásicos y de Color (2.220 dims)

Descriptor	Parametrización	Dim.
LBP	Multiescala $(8,1),(16,2),(24,3)$ riu2	54
LBP-rot (`drlbp`)	$P = 8, R = 1$, 8 rotaciones $[0, 10]$	80
Gabor	4 frecuencias, 6 orientaciones	48
GLCM	256 niveles, dist. 1–3, 4 ángulos	18
HOG	9 orient., celda 16^2, bloque 2^2	1.764
RGB N-gramas+SVD	Ventana 2×1, 8.192 bins, SVD	256

Table 2: 16 Extractores Profundos y Fundacionales (18.432 dims)

Familia	Modelos Incluidos	Salida
CNN (5)	VGG16 (4096), ResNet-50 (2048), ResNet-101 (2048), DenseNet-121 (1024), EfficientNet-B0 (1280), ConvNeXt V2-T (768)	Preclas.
ViT (5)	ViT-B/16 (768), DeiT-S (384), Swin-T (768), EVA-02-B (768), BEiT-v2-B (768)	Pooler/ CLS
Autosup./ Multim. (5)	DINOv2-S (384), DINOv2-B (768), DINOv2-L (1024), MAE-B (768), SigLIP-B (768)	Pooler/ Preclas.

Normalización Conjunta por Bloque

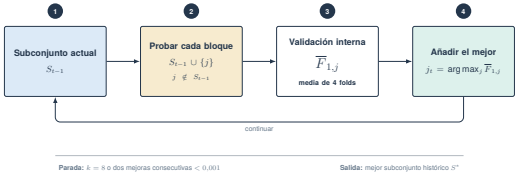
$$\mathbf{z}_{i,S} = \Big\Vert_{j \in S} \frac{\mathbf{z}_{ij}}{\max\left(\|\mathbf{z}_{ij}\|_2, 10^{-12}\right)}, \quad d_{\text{total}} = 20.652$$

4. Estrategias Estáticas Comparadas y Selección Anidada

Cinco Controles Estáticos Evaluados

1. **Individual:** Mejor bloque único en validación interna.
2. **Completa-22:** Unión de los 22 bloques (20.652 dims).
3. **Top-k:** Concatenación de los k mejores individuales internos (k igualado al tamaño de GFS).
4. **GFS (*Greedy Forward Selection*):** Adición voraz paso a paso hasta $k \leq 8$ (parada tras dos mejoras $< 0{,}001$).
5. **Homogénea:** Mejor GFS restringido a una sola familia.

Aislamiento Estricto (Cero Fuga de Datos)



Esquema de selección anidada de bloques mediante GFS dentro de T_{train}.

5. Conjuntos de Datos y Cobertura Experimental

Table 3: Seis conjuntos de datos de referencia evaluados en la tesis

Conjunto de Datos	Dominio Textural	Imágenes	Clases	Protocolo Fase 1 (Estática)	F
DTD	Texturas en la naturaleza (*in-the-wild*)	5.640	47	10 splits oficiales	1
FMD	Categorías de materiales (Flickr)	1.000	10	5 folds × 3 semillas (15)	5
CUReT	Materiales bajo pose/iluminación variable	5.612	61	2 direcciones (`a_to_b`, `b_to_a`)	2
Outex13	Texturas controladas en color (TC-00013)	1.360	68	1 split oficial (680/680)	1
SoilOriginal	Texturas de suelos agrícolas deduplicados	1.140	7	5 folds × 3 semillas (15)	5
KTH-TIPS-2b	Materiales con 4 muestras físicas (*a*–*d*)	4.752	11	4 splits invertidos (`innergrp`)	4

- **Clasificadores Evaluados:**
  - **Linear SVM (`LinearSVC`):** $C = 1$, pesos balanceados, regularización L_2 (Fase 1 y Fase 2).
  - **ResMLP:** Red residual multicapa (proyección a 256d, 3 bloques residuales, LayerNorm, GELU, AdamW) para contrastar sesgo inductivo no lineal en Fase 1.

6. Resultados Fase 1: Concatenación Estática por Dataset

Table 4: Macro-F1 medio por conjunto de datos (22 descriptores)

Modelo	Dataset	Indiv.	Completa	Top-k	GFS	Ho
SVM	DTD	0,8426	0,8639	0,8700	**0,8703**	0,
	FMD	0,9726	0,9647	**0,9820**	0,9766	0,
	CUReT	0,9948	**0,9989**	**0,9989**	0,9988	**0,**
	Outex13	0,9066	**0,9656**	0,9426	0,9589	0,
	SoilOriginal	0,8578	**0,8816**	0,8776	0,8671	0,
	KTH-TIPS-2b	0,9396	**0,9601**	0,9445*	0,9355*	0,
ResMLP	DTD	0,8379	0,8622	**0,8643**	0,8640	0,
	FMD	0,9689	0,9714	**0,9766**	0,9763	0,
	CUReT	0,9951	**0,9991**	0,9990	0,9990	0,
	Outex13	0,9179	0,9661	0,9580	**0,9715**	0,
	SoilOriginal	0,8532	0,8606	0,8678	**0,8691**	0,8558
	KTH-TIPS-2b	0,9061	**0,9487**	0,9322	0,9201	0,9127

*En KTH con SVM: Top-k corregido (`innergrp-sample`, 4 folds) = 0,9445 (archivo original = 0,9350).

Pruebas de Demšar por Clasificador ($N = 6$)

- **Friedman / Iman–Davenport:**
  - **SVM:** $p = 0{,}0289$ / $p = 0{,}0139$. Mejor rango: Completa y Top-k (2,000).
  - **ResMLP:** $p = 0{,}0110$ / $p = 0{,}0025$. Mejor rango: **GFS (**1,667**)**.
- **Ajuste de Holm (10 pares):**
  - **ResMLP:** GFS supera significativamente a Individual ($p_{\text{Holm}} =$ **0,0191**).
  - **SVM:** Top-k y Completa vs. Individual obtienen $p_{\text{Holm}} = 0{,}0617$.
- **Contracción dimensional:** GFS reduce entre **67,1% y 95,3%** las dimensiones frente a las 20.652 de Completa, pero aún exige ejecutar varios modelos para cada imagen.

7. Fase 2: Cascada Adaptativa Costo-Consciente (FSC-Tex)

Idea Central: Adquisición Condicional Guiada por Incertidumbre

En lugar de extraer todos los descriptores del subconjunto para todas las imágenes, el sistema evalúa inicialmente un **único extractor económico** ϕ_{cheap} y decide en tiempo de ejecución si la predicción es confiable o si requiere escalar al conjunto denso Top-k.

Etapa 1: Inferencia Económica y Salida Temprana

- Se extrae el descriptor inicial $\phi_{\text{cheap}} \in \{\text{SigLIP-B}, \text{ResNet-50}, \text{BEiT-v2-B}, \text{ConvNeXt-V}$
- El clasificador lineal produce el vector de puntuaciones de clase $\mathbf{s}(x) = [s_1, \ldots, s_C]$.
- Si el margen $m(x) > \tau$, se emite $\hat{y}_{\text{cheap}}(x)$ de inmediato (**74,0% de los casos en GPU**).

Etapa 2: Escalamiento Condicional Denso

- Solo cuando $m(x) \leq \tau$ (muestra ambigua o con incertidumbre alta, **26,0% de los casos**), se activan los bloques restantes de $\mathcal{B}_{\text{Top-}k}$.
- Se reutiliza el bloque inicial si pertenece a Top-k, se concatenan los vectores normalizados y se predice con el modelo conjunto $\hat{y}_{\text{Top-}k}(x)$.

8. Cálculo del Margen de Incertidumbre y Calibración OOF

1. Margen de Confianza Muestra por Muestra

Sean $s_{(1)}$ y $s_{(2)}$ la mayor y la segunda mayor puntuación de decisión en la Etapa 1:

$$m(x) = s_{(1)} - s_{(2)}$$

- $m(x)$ **alto:** Separación clara entre la clase líder y su competidora $\rightarrow$ **baja incertidumbre**.
- $m(x) \approx 0$**:** Empate técnico entre dos texturas $\rightarrow$ **alta incertidumbre**.

$$\hat{y}(x) = \begin{cases} \hat{y}_{\text{cheap}}(x), & \text{si } m(x) > \tau \text{ (Salida Etapa 1)} \\ \hat{y}_{\text{Top-}k}(x), & \text{si } m(x) \leq \tau \text{ (Escala a Etapa 2,} \end{cases}$$

2. Calibración Prospectiva de τ (Cero Fuga)

1. En T_{train}, se obtienen predicciones y márgenes fuera de pliegue (*Out-of-Fold*, 4-fold StratifiedGroupKFold).
2. Para cada presupuesto candidato $B \in \{0{,}25; 0{,}50; 0{,}75\}$, el umbral se fija como el cuantil empírico:

$$\tau_B = \text{Cuantil}_B\left(\{m_{\text{OOF}}(x_i)\}_{i \in T_{\text{train}}}\right)$$

3. Se elige el par $(\phi_{\text{cheap}}, \tau_B)$ que **minimiza el costo proyectado** sujeto a conservar el macro-F1 OOF dentro de $\Delta \leq 0{,}005$ respecto a Top-k.

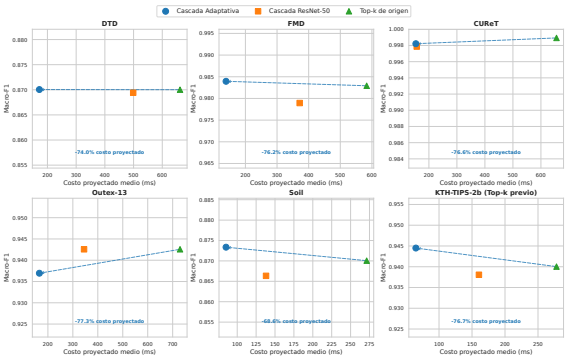
9. Evaluación Predictiva en 27 Condiciones Canónicas (Linear SVM)

Table 5: Desempeño macro-F1 y costo analítico proyectado por conjunto de datos (27 condiciones)

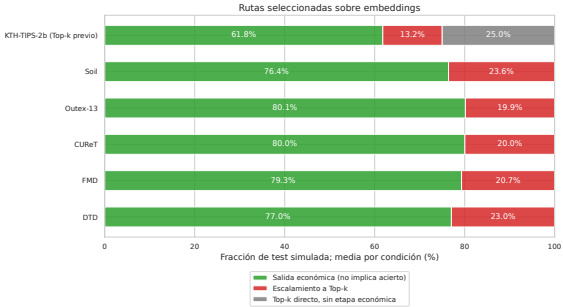
Conjunto de Datos	Cond. (N)	Cascada Adaptativa	Top-k Origen	Completa-22	Dif. vs. Top-k	Costo Pr
DTD	10	**0,8700**	0,8700	0,8639	**0,0000**	172,
FMD	5	**0,9840**	0,9829	0,9651	**+0,0011**	138,
CUReT	2	**0,9982**	0,9989	0,9989	$-0,0007$	153,
Outex13	1	**0,9369**	0,9426	0,9656	$-0,0057$	165,
SoilOriginal	5	**0,8734**	0,8701	0,8919	**+0,0033**	85,2
*KTH-TIPS-2b**	4	**0,9445**	0,9400 (0,9445*)	0,9601	**+0,0045** (0,0000*)	64,9
Media 5 Reconciliados ($N = 5$)	23	**0,9325**	0,9329	0,9371	$-0,0004$	143,
Media Global (6 Datasets)	27	**0,9345**	0,9341	0,9409	**+0,0004**	**130,**

- **Contrastes de Demšar ($N = 5$ conjuntos reconciliados):** Friedman $\chi^2_F = 2,6327$ ($p = 0,4518$), Iman–Davenport $F = 0,8515$ ($p = 0,4922$). Rangos medios: **Cascada = 2,200**, Completa-22 = 2,200, Top-k = 2,300, Cascada Fija ResNet-50 = 3,300. Wilcoxon con ajuste de Holm: $p_{\text{Holm}} = 1,0000$.
- **Rigor inferencial:** No rechazar H_0 refleja ausencias de diferencias significativas de rango con $N = 5$ (diferencia empírica media de apenas $-0,0004$ frente a Top-k), documentando un compromiso calidad–costo altamente favorable.

10. Frontera Calidad–Costo y Eficiencia de Enrutamiento



Frontera de Pareto: La Cascada Adaptativa conserva el nivel de macro-F1 de Top-k desplazando el costo hacia la izquierda.



Eficiencia de enrutamiento: Aproximadamente 3 de cada 4 imágenes se resuelven en la Etapa 1 económica.

11. Protocolo de Validación Física Pareada en GPU (RTX 4060)

¿Por qué medir en hardware real y no solo proyectar desde caché?

Las proyecciones analíticas suman latencias medias por bloque, pero en ejecución real intervienen transferencias a GPU, preprocesamiento por modelo y sincronización de kernels CUDA.

Diseño Experimental en los 6 Datasets

- **Hardware:** GPU NVIDIA GeForce RTX 4060 (8 GB VRAM), lote unitario (batch size = 1).
- **Muestreo estratificado:** 1 condición fija por dataset, 1 imagen de prueba por clase (semilla 42) → **204 imágenes únicas** (47 DTD + 61 CUReT + 11 KTH + 68 Outex + 7 Soil + 10 FMD).
- **Control de orden: 3 repeticiones pareadas por imagen** alternando aleatoriamente el orden (`cascade_first` vs. `topk_first`) → **612 mediciones físicas pareadas**.

Instrumentación y Auditoría

- Modelos residentes en VRAM; imágenes RGB decodificadas en RAM.
- Barreras explícitas `torch.cuda.synchronize()` antes y después de cada inferencia.
- Cada una de las 612 observaciones persiste: ruta, hash SHA-256, orden aleatorio, latencia en ms, decisión de ruta y predicción.

12. Resultados del Benchmark Físico en GPU en los 6 Datasets

Table 6: Latencia física de reloj de pared medida en GPU NVIDIA RTX 4060 (612 parejas aleatorizadas)

Dataset	Protocolo	Clases	Pares	Cascada (ms)	Top-k (ms)	Aceleración	Reducción	Salida Et. 1	Ince
DTD	`official1`	47	141	90,6 ± 124,7	295,6 ± 12,6	**3,26**×	**69,4%**	72,3%	
CUReT	`half_a_to_b`	61	183	92,5 ± 124,3	270,6 ± 8,8	**2,92**×	**65,8%**	70,5%	
KTHTIPS2b	`official1_inv`	11	33	46,1 ± 68,8	188,3 ± 4,9	**4,09**×	**75,5%**	81,8%	
Outex13	`official1`	68	204	111,5 ± 148,6	354,3 ± 30,7	**3,18**×	**68,5%**	76,5%	
SoilOriginal	`strat_fold0`	7	21	42,0 ± 38,7	109,1 ± 20,4	**2,60**×	**61,5%**	71,4%	
FMD	`strat_fold0`	10	30	13,0 ± 3,1	208,1 ± 8,5	**16,00**×	**93,7%**	100,0%	
Global Agregado	—	**204**	**612**	**90,25 ms**	**291,21 ms**	**3,23**×	**69,0%**	**74,0%**	

Verificación de Fidelidad Funcional Físico vs. Caché

- **Concordancia del 100,0% en las 612 inferencias:** tanto las rutas tomadas (`route_matches_cache` = 100%) como las predicciones emitidas (`cascade_matches_cache` = 100% y `topk_matches_cache` = 100%) coincidieron exactamente con la evaluación fuera de línea.
- El ahorro físico se verifica en **todos los conjuntos de datos** (entre **61,5%** y **93,7%**).

13. Discusión Metodológica y Límites del Estudio

¿Por qué 2 etapas y no una política secuencial profunda ($H \geq 2$, MDP / AFA)?

- Se exploraron pilotos multietapa inspirados en Adquisición Activa de Características (AFA) y recurrencias de Bellman.
- Dado que modelos fundacionales como SigLIP o ResNet-50 resuelven tempranamente el **74,0%** de las muestras en el primer paso, evaluar políticas dinámicas paso a paso añadió sobrecarga de decisión sin mejoras consistentes de macro-F1.
- **Principio de parsimonia:** la cascada de dos etapas captura la ganancia de eficiencia de forma directa, interpretable y auditable.

Transparencia y Límites Epistémicos

- **Interpretación de Demšar:** $p_{\text{Holm}} = 1{,}0000$ indica no rechazo de igualdad de rangos ($N = 5$), no una prueba formal de equivalencia matemática.
- **Decisiones observacionales:** La incorporación de BEiT-v2 se informó por evaluaciones previas; por ello, resultados con $p < 0{,}05$ (como GFS vs. Individual en ResMLP, $p_{\text{Holm}} = 0{,}0191$) se reportan sin reclamar carácter confirmatorio pre-registrado.
- **Alcance del benchmark GPU:** Evalúa 1 condición fija por dataset con 3 repeticiones aleatorizadas (612 pares).

14. Conclusiones y Trabajo Futuro

Conclusiones Principales

1. **Concatenación estática y saturación:** Combinar descriptores supera al mejor individual en los 6 datasets; GFS reduce hasta el **95,3%** de las dimensiones y alcanza $p_{\text{Holm}} = 0{,}0191$ bajo ResMLP, pero mantiene un costo de extracción estático elevado.
2. **Compromiso calidad–costo en 27 condiciones:** La Cascada Adaptativa alcanza un macro-F1 medio de **0,9345** frente a **0,9341** de Top-k (y **0,9445** frente a **0,9445** en KTH corregido), reduciendo el costo proyectado en **75,5%**.
3. **Demostración física multiconjunto en GPU:** En las 612 inferencias pareadas sobre los 6 datasets en RTX 4060, reduce un **69,0% la latencia real** (**3,23**×, resolviendo el **74,0%** en Etapa 1 con **100%** de fidelidad respecto al caché).
4. **Reproducibilidad auditada: 31.984 predicciones** muestra por muestra (10^{-12}) y **60/60 tests** unitarios aprobados.

Líneas de Trabajo Futuro

(1) Fusión temprana a nivel de tokens (*Early Token Fusion*); **(2)** Despliegue y medición energética en dispositivos de borde (*Edge AI*: Jetson Orin Nano / Raspberry Pi 5); **(3)** Extensión a segmentación densa de texturas por parches ambiguos.