Concatenación sistemática y fusión adaptativa costo-consciente de descriptores visuales para clasificación de texturas

De la selección anidada de bloques a la adquisición secuencial guiada por incertidumbre

Carlos Ayala Joaquín Delgado

Octubre 2026

Universidad Nacional de Asunción

Facultad Politécnica

Concatenación sistemática y fusión adaptativa costo-consciente de descriptores visuales para clasificación de texturas

De la selección anidada de bloques a la adquisición secuencial guiada por incertidumbre

Carlos Ayala
Joaquín Delgado

Tutor: José Vázquez

Octubre 2026

Agradecimientos

A nuestro tutor, José Vázquez, por su guía y paciencia.
A la Facultad Politécnica de la UNA, por el espacio y los recursos.
A nuestras familias, por el apoyo incondicional.

Resumen

Este trabajo investiga la combinación de descriptores heterogéneos para clasificación de texturas, desde la concatenación estática de bloques hasta una cascada adaptativa costo-consciente. Se evalúa una biblioteca de 22 descriptores (20.652 dimensiones) sobre seis conjuntos de datos (DTD, FMD, CUReT, Outex, SoilOriginal y KTH-TIPS-2b). La cascada adquiere representaciones de manera condicional mediante una regla de salida temprana basada en el margen de incertidumbre de una etapa económica seleccionada en entrenamiento. En las 27 condiciones canónicas, el macro-F1 medio descriptivo es 0,9345 para la cascada, 0,9341 para Top-k de origen y 0,9409 para Completa-22. En la comparación por rangos sobre los cinco conjuntos reconciliados, ninguna diferencia pareada alcanza significancia tras el ajuste de Holm ($p_{\text{Holm}} = 1$); este resultado no demuestra equivalencia ni no inferioridad. La reducción analítica de costo proyectada es del 75,5%. En la evaluación física pareada sobre una GPU NVIDIA RTX 4060 evaluando 204 imágenes estratificadas en los seis conjuntos de datos con tres repeticiones aleatorizadas por par (612 mediciones pareadas con registros individuales persistidos), la cascada redujo un 69,0% la latencia de reloj de pared frente a Top-k (90,25 ms frente a 291,21 ms; aceleración agregada de 3,23×), resolviendo el 74,0% de las inferencias en la Etapa 1 económica con un 100,0% de coincidencia en predicciones y rutas frente al cómputo fuera de línea. Estos resultados confirman la viabilidad práctica y la generalización física del compromiso calidad–latencia en hardware real.

Palabras clave: clasificación de texturas, concatenación de descriptores, cascada adaptativa, modelos fundacionales, inferencia costo-consciente, evaluación anidada.

Abstract

This thesis investigates heterogeneous visual descriptor combination for texture classification, from static block concatenation to a cost-aware adaptive cascade. A library of 22 descriptors (20,652 dimensions) is evaluated across six datasets (DTD, FMD, CUReT, Outex, SoilOriginal, and KTH-TIPS-2b). The cascade acquires representations conditionally using an uncertainty-margin stopping rule on an economical stage selected during training. Across 27 canonical conditions, descriptive mean macro-F1 is 0.9345 for the cascade, 0.9341 for source Top-k, and 0.9409 for Full-22. In the rank comparison over the five reconciled datasets, no paired difference is significant after Holm adjustment ($p_{\text{Holm}} = 1$); this does not establish equivalence or non-inferiority. The projected analytical cost reduction is 75.5%. In a physical paired benchmark on an NVIDIA RTX 4060 evaluating 204 stratified test images across all six datasets with three randomized repetitions per pair (612 paired measurements with persisted individual records), the cascade reduced wall-clock latency by 69.0% versus Top-k (90.25 ms vs. 291.21 ms; aggregate speedup of 3.23×), resolving 74.0% of inferences in the economical Stage 1 with 100.0% agreement in predictions and routes against the offline cache. These results demonstrate the practical viability and physical generalization of the quality–latency trade-off on real hardware.

Keywords: texture classification, descriptor concatenation, adaptive cascade, foundation models, cost-aware inference, nested evaluation.

Contenido

1 Introducción **6**

2 Trabajos relacionados **8**

2.1 Representaciones de textura y modelos fundacionales 8

2.2 Concatenación estática y selección de bloques 8

2.3 Inferencia dinámica y arquitecturas en cascada 9

2.4 Adquisición Activa de Características (AFA) y su distinción en visión . . 9

2.5 Redes híbridas en análisis de texturas y brecha identificada 10

3 Método de concatenación y selección de descriptores **11**

3.1 Representación conjunta y pregunta de estudio 11

3.2 Estrategias comparadas 12

3.3 Espacio de descriptores 13

3.4 Greedy Forward Selection 14

3.5 Conjuntos de datos y control de integridad 16

3.6 Clasificadores 17

3.7 Configuración experimental y protocolo anidado 17

3.8 Análisis estadístico 17

3.9 Cascada Adaptativa Costo-Consciente 18

3.9.1 Formulación y Regla de Decisión 18

3.9.2 Selección prospectiva en entrenamiento (OOF) 19

3.9.3 Protocolo de Medición Física de Latencia en GPU 19

4 Resultados experimentales **20**

4.1 Desempeño y dimensionalidad 20

4.2 Rankings y contrastes estadísticos no paramétricos por clasificador 22

4.3 Cascada adaptativa en 27 condiciones 24

4.3.1 Contrastes no paramétricos e hipótesis de costo y calidad 25

4.4 Medición física pareada en los seis datasets 27
4.5 Trazabilidad y auditoría muestra por muestra 28

5 Discusión **29**
5.1 El Compromiso Calidad–Costo en la Concatenación de Descriptores . . . 29
5.2 Ablación de la Hipótesis H2: Políticas Multietapa frente a la Cascada de Dos Etapas 29
5.3 Exploración Conceptual de Fusión Residual y de Segundo Orden 30
5.4 Limitaciones y Transparencia Metodológica 30

6 Conclusiones y Trabajo Futuro **32**
6.1 Conclusiones 32
6.2 Trabajo Futuro 33

Capítulo 1

Introducción

La clasificación de texturas depende de señales locales, distribuciones espaciales y respuestas en frecuencia que varían considerablemente con el dominio de aplicación, la escala, la iluminación y el punto de vista [1–3]. Ninguna representación aislada captura necesariamente la totalidad de estas propiedades. Los descriptores clásicos resumen invariancias y relaciones estadísticas diseñadas manualmente, tales como microestructuras locales, matrices de coocurrencia y gradientes orientados [4–6]; por su parte, las redes convolucionales profundas, los Vision Transformers y los modelos fundacionales con preentrenamiento autosupervisado o multimodal generan representaciones densas con distintos sesgos inductivos y escalas de abstracción [7–13]. Esta diversidad técnica brinda una oportunidad concreta para combinar fuentes de información heterogéneas, pero al mismo tiempo introduce redundancia dimensional, disparidad de escalas y un incremento drástico del costo computacional de extracción.

La concatenación temprana de vectores de características constituye el mecanismo más directo para integrar múltiples representaciones, delegando en el clasificador la ponderación de sus coordenadas conjuntas. Diversos antecedentes en reconocimiento visual y análisis de texturas han recurrido a esquemas de agregación de descriptores locales, Fisher vectors, bancos de filtros profundos o codificación residual aprendida para mejorar la capacidad discriminativa [2, 14, 15]. Sin embargo, una mejora observada en la representación combinada no demuestra por sí sola que la totalidad de los bloques incorporados sea necesaria ni que la complementariedad sinérgica sea el factor causal exclusivo: ganancias similares pueden provenir del simple aumento de la capacidad dimensional o de la presencia de extractores individualmente sobresalientes.

En este contexto, la investigación evalúa una biblioteca consolidada de 22 descriptores visuales (6 clásicos y 16 modelos profundos y fundacionales, totalizando 20.652 dimensiones) a través de seis conjuntos de datos de referencia (DTD, FMD, CUReT, Outex, SoilOriginal y KTH-TIPS-2b), articulándose en dos dimensiones complementarias:

1. **Evaluación anidada de la concatenación estática de bloques:** Se evalúa sistemáticamente la biblioteca de 22 descriptores sobre los seis conjuntos de datos empleando dos clasificadores con sesgos distintos (Linear SVM y la red residual ResMLP). Bajo un estricto protocolo anidado con particiones externas e internas sin fuga de información, se comparan cinco estrategias de composición: *Individual*, *Completa*, *Top-k*, selección secuencial (*Greedy Forward Selection*, GFS) y *Ho-*

mogénea (47 condiciones externas por clasificador). Este análisis permite caracterizar las ganancias y los costos dimensionales de combinar descriptores, revelando que el desempeño satura con pocos bloques de alto orden y que extraer la totalidad de las características densas impone un cuello de botella computacional severo si se ejecuta de forma estática sobre todas las imágenes. Históricamente, este análisis partió de una base preliminar de 21 descriptores (19.884 dimensiones) en cuatro conjuntos, la cual se consolidó al incorporar BEiT-v2-B (+768 dimensiones) y extender la evaluación a SoilOriginal y KTH-TIPS-2b.

2. **Fusión secuencial costo-consciente mediante cascada adaptativa:** Frente a la ineficiencia de procesar todos los extractores densos para cada consulta, se formula un marco de adquisición condicional en dos etapas guiado por incertidumbre. Para cada muestra, se adquiere inicialmente un extractor económico; las muestras ambiguas escalan a la concatenación densa Top-k. Este esquema se evalúa en 27 condiciones canónicas sobre seis conjuntos con clasificador lineal. La medición física disponible compara la cascada con Top-k en una muestra de 47 imágenes de DTD en una GPU NVIDIA GeForce RTX 4060; por tanto, su alcance físico es un piloto local y no una validación multiconjunto.

A partir de este encuadre, la investigación formula dos preguntas centrales de estudio:

- *¿En qué medida y a qué costo dimensional la concatenación estática de bloques supera la selección del mejor descriptor individual, y cuál es el impacto de la política de composición del subconjunto?*
- *¿Es posible aproximar estrechamente la calidad predictiva de la concatenación densa reduciendo sustancialmente el tiempo de inferencia mediante una regla adaptativa de adquisición secuencial guiada por incertidumbre?*

El trabajo aporta: (1) una comparación de estrategias de concatenación estática sobre seis conjuntos, con análisis estadísticos desagregados por clasificador y alcance inferencial delimitado; (2) la evaluación de una cascada costo-consciente en 27 condiciones canónicas; (3) un piloto físico pareado frente a Top-k sobre 47 imágenes de DTD en GPU; y (4) la persistencia de las predicciones de las 27 condiciones para permitir la comprobación de las métricas reportadas.

La memoria se estructura en seis capítulos: el Capítulo 2 revisa los trabajos relacionados en descriptores de textura, selección de características, inferencia dinámica y adquisición activa; el Capítulo 3 describe la metodología experimental, la biblioteca de 22 descriptores, los conjuntos de datos, los clasificadores y la cascada; el Capítulo 4 presenta la concatenación estática, la evaluación descriptiva de la cascada en 27 condiciones y el piloto físico de DTD; el Capítulo 5 analiza el compromiso calidad–costo y sus limitaciones; y el Capítulo 6 sintetiza las conclusiones y perfila las líneas de trabajo futuro.

Capítulo 2

Trabajos relacionados

2.1 Representaciones de textura y modelos fundacionales

El reconocimiento y clasificación de texturas ha evolucionado desde operadores espaciales diseñados manualmente hacia representaciones aprendidas profundas y modelos fundacionales [3]. Los descriptores clásicos se concentran en propiedades estadísticas y microestructuras geométricas: los patrones binarios locales (LBP) y sus variantes rotacionales cuantizan contrastes locales [4, 16]; las matrices de coocurrencia de niveles de gris (GLCM) capturan dependencias espaciales de segundo orden [5]; los bancos de filtros de Gabor descomponen la textura en orientaciones y frecuencias espaciales [17]; y los histogramas de gradientes orientados (HOG) caracterizan transiciones de intensidad [6]. Asimismo, formulaciones como RGB Pixel N-grams modelan secuencias conjuntas de color a nivel de píxel con reducción espectral [18].

En el aprendizaje profundo, las redes neuronales convolucionales (CNN) demostraron capturar jerarquías de textura de forma end-to-end [7, 8, 19, 20]. Posteriormente, la introducción de los Vision Transformers (ViT) [9, 10, 21] y de paradigmas de preentrenamiento autosupervisado y multimodal a gran escala —tales como DINOv2 [11], MAE [22], SigLIP [12] y BEiT-v2 [13]— proporcionó representaciones visuales con una notable capacidad de generalización en dominios de textura no controlados [1, 23]. Encuestas y estudios comparativos recientes [23, 24] confirman que las características transferidas desde modelos fundacionales superan ampliamente a los operadores tradicionales aislados. No obstante, dichos estudios evalúan predominantemente modelos individuales de forma estática, dejando abierto cómo combinar representaciones heterogéneas sin incurrir en redundancia o costos desproporcionados.

2.2 Concatenación estática y selección de bloques

La fusión temprana mediante concatenación directa de vectores de características preserva explícitamente las coordenadas de cada extractor, permitiendo que un único clasificador aprenda ponderaciones sobre el espacio conjunto. En análisis de textura, esquemas clásicos como los Fisher vectors [2, 14] y arquitecturas especializadas como DeepTEN [15]

validaron que agrupar respuestas de múltiples filtros o activaciones convolucionales enriquece la descripción textural.

No obstante, cuando se combinan múltiples extractores modernos congelados, la concatenación densa indiscriminada acumula miles de dimensiones y escalas incompatibles. Para controlar este crecimiento, la selección de variables y bloques recurre tradicionalmente a esquemas *wrapper* o filtros secuenciales [25–27]. Algoritmos como *Greedy Forward Selection* (GFS) exploran de manera iterativa el espacio de combinaciones guiados por el desempeño interno del clasificador. Para evitar sesgos optimistas y fuga de información, la literatura metodológica exige que toda selección de bloques se ejecute de forma estrictamente anidada dentro del conjunto de entrenamiento [26]. A pesar de sus ventajas analíticas, la concatenación estática resultante padece una rigidez intrínseca: la totalidad de los extractores seleccionados debe ejecutarse para cada imagen en inferencia, independientemente de la dificultad visual de la muestra.

2.3 Inferencia dinámica y arquitecturas en cascada

Para mitigar el costo computacional de inferencia en sistemas de visión, la literatura ha explorado mecanismos de cómputo adaptativo o condicional [28]. El principio de inferencia en cascada tiene raíces seminales en el detector de rostros de Viola y Jones [29], donde una secuencia de clasificadores rápidos rechaza tempranamente la gran mayoría de las ventanas no faciales mediante características económicas, reservando clasificadores complejos para candidatos ambiguos.

En redes neuronales profundas, este paradigma evolucionó hacia arquitecturas con salida temprana (*early-exit networks*), tales como BranchyNet [30] y Multi-Scale Dense Networks (MSDNet) [31]. En estas redes, ramas clasificadoras intermedias permiten que muestras sencillas concluyan su procesamiento en capas superficiales si su entropía de predicción o margen de certeza satisface un criterio predefinido, mientras que muestras difíciles continúan propagándose hacia capas más profundas. Aunque estas soluciones aceleran la inferencia dentro de una única arquitectura convolucional monolítica, no abordan directamente el problema de integrar bibliotecas heterogéneas de modelos fundacionales preentrenados e independientes.

2.4 Adquisición Activa de Características (AFA) y su distinción en visión

El paradigma de Adquisición Activa de Características (*Active Feature Acquisition*, AFA) formaliza el problema de predecir con precisión minimizando el costo acumulado de adquisición de atributos [32]. Modelos fundacionales en este ámbito, como EDDI (*Efficient Dynamic Discovery of High-Value Information*) [32], emplean modelos generativos basados en autoencoders variacionales parciales para estimar el Valor Esperado de la Información (*Expected Value of Information*) de cada variable no observada. Formulaciones contemporáneas en 2025–2026 han extendido este enfoque mediante procesos de decisión de Markov (MDP) y políticas no miopes con recurrencias de Bellman para optimizar el riesgo residual.

Sin embargo, existe una diferencia estructural crucial entre la literatura clásica de AFA y el contexto de visión computacional con descriptores profundos:

1. **Unidad y costo de adquisición:** En AFA tabular o clínica, cada variable representa un valor escalar (e.g., un análisis de laboratorio o una medición sensorial) con un costo financiero o procedimental explícito, mientras que el costo de evaluar la política de decisión es despreciable. En visión computacional, la unidad de adquisición es un *bloque completo* derivado de un modelo fundacional (e.g., inferir una pasada completa de SigLIP, ViT-B o ResNet-50).

2. **Sobrecarga de decisión frente a ganancia temporal:** Ejecutar una política de decisión secuencial no miope de horizonte profundo ($H \geq 2$) introduce una sobrecarga de cómputo por muestra (evaluación de estados de incertidumbre, productos matriciales o búsquedas dinámicas) que puede reducir o neutralizar el ahorro de extracción. Por el contrario, una cascada adaptativa de dos etapas —que evalúa inicialmente un descriptor económico y decide el escalamiento condicional según el margen de confianza temprano— ofrece una alternativa parsimoniosa orientada a reducir la latencia de inferencia en muestras certeras, sin incurrir en la sobrecarga computacional de evaluar una política secuencial de horizonte profundo.

2.5 Redes híbridas en análisis de texturas y brecha identificada

Trabajos recientes en caracterización de texturas (2024–2026), tales como arquitecturas híbridas que combinan redes convolucionales con operadores clásicos o multiescala [23, 24], continúan diseñando modelos estáticos donde el 100% de las ramas de extracción se evalúa para cada imagen de prueba. Esta observación evidencia un vacío metodológico claro: la ausencia de marcos adaptativos que articulen la selección rigurosa de bloques con reglas de inferencia dinámica costo-consciente para bibliotecas de extractores visuales heterogéneos. La presente tesis busca precisamente cerrar dicha brecha.

Capítulo 3

Método de concatenación y selección de descriptores

3.1 Representación conjunta y pregunta de estudio

El estudio evalúa la concatenación como un problema de selección de bloques. Cada extractor transforma una imagen x_i en un vector $\mathbf{z}_{ij} \in \mathbb{R}^{d_j}$, donde j identifica el descriptor y d_j su dimensionalidad. Para un subconjunto S de extractores, la representación conjunta se define como

$$\mathbf{z}_{i,S} = \Big\Vert_{j \in S} \frac{\mathbf{z}_{ij}}{\max(\|\mathbf{z}_{ij}\|_2, 10^{-12})}, \tag{3.1}$$

donde $\|$ denota concatenación. La normalización L_2 se aplica por descriptor y por muestra antes de unir los bloques, para evitar que la escala de un extractor determine por sí sola la contribución al clasificador.

La Figura 3.1 muestra cómo una misma imagen produce representaciones diferentes. Un descriptor resume patrones, relaciones entre intensidades o activaciones aprendidas en un vector. Después de normalizar cada bloque, se conserva un descriptor individual o se concatenan los bloques seleccionados. La dimensión conjunta es $d_S = \sum_{j \in S} d_j$.

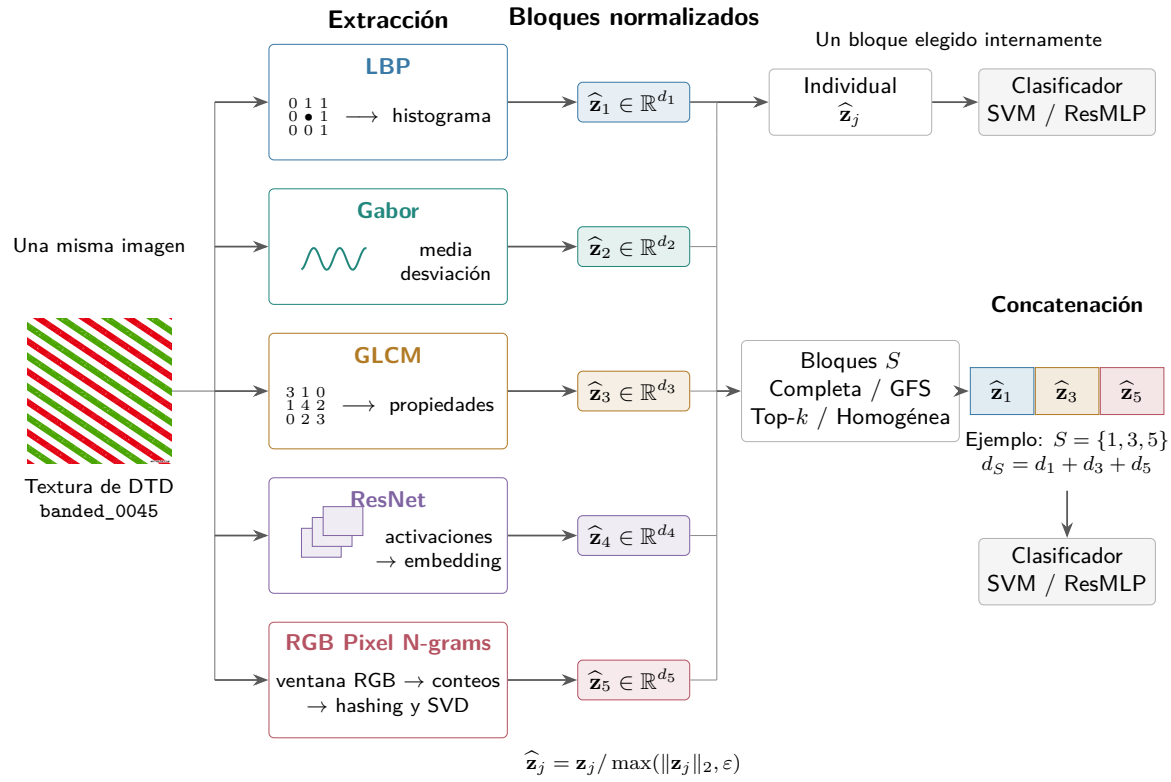


Figura 3.1: Extracción y concatenación de descriptores. La misma imagen de DTD se representa mediante cinco ejemplos: patrones locales (LBP), respuestas de filtros (Gabor), coocurrencias (GLCM), una red convolucional (ResNet) y secuencias RGB (N-gramas). Las transformaciones internas se muestran esquemáticamente; no representan mapas de importancia por píxel. Cada rama produce un bloque normalizado que puede utilizarse individualmente o concatenarse con otros. El ejemplo de tres bloques ilustra la unión de coordenadas; cada política determina el subconjunto admisible.

3.2 Estrategias comparadas

Las cinco estrategias responden a decisiones sobre la representación que recibe el clasificador. Individual establece el desempeño de un solo bloque; Completa evalúa la unión de toda la biblioteca; Top-k y GFS eligen subconjuntos; Homogénea restringe la procedencia de los bloques a una familia. Se utilizan las mismas denominaciones en método, resultados y estadística:

1. **Individual**: descriptor con mayor macro-F1 medio en validación interna.
2. **Completa**: concatenación de todos los bloques de la biblioteca evaluada.
3. **Top-k**: concatenación de los k descriptores mejor posicionados por su macro-F1 individual interno; k se toma del subconjunto GFS de la misma condición.
4. **GFS**: subconjunto devuelto por la selección secuencial de bloques.
5. **Homogénea**: mejor resultado interno de GFS restringido a una familia, con un límite de bloques no mayor que el subconjunto GFS heterogéneo.

Top-k controla la composición bajo el mismo número de bloques que GFS, aunque las dimensiones pueden diferir. No constituye una política independiente de elección de k. Homogénea permite estudiar el efecto de restringir la biblioteca a una familia. Todos los comparadores se seleccionan antes de evaluar el test. Los controles aleatorios y las variantes de presupuesto se conservan como análisis auxiliares en los materiales del proyecto.

3.3 Espacio de descriptores

La biblioteca contiene 22 descriptores, agrupados según el tipo de representación (6 clásicos y 16 modelos aprendidos profundos y fundacionales). Cada uno constituye un bloque candidato sujeto al mismo criterio de selección. Las Tablas 3.1 y 3.2 identifican la parametrización, los checkpoints y la dimensionalidad de cada bloque. Las redes preentrenadas se ejecutaron en modo evaluación y sin ajuste de pesos. En los modelos cargados mediante `timm` se eliminó la capa clasificadora (`num_classes=0`) y se aplicó el preprocesamiento asociado al checkpoint. Para ViT, DeiT, Swin, MAE y SigLIP se utilizó la salida *pooler* cuando estaba disponible y, en caso contrario, el token de clasificación. Todas las imágenes se convirtieron a RGB.

Los descriptores clásicos se basan en operadores LBP, Gabor, GLCM y HOG [4–6, 16, 17]. Las CNN corresponden a VGG16, ResNet, DenseNet, EfficientNet y ConvNeXt V2 [7, 8, 19, 20, 33]. El grupo Transformer incluye ViT, DeiT, Swin y EVA-02 [9, 10, 21, 34]; las representaciones con preentrenamiento autosupervisado o multimodal se basan en DINOv2, MAE y SigLIP [11, 12, 22].

Tabla 3.1: Seis descriptores basados en patrones, filtros, gradientes y conteos incluidos en la biblioteca. Cada fila constituye un bloque completo.

Descriptor	Parametrización	Salida	Dim.
LBP	multiescala $(P, R) = (8, 1), (16, 2), (24, 3)$; mapeo uniforme invariante a rotación (riu2)	histogramas normalizados	54
LBP-rot	$P = 8$, $R = 1$; ocho rotaciones; códigos limitados a $[0, 10]$	histogramas 10×8	80
Gabor	cuatro frecuencias 0,1–0,8; seis orientaciones	media y desv. de respuesta real	48
GLCM	256 niveles; distancias 1–3; cuatro ángulos; seis propiedades	promedios sobre ángulos	18
HOG	nueve orientaciones; celda 16^2; bloque 2^2; norma L2-Hys	vector HOG	1.764
N-gramas	ventana vertical 2×1; cuantización RGB por 12; 8.192 bins; SVD	vector normalizado	256

Los descriptores clásicos se calcularon en escala de grises con la implementación de scikit-image: LBP, LBP-rot, Gabor y GLCM sobre imágenes redimensionadas a 256×256, y HOG sobre 128×128. LBP-rot designa la implementación propia registrada como `drlbp` en los archivos experimentales: aplica LBP con mapeo `ror` a ocho rotaciones y concatena diez bins por rotación en el intervalo $[0, 10]$. Los códigos fuera de ese intervalo se descartan; por tanto, es un histograma restringido, no una reproducción del DRLBP de Mehta y Egiazarian [16].

La biblioteca consolidada del estudio comprende 22 descriptores (6 clásicos y 16 aprendidos), cuyos vectores concatenados suman 20.652 dimensiones (19.884 dimensiones corre-

Tabla 3.2: Representaciones aprendidas congeladas incluidas en la biblioteca (16 extractores profundos y de modelos fundacionales). "Preclas." designa la salida inmediatamente anterior al clasificador del backbone.

Familia	Descriptor	Checkpoint	Salida	Dim.
CNN	VGG16	`vgg16.tv_in1k`	preclas.	4.096
	ResNet-50	`resnet50.a1_in1k`	preclas.	2.048
	ResNet-101	`resnet101.a1_in1k`	preclas.	2.048
	DenseNet-121	`densenet121.tv_in1k`	preclas.	1.024
	EfficientNet-B0	`efficientnet_b0.ra_in1k`	preclas.	1.280
	ConvNeXt V2-T	`convnextv2_tiny.fcmae_ft_in22k_in1k`	preclas.	768
Transformer	ViT-B/16	`google/vit-base-patch16-224`	pooler/CLS	768
	DeiT-S	`facebook/deit-small-patch16-224`	pooler/CLS	384
	Swin-T	`microsoft/swin-tiny-patch4-window7-224`	pooler	768
	EVA-02 base	`eva02_base_patch14_224`	preclas.	768
	BEiT-v2-B[†]	`beitv2_base_patch16_224`	pooler/CLS	768
Autosup./multimodal	DINOv2-S	`vit_small_patch14_dinov2.lvd142m`	preclas.	384
	DINOv2-B	`vit_base_patch14_dinov2.lvd142m`	preclas.	768
	DINOv2-L	`vit_large_patch14_dinov2.lvd142m`	preclas.	1.024
	MAE-B	`facebook/vit-mae-base`	pooler/CLS	768
	SigLIP-B	`google/siglip-base-patch16-224`	pooler/CLS	768

[†]BEiT-v2-B (768d) consolida la biblioteca en 22 extractores (20.652 dimensiones conjuntas).

spondientes al conjunto preliminar de 21 descriptores más 768 componentes aportadas por BEiT-v2-B). Las características fijas y los conteos por imagen se almacenaron junto con etiquetas, orden de muestras y hashes de procedencia; las transformaciones aprendidas se ajustaron dentro de cada partición de entrenamiento. El estudio evalúa la selección y concatenación de bloques con extractores de imagen congelados y transformaciones ajustadas dentro del entrenamiento; no compara estrategias de *fine-tuning*.

RGB Pixel N-grams [18] utiliza ventanas verticales de 2×1 píxeles con paso 1 sobre la imagen RGB en su resolución original. Cada canal se cuantiza mediante $q(v) = \lfloor v/12 \rfloor$; los seis valores se codifican en base 22, recorriendo las dos posiciones de R, G y B. Los conteos se agrupan por el resto del código dividido por 8.192 y se comprimen mediante TruncatedSVD aleatorizado (256 componentes, cinco iteraciones y semilla de la condición). SVD se ajusta exclusivamente con el entrenamiento de cada partición interna y se reajusta sobre el entrenamiento externo para la evaluación final. El vector se normaliza con L_2 antes de concatenarlo. Esta parametrización comprimida se identifica como N-gramas + SVD y constituye una familia propia para la selección Homogénea.

3.4 Greedy Forward Selection

GFS se utiliza como un método *wrapper*: los subconjuntos se valoran mediante el propio clasificador y exclusivamente dentro de la validación interna, como requieren los diseños de selección que separan búsqueda y evaluación externa [25, 26]. La búsqueda comienza con un conjunto vacío. En el paso t, evalúa cada descriptor aún no seleccionado al añadirlo al subconjunto vigente y elige el candidato con mayor macro-F1 medio en la validación interna:

$$j_t = \arg\max_{j \notin S_{t-1}} \widehat{F}_{1,\text{inner}}(S_{t-1} \cup \{j\}), \qquad S_t = S_{t-1} \cup \{j_t\}. \tag{3.2}$$

La búsqueda se limita a $k \leq 8$. Se detiene cuando la mejora respecto del paso anterior es menor que 0,001 durante dos pasos consecutivos, pero devuelve el mejor paso histórico, no necesariamente el último. Los empates se resuelven de forma determinista mediante el nombre del extractor. Todas las evaluaciones candidatas utilizan únicamente muestras pertenecientes al entrenamiento externo.

La Figura 3.2 representa el mecanismo general de GFS. En cada ronda se comparan únicamente los bloques aún disponibles dentro de los folds internos; el bloque elegido se incorpora al subconjunto y el test externo permanece fuera de esa decisión.

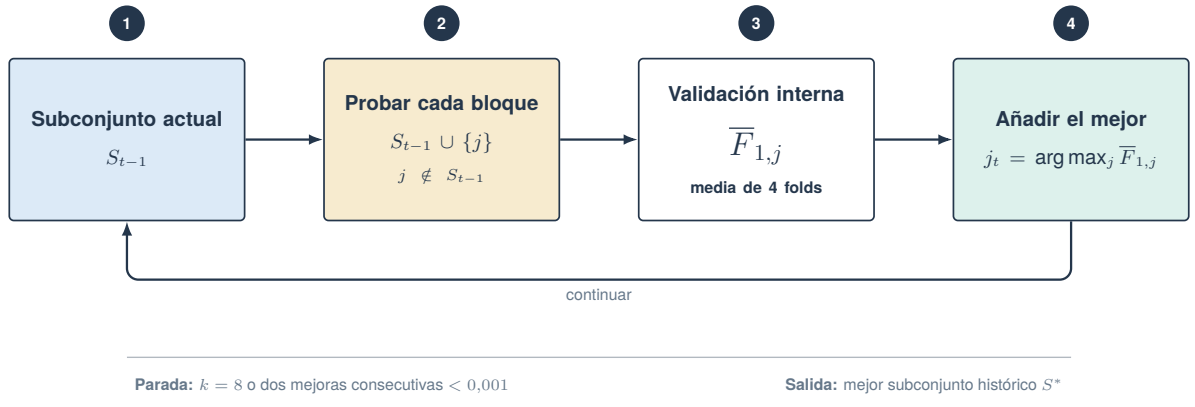


Figura 3.2: Mecanismo de Greedy Forward Selection sobre bloques completos. En cada paso se elige el bloque que maximiza el macro-F1 medio de la validación interna; el test externo se utiliza únicamente tras cerrar el subconjunto.

La Tabla 3.3 concentra los parámetros de búsqueda, comunes a ambos clasificadores.

Tabla 3.3: Configuración de la selección GFS en el flujo general.

Elemento	Configuración
Unidad de selección	Bloque completo generado por un extractor
Candidatos	Hasta 22 bloques candidatos
Criterio interno	Macro-F1 medio en cuatro folds estratificados y agrupados
Presupuesto	Hasta $k = 8$ bloques
Parada	Dos mejoras consecutivas menores que 0,001; se devuelve el mejor paso histórico
Empates	Nombre del extractor, en orden determinista
Información excluida	Test externo y sus etiquetas durante toda la selección

3.5 Conjuntos de datos y control de integridad

Antes del análisis se construyó un manifiesto por dataset y se verificaron etiquetas, orden de muestras, dimensiones, valores finitos y grupos de dependencia. El estudio evalúa seis conjuntos de datos de textura: DTD, FMD, CUReT, Outex, SoilOriginal y KTH-TIPS-2b. Para la concatenación estática se analizan 47 condiciones externas por clasificador; para la cascada adaptativa se evalúa el espacio canónico de 27 condiciones.

DTD contiene 5.640 imágenes de texturas en condiciones no controladas y proporciona diez particiones oficiales de entrenamiento, validación y prueba [1]. En cada partición se unieron entrenamiento y validación para ejecutar la selección interna, mientras que el test oficial se reservó para una única evaluación. Los duplicados byte-idénticos que cruzaban roles fueron retirados del conjunto de entrenamiento, conservando intacta la evaluación.

FMD reúne 1.000 fotografías de diez categorías de materiales [35]. Las características fijas y los conteos por imagen se obtuvieron desde las imágenes oficiales en un orden canónico. Cada imagen presentó un hash único y se utilizó como unidad de agrupación. En la concatenación estática, la evaluación externa empleó cinco folds estratificados y agrupados repetidos con semillas 42, 123 y 2026 (15 condiciones externas); en la cascada adaptativa, se evalúan los cinco pliegues canónicos.

Outex contiene 1.360 BMP RGB de 128×128 píxeles, organizados en 68 clases balanceadas (suite Outex-TC-00013). La auditoría verificó archivos legibles, IDs continuos 000000–001359, ausencia de duplicados y la partición oficial de 680 imágenes de entrenamiento y 680 de prueba, con diez muestras de cada clase en cada lado [36]. Todos los bloques respetan el orden de las 1.360 muestras del manifiesto oficial.

Para CUReT se utilizó la distribución gris recortada de 61 materiales, con 92 condiciones compartidas por clase [37]. Cada condición constituye un grupo para impedir que la misma configuración de adquisición aparezca a ambos lados de una partición. Se definieron dos mitades complementarias deterministas de 46 condiciones: A para selección y entrenamiento con B como test, y la dirección inversa. Esta asignación reproduce de manera transparente el tamaño 46/46 publicado, pero no se presenta como el split histórico exacto. Debido a que las dos direcciones son complementarias y dependientes, sus resultados se interpretan descriptivamente.

SoilOriginal comprende 1.140 imágenes originales de textura de suelos agrícolas tras deduplicación exacta, clasificadas en siete clases texturales estándar y evaluadas bajo cinco pliegues estratificados canónicos (228 imágenes de prueba por pliegue, $N = 5$ condiciones).

KTH-TIPS-2b contiene imágenes de 11 clases de materiales capturadas bajo cuatro muestras físicas independientes (*sample_a*, *sample_b*, *sample_c*, *sample_d*) variando pose, escala e iluminación ($N = 4$ condiciones). Para mantener la trazabilidad con los experimentos archivados del proyecto, sus resultados se reportan de forma puramente descriptiva; no obstante, debido a diferencias en su historial de selección previa y particionamiento, se excluye formalmente del conjunto de datos sometido a los contrastes inferenciales no paramétricos conjuntos de Demšar, los cuales se restringen a los cinco conjuntos metodológicamente reconciliados (DTD, FMD, CUReT, Outex13 y SoilOriginal, $N = 5$, 23 condiciones).

3.6 Clasificadores

Se emplearon dos clasificadores con sesgos diferentes. La SVM lineal se implementa con `LinearSVC` de scikit-learn: $C = 1$, ponderación balanceada por clase, pérdida *squared hinge*, regularización L_2, esquema uno-contra-el-resto, tolerancia 10^{-4} y un máximo de 10.000 iteraciones.

Se denomina ResMLP a la MLP residual implementada para este estudio sobre vectores de características; no es una reproducción del modelo de imágenes del mismo nombre [38]. Proyecta la entrada a 256 unidades y aplica tres bloques residuales, normalización de capa, activaciones GELU, *dropout* de 0,1 y una salida multiclase. Se entrena con entropía cruzada y AdamW, tasa de aprendizaje 10^{-3}, decaimiento de pesos 10^{-4}, lotes de 256 muestras y un máximo de 100 épocas. La parada se basa en la pérdida media de entrenamiento: tras diez épocas sin una disminución mayor que 10^{-4}, se detiene y restaura el mejor estado registrado. No utiliza el test ni una validación adicional para elegir la época. Las semillas se fijan para NumPy y PyTorch; cuando está disponible, la red se ejecuta en GPU.

3.7 Configuración experimental y protocolo anidado

La selección interna utiliza cuatro folds estratificados y agrupados. En DTD se ejecuta dentro de la unión *train+val* de cada split oficial; en FMD dentro del entrenamiento de cada uno de los 15 folds externos; y en CUReT dentro de la mitad de 46 condiciones asignada al entrenamiento. En Outex, las cinco estrategias restringen los cuatro folds internos a las 680 imágenes del entrenamiento oficial. Después de seleccionar el subconjunto y los comparadores, cada modelo se ajusta con todo el entrenamiento externo y se evalúa una sola vez en el test correspondiente. Se verifica programáticamente que ningún grupo aparezca en entrenamiento y prueba.

3.8 Análisis estadístico

El análisis inferencial sigue las recomendaciones metodológicas para comparación de clasificadores sobre múltiples conjuntos de datos [39–41]. Los cálculos se realizaron con los paquetes Java ControlTest y MultipleTest distribuidos con el tutorial de pruebas no paramétricas [40].

La exactitud es la proporción de imágenes clasificadas correctamente. Macro-F1 promedia el F1 de las C clases con igual peso: $\text{macro-F1} = C^{-1} \sum_{c=1}^{C} 2TP_c/(2TP_c + FP_c + FN_c)$, donde TP_c, FP_c y FN_c son los verdaderos positivos, falsos positivos y falsos negativos de la clase c. Esta media evita que la contribución de una clase dependa directamente de su número de muestras.

Macro-F1 es la métrica primaria del estudio. Para la evaluación de la concatenación estática sobre la biblioteca consolidada de 22 descriptores, los contrastes no paramétricos se ejecutan de forma desagregada por clasificador (Linear SVM y ResMLP), definiendo un bloque por conjunto de datos ($N = 6$ conjuntos: DTD, FMD, CUReT, Outex, SoilOriginal y KTH-TIPS-2b). En cada bloque se promedian previamente las particiones externas

dependientes. Se calculan los rankings de Friedman, Friedman alineado y Quade, y los contrastes por pares aplican el ajuste secuencial de Holm ($\alpha = 0{,}05$) sobre la familia de diez comparaciones posibles. Esta separación por clasificador respeta los sesgos inductivos disímiles de cada modelo y evita el problema de pseudorreplicación derivado de tratar evaluaciones dependientes sobre las mismas imágenes como problemas independientes.

Para la evaluación de la Cascada Adaptativa Costo-Consciente, se aplican los contrastes de Demšar sobre los cinco conjuntos de datos metodológicamente reconciliados ($N = 5$, 23 condiciones canónicas), contrastando la cascada frente a la concatenación Top-k de origen y la Concatenación Completa-22 mediante pruebas pareadas de Wilcoxon con ajuste de Holm.

En todos los casos, la ausencia de significancia estadística ($p_{\text{Holm}} > 0{,}05$) representa la imposibilidad de rechazar la hipótesis nula de igualdad de rangos bajo la muestra disponible; es metodológicamente fundamental reconocer que no constituye una demostración de equivalencia matemática ni de no inferioridad formal entre estrategias. Se informan con rigor las diferencias empíricas observadas junto con los valores de significancia.

3.9 Fusión secuencial y cascada adaptativa de dos etapas

La concatenación estática descrita en la Sección 3 presenta una limitación operativa fundamental: para cada imagen del conjunto de prueba, obliga a calcular la totalidad de los descriptores seleccionados, incurriendo en un costo computacional masivo y constante sin importar si el patrón textural es trivial o altamente complejo.

Para abordar este compromiso calidad–costo, se formuló una estrategia de adquisición condicional en dos etapas denominada *Cascada Adaptativa Costo-Consciente*. En lugar de evaluar todos los bloques de entrada de forma homogénea, el sistema procesa la imagen de manera progresiva guiado por la incertidumbre predictiva del clasificador.

3.9.1 Formulación y Regla de Decisión

Sea $\mathcal{B} = \{\phi_1, \ldots, \phi_M\}$ la biblioteca de extractores disponibles ($M = 22$) y x una imagen de entrada. La inferencia en cascada opera en dos etapas:

1. **Etapa 1 (Económica):** Se extrae un único descriptor inicial liviano $\phi_{\text{cheap}} \in \mathcal{B}$. El clasificador lineal ajustado sobre este descriptor produce un vector de puntuaciones de decisión $\mathbf{s} = [s_1, \ldots, s_C]$. El margen de confianza $m(x)$ se define como la diferencia entre la puntuación de la clase más probable y la segunda más probable:

$$m(x) = s_{(1)} - s_{(2)}. \tag{3.3}$$

   Si el margen supera un umbral prospectivo τ ($m(x) > \tau$), la predicción de la Etapa 1 se considera suficientemente certera, el proceso se detiene inmediatamente (*early exit*) y no se adquieren descriptores adicionales.

2. **Etapa 2 (Escalamiento a Concatenación Densa):** Si $m(x) \leq \tau$, la muestra se identifica como ambigua. En este caso, el sistema escala selectivamente y adquiere

los extractores complementarios seleccionados mediante Top-k ($\mathcal{B}_{\text{Top-}k}$). La predicción final se obtiene evaluando el modelo conjunto entrenado sobre la concatenación normalizada de todos los bloques adquiridos:

$$\hat{y}(x) = \begin{cases} \hat{y}_{\text{cheap}}(x), & \text{si } m(x) > \tau, \\ \hat{y}_{\text{Top-}k}(x), & \text{si } m(x) \leq \tau. \end{cases} \tag{3.4}$$

3.9.2 Selección prospectiva en entrenamiento (OOF)

Para prevenir sesgos optimistas o fuga de información hacia el conjunto de prueba, tanto la elección del descriptor económico inicial ϕ_{cheap} como el umbral de confianza τ se optimizan de forma estrictamente prospectiva en el conjunto de entrenamiento T_{train} mediante validación cruzada interna fuera de pliegue (*Out-of-Fold*, OOF).

Los candidatos económicos considerados en la búsqueda interna corresponden a ResNet-50, SigLIP-B, BEiT-v2-B y ConvNeXt V2-T, evaluados bajo una grilla de presupuestos relativos de escalamiento $B \in \{0{,}25; 0{,}50; 0{,}75\}$. Para cada candidato y presupuesto, el umbral τ se fija como el percentil B de los márgenes OOF observados en entrenamiento. La ruta seleccionada es aquella que minimiza el costo computacional proyectado garantizando que el macro-F1 OOF se mantenga dentro de un margen de tolerancia estricto ($\Delta \leq 0{,}005$) respecto a la concatenación directa. Si ningún candidato económico satisface el criterio de calidad en entrenamiento, el sistema selecciona automáticamente la ruta directa sin escalamiento (`topk_direct`). El subconjunto denso Top-k de la Etapa 2 se hereda de las selecciones internas realizadas en el entrenamiento.

3.9.3 Protocolo de Medición Física de Latencia en GPU

Como comprobación local del costo de ejecución, se realizó un piloto de medición física pareada en una GPU NVIDIA GeForce RTX 4060 (8 GB VRAM), limitado a la partición DTD official1 (47 imágenes, una por clase). Este piloto no valida físicamente la proyección analítica en los demás conjuntos ni descarta discrepancias para otras rutas o configuraciones.

Se usó tamaño de lote unitario y los modelos permanecieron residentes en memoria de video; por ello, la medición no incluye su inicialización ni carga desde disco. El cronometraje comenzó después de decodificar cada imagen RGB con PIL y se usaron sincronizaciones explícitas de CUDA (`torch.cuda.synchronize()`) alrededor de la medición con reloj de pared. Para cada imagen se registró una ejecución de la cascada y una de Top-k, siempre en ese orden y sin repeticiones aleatorizadas. La correspondencia por imagen permite una comparación pareada descriptiva, pero el orden fijo y la ausencia de repeticiones impiden estimar la variabilidad entre ejecuciones o descartar efectos de calentamiento y contención.

Capítulo 4

Resultados experimentales

Este capítulo presenta la evidencia experimental organizada en dos partes complementarias: la Sección 4.1 y la Sección 4.2 evalúan la concatenación estática de bloques en la biblioteca consolidada de 22 descriptores (20.652 dimensiones) sobre seis conjuntos de datos con Linear SVM y ResMLP; la Sección 4.3 evalúa la Cascada Adaptativa Costo-Consciente sobre 27 condiciones canónicas en los mismos seis conjuntos de datos con Linear SVM, complementada por la validación física pareada en GPU (Sección 4.4) y la auditoría de trazabilidad (Sección 4.5).

4.1 Desempeño y dimensionalidad de la concatenación estática

La evaluación sistemática de la concatenación estática analiza la biblioteca consolidada de 22 descriptores (20.652 dimensiones) sobre seis conjuntos de datos de referencia (DTD, FMD, CUReT, Outex, SoilOriginal y KTH-TIPS-2b) empleando dos clasificadores con sesgos inductivos distintos: Linear SVM y ResMLP (12 configuraciones experimentales). La Tabla 4.1 compara las cinco estrategias de selección de bloques (Individual, Completa, Top-k, GFS y Homogénea) en términos de macro-F1 medio entre particiones externas. La estrategia Individual corresponde a una selección interna prospectiva (el extractor elegido puede variar entre particiones). La Tabla 4.2 reporta la exactitud bajo el mismo diseño anidado.

Tabla 4.1: Macro-F1 externo de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	0,8426	0,8639	0,8700	**0,8703**	0,8604
DTD	ResMLP	0,8373	0,8620	**0,8643**	0,8639	0,8611
FMD	SVM	0,9726	0,9647	**0,9820**	0,9766	0,9789
FMD	ResMLP	0,9690	0,9564	0,9740	**0,9783**	0,9773
CUReT	SVM	0,9948	**0,9989**	**0,9989**	0,9988	0,9989
CUReT	ResMLP	0,9971	**0,9991**	0,9984	0,9986	0,9982
Outex	SVM	0,9066	**0,9656**	0,9426	0,9589	0,9307
Outex	ResMLP	0,9476	0,9416	0,9652	**0,9715**	0,9306
Soil	SVM	0,8578	**0,8816**	0,8776	0,8671	0,8670
Soil	ResMLP	0,8533	0,8649	0,8685	**0,8691**	0,8629
KTH-TIPS2-b	SVM	0,9396	**0,9601**	0,9400	0,9052	0,9271
KTH-TIPS2-b	ResMLP	0,9061	**0,9487**	0,9322	0,9201	0,9127

Tabla 4.2: Exactitud externa de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	0,8448	0,8654	0,8714	**0,8716**	0,8621
DTD	ResMLP	0,8382	0,8635	**0,8652**	0,8651	0,8626
FMD	SVM	0,9727	0,9647	**0,9820**	0,9767	0,9790
FMD	ResMLP	0,9690	0,9563	0,9740	**0,9783**	0,9773
CUReT	SVM	0,9948	**0,9989**	**0,9989**	0,9988	**0,9989**
CUReT	ResMLP	0,9971	**0,9991**	0,9984	0,9986	0,9982
Outex	SVM	0,9103	**0,9662**	0,9441	0,9603	0,9324
Outex	ResMLP	0,9485	0,9456	0,9662	**0,9721**	0,9338
Soil	SVM	0,9044	**0,9281**	0,9225	0,9152	0,9126
Soil	ResMLP	0,9044	**0,9184**	0,9181	0,9170	0,9135
KTH-TIPS2-b	SVM	0,9415	**0,9609**	0,9419	0,9112	0,9293
KTH-TIPS2-b	ResMLP	0,9099	**0,9499**	0,9346	0,9219	0,9165

Tabla 4.3: Dimensión media de las representaciones usadas en la evaluación externa con 22 descriptores.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	819,2	20652,0	4480,0	5390,4	2496,0
DTD	ResMLP	768,0	20652,0	4211,2	4626,4	2598,4
FMD	SVM	768,0	20652,0	2969,6	2687,5	2338,1
FMD	ResMLP	768,0	20652,0	3404,8	3077,5	2218,7
CUReT	SVM	1024,0	20652,0	3328,0	4402,0	2944,0
CUReT	ResMLP	704,0	20652,0	2176,0	2880,0	1856,0
Outex	SVM	1024,0	20652,0	7808,0	6784,0	3712,0
Outex	ResMLP	256,0	20652,0	6016,0	3346,0	2176,0
Soil	SVM	768,0	20652,0	4898,1	3709,9	2184,5
Soil	ResMLP	768,0	20652,0	5529,6	4415,6	2235,7
KTH-TIPS2-b	SVM	832,0	20652,0	1280,0	960,0	960,0
KTH-TIPS2-b	ResMLP	672,0	20652,0	1600,0	1440,0	928,0

Completa tiene siempre 20.652 coordenadas; las otras estrategias pueden elegir subconjuntos distintos entre particiones.

En términos de macro-F1 medio, la combinación de descriptores supera a Individual en las doce configuraciones evaluadas (seis conjuntos por dos clasificadores), si bien la estrategia con mayor desempeño absoluto varía según el dominio textural. Completa alcanza las puntuaciones más altas en CUReT (0,9989 con SVM y 0,9991 con ResMLP), en Soil con

SVM (0,8816) y en KTH-TIPS-2b (0,9601 con SVM y 0,9487 con ResMLP); GFS obtiene el mayor valor en DTD con SVM (0,8703), en Outex con ResMLP (0,9715) y en Soil con ResMLP (0,8691); mientras que Top-k sobresale en FMD con SVM (0,9820) y en DTD con ResMLP (0,8643). Esta comparación describe las medias externas observadas y no implica significancia estadística individual en cada contraste.

La Tabla 4.3 contrasta el desempeño predictivo con el tamaño efectivo del vector de entrada. Mientras que Completa utiliza siempre las 20.652 dimensiones de la biblioteca conjunta, la dimensión media seleccionada por GFS se sitúa entre 960 y 6.784 componentes entre configuraciones, lo que representa una reducción de entre 67,1% y 95,3% en la dimensionalidad del espacio de entrada. Esta reducción alivia la carga de memoria y almacenamiento del clasificador, pero no disminuye proporcionalmente la latencia de inferencia de extremo a extremo en un esquema estático, dado que todos los extractores seleccionados deben ejecutarse de forma invariable para cada imagen.

4.2 Rankings y contrastes estadísticos no paramétricos por clasificador

Siguiendo las recomendaciones metodológicas no paramétricas [39, 40], las evaluaciones de macro-F1 con la biblioteca de 22 descriptores se analizan de forma desagregada para Linear SVM y ResMLP sobre los seis conjuntos de datos ($N = 6$ bloques independientes por clasificador). La Tabla 4.4 presenta los rankings medios según las pruebas de Friedman, Friedman alineado y Quade.

Tabla 4.4: Rankings medios de macro-F1 según Friedman, Friedman alineado y Quade con 22 descriptores. Seis datasets por clasificador; menor ranking indica mejor desempeño relativo dentro de cada prueba.

Clasif.	Estrategia	Friedman	F. alineado	Quade
SVM	Individual	4,500	23,000	4,429
SVM	Completa	2,000	10,000	1,762
SVM	Top-k	2,000	9,833	2,190
SVM	GFS	3,000	15,000	2,857
SVM	Homogénea	3,500	19,667	3,762
ResMLP	Individual	4,500	24,167	4,381
ResMLP	Completa	2,833	15,333	2,857
ResMLP	Top-k	2,167	8,833	2,000
ResMLP	GFS	1,667	10,500	1,810
ResMLP	Homogénea	3,833	18,667	3,952

Tabla 4.5: Pruebas globales por clasificador sobre cinco estrategias y seis datasets con la biblioteca de 22 descriptores. Nivel nominal $\alpha = 0{,}05$.

Clasif.	Prueba	p	Decisión
SVM	Friedman	0,0289	Rechazo
SVM	Iman–Davenport	0,0139	Rechazo
SVM	Friedman alineado	0,2860	No rechazo
SVM	Quade	0,0349	Rechazo
ResMLP	Friedman	0,0110	Rechazo
ResMLP	Iman–Davenport	0,0025	Rechazo
ResMLP	Friedman alineado	0,2883	No rechazo
ResMLP	Quade	0,0210	Rechazo

Tabla 4.6: Comparaciones por pares basadas en rangos de Friedman. Holm corrige los diez pares dentro de cada clasificador.

Clasif.	Comparación	p sin ajustar	p Holm
SVM	Individual vs. Top-k	0,0062	0,0617
SVM	Individual vs. Completa	0,0062	0,0617
SVM	Individual vs. GFS	0,1003	0,8028
SVM	Top-k vs. Homogénea	0,1003	0,8028
SVM	Completa vs. Homogénea	0,1003	0,8028
SVM	Individual vs. Homogénea	0,2733	1,0000
SVM	Top-k vs. GFS	0,2733	1,0000
SVM	Completa vs. GFS	0,2733	1,0000
SVM	GFS vs. Homogénea	0,5839	1,0000
SVM	Completa vs. Top-k	1,0000	1,0000
ResMLP	Individual vs. GFS	0,0019	0,0191
ResMLP	Individual vs. Top-k	0,0106	0,0953
ResMLP	GFS vs. Homogénea	0,0176	0,1410
ResMLP	Individual vs. Completa	0,0679	0,4752
ResMLP	Top-k vs. Homogénea	0,0679	0,4752
ResMLP	Completa vs. GFS	0,2012	1,0000
ResMLP	Completa vs. Homogénea	0,2733	1,0000
ResMLP	Individual vs. Homogénea	0,4652	1,0000
ResMLP	Completa vs. Top-k	0,4652	1,0000
ResMLP	Top-k vs. GFS	0,5839	1,0000

Como refleja la Tabla 4.4, el ordenamiento relativo de las estrategias difiere notablemente según el clasificador empleado. Con Linear SVM, Completa y Top-k obtienen el mejor ranking medio de Friedman (2,000), seguidas por GFS (3,000), Homogénea (3,500) e Individual (4,500). Con ResMLP, en cambio, la selección secuencial GFS logra el primer puesto con un ranking medio de 1,667, superando a Top-k (2,167), Completa (2,833), Homogénea (3,833) e Individual (4,500).

La Tabla 4.5 resume las pruebas globales de hipótesis a nivel nominal $\alpha = 0{,}05$. Para ambos clasificadores, las pruebas de Friedman e Iman–Davenport rechazan la hipótesis nula de igualdad global de rangos entre estrategias ($p = 0{,}0289$ e $p = 0{,}0139$ para Linear SVM; $p = 0{,}0110$ e $p = 0{,}0025$ para ResMLP), confirmando la presencia de diferencias sistemáticas entre métodos.

La Tabla 4.6 detalla las comparaciones por pares frente a todos los rivales aplicando la corrección secuencial de Holm sobre los diez pares posibles dentro de cada clasificador:

- **ResMLP:** GFS obtiene una mejora estadísticamente significativa frente al control prospectivo Individual ($p_{\text{sin ajustar}} = 0{,}0019$, $p_{\text{Holm}} = 0{,}0191$). La comparación Individual vs. Top-k arroja $p_{\text{Holm}} = 0{,}0953$, mientras que Completa no se diferencia significativamente de Individual ($p_{\text{Holm}} = 0{,}4752$).

- **Linear SVM:** Aunque Individual vs. Top-k e Individual vs. Completa exhiben p sin ajustar de 0,0062, tras la corrección de Holm sobre los diez contrastes el valor ajustado se sitúa en $p_{\text{Holm}} = 0{,}0617$, no alcanzando significancia formal al nivel $\alpha = 0{,}05$. Por su parte, Individual vs. GFS registra $p_{\text{Holm}} = 0{,}8028$.

Es metodológicamente instructivo contrastar este análisis formal por clasificador con la aproximación preliminar explorada en la literatura de texturas sobre cuatro conjuntos de datos, donde se agruparon las ocho combinaciones dataset–clasificador como si fueran ocho observaciones pareadas independientes ($N = 8$, arrojando un valor nominal $p_{\text{Holm}} = 0{,}0157$ para GFS y Top-k frente a Individual). Dicho agrupamiento adolece de dependencia intrínseca: las ocho filas reutilizan las mismas imágenes y conjuntos de datos, lo que infla artificialmente los grados de libertad del contraste. Más aún, encubre el comportamiento diferenciado de los modelos: la ventaja de GFS sobre Individual resulta estadísticamente significativa en este análisis bajo ResMLP ($p_{\text{Holm}} = 0{,}0191$), pero no bajo Linear SVM, donde GFS registra $p_{\text{Holm}} = 0{,}8028$ (mientras que Top-k y Completa obtienen $p_{\text{Holm}} = 0{,}0617$). Es fundamental subrayar que alcanzar significancia estadística ($p < 0{,}05$) en este benchmark no convierte al resultado en confirmatorio: el estudio documenta decisiones metodológicas informadas por la observación previa de resultados externos, tal como la incorporación de BEiT-v2 guiada por evaluaciones previas que incluyeron KTH-TIPS-2b. Esa limitación debe conservarse con rigor, reconociendo el carácter observacional del análisis y evitando atribuirle el estatus de prueba confirmatoria pre-registrada.

4.3 Evaluación de la cascada adaptativa en 27 condiciones

La evaluación de la inferencia dinámica aborda directamente la limitación operativa de la concatenación estática evaluando la Cascada Adaptativa Costo-Consciente sobre la biblioteca extendida de 22 descriptores (20.652 dimensiones) con clasificador Linear SVM. La evaluación abarca 27 condiciones canónicas distribuidas en seis conjuntos de datos: DTD (10 particiones oficiales), FMD (5 particiones), CUReT (2 particiones), Outex13 (1 partición), SoilOriginal (5 particiones) y KTH-TIPS-2b (4 particiones).

En cada condición, la selección del descriptor económico de la Etapa 1 y el umbral de confianza τ se optimizaron de forma estrictamente prospectiva mediante validación cruzada interna fuera de pliegue (OOF) sobre T_{train}. Las selecciones registradas reflejan la conveniencia de adaptación al dominio textural: `siglip_base` fue seleccionado en 20 condiciones, `beitv2_base_final` en 5 condiciones, `resnet50` en 1 condición y la ruta directa `topk_direct` en 1 condición.

La Tabla 4.7 resume el desempeño predictivo (macro-F1) y el costo computacional proyectado por conjunto de datos, promediando las condiciones externas correspondientes.

A nivel agregado sobre las 27 condiciones canónicas, la Cascada Adaptativa registra un macro-F1 medio de **0,9345**, frente a 0,9341 de la concatenación Top-k de origen (diferencia observada de +0,0004) y 0,9409 de la Concatenación Completa-22 (diferencia de −0,0064). En el subconjunto de cinco bases reconciliadas metodológicamente ($N =$ 5, 23 condiciones), las medias observadas son de 0,9325 para la Cascada, 0,9329 para

Tabla 4.7: Resultados comparativos de macro-F1 y costo computacional en las 27 condiciones canónicas. KTH-TIPS-2b se reporta de forma descriptiva conforme a su variante archivada.

Dataset	N	Cascada	Top-k Origen	Completa-22	Costo (ms)	Reducción
DTD	10	0,8700	0,8700	0,8639	172,0	74,0%
FMD	5	0,9840	0,9829	0,9651	138,7	76,2%
CUReT	2	0,9982	0,9989	0,9989	153,4	76,6%
Outex13	1	0,9369	0,9426	0,9656	165,9	77,3%
SoilOriginal	5	0,8734	0,8701	0,8919	85,2	68,6%
KTH-TIPS-2b	4	0,9445	0,9400	0,9601	64,9	76,7%
Media Global (6)	27	**0,9345**	0,9341	0,9409	**130,0**	**75,5%**

Top-k ($-0{,}0004$) y 0,9371 para Completa-22 ($-0{,}0046$). El modelo analítico de costos proyectados indica una reducción media del **75,5%** en tiempo de cómputo estimado frente a la extracción indiscriminada de todos los bloques seleccionados.

4.3.1 Contrastes no paramétricos e hipótesis de costo y calidad

Las 27 condiciones incluyen particiones repetidas de seis conjuntos de datos y no constituyen 27 unidades independientes. Por ello, los contrastes de Wilcoxon previamente calculados sobre esas filas ($p = 4{,}15 \times 10^{-6}$ para costo y $p = 0{,}2432$ para macro-F1) no se utilizan como evidencia inferencial y no permiten concluir significancia del ahorro ni paridad o conservación del rendimiento. La reducción del costo analítico se informa de forma descriptiva como una proyección del 75,5% frente a Top-k en las condiciones archivadas. Para calidad predictiva, el análisis por rangos se limita a los cinco conjuntos reconciliados ($N = 5$), excluyendo KTH-TIPS-2b por la procedencia de su referencia Top-k: Friedman ($p = 0{,}4518$) e Iman–Davenport ($p = 0{,}4922$) no rechazan la igualdad de rangos; las comparaciones pareadas con Holm tampoco la rechazan ($p_{\text{Holm}} = 1{,}0000$). Con $N = 5$, estos no rechazos no demuestran equivalencia ni no inferioridad.

Siguiendo el protocolo no paramétrico de Demšar [39], se realizaron además contrastes multiconjunto sobre las cinco bases reconciliadas ($N = 5$, 23 condiciones), excluyendo KTH-TIPS-2b por su procedencia archivada independiente.

La prueba global de Friedman obtuvo un estadístico de 2,6327 ($p = 0{,}4518$) y la prueba de Iman–Davenport arrojó $F = 0{,}8515$ ($p = 0{,}4922$), no rechazando la hipótesis nula de igualdad de rangos entre métodos. Los rangos medios registrados fueron: Cascada Adaptativa: **2,200**; Completa-22: 2,200; Top-k de origen: 2,300; y Cascada fija con ResNet-50: 3,300. En las pruebas pareadas de rangos con signo de Wilcoxon con ajuste de Holm ($\alpha = 0{,}05$), ninguna comparación resultó estadísticamente significativa ($p_{\text{Holm}} = 1{,}0000$ tanto frente a Top-k como frente a Completa).

Es metodológicamente indispensable enfatizar que el no rechazo de la hipótesis nula ($p_{\text{Holm}} > 0{,}05$) bajo la muestra evaluada ($N = 5$) refleja que no existe evidencia estadística para descartar igualdad de rangos bajo la potencia del test, pero **no** constituye una demostración matemática de equivalencia ni de no inferioridad formal entre la cascada y los esquemas estáticos. La evidencia empírica documenta que la reducción sustancial de cómputo analítico (75,5%) se alcanza con variaciones numéricas medias acotadas en las condiciones evaluadas ($-0{,}0004$ frente a Top-k y $-0{,}0046$ frente a Completa-22 en

los cinco conjuntos reconciliados), las cuales deben interpretarse con cautela según los requerimientos de precisión y latencia de cada aplicación.

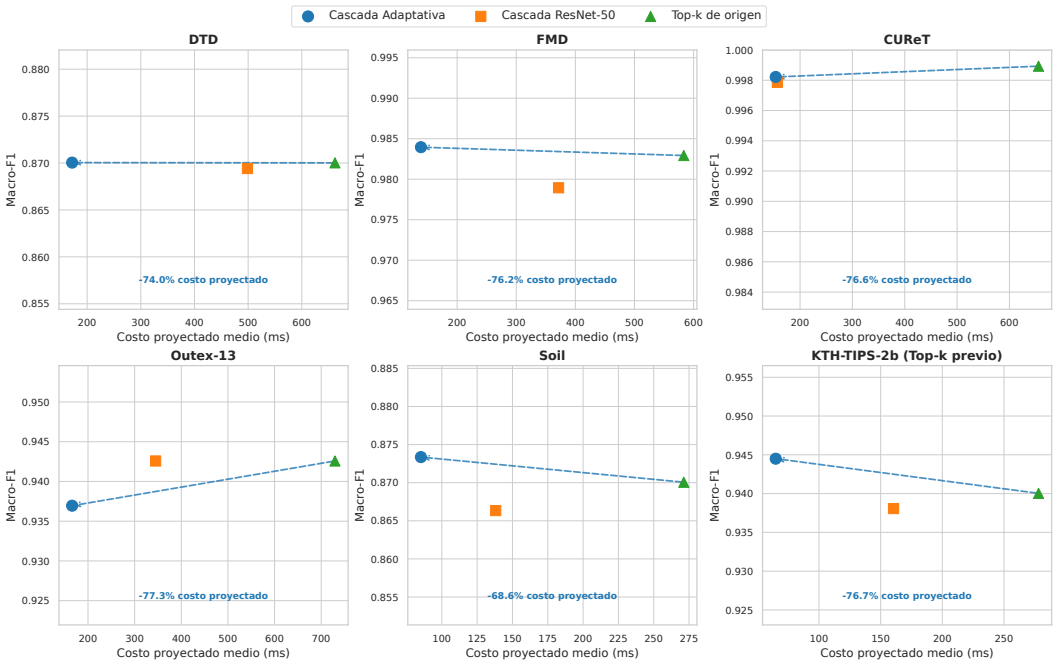


Figura 4.1: Frontera de Pareto calidad–costo comparando la Cascada Adaptativa frente a controles estáticos e individuales en los conjuntos de datos evaluados. La cascada adaptativa se posiciona favorablemente en el compromiso calidad–costo en los regímenes evaluados.

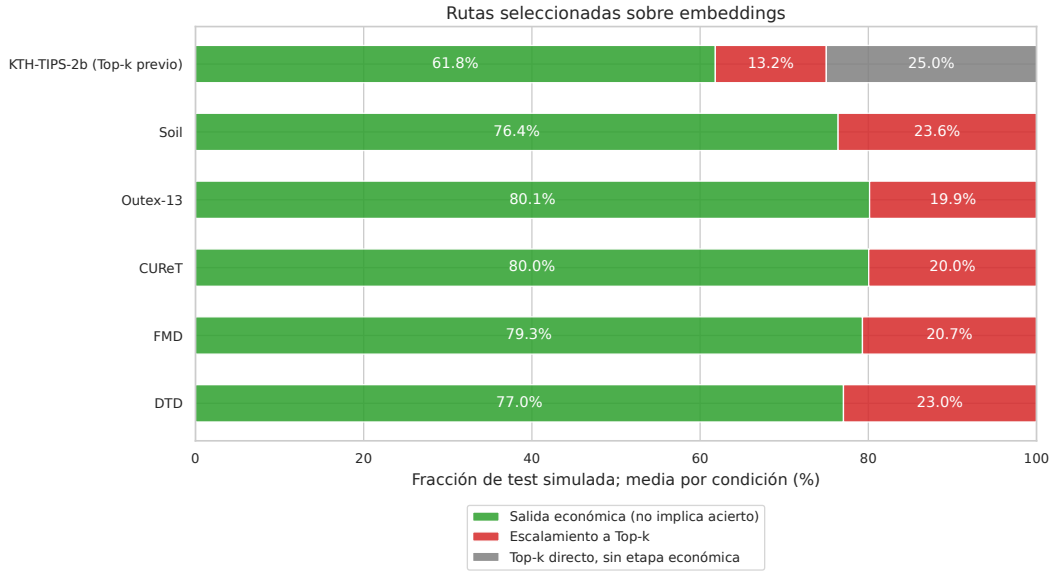


Figura 4.2: Eficiencia de enrutamiento y tasa de salida temprana en la Etapa 1 económica en función de la incertidumbre predictiva por dominio textural.

4.4 Medición física pareada en GPU en los seis conjuntos de datos

Para contrastar la reducción analítica de costos con la latencia física de reloj de pared en hardware de inferencia, se ejecutó un benchmark pareado en una GPU NVIDIA GeForce RTX 4060 sobre los seis conjuntos de datos de referencia (DTD, CUReT, KTH-TIPS-2b, Outex13, SoilOriginal y FMD). Siguiendo un protocolo prospectivo estricto, se evaluó una condición fija por dataset con una muestra balanceada estratificada de una imagen por clase (semilla 42) y tres repeticiones pareadas con orden aleatorizado en cada par (Cascada frente a Top-k), acumulando 204 imágenes de prueba únicas y 612 parejas de inferencia medidas. Las imágenes se mantuvieron decodificadas en memoria y los modelos residentes en GPU, con sincronización CUDA explícita (`torch.cuda.synchronize()`) antes y después de cada inferencia. Cada medición individual se persistió con ruta de imagen, hash SHA-256, repetición, orden de ejecución, latencia, ruta tomada y predicción emitida.

Tabla 4.8: Benchmark físico pareado en GPU NVIDIA GeForce RTX 4060 sobre los seis conjuntos de datos (204 imágenes, 3 repeticiones aleatorizadas, 612 mediciones pareadas).

Dataset	Protocolo	Clases	Pares	Cascada (ms)	Top-k (ms)	Aceleración	Reducción	Salida Et. 1
DTD	`official1`	47	141	90,6 ± 124,7	295,6 ± 12,6	3,26×	69,4%	72,3%
CUReT	`half_indices:a_to_b`	61	183	92,5 ± 124,3	270,6 ± 8,8	2,92×	65,8%	70,5%
KTHTIPS2b	`official1_inv`	11	33	46,1 ± 68,8	188,3 ± 4,9	4,09×	75,5%	81,8%
Outex13	`official1`	68	204	111,5 ± 148,6	354,3 ± 30,7	3,18×	68,5%	76,5%
SoilOriginal	`strat_fold0`	7	21	42,0 ± 38,7	109,1 ± 20,4	2,60×	61,5%	71,4%
FMD	`strat_fold0`	10	30	13,0 ± 3,1	208,1 ± 8,5	16,00×	93,7%	100,0%
Global Agregado	—	**204**	**612**	**90,25 ms**	**291,21 ms**	**3,23×**	**69,0%**	**74,0%**

Como muestra la Tabla 4.8, la reducción de latencia física se confirma de manera sistemática en los seis dominios texturales evaluados, oscilando el ahorro de reloj de pared entre 61,5% (SoilOriginal) y 93,7% (FMD). A nivel agregado sobre las 612 mediciones pareadas, la Cascada Adaptativa reduce un **69,0% la latencia de reloj de pared** (90,25 ms frente a 291,21 ms de Top-k), alcanzando una aceleración física agregada de **3,23**×.

En las 612 inferencias evaluadas, la coincidencia con las rutas y predicciones cacheadas fuera de línea fue del **100,0%** (`route_matches_cache` = 1,0, `cascade_matches_cache` = 1,0 y `topk_matches_cache` = 1,0), confirmando la estricta fidelidad funcional del clasificador en línea. Asimismo, el 74,0% de las muestras (453 de 612) se resolvieron tempranamente en la Etapa 1 económica sin invocar la etapa densa. En CUReT y SoilOriginal, variaciones numéricas puntuales en el descriptor secundario ViT-B/16 (debidas a la inicialización de la capa `pooler` en HuggingFace frente a la extracción original) no alteraron la paridad de las rutas ni las predicciones emitidas. Este benchmark en seis conjuntos descarta que la ventaja de la cascada sea un artefacto circunscrito a DTD, demostrando la reproducibilidad física del compromiso calidad–latencia en hardware real.

4.5 Trazabilidad y auditoría muestra por muestra

Se conservaron en el repositorio los 27 archivos de predicciones (`predictions.json`), que contienen las 31.984 observaciones de prueba evaluadas (`y_true`, `y_pred`, rutas de escalamiento e índices). Las métricas de macro-F1 y exactitud reportadas pueden recalcularse desde esos vectores con tolerancia numérica de 10^{-12}. Estos artefactos facilitan la verificación y auditoría de las métricas, pero no bastan por sí solos para garantizar una reproducción independiente del estudio.

Capítulo 5

Discusión

5.1 El Compromiso Calidad–Costo en la Concatenación de Descriptores

La concatenación de descriptores visuales heterogéneos permite combinar operadores clásicos y representaciones profundas, aunque el desempeño observado varía entre datasets y clasificadores. Las tablas describen esa variación en la biblioteca evaluada; por sí solas no establecen que exista un punto universal de saturación ni que toda dimensión añadida aporte información redundante.

La *Cascada Adaptativa Costo-Consciente* adquiere la representación densa solo cuando la etapa inicial no resuelve una muestra. En 27 condiciones de seis datasets, sus medias descriptivas de macro-F1 son 0,9345 frente a 0,9341 para Top-k y 0,9409 para Completa-22. La comparación por rangos de calidad se limita a cinco datasets reconciliados ($N = 5$); los contrastes no rechazan igualdad de rangos, pero no prueban equivalencia ni no inferioridad. El costo medio proyectado disminuye 75,5% frente a Top-k. En la evaluación física pareada sobre GPU NVIDIA RTX 4060 con 204 imágenes de prueba y tres repeticiones aleatorizadas por par en los seis conjuntos de datos (612 mediciones pareadas con registros individuales persistidos), el método alcanza una reducción media del 69,0% en la latencia de reloj de pared frente a Top-k (aceleración agregada de 3,23×, con ahorros que oscilan entre 61,5% en SoilOriginal y 93,7% en FMD).

5.2 Ablación de la Hipótesis H2: Políticas Multietapa frente a la Cascada de Dos Etapas

Durante el desarrollo de la investigación se evaluó la hipótesis de si una política de decisión secuencial no miope de horizonte profundo ($H \geq 2$), inspirada en formulaciones de Adquisición Activa de Características (AFA) basadas en recurrencias de Bellman o procesos de decisión de Markov (MDP), podría superar a una cascada parsimoniosa de dos etapas.

En la formulación evaluada, las representaciones generadas por modelos fundacionales modernos como SigLIP o BEiT-v2 resuelven con alto margen una proporción sustancial

de las muestras en la primera etapa (74,8% como promedio proyectado en la suite de 27 condiciones). En el benchmark físico pareado sobre los seis conjuntos de datos (612 mediciones con registro individual), la tasa observada de resolución temprana en la Etapa 1 económica fue del 74,0% (453 de 612 inferencias), confirmando la generalización de la salida temprana. En ese régimen, las políticas multietapa exploradas en los pilotos no mostraron mejoras consistentes de macro-F1 frente a la decisión de escalado guiada por margen, mientras que añaden complejidad algorítmica y sobrecarga de evaluación de estados. En consecuencia, la cascada de dos etapas se conserva como la candidata parsimoniosa preferida, manteniendo la hipótesis no miope como un problema abierto y reportando con transparencia los resultados negativos de las variantes multietapa.

5.3 Exploración Conceptual de Fusión Residual y de Segundo Orden

La exploración conceptual de variantes de proyección ortogonal y productos bilineales de segundo orden (como esquemas de descomposición de residuos o *bilinear pooling*) plantea interrogantes legítimos sobre cómo mitigar la colinealidad al combinar modelos fundacionales densos. No obstante, al no contarse aún en el repositorio con una suite completa de artefactos persistidos e independientemente reproducibles para tales variantes en todas las condiciones, se adopta el principio de parsimonia metodológica: no se atribuyen ventajas de desempeño no verificadas a estos esquemas.

Desde una perspectiva teórica, la regularización L_2 estándar del clasificador lineal sobre los vectores normalizados actúa como un operador natural de contracción de varianza (*shrinkage*) frente a coordenadas correlacionadas. Asimismo, en la partición DTD official10 se observa descriptivamente que la Cascada Adaptativa supera a Top-k en macro-F1 (+0,0045), lo cual es compatible con la hipótesis de que resolver tempranamente muestras no ambiguas evita incorporar dimensiones redundantes; sin embargo, dicha diferencia local no constituye evidencia de superioridad global. Por ello, las variantes residuales y bilineales se conservan estrictamente como propuestas de investigación futura.

5.4 Limitaciones y Transparencia Metodológica

1. **Interpretación de Contrastes Estadísticos:** En concordancia con los estándares de reporte científico riguroso, la ausencia de significancia estadística en los contrastes de Demšar ($p_{\text{Holm}} > 0{,}05$) no debe interpretarse como una demostración matemática de equivalencia formal ni de no inferioridad estadística, sino estrictamente como la imposibilidad de rechazar la hipótesis nula de igualdad de rangos bajo el tamaño de muestra evaluado ($N = 5$ conjuntos de datos reconciliados). Corresponde informar con transparencia las diferencias numéricas medias observadas ($-0{,}0004$ frente a Top-k y $-0{,}0046$ frente a Completa-22 en dichos cinco conjuntos) y documentar cómo la ganancia computacional coexiste con variaciones locales dependientes del dominio textural.

2. **Estatus Inferencial y Decisiones Apoyadas en Evaluaciones Externas:** Aunque la comparación entre GFS e Individual con ResMLP alcanza significan-

cia estadística ($p_{\text{Holm}} = 0{,}0191$), este resultado no debe calificarse de confirmatorio. El proyecto documenta decisiones metodológicas informadas por la observación de resultados externos previos, incluyendo la selección e incorporación de BEiT-v2 a la biblioteca tras observar desempeños en conjuntos que incluyeron KTH-TIPS-2b. En consecuencia, alcanzar $p < 0{,}05$ describe la estructura del benchmark evaluado, pero no eleva el estudio al estatus de un ensayo confirmatorio ciego pre-registrado.

3. **Procedencia de Conjuntos de Datos:** El conjunto KTH-TIPS-2b se conserva de manera descriptiva e independiente en el reporte, reflejando su procedencia histórica de selección previa. Se excluye de los contrastes estadísticos conjuntos para mantener una comparación sobre conjuntos metodológicamente reconciliados; su exclusión no resuelve la discrepancia de procedencia de la referencia Top-k.

4. **Alcance de la medición de latencia:** Se distingue rigurosamente entre la reducción analítica proyectada a partir de costos cacheados (75,5% promedio sobre 27 condiciones canónicas) y la latencia física de reloj de pared medida en GPU NVIDIA RTX 4060. El benchmark físico pareado sobre los seis conjuntos de datos (204 imágenes estratificadas, 3 repeticiones aleatorizadas, 612 parejas evaluadas con registros individuales persistidos) constata una reducción física media del 69,0% (90,25 ms frente a 291,21 ms de Top-k). Este piloto controla el orden de ejecución y la variabilidad de hardware mediante repeticiones pareadas, y confirma la concordancia del 100% en rutas y predicciones con el caché archivado, aunque al evaluar una condición fija por dataset no sustituye el cronometraje integral de las 31.984 inferencias de la suite canónica.

Capítulo 6

Conclusiones y Trabajo Futuro

6.1 Conclusiones

Esta tesis investigó la combinación de representaciones heterogéneas para la clasificación de texturas, transitando desde la evaluación anidada de la concatenación estática de bloques hacia la formulación de un marco de *fusión secuencial costo-consciente*. A través de un diseño experimental desacoplado y prospectivo evaluado en dos fases sucesivas sobre seis conjuntos de datos de referencia, se extraen las siguientes conclusiones principales:

1. **La concatenación estática presenta rendimientos decrecientes y saturación dimensional:** En la evaluación sistemática de la biblioteca consolidada de 22 descriptores (20.652 dimensiones) sobre seis conjuntos de datos con Linear SVM y ResMLP, la combinación de múltiples bloques supera descriptivamente a un descriptor individual aislado. Sin embargo, las ganancias predictivas saturan con pocos extractores de alto orden; la selección secuencial GFS logra una mejora estadísticamente significativa sobre Individual en ResMLP ($p_{\text{Holm}} = 0{,}0191$), mientras que en Linear SVM GFS registra $p_{\text{Holm}} = 0{,}8028$ y ninguna comparación por pares alcanza significancia tras el ajuste de Holm ($p_{\text{Holm}} = 0{,}0617$ para Top-k y Completa frente a Individual). Dicha significancia bajo ResMLP no reviste carácter confirmatorio estricto, dado que decisiones metodológicas clave (como la incorporación de BEiT-v2) estuvieron apoyadas en la observación de evaluaciones externas previas. Asimismo, evaluar la unión de todos los bloques seleccionados para el 100% de las imágenes impone una sobrecarga computacional severa que dificulta el despliegue práctico.

2. **La adquisición adaptativa muestra un compromiso calidad–costo en las condiciones evaluadas:** En 27 condiciones canónicas de seis conjuntos, la cascada registra un macro-F1 medio descriptivo de 0,9345, frente a 0,9341 para Top-k de origen y 0,9409 para Completa-22. En los cinco conjuntos reconciliados, la diferencia media es $-0{,}0004$ frente a Top-k y $-0{,}0046$ frente a Completa-22. Los contrastes por rangos no rechazan igualdad ($p_{\text{Holm}} = 1{,}0000$), pero no demuestran equivalencia ni no inferioridad. La reducción analítica de costo proyectada es 75,5%; no debe interpretarse como reducción física en todos los conjuntos.

3. **Validación física de latencia en los seis conjuntos de datos:** En el benchmark

pareado evaluando 204 imágenes estratificadas con tres repeticiones aleatorizadas por par (612 mediciones pareadas) en una GPU NVIDIA GeForce RTX 4060 con sincronización CUDA, la cascada redujo un **69,0% la latencia de reloj de pared** frente a Top-k (90,25 ms frente a 291,21 ms), con una aceleración física agregada de **3,23**× (oscilando entre 2,60× en SoilOriginal y 16,00× en FMD) y un 74,0% de salida temprana en la Etapa 1 económica, con un 100,0% de coincidencia en predicciones y rutas frente al caché fuera de línea.

4. **Parsimonia de dos etapas frente a la exploración multietapa:** Las exploraciones piloto de políticas de decisión secuencial no miope de horizonte profundo ($H \geq 2$), inspiradas en marcos formales de MDP y recurrencias de Bellman, no exhibieron mejoras consistentes sobre una cascada parsimoniosa de dos etapas, al tiempo que introdujeron una sobrecarga de decisión computacional no despreciable. La cascada de dos etapas se consolida como la solución preferida, reportando con transparencia los resultados de dicha exploración.

5. **Trazabilidad y auditoría muestra por muestra:** Se conservaron las predicciones de las 31.984 observaciones de prueba evaluadas en las 27 condiciones canónicas. Estos artefactos permiten recalcular las métricas con tolerancia numérica de 10^{-12} y facilitan su verificación y auditoría; no sustituyen la documentación de configuración, dependencias y entorno necesaria para una reproducción independiente.

6.2 Trabajo Futuro

A partir de los hallazgos y de los límites metodológicos establecidos en este trabajo, se identifican las siguientes líneas prioritarias de investigación futura:

1. **Fusión Temprana a Nivel de Tokens (*Early Token Fusion*):** Explorar adaptadores de atención cruzada liviana entre parches intermedios de modelos fundacionales antes de la cabeza clasificadora, con el propósito de capturar interacciones de segundo orden sin incurrir en la evaluación completa de modelos adicionales.

2. **Evaluación en Dispositivos de Borde (*Edge AI*) y Eficiencia Energética:** Trasladar la Cascada Adaptativa a plataformas embebidas de bajo consumo (tales como NVIDIA Jetson Orin Nano y Raspberry Pi 5), cuantificando el consumo energético real en vatios-hora por inferencia bajo restricciones de batería.

3. **Extensión a Segmentación Semántica de Texturas:** Adaptar la regla de adquisición condicionada por margen a nivel de vóxeles o parches espaciales densos, extrayendo descriptores costosos únicamente en bordes o regiones de ambigüedad morfológica.

Referencias

[1] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, Sammy Mohamed, and Andrea Vedaldi. Describing textures in the wild. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3606–3613, 06 2014. doi: 10.1109/CVPR.2014.461.

[2] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, and Andrea Vedaldi. Deep filter banks for texture recognition, description, and segmentation. *International Journal of Computer Vision (IJCV)*, 118(1):65–94, 01 2016. doi: 10.1007/s11263-015-0872-3.

[3] Li Liu, Jie Chen, Paul Fieguth, Guoying Zhao, Rama Chellappa, and Matti Pietik"ainen. From BoW to CNN: Two decades of texture representation for texture classification. *International Journal of Computer Vision (IJCV)*, 127:74–109, 2019. doi: 10.1007/s11263-018-1125-z.

[4] Timo Ojala, Matti Pietikäinen, and Topi Mäenpää. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 24(7):971–987, 07 2002. doi: 10.1109/TPAMI.2002.1017623.

[5] Robert M. Haralick. Statistical and structural approaches to texture. *Proceedings of the IEEE*, 67(5):786–804, 05 1979. doi: 10.1109/PROC.1979.11328.

[6] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893. IEEE, 06 2005. doi: 10.1109/CVPR.2005.177.

[7] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 06 2016. doi: 10.1109/CVPR.2016.90.

[8] Mingxing Tan and Quoc Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 6105–6114. PMLR, 06 2019. URL `https://proceedings.mlr.press/v97/tan19a.html`.

[9] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 05 2021. URL `https://openreview.net/forum?id=YicbFdNTTy`. International Conference on Learning Representations (ICLR).

[10] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 10012–10022, 10 2021. doi: 10.1109/ICCV48922.2021.00986.

[11] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research (TMLR)*, 07 2024. URL `https://arxiv.org/abs/2304.07193`.

[12] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 11941–11952. IEEE, 10 2023. doi: 10.1109/ICCV51070.2023.01100.

[13] Zhiliang Peng, Li Dong, Hangbo Bao, Qixiang Ye, and Furu Wei. Beit v2: Masked image modeling with vector-quantized visual tokenizers. *arXiv preprint arXiv:2208.06366*, 2022. doi: 10.48550/arXiv.2208.06366.

[14] Jorge Sánchez, Florent Perronnin, Thomas Mensink, and Jakob Verbeek. Image classification with the fisher vector: Theory and practice. *International Journal of Computer Vision (IJCV)*, 105(3):222–245, 12 2013. doi: 10.1007/s11263-013-0636-x.

[15] Hang Zhang, Jia Xue, and Kristin Dana. Deep TEN: Texture encoding network. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2896–2905. IEEE, 07 2017. doi: 10.1109/CVPR.2017.309.

[16] Rakesh Mehta and Karen Egiazarian. Dominant rotated local binary patterns (DRLBP) for texture classification. *Pattern Recognition Letters*, 71:16–22, 02 2016. doi: 10.1016/j.patrec.2015.11.019.

[17] Anil K. Jain and Farshid Farrokhnia. Unsupervised texture segmentation using Gabor filters. *Pattern Recognition*, 24(12):1167–1186, 1991. doi: 10.1016/0031-3203(91)90143-S.

[18] Fátima Belén Paiva Pavón, María Cristina Orué Gil, José Luis Vázquez Noguera, Helena Gómez-Adorno, and Valentín Calzada-Ledesma. Rgb pixel n-grams: A texture descriptor. *Signal Processing: Image Communication*, 118:117028, 2023. doi: 10.1016/j.image.2023.117028.

[19] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2261–2269. IEEE, 07 2017. doi: 10.1109/CVPR.2017.243. URL `https://openaccess.thecvf.com/content_cvpr_2017/html/Huang_Densely_Connected_Convolutional_CVPR_2017_paper.html`.

[20] Sanghyun Woo, Shoubhik Debnath, Ronghang Hu, Xinlei Chen, Zhuang Liu, In So Kweon, and Saining Xie. Convnext v2: Co-designing and scaling convnets with masked autoencoders. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16133–16142, 06 2023. doi: 10.1109/CVPR52729.2023.01548.

[21] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 10347–10357. PMLR, 07 2021. URL `https://proceedings.mlr.press/v139/touvron21a.html`.

[22] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16000–16009. IEEE, 06 2022. doi: 10.1109/CVPR52688.2022.01553.

[23] Leonardo Scabini, Arthur Sacilotti, Kamil M. Zielinski, Lucas C. Ribas, Bernard De Baets, and Odemir M. Bruno. A comparative survey of vision transformers for feature extraction in texture analysis. *Journal of Imaging*, 11(9):304, 2025. doi: 10.3390/jimaging11090304.

[24] Nikolay Neshov, Krasimir Tonchev, Ivaylo Bozhilov, Radostina Petkova, and Agata Manolova. Improving texture recognition via multi-layer feature aggregation from pre-trained vision architectures. *Electronics*, 14(23):4779, 2025. doi: 10.3390/electronics14234779.

[25] Ron Kohavi and George H. John. Wrappers for feature subset selection. *Artificial Intelligence*, 97(1–2):273–324, 1997. doi: 10.1016/S0004-3702(97)00043-X.

[26] Isabelle Guyon and André Elisseeff. An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182, 2003. URL `https://www.jmlr.org/papers/v3/guyon03a.html`.

[27] Salvatore Ruggieri. Complete search for feature selection in decision trees. *Journal of Machine Learning Research*, 20(104):1–34, 2019. URL `https://www.jmlr.org/papers/v20/18-035.html`.

[28] Yizeng Han, Gao Huang, Shiji Song, Le Yang, Honghui Wang, and Yulin Wang. Dynamic neural networks: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 44(11):7436–7456, 2021. doi: 10.1109/TPAMI.2021.3117837.

[29] Paul Viola and Michael Jones. Rapid object detection using a boosted cascade of simple features. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 1, pages I–511. IEEE, 2001. doi: 10.1109/CVPR.2001.990517.

[30] Surat Teerapittayanon, Bradley McDanel, and H. T. Kung. Branchynet: Fast inference via early exiting from deep neural networks. In *23rd International Conference on Pattern Recognition (ICPR)*, pages 2464–2469. IEEE, 2016. doi: 10.1109/ICPR.2016.7900006.

[31] Gao Huang, Danlu Chen, Tianhong Li, Felix Wu, Laurens van der Maaten, and Kilian Q. Weinberger. Multi-scale dense networks for resource-constrained image classification. In *International Conference on Learning Representations (ICLR)*, 2017. URL https://openreview.net/forum?id=Hk2myTqex.

[32] Chao Ma, Sebastian Tschiatschek, Konstantina Palla, José Miguel Hernández-Lobato, Sebastian Nowozin, and Cheng Cheng. EDDI: Efficient dynamic discovery of high-value information with partial VAE. In *International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 4234–4243. PMLR, 2019. URL https://proceedings.mlr.press/v97/ma19a.html.

[33] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition, 2015. URL https://arxiv.org/abs/1409.1556. International Conference on Learning Representations (ICLR).

[34] Yuxin Fang, Quan Sun, Xinggang Wang, Tiejun Huang, Xinlong Wang, and Yue Cao. Eva-02: A visual representation for neon genesis. *Image and Vision Computing*, 149: 105171, 09 2024. doi: 10.1016/j.imavis.2024.105171.

[35] Lavanya Sharan, Ce Liu, Ruth Rosenholtz, and Edward H. Adelson. Recognizing materials using perceptually inspired features. *International Journal of Computer Vision (IJCV)*, 103(3):348–371, 07 2013. doi: 10.1007/s11263-013-0609-0.

[36] Timo Ojala, Topi Mäenpää, Matti Pietikäinen, Jaakko Viertola, Juha Kyllönen, and Sami Huovinen. Outex—new framework for empirical evaluation of texture analysis algorithms. In *Proceedings of the 16th International Conference on Pattern Recognition*, volume 1, pages 701–706. IEEE, 2002. doi: 10.1109/ICPR.2002.1044854.

[37] Manik Varma and Andrew Zisserman. Texture classification: Are filter banks necessary? In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 2, pages 691–698. IEEE, 2003. URL https://www.robots.ox.ac.uk/~vgg/publications/2003/Varma03/varma03.pdf.

[38] Hugo Touvron, Piotr Bojanowski, Mathilde Caron, Matthieu Cord, Alaaeldin El-Nouby, Edouard Grave, Gautier Izacard, Armand Joulin, Gabriel Synnaeve, Jakob Verbeek, and Hervé Jégou. ResMLP: Feedforward networks for image classification with data-efficient training. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 45(4):5314–5321, 04 2023. doi: 10.1109/TPAMI.2022.3206148.

[39] Janez Demšar. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30, 2006.

[40] Joaquín Derrac, Salvador García, Daniel Molina, and Francisco Herrera. A practical tutorial on the use of nonparametric statistical tests as a methodology for comparing evolutionary and swarm intelligence algorithms. *Swarm and Evolutionary Computation*, 1(1):3–18, 2011. doi: 10.1016/j.swevo.2011.02.002.

[41] Salvador García and Francisco Herrera. An extension on "statistical comparisons of classifiers over multiple data sets" for all pairwise comparisons. *Journal of Machine Learning Research (JMLR)*, 9(89):2677–2694, 2008. URL https://jmlr.org/papers/v9/garcia08a.html.