Universidad Nacional de Asunción

Facultad Politécnica

Fusión costo-consciente de descriptores de textura mediante ensambles y adquisición condicional

Carlos Ayala
Joaquín Delgado

Tutor: José Vázquez

Octubre 2026

Agradecimientos

A nuestro tutor, José Vázquez, por su guía y paciencia.
A la Facultad Politécnica de la UNA, por el espacio y los recursos.
A nuestras familias, por el apoyo incondicional.

Resumen

La fusión de descriptores para clasificar texturas plantea dos decisiones: qué representaciones combinar y para qué imágenes adquirirlas. Esta tesis compara cinco estrategias estáticas sobre 22 bloques y seis conjuntos de datos con SVM lineal y una MLP residual. También caracteriza una cascada de referencia y desarrolla una política de dos etapas que selecciona base, compuerta y rescate de ensamble bajo un presupuesto medio proyectado. El costo contabiliza la unión de bloques compartidos entre clasificadores, distinguiendo extractores, modelos únicos y votos.

El benchmark estático muestra que la estrategia de mayor macro-F1 depende del conjunto y del clasificador. En el piloto OOF sobre las 680 imágenes del entrenamiento oficial de Outex, la poda por ganancia de F1 en B60 obtiene macro-F1 0,910742 frente a 0,914389 del ensamble permanente, con costo proyectado 85,40% menor. Un control sobre predicciones guardadas distingue dos reducciones sucesivas: 69,76% por poda y 51,72% adicional al activar condicionalmente el mismo rescate podado, con una pérdida adicional de F1 de 0,001251. La compuerta no mejora F1 en las ocho configuraciones con rescate de ese piloto. El barrido incluye casos sin rescate y una excedencia.

Una réplica en tres semillas FMD y dos semillas adicionales Outex conserva los cuatro presupuestos y las tres reglas. En B60, relevancia alcanza macro-F1 medio 0,977489 frente a 0,974600 del rival estático presupuestado en FMD, y 0,905991 frente a 0,889152 en las nuevas semillas Outex, con menor adquisición media proyectada. FMD/42 favorece al estático en calidad y costo. La activación del mismo rescate mejora el F1 medio FMD/B60 y lo reduce en Outex. Por último, se completó un panel físico online sobre las 94 condiciones externas (362.640 llamadas individuales `batch=1` en GPU RTX 4060, midiendo macro-F1 y latencia física en la misma llamada) y se validaron y adaptaron cuatro métodos recientes de concatenación del estado del arte (`Neshov BEiT-v2` multicapa, *DeepLumina*, *HyTexNet* y *6LBP+dCellNN*). En el panel común estricto, nuestra política `Adaptive-selection-margin` supera en macro-F1 a los cuatro comparadores externos en los seis conjuntos de datos con latencias medias de 21,65 a 54,35 ms por imagen.

Palabras clave: clasificación de texturas, fusión de descriptores, selección de bloques, ensambles, adquisición condicional, inferencia costo-consciente.

Abstract

Texture descriptor fusion requires choosing both the representations to combine and the images for which they should be acquired. This thesis evaluates five static strategies over 22 descriptor blocks and six datasets using Linear SVM and a residual feature MLP. It also examines a reference cascade and develops a two-stage policy that selects a base, gate and ensemble rescue under a projected mean acquisition budget. Shared blocks are counted once, separating feature extractors, unique classifiers and repeated votes.

The static benchmark identifies no uniformly best strategy across datasets and classifiers. An out-of-fold pilot on the 680 official Outex training images attains macro-F1 0.910742 at B60 using F1-gain pruning, versus 0.914389 for the always-active ensemble, with an 85.40% lower projected cost. Replaying saved predictions separates a 69.76% reduction through pruning from a further 51.72% through conditional activation of the same rescue, which incurs an additional F1 loss of 0.001251. Routing improves F1 in none of that pilot's eight configurations with a rescue. Base-only policies and a validation budget exceedance remain in the sweep.

Five additional development conditions retain all four budgets and three routing rules: three FMD seeds and two further Outex seeds. At B60, relevance pruning attains mean macro-F1 0.977489 versus 0.974600 for a budget-selected static ensemble on FMD, and 0.905991 versus 0.889152 on the new Outex seeds, with lower mean projected acquisition costs. The static control instead wins on both measures for FMD/42. Relative to the same permanent rescue, routing raises mean F1 on FMD/B60 and lowers it on Outex. Finally, a full physical online panel across all 94 external conditions (362,640 single-image `batch=1` calls on an RTX 4060 GPU measuring macro-F1 and wall-clock latency from the same calls) is compared against four state-of-the-art concatenation methods validated for code and formula fidelity (`Neshov BEiT-v2` multilayer, *DeepLumina*, *HyTexNet*, and *6LBP+dCellNN*). Across the common six-dataset panel, `Adaptive-selection-margin` outperforms all four external comparators in macro-F1 while achieving mean single-image latencies of 21.65 to 54.35 ms.

Keywords: texture classification, descriptor fusion, block selection, ensembles, conditional acquisition, cost-aware inference.

Siglas y notación

OOF	Predicciones fuera de pliegue del entrenamiento
CKA	Alineamiento centrado de kernels; similitud entre representaciones
GFS	Selección secuencial hacia delante de bloques
SVD	Descomposición en valores singulares truncada
SVM	Máquina de vectores de soporte; se emplea un clasificador lineal
Bloque	Vector producido por un extractor
Miembro	Clasificador sobre una concatenación de bloques
b, E, τ	Base, lista de miembros de rescate y umbral de margen
$U(E)$	Unión de los bloques utilizados por el rescate
$B, \widehat{C}$	Presupuesto y costo medio proyectado de adquisición
c_j, c_{pol}	Costo por bloque y sobrecosto fijado de política
P1, P2, P3	Preguntas de investigación, no identificadores de pliegues

Contenido

Siglas y notación **iv**

1 Introducción **1**

1.1 Problema y motivación 1

1.2 Objetivo y preguntas de investigación 1

1.3 Enfoque y alcance 2

1.4 Aportes y organización 2

2 Fundamentos y trabajos relacionados **4**

2.1 Representaciones y niveles de fusión 4

2.2 Selección estática de bloques 5

2.3 Ensambles, diversidad y selección de miembros 5

2.4 Adquisición bajo costo e inferencia condicional 5

2.5 Delimitación de la contribución evaluada 6

3 Método de fusión y adquisición condicional **7**

3.1 Bloques, miembros y política de adquisición 7

3.2 Generación del ensamble de subconjuntos 7

3.3 Puntuaciones y agregación 8

3.4 Base y compuerta 8

3.5 Costo compartido y presupuesto 9

3.5.1 Interpretación del costo de adquisición 9

3.6 Selección completa y poda del rescate 10

3.7 Referencias estáticas y cascada de comparación 13

4 Diseño experimental **14**

4.1 Evaluaciones y unidades de análisis 14

4.2 Datos, particiones y procedencia 14

4.3 Clasificadores y selección interna . . . 15
4.4 Piloto de rescate de ensamble . . . 16
4.4.1 Ablación del mismo rescate con y sin compuerta . . . 16
4.4.2 Control estático bajo presupuesto . . . 17
4.4.3 Réplica en FMD y semillas adicionales . . . 17
4.5 Métricas y agregación . . . 18
4.6 Medición física de la cascada de referencia . . . 18
4.7 Panel físico online completo (94 condiciones) y comparadores del estado del arte . . . 19
4.8 Análisis estadístico . . . 20

5 Resultados experimentales 21
5.1 P1: selección y dimensionalidad . . . 21
5.2 Contrastes de la selección estática . . . 22
5.2.1 Sensibilidad a la exclusión de KTH . . . 23
5.3 P2: adquisición condicional en 27 condiciones . . . 23
5.4 Pilotos físicos de la cascada histórica . . . 24
5.5 P3: rescate de ensamble en desarrollo Outex . . . 25
5.5.1 Separación de poda y activación condicional . . . 26
5.5.2 Comparación con selección estática bajo presupuesto . . . 27
5.6 Réplica del rescate en dos datasets . . . 28
5.7 Panel físico online completo (94 condiciones) y comparación con el estado del arte . . . 29
5.7.1 Validación de fidelidad de ecuaciones, código y protocolos publicados 30
5.7.2 Comparación cabeza a cabeza en el panel común de seis datasets . 31

6 Discusión y amenazas a la validez 33
6.1 Qué aporta seleccionar bloques . . . 33
6.2 Qué cambia con adquisición condicional . . . 33
6.3 Poda, diversidad y enrutamiento . . . 34
6.4 Interpretación de presupuesto y costo . . . 35
6.5 Amenazas a la validez . . . 36
6.5.1 Selección y exposición . . . 36
6.5.2 Dependencia y procedencia . . . 36
6.5.3 Fidelidad y generalización . . . 36

7 Conclusiones y trabajo futuro **37**
7.1 Respuestas a las preguntas de investigación 37
7.2 Limitaciones y trabajo futuro 38

A Especificaciones de representación y selección **39**
A.1 Espacio de descriptores 39
A.2 Greedy Forward Selection 41
A.3 Perfil numérico de costos del piloto 42

B Protocolos y variantes de referencia **43**
B.1 Separación de evaluaciones 43
B.2 Procedencia de KTH 43
B.3 Fidelidad de los pilotos físicos 43
B.4 Particiones y multiplicidades del piloto híbrido 44
B.5 Figuras de la cascada de referencia 44

C Resultados secundarios y variabilidad **46**
C.1 Exactitud y dispersión del benchmark estático 46
C.2 Rankings y contrastes completos por clasificador 47
C.2.1 Sensibilidad del benchmark sin KTH 48
C.2.2 Control emparejado de N-gramas 49
C.3 Barrido del control de poda y compuerta 49
C.4 Réplica del rescate por condición y regla 50
C.4.1 Activación del mismo rescate en la réplica 52
C.5 Alcance de las exploraciones secundarias 52

D Reproducibilidad y disponibilidad **53**
D.1 Materiales, procedencia y acceso 53
D.2 Comprobaciones registradas y alcance 53
D.3 Reconstrucción mínima y límites de entrega 54

Declaraciones **55**

Lista de figuras

3.1 Construcción de la política y especificación de su ejecución. La selección usa entrenamiento; la compuerta utiliza el margen de cada imagen, no su etiqueta. En el piloto las rutas se reconstruyen con puntuaciones guardadas y costos proyectados; no se cronometra esta ruta completa desde RGB. . 12

5.1 Políticas del piloto Outex y controles del mismo protocolo. Se muestran los cuatro presupuestos de cada variante, incluidos puntos coincidentes. El eje horizontal es costo proyectado en escala logarítmica, no latencia física; las líneas no representan una frontera óptima. 25

A.1 Mecanismo de Greedy Forward Selection sobre bloques completos. En cada paso se elige el bloque que maximiza el macro-F1 medio de la validación interna; el test externo se utiliza únicamente tras cerrar el subconjunto. . 41

B.1 Comparación histórica calidad–costo bajo su perfil analítico. No representa el rescate de diversidad ni una medición física de todas las rutas. 44

B.2 Enrutamiento de la cascada histórica según los artefactos archivados. Las proporciones no garantizan una tasa de salida para imágenes nuevas. . . 45

Lista de tablas

2.1 Antecedentes seleccionados y relación conceptual con el estudio. No es una clasificación de rendimiento ni una revisión sistemática exhaustiva. 6

3.1 Procedimiento de selección dentro de un entrenamiento productor. La validación productora no interviene en estos pasos. 11

3.2 Especificación de inferencia de la política seleccionada. El piloto la evalúa sobre puntuaciones guardadas; la ejecución física completa del híbrido no ha sido medida. 11

4.1 Cobertura efectiva de las evaluaciones. Las condiciones de cada conjunto se agregan antes de la inferencia entre datasets. 14

5.1 Macro-F1 externo de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial. . . . 21

5.2 Dimensión media de las representaciones usadas en la evaluación externa con 22 descriptores. 22

5.3 Sensibilidad del benchmark estático a excluir KTH archivado: seis datasets originales frente a los cinco restantes. Valores p SCI2S por clasificador; no son evaluaciones del híbrido. 23

5.4 Macro-F1 externo de la cascada histórica. Medias por dataset; KTH conserva la variante archivada, no una cascada reconciliada con el Top-k corregido. 24

5.5 Tiempos archivados de la cascada histórica y Top-k. Las discrepancias de representación se mantienen visibles; estos tiempos no miden el híbrido nuevo. 24

5.6 Controles del mismo piloto Outex: macro-F1 OOF sobre 680 imágenes de entrenamiento oficial y costo medio proyectado, no latencia física. 25

5.7 Piloto híbrido de Outex: macro-F1 OOF de desarrollo y costo proyectado. B es el presupuesto de selección en ms; los costos no son latencias físicas. 26

5.8 Control de poda y compuerta en relevancia/B60. Macro-F1 OOF sobre las mismas 680 imágenes; costo medio de adquisición proyectado y llamadas a clasificadores únicos por imagen. No son tiempos físicos. 27

5.9 Control estático optimizado dentro del pool visitado, con hasta tres miembros, frente al híbrido por relevancia bajo el mismo presupuesto. Macro-F1 OOF de desarrollo sobre 680 imágenes; C es adquisición media proyectada en ms. Δ es híbrido menos estático. 28

5.10 Réplica de desarrollo: media entre semillas nuevas de macro-F1 / costo proyectado (ms). El número entre paréntesis es el de semillas, no datasets independientes. B restringe el costo interno medio; no es el costo medido. Outex/42 no integra estas medias. 28

5.11 Panel local online completo (94 condiciones, 362.640 llamadas primarias). Se informa macro-F1 medio entre particiones y, entre paréntesis, latencia física media en ms por llamada individual (`batch=1`). 30

5.12 Auditoría de código oficial, pruebas de paridad matemática y validación en los protocolos de origen de los cuatro métodos externos de concatenación. 31

5.13 Comparación en el panel común (47 particiones base) entre los cuatro métodos externos de concatenación y nuestras políticas locales. Se reporta macro-F1 medio por condición y, entre paréntesis, latencia física media en ms por imagen (`batch=1`). 32

A.1 Seis descriptores basados en patrones, filtros, gradientes y conteos incluidos en la biblioteca. Cada fila constituye un bloque completo. 40

A.2 Representaciones aprendidas congeladas incluidas en la biblioteca (16 extractores profundos y de modelos fundacionales). “Preclas.” designa la salida inmediatamente anterior al clasificador del backbone. 40

A.3 Configuración de la selección GFS en el flujo general. 42

A.4 Constantes del perfil del piloto, en ms por imagen. Son parámetros archivados del modelo de costos, no tiempos medidos del híbrido. 42

B.1 Tamaños y modelos únicos del control de diversidad permanente en cada pliegue productor. No son nuevas réplicas ni 15 ejecuciones distintas por imagen. 44

C.1 Exactitud externa de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial. . . . 46

C.2 Desviación estándar descriptiva del macro-F1 entre condiciones externas del benchmark estático. No es error estándar ni intervalo de confianza; las condiciones comparten imágenes. El guion indica un único split. 46

C.3 Rankings medios de macro-F1 según Friedman, Friedman alineado y Quade con 22 descriptores. Seis datasets por clasificador; menor ranking indica mejor desempeño relativo dentro de cada prueba. 47

C.4 Pruebas globales por clasificador sobre cinco estrategias y seis datasets con la biblioteca de 22 descriptores. Nivel nominal $\alpha = 0{,}05$. 47

C.5 Comparaciones por pares basadas en rangos de Friedman. Holm corrige los diez pares dentro de cada clasificador. 48

C.6 Sensibilidad sin KTH: post-hoc de rangos de Friedman sobre cinco datasets. Holm corrige diez pares por clasificador. Son contrastes exploratorios, no Wilcoxon exactos. 49

C.7 Barrido completo del control de rescate fijo en desarrollo Outex. F1 es macro-F1 OOF; C es adquisición media proyectada en ms. Permanente utiliza el mismo rescate que la política condicional, sin reselección estática. 50

C.8 Barrido de la réplica por dataset/semilla: macro-F1 / costo proyectado (ms). Las tres reglas híbridas y el control estático mantienen los cuatro presupuestos. Las filas comparten imágenes; no representan dominios independientes. 51

C.9 Referencias del mismo desarrollo productor. Top-3/4/5 tienen tamaño fijo y no equivalen al Top-k heredado de GFS del benchmark. Costos proyectados, no latencias físicas. 51

C.10 Mismo rescate permanente frente a condicional en la réplica: macro-F1 / costo proyectado (ms), media de tres semillas FMD y dos Outex. La referencia permanente conserva los miembros seleccionados para la ruta condicional y no se reoptimiza bajo B. Incluye los casos sin rescate. . . . 52

Capítulo 1

Introducción

1.1 Problema y motivación

La clasificación de texturas utiliza propiedades locales, relaciones espaciales y representaciones aprendidas que responden de manera diferente a cambios de escala, iluminación y punto de vista [1–3]. Combinar descriptores amplía la información disponible para la clasificación, pero también requiere almacenar más coordenadas y ejecutar más operaciones de extracción.

La concatenación une bloques de características y ajusta un clasificador sobre el vector resultante. Un ensamble combina las salidas de varios clasificadores, cada uno entrenado sobre uno o más bloques. Reducir el número de miembros no necesariamente reduce el número de extractores, porque distintos miembros pueden compartir bloques. De manera recíproca, un vector corto no garantiza una extracción rápida. El costo depende de qué extractores se ejecutan y de cuáles pueden reutilizarse.

La adquisición condicional permite que una primera predicción determine si se necesitan características adicionales. Este principio tiene antecedentes en cascadas, inferencia dinámica y clasificación bajo presupuesto [4–6]. Para una biblioteca heterogénea de texturas, el problema consiste en decidir qué información adquirir y para qué imágenes hacerlo. Elegir únicamente el mejor descriptor global o un subconjunto estático no responde a la segunda decisión.

Esta tesis estudia una política de dos etapas: un clasificador base atiende todas las imágenes y una compuerta activa un rescate cuando su margen es bajo. El rescate combina clasificadores sobre subconjuntos de bloques. Su selección considera el costo de la unión de esos bloques, porque un extractor compartido puede reutilizarse entre miembros. La premisa de trabajo es que reducir el rescate y limitar su activación ofrecen dos mecanismos de control del costo que deben evaluarse por separado y en conjunto.

1.2 Objetivo y preguntas de investigación

El objetivo general es estudiar la fusión de descriptores de textura mediante selección de bloques y adquisición condicional, distinguiendo desempeño predictivo, dimensionalidad y costo de ejecución. Los objetivos específicos son comparar estrategias estáticas con una

biblioteca común; caracterizar una ruta de dos etapas frente a referencias estáticas; e implementar y evaluar en desarrollo la selección de una base, una compuerta y un rescate completo o podado de un ensamble de subconjuntos.

Estos objetivos se articulan en tres preguntas:

1. **P1:** ¿Cómo cambian la calidad y la dimensionalidad al seleccionar bloques frente a concatenar toda la biblioteca?
2. **P2:** ¿Qué compromiso calidad–costo permite una ruta de adquisición condicional?
3. **P3:** ¿Seleccionar conjuntamente un rescate reducido y su activación aporta ventajas frente a usar permanentemente el ensamble?

La evaluación responde a las dos primeras preguntas dentro de los protocolos observados y ofrece evidencia preliminar para la tercera. Un control sobre predicciones OOF guardadas compara exactamente el mismo rescate podado con y sin compuerta. Otro selecciona un ensamble estático bajo cada presupuesto dentro del pool disponible. Se distinguen así la atribución de componentes y la comparación competitiva, sin inferir optimalidad global ni sustituir una medición física.

1.3 Enfoque y alcance

La biblioteca principal contiene 22 bloques y 20.652 dimensiones nominales: cinco operadores clásicos, RGB N-gramas con descomposición en valores singulares truncada (SVD) y 16 extractores aprendidos congelados. El estudio estático incluye DTD, FMD, CUReT, Outex-TC-00013, SoilOriginal y KTH-TIPS-2b, con SVM lineal y una MLP residual sobre características.

Se distinguen tres evaluaciones: selección estática, una cascada de referencia con rescate Top-k y selección de un rescate de ensamble bajo presupuesto. El Capítulo 4 identifica las particiones y cobertura de cada una. No se atribuye al piloto nuevo la cobertura multiconjunto del benchmark anterior.

El rescate de ensamble se evaluó inicialmente con predicciones fuera de pliegue (OOF, *out-of-fold*) dentro del entrenamiento oficial de Outex, semilla 42. Una réplica posterior mantiene el procedimiento en FMD con semillas 42, 123 y 2026, y en Outex con 123 y 2026. No se evaluaron los tests externos de esas condiciones ni se midió físicamente el híbrido. Son dos datasets con semillas adicionales, no una validación del híbrido en los seis conjuntos del benchmark. Los benchmarks también influyeron en decisiones previas del proyecto. Por ello, el alcance es exploratorio y no una confirmación ciega preespecificada.

1.4 Aportes y organización

El trabajo aporta un benchmark con biblioteca común y un procedimiento de adquisición condicional por bloques compartidos. La implementación distingue votos, modelos únicos y extractores, y permite comparar poda y activación con un modelo de costos explícito. La ablación de rescate fijo identifica un ahorro adicional de adquisición proyectada por

activación condicional, con cambios predictivos que se informan por separado. El rival estático presupuestado permite examinar ese compromiso bajo recursos compatibles. La réplica en dos datasets examina su variación por semilla y conserva los casos desfavorables; otras familias de control y la medición física permanecen pendientes.

Los Capítulos 2–4 presentan antecedentes, método y diseño. Los Capítulos 5–7 desarrollan resultados, discusión y conclusiones. Los anexos reúnen especificaciones, procedencia y resultados secundarios.

Capítulo 2

Fundamentos y trabajos relacionados

2.1 Representaciones y niveles de fusión

Los descriptores clásicos resumen regularidades locales, gradientes, frecuencias o dependencias entre intensidades. LBP, GLCM, Gabor y HOG representan estas alternativas [7–10]. RGB Pixel N-grams incorpora secuencias de color [11]. Las redes preentrenadas permiten utilizar activaciones como características sin ajustar sus pesos al conjunto textural [12–14].

La fusión temprana concatena coordenadas antes de clasificar; la fusión de decisiones combina puntuaciones o predicciones de clasificadores. En esta tesis ambos niveles coexisten: cada miembro del ensamble recibe una concatenación y su salida se agrega con la de otros miembros. Esta distinción evita interpretar el número de miembros como el número de bloques extraídos.

Neshov et al. combinan representaciones de capas tempranas, intermedias y finales de redes preentrenadas y las clasifican mediante una MLP [15]. Su estudio motiva conservar información de distintos niveles y señala como trabajo futuro variantes comprimidas e integración mediante atención, proyecciones o compuertas. En una línea complementaria de concatenación estática, Simon y Uma (*DeepLumina*) concatenan activaciones `fc1000` de `ResNet-101` extraídas sobre la imagen RGB y sobre el canal de luminancia Y del espacio YIQ (2.000 dimensiones), clasificándolas con un esquema multiclase ECOC-SVM *sparse-random* [16]. Por su parte, Gupta et al. (*HyTexNet*) concatenan el vector global de `DenseNet-121` (1.024 dimensiones) con un descriptor estadístico local basado en el percentil 75 empírico de magnitudes vecinales (514 dimensiones, totalizando 1.538 dimensiones) antes de una cabeza MLP [17], mientras que Chang et al. (*6LBP+dCellNN*) fusionan mapas de contorno generados por una red neuronal celular dinámica (*dCellNN*) con patrones binarios locales en seis escalas (P, R) concatenadas en un histograma de 768 dimensiones [18]. A diferencia de estos cuatro enfoques —que extraen y concatenan todas sus ramas de manera fija para el 100% de las imágenes de prueba—, la adquisición estudiada en esta tesis opera en otro nivel: decide condicionalmente por imagen si basta un predictor base económico o si conviene ejecutar extractores adicionales y miembros de rescate.

Scabini et al. comparan 25 modelos ViT en ocho tareas de textura e incluyen un análisis de eficiencia [19]. Proponen estudiar agregación de características y configuraciones que

equilibren calidad y cómputo. Su distinción entre arquitecturas, preentrenamiento y régimen de ejecución justifica medir el costo físico de los bloques en lugar de deducirlo únicamente del nombre del modelo, así como reimplementar y evaluar los métodos de concatenación del estado del arte bajo exactamente las mismas particiones y en llamadas individuales (`batch=1`) cuando se comparan calidad predictiva y latencia física.

2.2 Selección estática de bloques

La selección *wrapper* valora subconjuntos con el propio clasificador [20, 21]. GFS añade secuencialmente el bloque que mejora el criterio interno. El ranking individual Top-k es más simple, pero no evalúa directamente el aporte de un bloque una vez presentes los anteriores. La comparación entre ambos examina composición del subconjunto, no solo su tamaño.

La selección estática fija una representación para todas las consultas. Puede reducir almacenamiento y extracción respecto de una concatenación completa, pero sigue ejecutando todos sus bloques para cada imagen. Su evaluación exige mantener la búsqueda dentro del entrenamiento. La observación posterior de benchmarks durante el desarrollo limita, además, la interpretación confirmatoria de futuras comparaciones.

2.3 Ensambles, diversidad y selección de miembros

Seleccionar modelos dentro de un ensamble tiene antecedentes distintos de seleccionar características. Caruana et al. añaden modelos según una métrica de validación; las selecciones repetidas modifican sus pesos [22]. Esta perspectiva permite distinguir la biblioteca de extractores del conjunto de clasificadores que los utiliza. En esta tesis, los candidatos son SVM sobre concatenaciones de bloques y la selección de miembros se integra con una decisión de adquisición por imagen.

La generación de subconjuntos utiliza relevancia individual y CKA lineal (*centered kernel alignment*), una medida de comparación entre representaciones [23]. Se calcula sobre las mismas imágenes de entrenamiento. Su reducción se emplea como heurística, no como demostración de independencia de errores ni garantía de mejora predictiva.

Poda y adquisición condicional actúan en niveles distintos. La primera reduce los miembros disponibles; la segunda decide para qué imágenes ejecutarlos. Un compromiso favorable puede originarse en cualquiera de esas decisiones. Para atribuir una diferencia al enrutamiento se necesita el mismo ensamble podado siempre activo.

2.4 Adquisición bajo costo e inferencia condicional

El método *The Greedy Miser* incorpora el costo de extracción durante el aprendizaje mediante regresión por etapas [24]. Muestra que la calidad predictiva y el costo de obtener características pueden intervenir en un mismo procedimiento de selección. El presente estudio utiliza un conjunto finito de representaciones congeladas y clasificadores lineales, con costo compartido entre los miembros seleccionados.

Las cascadas asignan trabajo adicional según decisiones intermedias [4]. Nan y Saligrama aprenden una compuerta y un predictor económico para limitar el uso de un modelo costoso [6]. Aquí se utiliza un umbral de margen y un rescate compuesto por SVM sobre bloques compartidos; no se reproduce su optimización conjunta.

EDDI combina un modelo generativo parcial con una adquisición basada en ganancia de información esperada [25]. El método estudiado no estima esa cantidad: restringe la política a una base y un rescate seleccionado.

Las salidas tempranas de redes, como BranchyNet, reutilizan cómputo dentro de una arquitectura [26]. Este sistema trabaja con extractores independientes; su costo depende de la unión de bloques adquiridos. La diferencia de implementación requiere medición propia y no implica superioridad frente a redes dinámicas [5].

Tabla 2.1: Antecedentes seleccionados y relación conceptual con el estudio. No es una clasificación de rendimiento ni una revisión sistemática exhaustiva.

Antecedente	Decisión principal	Relación y diferencia relevante
Wrappers/GFS	Subconjunto estático	Selección de bloques sin activación por imagen
Concatenación multicapa / híbrida [15–18]	Fusión estática de capas o ramas heterogéneas	Extrae siempre todas las ramas concatenadas en cada imagen
Selección de ensambles [22]	Miembros y pesos	Reducción del ensamble; no equivale a adquirir sus bloques
Greedy Miser [24]	Aprendizaje con costo de extracción	Predictor y optimización diferentes
Clasificación adaptativa [6]	Compuerta y predictor económico	Antecedente de utilización condicional de un modelo costoso
EDDI [25]	Adquisición por información esperada	Modelo generativo y criterio distintos del margen

2.5 Delimitación de la contribución evaluada

La selección estática determina qué información queda disponible para todas las imágenes; la política condicional añade una decisión sobre cuándo adquirirla. En el sistema estudiado, la búsqueda relaciona calidad interna, composición del rescate y costo de la unión de bloques. Dos miembros pueden añadir votos sin requerir dos extracciones de una representación compartida, mientras que retirar un miembro puede no eliminar ningún extractor si sus bloques siguen presentes en otros.

La Tabla 2.1 delimita los antecedentes de cada decisión. El contraste empírico se centra en una implementación concreta: seleccionar un rescate de SVM sobre bloques compartidos y activarlo mediante un margen de la base. Evaluar por separado composición y activación permite determinar si un compromiso observado procede de poda, adquisición condicional o ambas. Ese contraste, y no la sola combinación de componentes conocidos, define el aporte que debe sustentar la evidencia.

Capítulo 3

Método de fusión y adquisición condicional

3.1 Bloques, miembros y política de adquisición

Sea $\mathcal{B} = \{1, \ldots, M\}$ una biblioteca de extractores congelados. El bloque j transforma una imagen x_i en $\mathbf{z}_{ij} \in \mathbb{R}^{d_j}$. Para un subconjunto $S \subseteq \mathcal{B}$, se utiliza

$$\mathbf{z}_{i,S} = \mathop{\Big\|}_{j \in S} \frac{\mathbf{z}_{ij}}{\max(\|\mathbf{z}_{ij}\|_2, 10^{-12})}, \qquad d_S = \sum_{j \in S} d_j. \tag{3.1}$$

Cada miembro f_S es una SVM entrenada sobre una concatenación de bloques; distintos votos pueden corresponder al mismo modelo. Una política $\pi = (b, E, \tau)$ consta de un bloque base b, una lista de miembros de rescate E y un umbral τ. El ensamble completo puede contener miembros repetidos con efecto en el voto, aunque cada modelo único se ejecute una sola vez.

La biblioteca comprende 22 bloques y 20.652 dimensiones nominales. Los descriptores fijos se almacenan por imagen, mientras que la proyección SVD de N-gramas se aprende con el entrenamiento del ajuste pertinente. Los detalles de extracción, checkpoints y dimensiones se conservan en el Anexo A. La selección actúa sobre bloques completos, no sobre coordenadas individuales.

Se denomina entrenamiento productor al conjunto utilizado para construir candidatos, seleccionar la política y reajustar los modelos. Dentro de él se obtienen predicciones OOF internas para la selección. La validación productora permanece fuera de esas decisiones y evalúa la política elegida. El Capítulo 4 detalla ambos niveles de partición.

3.2 Generación del ensamble de subconjuntos

Se construye un ensamble de 15 miembros, cada uno con cuatro bloques. La relevancia R_j se obtiene normalizando a_j, la media aritmética del macro-F1 individual entre los pliegues internos:

$$R_j = \frac{a_j - a_{\min}}{a_{\max} - a_{\min}}, \tag{3.2}$$

con denominador uno cuando todos los valores coinciden. La frontera de bases y las ganancias de poda, en cambio, usan macro-F1 sobre las predicciones OOF internas reunidas. Ambas agregaciones pueden producir ordenamientos diferentes. La similitud entre dos matrices de características centradas por columna, X e Y, se calcula mediante CKA lineal [23]:

$$\mathrm{CKA}(X, Y) = \frac{\|Y^\top X\|_F^2}{\|X^\top X\|_F \, \|Y^\top Y\|_F}. \tag{3.3}$$

Si el denominador es cero, la implementación devuelve cero. Se usa únicamente el entrenamiento productor, es decir, las imágenes disponibles para construir y seleccionar la ruta antes de evaluar su pliegue de validación.

Dado el conjunto parcial S, la utilidad de un candidato es

$$u_j(S) = R_j - \lambda \, |S|^{-1} \sum_{\ell \in S} \mathrm{CKA}(j, \ell); \qquad u_j(\varnothing) = R_j. \tag{3.4}$$

Los candidatos se ordenan por utilidad decreciente y nombre en caso de empate. Si quedan n candidatos y $r_j = 1$ identifica el mejor, el sorteo utiliza

$$p(j \mid S) = \frac{(n - r_j + 1)^\beta}{\sum_{\ell=1}^{n} \ell^\beta}. \tag{3.5}$$

Cada bloque elegido se retira del sorteo del mismo miembro. Entre miembros sí pueden repetirse subconjuntos. En el piloto se fijaron $\beta = 8$ y $\lambda = 0{,}25$, procedentes de la configuración archivada del ensamble. No se presentan como hiperparámetros óptimos universales.

3.3 Puntuaciones y agregación

Cada SVM produce un vector de puntuaciones $s_S(x) \in \mathbb{R}^C$, con el mismo orden de clases. Su escala σ_S es la desviación estándar poblacional de todas las puntuaciones de sus imágenes de entrenamiento, agrupando filas y clases. Se fija en uno si no es positiva o finita. La puntuación normalizada es

$$\widetilde{s}_S(x) = s_S(x)/\sigma_S, \qquad \widehat{y}_E(x) = \arg\max_c \frac{1}{|E|} \sum_{S \in E} \widetilde{s}_{S,c}(x). \tag{3.6}$$

La escala permanece congelada en validación; no se recalcula con el lote evaluado. Esta operación no convierte las puntuaciones en probabilidades calibradas. Los miembros repetidos conservan su multiplicidad en la suma del ensamble completo. El rescate podado, en cambio, usa pesos uniformes sobre modelos únicos seleccionados.

3.4 Base y compuerta

Las bases candidatas pertenecen a la frontera no dominada de macro-F1 individual interno y costo proyectado. Una base se excluye si otra no es peor en calidad ni costo y la mejora estrictamente en al menos uno. Es una restricción del espacio de búsqueda: no demuestra que una base dominada individualmente carezca de utilidad para enrutamiento.

El margen de la base es la diferencia entre sus dos puntuaciones más altas:

$$m_b(x) = \widetilde{s}_{b,(1)}(x) - \widetilde{s}_{b,(2)}(x). \tag{3.7}$$

Para cada base se consideran cuantiles $q \in \{0{,}1; 0{,}25; 0{,}5\}$ de márgenes OOF internos. Un umbral $\tau_{b,q}$ define la regla

$$\widehat{y}_\pi(x) = \begin{cases} \widehat{y}_b(x), & E = \varnothing \text{ o } m_b(x) \geq \tau_{b,q}, \\ \widehat{y}_E(x), & m_b(x) < \tau_{b,q}. \end{cases} \tag{3.8}$$

Cuando se activa el rescate, su predicción reemplaza a la base; esta no se añade como voto adicional. El margen ordena las muestras para esta regla de parada, pero no es una probabilidad de acierto. Tras reajustar la base con todo el entrenamiento productor, su escala se vuelve a estimar únicamente con ese entrenamiento y se conserva el valor numérico del umbral OOF. No se recalcula el cuantil con la validación productora. Por ello, el cuantil seleccionado no fija una fracción exacta de derivación al evaluar.

3.5 Costo compartido y presupuesto

Sea $U(E)$ la unión de bloques de los miembros y c_j el costo por extractor del perfil fijado. Para la fracción interna derivada $\widehat{r}$, se estima

$$\widehat{C}(b, E) = \begin{cases} c_b, & E = \varnothing, \\ c_b + c_{\text{pol}} + \widehat{r} \displaystyle\sum_{j \in U(E) \setminus \{b\}} c_j, & E \neq \varnothing. \end{cases} \tag{3.9}$$

Los bloques compartidos se contabilizan una vez y la representación base se reutiliza. El piloto fija $c_{\text{pol}} = 0{,}45$ ms como sobrecosto del perfil. Este valor no constituye un cronometraje de todos los clasificadores del híbrido. El Anexo A registra las constantes utilizadas.

Los presupuestos $B \in \{15, 30, 60, 120\}$ ms restringen la media proyectada de selección, no el costo de cada imagen ni una media futura. La fracción derivada puede cambiar al evaluar. También se registra el número esperado de llamadas:

$$\widehat{L} = 1 + \widehat{r}\,|\,\text{unique}(E)|. \tag{3.10}$$

Menos llamadas no implica por sí solo una reducción física proporcional.

3.5.1 Interpretación del costo de adquisición

Para una política no vacía, sea $A_{b,E} = \sum_{j \in U(E) \setminus \{b\}} c_j$ el costo adicional del rescate. El modelo por imagen es

$$C_\pi(x) = c_b + c_{\text{pol}} + \mathbb{I}[m_b(x) < \tau]\, A_{b,E}. \tag{3.11}$$

La media de esta expresión da la Ecuación 3.9. El sobrecosto fijo se aplica a todas las imágenes cuando existe rescate, no solo a las derivadas.

Una referencia que extrae permanentemente la misma unión tiene costo de adquisición $C_E = \sum_{j \in U(E)} c_j$, sin incluir latencia de clasificadores. Si $A_{b,E} > 0$, la política condicional reduce ese costo estimado únicamente cuando

$$\widehat{r} < \frac{C_E - c_b - c_{\text{pol}}}{A_{b,E}}. \tag{3.12}$$

La condición muestra dos efectos distintos: podar puede reducir $U(E)$ y enrutar puede reducir $\widehat{r}$. Una base fuera de la unión añade un costo que debe compensarse; el umbral también puede derivar demasiadas imágenes para que la adquisición resulte ventajosa. Esta identidad del modelo de costos no es una garantía de latencia física. Además, comparar un rescate podado condicional con un ensamble completo permanente cambia ambos mecanismos, por lo que no aísla el aporte de la compuerta.

3.6 Selección completa y poda del rescate

Sea $\mathcal{P}_B$ la familia restringida de políticas visitadas a partir de las bases candidatas, los cuantiles y la búsqueda de rescates para el presupuesto B. Se selecciona

$$\widehat{\pi}_B \in \underset{\pi \in \mathcal{P}_B : \widehat{C}(\pi) \le B}{\arg\max} \widehat{F}_{1,\text{OOF}}(\pi), \tag{3.13}$$

donde el macro-F1 se calcula sobre las puntuaciones internas reunidas. El desempate favorece menor costo, menos miembros y, finalmente, los identificadores deterministas de la implementación. La optimalidad se refiere solo a los puntos visitados en $\mathcal{P}_B$; no a todos los subconjuntos posibles. Si ninguna base cabe en el presupuesto, la configuración se registra como inviable.

El criterio operativo de este estudio es maximizar calidad interna dentro de un presupuesto de adquisición fijado, no aceptar una pérdida de F1 elegida después de observar validación. Al evaluar se informan conjuntamente ΔF_1, costo y cumplimiento del presupuesto frente a controles factibles para el mismo B. Una política domina descriptivamente a otra si no empeora ninguna de las dos magnitudes y mejora al menos una; de otro modo se conserva el compromiso, sin agregarlo en una puntuación arbitraria. No se escoge un presupuesto de despliegue ni se establece un margen retrospectivo de no inferioridad. Una excedencia en validación se registra como incumplimiento observado, aunque la selección interna fuera factible.

El rescate completo compara la base sola con los 15 votos para cada base, cuantil y presupuesto factibles. La poda empieza sin miembros y añade hasta tres modelos únicos del mismo ensamble. Cada adición debe mejorar el macro-F1 interno de la ruta y cumplir $\widehat{C} \le B$. Se comparan dos méritos:

$$h_{\text{rel}} = \Delta F_1, \qquad h_{\text{marg}} = \Delta F_1 / \Delta \widehat{C}. \tag{3.14}$$

Aquí ΔF_1 es el cambio de macro-F1 de la ruta completa sobre las imágenes internas reunidas, manteniendo base y umbral; no el F1 aislado del candidato ni el F1 de las imágenes derivadas solamente. $\Delta \widehat{C}$ es la diferencia de costo de adquisición al añadir ese miembro a los ya elegidos. El primer criterio se denomina *relevancia* en los registros, pero su mérito es la ganancia de macro-F1 de la ruta, no la relevancia individual R_j usada

para generar el ensamble. Solo se aceptan ganancias mayores que 10^{-12}. En el criterio marginal, una ganancia positiva con costo incremental no mayor que 10^{-12} tiene prioridad sobre razones finitas; el criterio de relevancia ordena por ganancia sin utilizar ese cociente. Los desempates consideran ganancia, costo y nombre del miembro. Se conserva el mejor punto interno visitado, incluida base sola.

Esta es una búsqueda heurística sobre candidatos generados, no una solución global del problema combinatorio. La relevancia y la razón marginal usan el mismo pool, bases y cuantiles; cambiar ese pool constituiría otra comparación.

Tabla 3.1: Procedimiento de selección dentro de un entrenamiento productor. La validación productora no interviene en estos pasos.

1. Recibir entrenamiento productor, biblioteca, grupos, semilla y perfil de costos.
2. Calcular ranking individual y CKA; generar 15 subconjuntos de cuatro bloques.
3. Obtener puntuaciones OOF internas de bases y miembros, ajustando SVD y escalas dentro de cada ajuste pertinente.
4. Construir la frontera de bases; para cada presupuesto y cuantil, evaluar base sola y rescate completo o la secuencia de poda.
5. Conservar la política de mayor macro-F1 interno bajo el presupuesto y los desempates especificados.
6. Reajustar los modelos necesarios con el entrenamiento productor; congelar escalas y umbral. Guardar selección e índices antes de evaluar la validación productora.

Tabla 3.2: Especificación de inferencia de la política seleccionada. El piloto la evalúa sobre puntuaciones guardadas; la ejecución física completa del híbrido no ha sido medida.

1. Extraer y normalizar la base; calcular su predicción y margen.
2. Si no hay rescate o el margen es al menos el umbral, devolver la predicción base.
3. En otro caso, adquirir $U(E) \setminus \{b\}$, reutilizando cada bloque ya disponible.
4. Evaluar cada modelo único del rescate; agregar puntuaciones con sus escalas y multiplicidades fijadas. Devolver la clase de mayor puntuación.

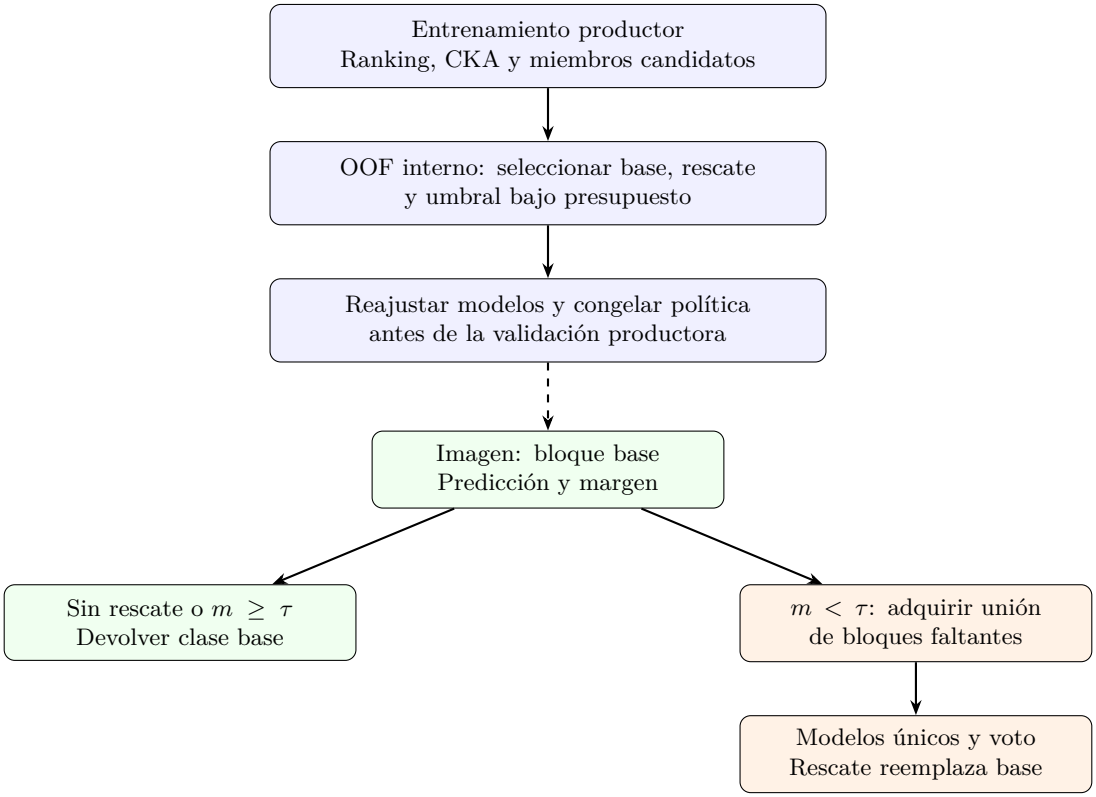


Figura 3.1: Construcción de la política y especificación de su ejecución. La selección usa entrenamiento; la compuerta utiliza el margen de cada imagen, no su etiqueta. En el piloto las rutas se reconstruyen con puntuaciones guardadas y costos proyectados; no se cronometra esta ruta completa desde RGB.

3.7 Referencias estáticas y cascada de comparación

Las estrategias estáticas son: Individual, mejor descriptor interno; Completa, los 22 bloques; GFS, selección secuencial; Top-k, los primeros del ranking individual con k heredado de GFS; y Homogénea, GFS restringido a una familia con el límite de tamaño del GFS heterogéneo. Top-k controla composición bajo igual número de bloques, no una elección independiente de k.

GFS inicia vacío y añade el bloque que maximiza macro-F1 interno, hasta ocho bloques. Se detiene tras dos mejoras consecutivas menores que 0,001 y devuelve el mejor paso visitado. Sus detalles y esquema se conservan en el Anexo A.

La cascada de referencia usa una base y una concatenación Top-k archivada como rescate. Su compuerta deriva si $m(x) \leq \tau$, mientras el híbrido usa $m(x) < \tau$. El umbral se seleccionó entre cuantiles 0,25/0,50/0,75 minimizando costo bajo tolerancia interna de F1 de 0,005. La ruta Top-k no se reconstruyó dentro de cada pliegue productor OOF; esta dependencia se mantiene como límite de esa referencia. Si ninguna ruta cumple, se elige Top-k directo.

En la referencia se consideraron ResNet-50, SigLIP, BEiT-v2 y ConvNeXt V2; KTH utilizó solo ResNet-50 y BEiT-v2. No se confunde este conjunto acotado de bases con la frontera individual del híbrido.

Capítulo 4

Diseño experimental

4.1 Evaluaciones y unidades de análisis

Se distinguen el benchmark estático, la cascada Top-k de referencia y el desarrollo del rescate de ensamble. La Tabla 4.1 especifica sus unidades; las condiciones externas no son datasets independientes. El híbrido se evalúa con SVM y no hereda los resultados ResMLP del benchmark.

Tabla 4.1: Cobertura efectiva de las evaluaciones. Las condiciones de cada conjunto se agregan antes de la inferencia entre datasets.

Conjunto	Imágenes/clases	Estático por clasif.	Cascada referencia
DTD	5.640/47	10	10
FMD	1.000/10	15	5
CUReT	5.612/61	2	2
Outex13	1.360/68	1	1
SoilOriginal	1.140/7	15	5
KTH-TIPS-2b	4.752/11	4	4
Total de condiciones		47	27

Piloto híbrido: entrenamiento oficial Outex, semilla 42. Réplica: FMD con semillas 42/123/2026 (800 imágenes de desarrollo por condición) y Outex con 123/2026 (680). Cada condición utiliza tres pliegues productores y tres internos. No se evalúan sus tests externos ni se añaden esas cinco condiciones al panel histórico de 27.

4.2 Datos, particiones y procedencia

Se utilizaron manifiestos para verificar etiquetas, orden de muestras, dimensiones, valores finitos y grupos de dependencia. Los bloques se alinearon con el mismo orden de imágenes dentro de cada conjunto.

DTD proporciona diez particiones oficiales [2]. En cada corrida estática se unieron entrenamiento y validación para seleccionar internamente; el test se reservó para evaluación externa de esa corrida. Se retiraron del entrenamiento los duplicados byte-idénticos que

cruzaban roles. Esta separación no significa que los resultados oficiales nunca influyeran en decisiones posteriores del proyecto.

FMD contiene diez categorías de materiales [27]. Cada imagen tuvo un hash único y se utilizó como grupo. El benchmark repite cinco pliegues estratificados y agrupados con semillas 42, 123 y 2026; la cascada conserva los cinco de la semilla 42.

Outex-TC-00013 contiene 68 clases balanceadas y una partición oficial de 680 imágenes de entrenamiento y 680 de prueba, diez por clase a cada lado [28]. Se verificaron archivos RGB legibles de 128×128, IDs continuos y ausencia de duplicados exactos. El piloto híbrido trabaja exclusivamente dentro de las 680 imágenes de entrenamiento.

CUReT utiliza la distribución gris recortada de 61 materiales y 92 condiciones por clase [29]. Se definieron mitades deterministas de 46 condiciones y ambas direcciones de entrenamiento/prueba. Las condiciones se agruparon para no cruzar una misma configuración de adquisición. El tamaño 46/46 no identifica el split histórico exacto de otros artículos; las dos direcciones son dependientes.

SoilOriginal procede de la versión 1 de Comprehensive Soil Classification Datasets, de ai4a-lab. Se admitió únicamente el árbol de imágenes originales del archivo auditado, excluyendo el conjunto aumentado. La deduplicación exacta por hash de archivo conserva 1.140 imágenes de siete clases y 962 grupos conservadores por familia de nombre, definidos dentro de cada clase. El manifiesto fija versión, rutas y hashes; no identifica un split oficial del proveedor. El benchmark utiliza cinco pliegues agrupados con tres semillas; la cascada, los cinco de la semilla 42, con 228 imágenes de prueba por pliegue.

KTH-TIPS-2b contiene 11 clases y cuatro muestras físicas por clase. Se conservaron cuatro particiones invertidas, con tres muestras físicas de entrenamiento y una de prueba. Las tablas estáticas principales conservan los controles archivados, incluido el Top-k anterior, y sus contrastes se reportan como análisis de ese archivo. No se les atribuye la corrección interna por muestra de controles posteriores. La cascada construida con el rescate anterior tampoco queda reconciliada por sustituir una media. Por esa reserva, KTH se excluye del contraste conjunto de la cascada. El Anexo B identifica las variantes y sus usos.

4.3 Clasificadores y selección interna

La SVM lineal utiliza `LinearSVC`, $C = 1$, clases balanceadas, pérdida *squared hinge*, regularización L_2, uno-contra-el-resto, tolerancia 10^{-4} y hasta 10.000 iteraciones. Se mantiene la misma receta al comparar concatenaciones en el piloto.

ResMLP designa una MLP residual sobre vectores de características, no una reproducción del modelo de imágenes homónimo [30]. Proyecta a 256 unidades y aplica tres bloques residuales, normalización de capa, GELU y *dropout* de 0,1. Se entrenó con entropía cruzada y AdamW, tasa 10^{-3}, decaimiento 10^{-4}, lotes de 256 y hasta 100 épocas. La parada controla pérdida media de entrenamiento, paciencia diez y disminución mínima 10^{-4}, restaurando el mejor estado. No selecciona época con test ni con validación adicional.

La búsqueda estática utiliza hasta cuatro pliegues internos estratificados y agrupados, limitados por disponibilidad de grupos. Las variantes KTH se delimitan en la sección

anterior. Las transformaciones aprendidas, incluida SVD de N-gramas, se ajustan en el entrenamiento pertinente. Las redes de extracción permanecen congeladas; no se comparan esquemas de ajuste fino.

4.4 Piloto de rescate de ensamble

Sea D_{dev} el entrenamiento oficial de Outex. Cada pliegue productor h lo divide en entrenamiento T_h y validación V_h, sin grupos compartidos. A su vez, T_h se divide en tres pliegues internos. Se distinguen cuatro operaciones:

1. Construir el ranking, calcular CKA y generar los subconjuntos utilizando T_h.
2. Reunir puntuaciones OOF internas de las imágenes de T_h y seleccionar base, umbral y rescate mediante la Ecuación 3.13.
3. Reajustar los modelos elegidos con T_h, estimar sus escalas y conservar el umbral numérico seleccionado.
4. Predecir las imágenes de V_h sin modificar la política a partir de sus etiquetas.

Al reunir las tres validaciones V_h se obtienen las 680 predicciones OOF de desarrollo, una por imagen y política. Esas predicciones son distintas de las puntuaciones OOF internas que guiaron la selección.

La biblioteca de candidatos se construye a nivel de T_h; no se genera de nuevo dentro de cada pliegue interno. Las puntuaciones internas, por tanto, sirven como criterio de selección dentro de una búsqueda adaptada a T_h, no como evaluación independiente del procedimiento completo. La evaluación productora conserva separadas las imágenes de V_h. La semilla de partición productora es 142 y la interna, 42; el Anexo B registra tamaños y multiplicidades.

El piloto reutiliza puntuaciones de validación productora de los miembros del control de diversidad previamente auditado. Se ajustaron las puntuaciones internas faltantes y las bases necesarias, comprobando igualdad de particiones y procedencia. Los parámetros del ensamble, presupuestos y cuantiles se fijaron desde la configuración de desarrollo; no son una preespecificación ciega de toda la investigación.

Los controles del mismo piloto incluyen mejor individual interno, Top-3/4/5, Completa-22 y ensamble de diversidad permanente. Top-3/4/5 son tamaños fijos; no equivalen al Top-k del benchmark que hereda k de GFS. Se añadió un ensamble estático seleccionado bajo cada presupuesto, definido a continuación; no se dispone de GFS concatenado reajustado para este protocolo.

4.4.1 Ablación del mismo rescate con y sin compuerta

Se reconstruyeron cuatro vistas de cada una de las doce políticas a partir de puntuaciones y predicciones de validación productora guardadas: base sola, mismo rescate permanente, ruta forzada y ruta condicional. Se conservaron los miembros, multiplicidades, pesos,

escalas, modelos y particiones; no se reentrenó ni se utilizó el test oficial. La base de cada vista es la elegida para esa política, no el mejor individual global.

El rescate permanente predice todas las imágenes con los miembros fijados y contabiliza únicamente la unión $U(E)$, sin extraer una base innecesaria. La ruta forzada conserva además la base y el sobrecosto de política, pero activa el mismo rescate en todas las imágenes. Ambas producen las mismas clases; la segunda tiene otra contabilidad de costo y llamadas. La vista condicional conserva la decisión archivada de la compuerta. Si el rescate es vacío, las cuatro vistas se reducen a la base; esos casos no aportan evidencia sobre enrutamiento.

El contraste entre rescate permanente y condicional aísla la activación para los modelos fijados en este archivo de desarrollo. No evalúa el mejor rescate estático posible: sus miembros fueron seleccionados conjuntamente con la compuerta. Las doce configuraciones reutilizan las mismas 680 imágenes y son dependientes. Se informan cambios predictivos, costos y llamadas, sin atribuirles significancia confirmatoria ni equivalencia poblacional.

4.4.2 Control estático bajo presupuesto

En cada entrenamiento productor se reúnen los 22 clasificadores individuales y los modelos únicos del ensamble de diversidad, con las puntuaciones OOF internas guardadas. Se enumeran todos los ensambles de uno a tres miembros únicos de ese pool, con igual peso y sin repetición. Para cada presupuesto 15, 30, 60 y 120 ms se elige el mayor macro-F1 interno cuya unión de bloques sea factible. Los desempates favorecen menor costo, menos modelos y orden léxico. No se añade una base ni una compuerta al costo del control permanente.

Las doce decisiones se guardaron antes de calcular sus predicciones de validación productora. Se reutilizaron nueve modelos disponibles y se reajustaron nueve con la misma receta SVM y el mismo entrenamiento productor. La enumeración es exhaustiva dentro de ese pool y límite de tres miembros, no sobre todas las concatenaciones o ponderaciones posibles. Se conservan los mismos pliegues y constantes del híbrido; el control no sustituye una ejecución GFS bajo presupuesto.

Este análisis se diseñó después de conocer el piloto y P0. Su regla se fijó antes de obtener las nuevas predicciones, pero no constituye una preinscripción ciega. Se conserva todo el barrido y no se usa el test oficial ni se reajusta el híbrido a partir del resultado del control.

4.4.3 Réplica en FMD y semillas adicionales

La réplica conserva la biblioteca de 22 bloques, SVM, tres pliegues productores y tres internos, presupuestos 15/30/60/120 ms y cuantiles 0,10/0,25/0,50. Mantiene cinco sorteos de candidatos de tamaño cuatro, hasta tres miembros podados y el ensamble de quince votos con $\beta = 8$ y $\lambda = 0{,}25$. No se modificaron estos parámetros a partir de sus resultados. Las cinco condiciones y los comandos se fijaron antes de ejecutar la cola, después de conocer el piloto; no constituyen una preinscripción ciega de la investigación.

En FMD se reserva el pliegue externo 0 de la partición estratificada y agrupada de cada

semilla 42, 123 y 2026: 800 imágenes forman D_{dev} y las 200 restantes quedan excluidas. En Outex se mantiene el entrenamiento oficial de 680 imágenes y se añaden las semillas 123 y 2026, sin evaluar las 680 imágenes de test. El piloto Outex/42 se conserva por separado. Las semillas alteran particiones, sorteos y transformaciones; no aíslan solamente el efecto de la inicialización. La partición productora usa semilla $s + 100$ y la interna, s.

Cada condición evalúa referencias individuales, Top-3/4/5, Completa-22, ensambles permanentes, las tres reglas híbridas y el rival estático bajo presupuesto. La vista P0 vuelve a aplicar permanentemente exactamente el rescate seleccionado, sin reoptimizarlo. La cobertura se audita por imagen, grupo y transformación, manteniendo el test externo excluido. El perfil de costos es el mismo del piloto Outex, no una medición nueva de extracción en FMD. Las reglas completas y el detalle por semilla se conservan en el Anexo C.4.

4.5 Métricas y agregación

Macro-F1 es la métrica primaria. Para C clases,

$$\text{macro-F1} = \frac{1}{C} \sum_{c=1}^{C} \frac{2TP_c}{2TP_c + FP_c + FN_c}. \tag{4.1}$$

Se asigna cero cuando el denominador no permite definir el cociente. La exactitud es la proporción de predicciones correctas. En el benchmark se promedian métricas entre condiciones externas de cada dataset; en cada condición del híbrido se calcula macro-F1 sobre las predicciones OOF productoras reunidas, una por imagen y política (680 Outex, 800 FMD). Las medias de la réplica promedian después esas métricas entre semillas dentro de cada dataset; no reúnen varias predicciones de una misma imagen como observaciones independientes.

El costo proyectado del piloto se promedia por imagen, ponderando tamaños de pliegue; no se usa una media no ponderada de costos de pliegues de distinto tamaño. Las tablas principales muestran medias sin formato mixto de desviaciones. El Anexo C conserva desviaciones descriptivas entre condiciones y el detalle del barrido; un único split Outex no permite estimar desviación entre splits.

4.6 Medición física de la cascada de referencia

Se midió una condición por dataset en RTX 4060 de 8 GB: DTD/Outex oficial 1, CUReT A a B, KTH oficial 1 invertido y FMD/Soil semilla 42, pliegue 0. Se seleccionó una imagen por clase, con semilla 42, para 204 imágenes y tres repeticiones pareadas de orden aleatorizado: 612 parejas, no 612 imágenes independientes.

Se utilizó lote unitario, modelos residentes e imágenes decodificadas, con sincronización CUDA. El cronómetro incluyó extracción y clasificación, excluyendo inicialización y disco. Se contrastaron representaciones y predicciones con el caché. Las discrepancias de CUReT/Soil limitan la fidelidad; esta medición no corresponde al híbrido nuevo.

4.7 Panel físico online completo (94 condiciones) y comparadores del estado del arte

Para superar la cobertura muestral limitada de los pilotos físicos iniciales y comparar directamente tanto calidad predictiva como tiempo físico de inferencia por imagen frente al estado del arte reciente de concatenación, se ejecutó un panel online completo en lote unitario (`batch=1`) sobre las 47 particiones externas de los seis conjuntos de datos (FMD: 15, DTD: 10, SoilOriginal: 15, KTH-TIPS-2b: 4, CUReT: 2 y Outex-13: 1):

1. **Panel local online (94 condiciones, 362.640 llamadas primarias):** En cada una de las 47 particiones externas y para ambos clasificadores (`LinearSVC` y `ResMLP`, totalizando 94 condiciones únicas y 470 combinaciones condición–método), se evaluaron cinco políticas locales sobre la totalidad de las imágenes de prueba: `Adaptive-selection-mar` (adquisición condicional con salida temprana por margen en la Etapa 1 y rescate en la Etapa 2), `Top-4` (concatenación estática de los cuatro mejores bloques individuales), `Ens-diversidad` (selección estática de cuatro bloques guiada por relevancia y diversidad CKA), `Ens-tombola` (selección estática ponderada de cuatro bloques) y `Completa-22` (concatenación de los 22 bloques). Cada llamada individual midió extremo a extremo la extracción y clasificación con sincronización CUDA (`perf_counter_ns`), derivando el macro-F1 y la latencia física (`ms`) exactamente de las mismas predicciones individuales, sin reutilizar cachés en línea.

2. **Validación de fidelidad y adaptación de cuatro métodos externos de concatenación:** Se seleccionaron cuatro artículos representativos del estado del arte que emplean concatenación de características profundas y/o artesanales:

   - **Neshov et al. (2025) [15]:** Agregación multicapa de los 12 bloques Transformer de `BEiT-v2` (`beitv2_base_patch16_224.in1k_ft_in22k_in1k`) mediante *Global Average Pooling* concatenado ($12 \times 768 = 9.216$ dimensiones) y clasificador MLP con normalización por lotes (`BN` $\rightarrow$ `Linear(9216,64)` $\rightarrow$ `BN` $\rightarrow$ `ReLU` $\rightarrow$ `Dropout(0,2)` $\rightarrow$ `Linear(64,`C`)`, Adam 10^{-3}, 100 épocas). Se verificó primero su protocolo publicado en FMD (10×10-fold CV, 100 condiciones y 10.000 llamadas) y luego se evaluó su adaptación con extracción individual `batch=1` en las 47 condiciones del panel común (36.264 llamadas).
   - **Simon y Uma (2022) — *DeepLumina* [16]:** Conversión de la imagen RGB al canal de luminancia $Y = 0{,}299R + 0{,}587G + 0{,}114B$ del espacio YIQ, extracción independiente de la capa `fc1000` de `ResNet-101` sobre la entrada RGB (1.000D) y sobre el canal Y replicado en tres canales (1.000D) para formar un vector concatenado de 2.000 dimensiones, clasificado mediante un diseño multiclase ECOC-SVM *sparse-random* ($\lceil 15 \log_2(C) \rceil$ columnas iniciales evaluadas sobre 10.000 matrices ternarias candidatas maximizando la distancia mínima entre pares de clases y decodificación *loss-weighted hinge*).
   - **Gupta et al. (2026) — *HyTexNet* [17]:** Concatenación de la representación profunda de `DenseNet-121` (1.024D) con el descriptor local *HyTex* de 514 dimensiones (histogramas de signo, magnitud umbralizada en el percentil 75 empírico T_{75} y media global central, totalizando 1.538 dimensiones) seguida de una cabeza MLP (`1538` $\rightarrow$ `256` $\rightarrow$ `ReLU` $\rightarrow$ `Dropout(0,5)` $\rightarrow$ C). Se

validaron mediante pruebas unitarias los cinco ejemplos numéricos paso a paso de la Tabla 1 del artículo original, el protocolo de un tercio de entrenamiento en KTH-TIPS-2b (3.168 llamadas) y las 47 condiciones del panel común (36.264 llamadas).

- **Chang et al. (2024) — *6LBP+dCellNN* [18]:** Fusión de mapas de contorno extraídos con el checkpoint oficial de los autores (`cellnn_model.ph`, commit `299502c` del repositorio público `UESTC-nnLab/LBP_Contour`) y patrones binarios locales en seis escalas $(P, R) \in \{(8,1), (16,2), (24,3), (8,3), (12,5), (16,7)\}$ concatenados en 768 dimensiones con clasificador MLP de 400 unidades ocultas. Se verificó paridad numérica exacta (error máximo = 0,0) frente al código original del autor antes de evaluar tanto el protocolo de un tercio en KTH-TIPS-2b como las 47 condiciones del panel común.

4.8 Análisis estadístico

Los análisis siguen la comparación no paramétrica entre datasets [31–33], con cálculos originales en ControlTest/MultipleTest de Java y comprobaciones locales posteriores. En estos contrastes de calidad predictiva, la unidad de inferencia es el dataset, después de agregar sus condiciones; las imágenes y pliegues de un mismo conjunto no incrementan ese número de unidades.

Para el benchmark estático se utiliza una media por dataset y clasificador: $N = 6$ bloques, con las reservas KTH descritas. Friedman es el contraste global principal de ese análisis histórico; sus post-hoc de diferencias de rangos aplican Holm a los diez pares por clasificador y no son Wilcoxon exactos. Iman–Davenport es una transformación del estadístico de Friedman, no una réplica independiente de evidencia. Friedman alineado y Quade son comprobaciones complementarias con sensibilidades distintas; su desacuerdo se informa sin escoger retrospectivamente la prueba más favorable.

Para examinar la reserva de KTH se repiten esas cuatro pruebas y las dos familias de diez pares excluyendo ese conjunto ($N = 5$). Se mantienen intactos los resultados de los otros datasets y se reproducen primero los contrastes Java de $N = 6$. Es una sensibilidad del mismo archivo, no una corrección de KTH ni una confirmación independiente; sus valores ajustados pertenecen a familias distintas de las originales.

Para la cascada de referencia se excluye KTH y se utilizan cinco datasets, correspondientes a 23 condiciones. La familia de tres contrastes pareados compara la cascada seleccionada con cascada ResNet, Top-k de origen y Completa-22, mediante Wilcoxon y Holm. Friedman y sus post-hoc examinan rangos entre métodos; Wilcoxon examina diferencias pareadas respecto de cero bajo sus supuestos, no una hipótesis idéntica a la de Friedman.

El no rechazo no demuestra equivalencia ni no inferioridad. Las particiones y repeticiones compartidas no se tratan como datasets nuevos. No se realizan contrastes confirmatorios del punto favorable del piloto Outex entre presupuestos explorados. La réplica del híbrido se informa descriptivamente: tiene dos datasets y semillas dependientes, no cinco dominios independientes para justificar una nueva batería de contrastes poblacionales.

Capítulo 5

Resultados experimentales

Se separan el benchmark estático externo, la cascada histórica con sus pilotos físicos y el desarrollo OOF del rescate de ensamble, con su piloto Outex y una réplica en dos datasets. Sus métricas no se mezclan entre protocolos.

5.1 P1: desempeño y dimensionalidad de la selección estática

La evaluación sistemática de la concatenación estática analiza la biblioteca consolidada de 22 descriptores (20.652 dimensiones) sobre seis conjuntos de datos de referencia (DTD, FMD, CUReT, Outex, SoilOriginal y KTH-TIPS-2b) empleando dos clasificadores con sesgos inductivos distintos: Linear SVM y ResMLP (12 configuraciones experimentales). La Tabla 5.1 compara las cinco estrategias de selección de bloques (Individual, Completa, Top-k, GFS y Homogénea) en términos de macro-F1 medio entre particiones externas. La estrategia Individual corresponde a una selección interna prospectiva (el extractor elegido puede variar entre particiones). La exactitud y la variabilidad descriptiva se conservan en el Anexo C bajo el mismo diseño.

Tabla 5.1: Macro-F1 externo de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	0,8426	0,8639	0,8700	**0,8703**	0,8604
DTD	ResMLP	0,8373	0,8620	**0,8643**	0,8639	0,8611
FMD	SVM	0,9726	0,9647	**0,9820**	0,9766	0,9789
FMD	ResMLP	0,9690	0,9564	0,9740	**0,9783**	0,9773
CUReT	SVM	0,9948	**0,9989**	**0,9989**	0,9988	0,9989
CUReT	ResMLP	0,9971	**0,9991**	0,9984	0,9986	0,9982
Outex	SVM	0,9066	**0,9656**	0,9426	0,9589	0,9307
Outex	ResMLP	0,9476	0,9416	0,9652	**0,9715**	0,9306
Soil	SVM	0,8578	**0,8816**	0,8776	0,8671	0,8670
Soil	ResMLP	0,8533	0,8649	0,8685	**0,8691**	0,8629
KTH-TIPS2-b	SVM	0,9396	**0,9601**	0,9400	0,9052	0,9271
KTH-TIPS2-b	ResMLP	0,9061	**0,9487**	0,9322	0,9201	0,9127

Tabla 5.2: Dimensión media de las representaciones usadas en la evaluación externa con 22 descriptores.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	819,2	20652,0	4480,0	5390,4	2496,0
DTD	ResMLP	768,0	20652,0	4211,2	4626,4	2598,4
FMD	SVM	768,0	20652,0	2969,6	2687,5	2338,1
FMD	ResMLP	768,0	20652,0	3404,8	3077,5	2218,7
CUReT	SVM	1024,0	20652,0	3328,0	4402,0	2944,0
CUReT	ResMLP	704,0	20652,0	2176,0	2880,0	1856,0
Outex	SVM	1024,0	20652,0	7808,0	6784,0	3712,0
Outex	ResMLP	256,0	20652,0	6016,0	3346,0	2176,0
Soil	SVM	768,0	20652,0	4898,1	3709,9	2184,5
Soil	ResMLP	768,0	20652,0	5529,6	4415,6	2235,7
KTH-TIPS2-b	SVM	832,0	20652,0	1280,0	960,0	960,0
KTH-TIPS2-b	ResMLP	672,0	20652,0	1600,0	1440,0	928,0

Completa tiene siempre 20.652 coordenadas; las otras estrategias pueden elegir subconjuntos distintos entre particiones.

Al menos una estrategia de combinación supera numéricamente a Individual en cada una de las doce configuraciones, pero la composición útil depende del dataset y del clasificador. FMD ilustra el límite de concatenar indiscriminadamente: con SVM, Completa obtiene 0,9647, por debajo de Individual (0,9726), mientras Top-k alcanza 0,9820. Con ResMLP también cae Completa respecto de Individual y GFS obtiene la mayor media. En cambio, Completa alcanza las medias más altas en KTH-TIPS-2b con ambos clasificadores. La tabla no respalda una regla uniforme de añadir o retirar bloques.

El clasificador también cambia el resultado dentro de un mismo dominio. En Outex, Completa es la mejor estrategia con SVM (0,9656), mientras GFS lo es con ResMLP (0,9715). Los máximos redondeados de CUReT están cerca del techo de la métrica y varias estrategias prácticamente coinciden. Estas observaciones describen diferencias de medias; su evidencia conjunta se examina mediante los contrastes por clasificador.

La Tabla 5.2 contrasta el desempeño predictivo con el tamaño efectivo del vector de entrada. Mientras que Completa utiliza siempre las 20.652 dimensiones de la biblioteca conjunta, la dimensión media seleccionada por GFS se sitúa entre 960 y 6.784 componentes entre configuraciones, lo que representa una reducción de entre 67,1% y 95,3% en la dimensionalidad del espacio de entrada. Esta reducción alivia la carga de memoria y almacenamiento del clasificador, pero no disminuye proporcionalmente la latencia de inferencia de extremo a extremo en un esquema estático, dado que todos los extractores seleccionados deben ejecutarse de forma invariable para cada imagen.

5.2 Contrastes de la selección estática

La comparación se agrega por conjunto de datos y se separa por clasificador. Friedman obtiene $p = 0{,}0289$ con SVM y $p = 0{,}0110$ con ResMLP; Iman–Davenport registra 0,0139 y 0,0025. Son resultados del benchmark archivado, no evidencia inferencial del híbrido ni de una superioridad uniforme.

Los post-hoc de rangos de Friedman con Holm sobre diez pares por clasificador identifican GFS frente a Individual con ResMLP ($p_{\text{Holm}} = 0{,}0191$). Con SVM, Completa y Top-k frente a Individual registran 0,0617 y GFS registra 0,8028. No se interpretan los no

rechazos como equivalencia. Las Tablas C.3, C.4 y C.5 del Anexo C conservan el análisis completo.

La inclusión de BEiT-v2 estuvo informada por evaluaciones previas y los controles KTH de estas tablas son la variante archivada, no la corrección posterior por muestra. La significancia observada no equivale a confirmación independiente del diseño.

5.2.1 Sensibilidad a la exclusión de KTH

La Tabla 5.3 conserva el análisis original y su repetición sobre los cinco datasets restantes. Sin KTH, Friedman obtiene $p = 0{,}0342$ con SVM y $p = 0{,}0199$ con ResMLP. En esta sensibilidad, GFS frente a Individual con ResMLP mantiene $p_{\text{Holm}} = 0{,}0270$, frente a 0,0191 en el archivo de seis conjuntos. Con SVM ningún par rechaza tras Holm; Top-k frente a Individual registra 0,0511, Completa 0,0839 y GFS 0,2225. No se redondea el primer valor para tratarlo como significativo.

Tabla 5.3: Sensibilidad del benchmark estático a excluir KTH archivado: seis datasets originales frente a los cinco restantes. Valores p SCI2S por clasificador; no son evaluaciones del híbrido.

Clasif.	N	Friedman	Iman–D.	F. alineado	Quade
SVM	6	0,0289	0,0139	0,2860	0,0349
SVM	5	0,0342	0,0145	0,3901	0,0203
ResMLP	6	0,0110	0,0025	0,2883	0,0210
ResMLP	5	0,0199	0,0051	0,3955	0,0157

Friedman alineado no rechaza en ninguno de los dos paneles: sin KTH registra 0,3901 para SVM y 0,3955 para ResMLP. Quade sí rechaza a nivel nominal. El resultado de rangos GFS–Individual con ResMLP se conserva al excluir KTH, pero la batería no aporta cuatro confirmaciones independientes ni demuestra superioridad uniforme. La Tabla C.6 conserva los veinte pares de la sensibilidad en el anexo. La procedencia de KTH continúa pendiente de reconciliación.

5.3 P2: adquisición condicional en 27 condiciones

La variante histórica utiliza una base y un rescate Top-k archivado. Sus medias se conservan como resultados descriptivos; el nuevo híbrido se evalúa aparte.

La media da igual peso a cada dataset. En los cinco conjuntos reconciliados, las medias son 0,9325 para la cascada, 0,9329 para Top-k y 0,9371 para Completa. El control KTH corregido por muestra alcanza aproximadamente 0,9445, pero coincidir en media no reconcilia la selección del rescate de la cascada histórica.

Las bases fueron SigLIP en 20 condiciones, BEiT-v2 en cinco y ResNet-50 en una; una condición eligió Top-k directo. El cociente de costos medios proyecta una reducción de 75,5% frente a Top-k bajo el perfil histórico por componentes, no un cronometraje del panel completo.

El análisis por dataset excluye KTH por procedencia y mantiene $N = 5$. Friedman obtiene $p = 0{,}4518$ e Iman–Davenport $p = 0{,}4922$. Las tres comparaciones pareadas de

Tabla 5.4: Macro-F1 externo de la cascada histórica. Medias por dataset; KTH conserva la variante archivada, no una cascada reconciliada con el Top-k corregido.

Dataset	Condiciones	Cascada	Top-k origen	Completa-22
DTD	10	0,8700	0,8700	0,8639
FMD	5	0,9840	0,9829	0,9651
CUReT	2	0,9982	0,9989	0,9989
Outex13	1	0,9369	0,9426	0,9656
SoilOriginal	5	0,8734	0,8701	0,8919
KTH-TIPS-2b	4	0,9445	0,9400	0,9601
Media por dataset	27	0,9345	0,9341	0,9409

Wilcoxon con Holm frente a cascada ResNet, Top-k y Completa dan valores ajustados de 1,0000. El no rechazo no establece equivalencia ni no inferioridad. Los contrastes que tratan las 27 condiciones dependientes como unidades independientes no se usan como evidencia inferencial.

Las figuras detalladas de la cascada de referencia se conservan en el Anexo B.

5.4 Pilotos físicos de la cascada histórica

Se midió una condición por dataset en RTX 4060 con modelos residentes e imágenes decodificadas: una imagen por clase, tres repeticiones pareadas y orden aleatorizado. Son 204 imágenes y 612 parejas, no 612 imágenes independientes.

Tabla 5.5: Tiempos archivados de la cascada histórica y Top-k. Las discrepancias de representación se mantienen visibles; estos tiempos no miden el híbrido nuevo.

Dataset	Imágenes	Pares	Cascada ms	Top-k ms	Reducción	Representación
DTD	47	141	90,57	295,55	69,36%	sin alerta del piloto
FMD	10	30	13,01	208,08	93,75%	sin alerta del piloto
CUReT	61	183	92,52	270,60	65,81%	discrepancia
Outex13	68	204	111,47	354,31	68,54%	sin alerta del piloto
SoilOriginal	7	21	41,99	109,10	61,51%	discrepancia
KTH-TIPS-2b	11	33	46,08	188,33	75,53%	variante histórica

La agregación de las 612 parejas registra 90,25 ms frente a 291,21 ms, reducción de aproximadamente 69,0% y razón de sumas 3,23. Es un agregado de registros, no una estimación equiponderada de generalización a seis dominios. En 453 ejecuciones se registra salida temprana; las repeticiones comparten imagen.

Las rutas y predicciones coinciden con el caché en esos registros. Sin embargo, los cosenos mínimos en CUReT y Soil son aproximadamente $-0{,}0707$ y 0,0085. Estas diferencias impiden concluir identidad de representaciones. Su atribución a una capa o preprocesamiento concreto requiere un diagnóstico controlado. Los tiempos no prueban fidelidad física cerrada del sistema cacheado ni validan el híbrido nuevo.

5.5 P3: rescate de ensamble en desarrollo Outex

El piloto usa las 680 imágenes del entrenamiento oficial de Outex, semilla 42, tres folds productores y tres internos. El test oficial no fue evaluado. La Tabla 5.7 muestra todas sus políticas; no se comparan directamente con el F1 de test de la Tabla 5.4.

Tabla 5.6: Controles del mismo piloto Outex: macro-F1 OOF sobre 680 imágenes de entrenamiento oficial y costo medio proyectado, no latencia física.

Control	Macro-F1	Costo proyectado ms
Individual interno	0,871642	177,300
Top-3	0,882967	236,862
Top-4	0,884244	256,272
Top-5	0,900824	288,435
Completa-22	0,913957	1706,420
Diversidad15 permanente	0,914389	365,196

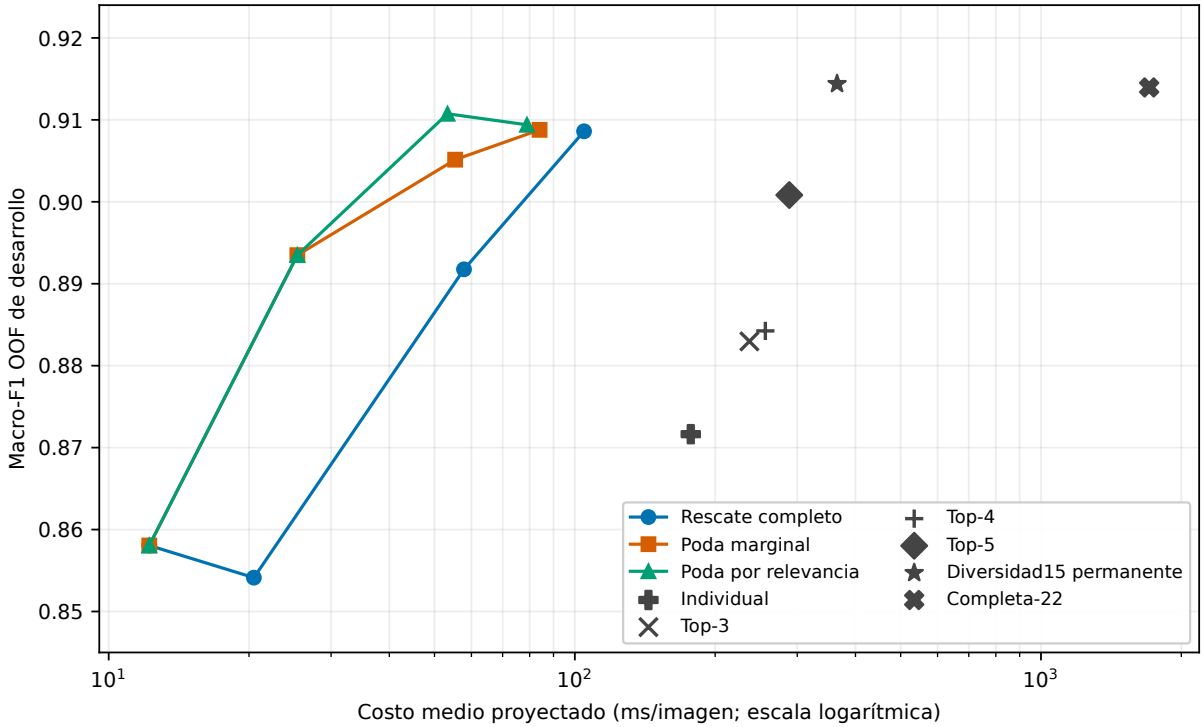


Figura 5.1: Políticas del piloto Outex y controles del mismo protocolo. Se muestran los cuatro presupuestos de cada variante, incluidos puntos coincidentes. El eje horizontal es costo proyectado en escala logarítmica, no latencia física; las líneas no representan una frontera óptima.

El punto podado por relevancia/B60 obtiene 0,910742, frente a 0,914389 de diversidad permanente, con 85,40% menos costo estimado y una diferencia de F1 de −0,003646 (aproximadamente −0,365 puntos porcentuales). Top-5 obtiene 0,900824/288,435 ms y Completa-22 0,913957/1706,420 ms. El híbrido supera numéricamente Top-5, pero no a Completa ni al ensamble permanente en calidad. B60 es un punto observado dentro del

Tabla 5.7: Piloto híbrido de Outex: macro-F1 OOF de desarrollo y costo proyectado. B es el presupuesto de selección en ms; los costos no son latencias físicas.

Ruta	B	Macro-F1	Costo proyectado ms
Diversidad15 permanente	–	0,914389	365,196
Completo como rescate	15	0,858056	12,220
Podado marginal	15	0,858056	12,220
Podado relevancia	15	0,858056	12,220
Completo como rescate	30	0,854129	20,485
Podado marginal	30	0,893488	25,394
Podado relevancia	30	0,893488	25,394
Completo como rescate	60	0,891759	57,839
Podado marginal	60	0,905140	55,365
Podado relevancia	60	0,910742	53,316
Completo como rescate	120	0,908603	104,660
Podado marginal	120	0,908781	84,018
Podado relevancia	120	0,909396	78,938

barrido de desarrollo, no un presupuesto validado de forma independiente después de su selección.

Ese punto deriva 278/680 imágenes: corrige 52 errores de las bases y perjudica cinco aciertos. El saldo de 47 aciertos adicionales describe exactitud, no una diferencia de macro-F1, que depende de la distribución de errores por clase. Sus bases son DINOv2-small, BEiT-v2-final y VGG16, con dos, dos y un modelos de rescate únicos. Las llamadas medias son 1,654 frente a 10,665 del ensamble permanente. El resto de las imágenes sale por la base; el Anexo B aclara la diferencia entre votos y modelos ejecutados.

A presupuesto 15 se elige base sola; el rescate completo/B30 tampoco se activa. Relevancia supera a marginal en calidad y costo en los puntos de 60 y 120 ms. Los 36 presupuestos internos se cumplen, pero completo/B60/fold1 registra 70,019604 ms proyectados en validación frente a 59,602804 internos. Se conservan esa excedencia y la falta de monotonía del F1 con el presupuesto.

La Tabla 5.6 y la Figura 5.1 permiten comparar referencias sin trasladar cifras de test externo. El primer control siguiente mantiene fijo el rescate; el segundo lo compara con una selección estática propia bajo presupuesto. GFS concatenado sigue sin evaluarse en este protocolo. El análisis emparejado de N-gramas se conserva como evidencia secundaria en el Anexo C.

5.5.1 Separación de poda y activación condicional

La Tabla 5.8 descompone el punto relevancia/B60 con el control de la Sección 4.4.1. Son las mismas 680 imágenes y los mismos modelos del piloto; el recálculo no constituye otra evaluación independiente.

La poda cambia el ensamble permanente de 0,914389/365,196 ms a 0,911993/110,421 ms: reduce la adquisición proyectada en 69,76%, con ΔF1 = −0,002395. Activar condicionalmente ese mismo rescate reduce otros 51,72% respecto de su ejecución permanente, hasta 53,316 ms, con ΔF1 = −0,001251. Las reducciones se aplican sucesivamente y no se

Tabla 5.8: Control de poda y compuerta en relevancia/B60. Macro-F1 OOF sobre las mismas 680 imágenes; costo medio de adquisición proyectado y llamadas a clasificadores únicos por imagen. No son tiempos físicos.

Vista	Macro-F1	Costo ms	Llamadas
Ensamble completo permanente	0,914389	365,196	10,665
Mismo rescate podado permanente	0,911993	110,421	1,668
Mismo rescate, ruta forzada	0,911993	110,871	2,668
Ruta condicional	0,910742	53,316	1,654

suman; el descenso total frente al ensamble completo es 85,40%. La ruta forzada retiene la base y tiene costo 110,871 ms; se distingue de la referencia permanente eficiente, que omite ese trabajo.

Frente al mismo rescate permanente, la compuerta cambia tres clases predichas: corrige una y perjudica dos. La exactitud pasa de 0,914706 a 0,913235. Es un contraste distinto del balance de 52 errores corregidos y cinco aciertos perjudicados frente a las bases. Las llamadas medias apenas disminuyen un 0,79% respecto del rescate podado permanente, de 1,668 a 1,654. La gran reducción de llamadas frente al ensamble completo corresponde principalmente a la poda, no a la compuerta.

En marginal/B60, las 680 predicciones condicionales coinciden exactamente con las del mismo rescate permanente: macro-F1 0,905140 y exactitud 0,907353. Su costo proyectado pasa de 97,282 a 55,365 ms, una reducción de 43,09%. Sin embargo, las llamadas aumentan de 1,334 a 1,672, un 25,36%, porque la ruta también calcula la base. Menor adquisición proyectada puede coexistir con más evaluaciones de clasificadores; la coincidencia de clases en estas imágenes no prueba equivalencia poblacional.

El barrido completo, incluida la base sola, se presenta en la Tabla C.7. En ocho configuraciones existe rescate: la compuerta reduce F1 en siete y conserva las predicciones en marginal/B60; no mejora F1 en ninguna. Las otras cuatro se reducen a la base. Los rescates permanentes de ambos criterios en B60 superan 60 ms proyectados, mientras sus rutas condicionales quedan por debajo en la media reunida. Esto no descarta una alternativa estática distinta que cumpla el mismo presupuesto. La excedencia del rescate completo/B60 en un pliegue sigue vigente. Para esta ablación no se calcularon valores p ni se midió latencia física.

5.5.2 Comparación con selección estática bajo presupuesto

El control de la Sección 4.4.2 cumple su presupuesto en las doce combinaciones de pliegue y presupuesto. Los pools contienen 31, 33 y 34 candidatos. En B60 se examinan 617 combinaciones factibles por pliegue; en B120, entre 1.287 y 1.701. La elección usa únicamente macro-F1 OOF interno. La Tabla 5.9 conserva los cuatro presupuestos frente a relevancia, sin recomendar uno retrospectivamente.

En B30, el híbrido por relevancia tiene mayor F1 observado y menor costo proyectado que el control: 0,893488/25,394 ms frente a 0,861264/28,463 ms. En B60 obtiene 0,910742 frente a 0,892923, pero también adquiere más información estimada: 53,316 frente a 44,831 ms. Ambos cumplen 60 ms en la media reunida; no son puntos de idéntico costo.

Tabla 5.9: Control estático optimizado dentro del pool visitado, con hasta tres miembros, frente al híbrido por relevancia bajo el mismo presupuesto. Macro-F1 OOF de desarrollo sobre 680 imágenes; C es adquisición media proyectada en ms. Δ es híbrido menos estático.

B	F1 estático	C estático	F1 híbrido	C híbrido	ΔF1
15	0,859690	13,752	0,858056	12,220	-0,001634
30	0,861264	28,463	0,893488	25,394	0,032225
60	0,892923	44,831	0,910742	53,316	0,017819
120	0,909612	103,040	0,909396	78,938	-0,000216

En B15, el estático tiene mayor F1 (0,859690 frente a 0,858056) y mayor costo (13,752 frente a 12,220 ms). En B120 también obtiene mayor F1 (0,909612 frente a 0,909396) con mayor costo (103,040 frente a 78,938 ms). Por tanto, la comparación no muestra superioridad uniforme de la adquisición condicional. La ventaja predictiva observada dentro de B60 corresponde a este pool, semilla y protocolo de desarrollo; no establece optimalidad global, significancia entre dominios ni aceleración física.

5.6 Réplica del rescate en dos datasets

Las cinco condiciones nuevas de la Sección 4.4.3 completaron sus etapas y la auditoría de índices, selecciones y predicciones. Las medias de la Tabla 5.10 no incluyen el piloto Outex/42: resumen tres semillas FMD y dos semillas Outex. Se conserva relevancia como referencia de la discusión del piloto, sin cambiar la regla para escoger retrospectivamente el mejor resultado de cada fila. Las tres reglas completas y las referencias emparejadas figuran en las Tablas C.8 y C.9.

Tabla 5.10: Réplica de desarrollo: media entre semillas nuevas de macro-F1 / costo proyectado (ms). El número entre paréntesis es el de semillas, no datasets independientes. B restringe el costo interno medio; no es el costo medido. Outex/42 no integra estas medias.

Dataset	B	Híbrido relevancia	Estático presupuestado
FMD (3)	15	0,970011 / 11,680	0,970011 / 11,680
FMD (3)	30	0,974618 / 18,499	0,968776 / 14,777
FMD (3)	60	0,977489 / 35,689	0,974600 / 41,888
FMD (3)	120	0,977074 / 46,923	0,977082 / 100,929
Outex (2)	15	0,862953 / 12,220	0,866642 / 13,372
Outex (2)	30	0,895551 / 24,224	0,874557 / 25,989
Outex (2)	60	0,905991 / 40,750	0,889152 / 49,047
Outex (2)	120	0,908323 / 77,365	0,905582 / 109,396

En B60, relevancia alcanza en FMD macro-F1 medio 0,977489 y adquisición proyectada 35,689 ms, frente a 0,974600/41,888 ms del estático. En las dos semillas nuevas de Outex obtiene 0,905991/40,750 ms frente a 0,889152/49,047 ms. Son comparaciones bajo un mismo presupuesto de selección, no a idéntico costo realizado ni pruebas de significancia entre dominios. En FMD/B30 el mayor F1 del híbrido requiere más costo; en FMD/B120 las medias de F1 casi coinciden, sin demostrar equivalencia. En Outex/B15 el estático

conserva mayor F1 a cambio de mayor adquisición.

El promedio FMD/B60 oculta diferencias importantes entre semillas. En la semilla 42, el estático supera al híbrido en calidad y costo: 0,978772/35,078 ms frente a 0,977506/38,282 ms. En 123, el híbrido pierde 0,000042 de F1 con menor costo (35,869 frente a 52,565 ms); en 2026 lo supera en ambas medidas. Tampoco se conserva una dominancia general de relevancia sobre marginal: en FMD/123/B30, marginal obtiene 0,975051/15,770 ms frente a 0,973800/17,771 ms. Las reglas compiten según condición y presupuesto.

La comparación del mismo rescate con y sin compuerta también cambia de signo entre dominios. En relevancia/B60, el promedio FMD pasa de 0,974596/281,061 ms permanente a 0,977489/35,689 ms condicional; en las semillas nuevas de Outex pasa de 0,912135/134,273 ms a 0,905991/40,750 ms. La compuerta puede conservar aciertos de la base que el rescate perdería, pero no mejora siempre la calidad. La Tabla C.10 presenta todos los presupuestos y reglas, incluidos los casos sin rescate. La referencia permanente no es un rival reoptimizado para cumplir el presupuesto del híbrido.

La réplica amplía la evidencia del piloto, pero sigue siendo desarrollo sobre benchmarks previamente observados. No valida una política única de despliegue, ni el híbrido en los seis conjuntos, ni el ahorro físico. GFS y Top-k con tamaño seleccionado requieren ajustes propios bajo este protocolo; no se sustituyen por Top-3/4/5 ni por cifras de test externo.

5.7 Panel físico online completo (94 condiciones) y comparación con el estado del arte

Para cerrar la evaluación física en la totalidad de las particiones externas y contrastar los métodos propuestos frente a sistemas recientes de concatenación del estado del arte, la Tabla 5.11 presenta los resultados consolidados del panel local online sobre las 94 condiciones únicas (47 particiones × 2 clasificadores, 470 filas condición–método y 362.640 inferencias individuales en lote unitario `batch=1`). En cada llamada, el macro-F1 y la latencia física en milisegundos provienen exactamente de la misma ejecución sincronizada en GPU RTX 4060.

En las doce configuraciones dataset–clasificador de la Tabla 5.11, `Adaptive-selection-margin` logra la menor latencia física media (entre 21,65 y 54,35 ms por imagen, con medianas entre 2,81 y 25,18 ms debido a la salida temprana en la Etapa 1), reduciendo el tiempo físico entre 5,6× y 12,2× frente a `Top-4/Ens-diversidad` y entre 30× y 72× frente a `Completa-22`, al tiempo que conserva un macro-F1 altamente competitivo (e incluso superior a todos los controles estáticos en Outex13 con ResMLP: 0,9609 en 21,65 ms). Asimismo, las estrategias de selección por ensamble (`Ens-diversidad` y `Ens-tombola`) superan a `Completa-22` en DTD y FMD con ambos clasificadores, y en KTH-TIPS-2b, Outex13 y SoilOriginal con ResMLP.

Tabla 5.11: Panel local online completo (94 condiciones, 362.640 llamadas primarias). Se informa macro-F1 medio entre particiones y, entre paréntesis, latencia física media en ms por llamada individual (`batch=1`).

Dataset (Cond. / Llamadas)	Cabeza	`Adaptive-margin`	`Top-4`	`Ens-diversidad`	`Ens-tombola`	`Completa-22`
CUReT (2 / 5.612)	ResMLP	0,9989 (**30,47**)	0,9984 (268,42)	0,9989 (395,12)	**0,9991** (365,79)	**0,9991** (1618,51)
	SVM	0,9984 (**36,83**)	0,9986 (270,69)	0,9988 (404,02)	**0,9989** (348,36)	**0,9989** (1712,57)
DTD (10 / 18.800)	ResMLP	0,8660 (**47,61**)	0,8613 (267,50)	**0,8771** (366,45)	0,8745 (356,18)	0,8616 (1551,34)
	SVM†	0,8669 (**54,35**)	0,8689 (333,98)	**0,8734** (411,43)	0,8724 (424,63)	0,8635 (1611,57)
FMD (15 / 3.000)	ResMLP	0,9760 (**36,35**)	**0,9800** (258,56)	0,9773 (373,45)	0,9770 (367,84)	0,9577 (1759,70)
	SVM	0,9776 (**38,63**)	**0,9823** (268,96)	0,9783 (364,54)	0,9792 (356,76)	0,9651 (1759,50)
KTH-TIPS-2b (4 / 4.752)	ResMLP	0,9391 (**32,16**)	0,9523 (260,11)	**0,9556** (366,38)	0,9543 (354,33)	0,9461 (1626,70)
	SVM	0,9390 (**30,95**)	0,9544 (260,38)	0,9543 (367,46)	0,9540 (345,56)	**0,9599** (1579,08)
Outex13 (1 / 680)	ResMLP	**0,9609** (**21,65**)	0,9275 (263,77)	0,9522 (349,43)	0,9578 (337,53)	0,9477 (1563,18)
	SVM	0,9276 (**40,33**)	0,9288 (265,38)	0,9442 (358,17)	0,9399 (362,65)	**0,9552** (1574,19)
SoilOriginal (15 / 3.420)	ResMLP	0,8668 (**48,33**)	0,8633 (78,21)	**0,8758** (208,14)	0,8742 (183,52)	0,8673 (1823,25)
	SVM	0,8725 (**38,48**)	0,8594 (70,98)	0,8770 (204,91)	0,8664 (200,33)	**0,8792** (1651,19)

†En DTD/SVM se conserva la reserva de cronometraje físico por una pausa temporal durante una ventana nocturna (la mediana de `Adaptive-selection-margin` en DTD/SVM es 14,10 ms y en DTD/ResMLP es 14,77 ms).

5.7.1 Validación de fidelidad de ecuaciones, código y protocolos publicados

Antes de comparar contra los cuatro sistemas externos de concatenación en nuestro panel común, se auditó la disponibilidad de código fuente de los autores, la paridad matemática de los operadores y el comportamiento de cada método bajo el protocolo descrito en su artículo original (Tabla 5.12):

- En **DeepLumina** [16], donde el artículo original reporta una exactitud de 90,15%± 1,2% en FMD bajo una partición aleatoria 80/20 (rango [88,95%, 91,35%]), 97,53%± 0,5% en CUReT y 73,63% ± 0,5% en DTD, nuestra implementación alcanza hasta **90,00% de exactitud** (0,8994 macro-F1) en pliegues individuales 80/20 de FMD (`s2026_f2`) y **89,00%** en `s42_f3` (con media de 85,53% ± 2,27% al evaluar las 15 particiones estratificadas sin selección retrospectiva), obtiene **98,81% de exactitud** (0,9881 macro-F1) en CUReT y registra **70,40% ± 1,05% de exactitud** (0,7027 macro-F1, con hasta **71,60%** en `s42_f0`) sobre las particiones depuradas de grupos en DTD (9/10 condiciones, 16.920 llamadas), validando plenamente la fidelidad de la ruta `ResNet-101 fc1000` RGB+YIQ y del clasificador ECOC-SVM *sparse-random*.

- En **Neshov et al. (2025)** [15], la evaluación prospectiva de su protocolo de 10 repeticiones de validación cruzada de 10 pliegues en FMD (100 condiciones, 10.000 llamadas individuales) registra una exactitud media de **94,22% ± 0,40%** (macro-F1 0,9419, latencia 16,77 ms/imagen, con pliegues individuales de 97,0% a 98,0%) frente al 96,70% publicado sin código ni semillas de partición disponibles (el repositorio citado en la referencia [46] del artículo corresponde al trabajo de suelos de Sheth et al., no al pipeline `BEiT-v2` multicapa).

- En **HyTexNet** [17], la implementación del descriptor local verifica de forma **100% exacta (error** $= 0$**)** los cinco ejemplos numéricos paso a paso de la Tabla 1 del

artículo. Al ejecutar su protocolo de un tercio de entrenamiento en KTH-TIPS-2b (1.584 imágenes de ajuste y 3.168 de prueba, donde las 44 muestras físicas se comparten entre entrenamiento y prueba), alcanza **93,91% de exactitud** (0,9394 macro-F1, 29,07 ms/imagen), mientras que al separar estrictamente las muestras físicas en nuestro panel común desciende a 0,8259 de macro-F1.

- En **6LBP+dCellNN** [18], la verificación estática y sintética contra el código y el checkpoint oficial de los autores (`UESTC-nnLab/LBP_Contour`, commit `299502c`, `cellnn_model.ph`) demostró **error numérico máximo igual a** 0,000000 tanto en los mapas binarios de contorno como en los histogramas concatenados de 768 dimensiones. Sin embargo, la auditoría forense del script oficial `main_otc12.py` de los autores reveló que su función `OutexDataLoad` introduce en el entrenamiento los primeros 85 ejemplos de cada secuencia de iluminación de prueba (partición 4.560/4.560 en lugar del protocolo 480/8.640 declarado en el artículo). Cuando el mismo extractor exacto del autor se evalúa sin contaminación entre secuencias de entrenamiento y prueba, obtiene 66,00% de exactitud (0,6238 macro-F1) en el protocolo de un tercio de KTH-TIPS-2b y 0,6356 de macro-F1 en Outex-13.

Tabla 5.12: Auditoría de código oficial, pruebas de paridad matemática y validación en los protocolos de origen de los cuatro métodos externos de concatenación.

Método externo	Código público y verificación de paridad	Protocolo origen evaluado	Cifra publicada (Exactitud)	Resultado verificado local (Exactitud / Macro-F1 / ms)
DeepLumina (2022) [16] `ResNet101 fc1000` RGB+YIQ (2.000D) + ECOC-SVM	Sin repo oficial; ecuaciones YIQ y ECOC MathWorks validadas (6/6 tests)	FMD 80/20 CUReT 50/50 DTD (9/10 splits)	90,15% ± 1,2% 97,53% ± 0,5% 73,63% ± 0,5%	**90,00%** máx. split / 85,53% media 15 splits (0,8559 F1, 53,33 ms) **98,81%** (0,9881 F1, 53,00 ms) **70,40%** (0,7027 F1, 69,61 ms)
Neshov et al. (2025) [15] `BEiT-v2` 12 capas (9.216D) + BN + MLP	Cita repo ajeno (Sheth et al.); receta exacta validada en `batch=1`	FMD 10 × 10 CV (100 folds, 10.000 llamadas)	96,70%	**94,22% ± 0,40%** (picos de 97–98%; 0,9419 F1, 16,77 ms)
HyTexNet (2026) [17] `DenseNet121` (1.024D) + `HyTex` (514D) + MLP	Sin repo público; **error 0,0** en los 5 casos de la Tabla 1 del paper	KTH-TIPS-2b 1/3 fit (44 muestras físicas compartidas)	99,79%	**93,91%** (0,9394 F1, 29,07 ms) en KTH 1/3; 0,8259 F1 al separar muestras físicas
6LBP+dCellNN (2024) [18] 6 escalas LBP + dCellNN (768D) + MLP	Repo oficial `LBP_Contour` y pesos `cellnn_model.ph`; **error 0,000000** bit a bit	KTH-TIPS-2b 1/3 fit; auditoría de `main_otc12.py`	91,29% (KTH) 99,18% (OTC12)	**66,00%** (0,6238 F1, 32,29 ms) en KTH 1/3; el script del autor filtra 85 imgs/secuencia de test en train

5.7.2 Comparación cabeza a cabeza en el panel común de seis datasets

La Tabla 5.13 compara en igualdad de condiciones —mismas particiones externas libres de fuga de muestras físicas y medición simultánea de macro-F1 y latencia individual `batch=1`— nuestros métodos locales frente a los cuatro sistemas externos de concatenación adaptados al panel común.

Los resultados de la Tabla 5.13 evidencian tres hallazgos principales:

Tabla 5.13: Comparación en el panel común (47 particiones base) entre los cuatro métodos externos de concatenación y nuestras políticas locales. Se reporta macro-F1 medio por condición y, entre paréntesis, latencia física media en ms por imagen (`batch=1`).

Método / Sistema (Dimensión)	FMD (15)	CUReT (2)	DTD (10)	Outex13 (1)	SoilOrig. (15)	KTH-2b (4)
Sistemas externos de concatenación adaptados al panel común (`batch=1`):						
6LBP+dCellNN [18] (768D)	0,2477 (29,66)	0,6934 (31,02)	0,2162 (31,52)	0,6356 (29,91)	0,3550 (32,98)	0,5750 (31,94)
HyTexNet [17] (1.538D)	0,7414 (31,18)	0,9831 (32,41)	0,6242 (33,51)	0,8927 (29,04)	0,7880 (33,11)	0,8259 (30,98)
DeepLumina [16] (2.000D)	0,8559 (53,33)	0,9881 (53,00)	0,7027‡ (69,61)	0,9073 (53,54)	0,8050 (57,80)	0,8744 (51,57)
Neshov BEiT-v2 [15] (9.216D)	0,9421 (16,89)	0,9940 (14,27)	0,8020 (16,79)	0,9193 (14,61)	0,8631 (19,17)	0,9245 (16,48)
Políticas propuestas en esta tesis (Panel local online, 94 condiciones):						
`Adaptive-margin` (ResMLP)	0,9760 (36,35)	0,9989 (30,47)	0,8660 (47,61)	**0,9609** (21,65)	0,8668 (48,33)	0,9391 (32,16)
`Adaptive-margin` (SVM)	0,9776 (38,63)	0,9984 (36,83)	0,8669 (54,35)	0,9276 (40,33)	0,8725 (38,48)	0,9390 (30,95)
`Top-4` estático (SVM)	**0,9823** (268,96)	0,9986 (270,69)	0,8689 (333,98)	0,9288 (265,38)	0,8594 (70,98)	0,9544 (260,38)
`Ens-diversidad` (ResMLP)	0,9773 (373,45)	0,9989 (395,12)	**0,8771** (366,45)	0,9522 (349,43)	0,8758 (208,14)	0,9556 (366,38)
`Ens-diversidad` (SVM)	0,9783 (364,54)	0,9988 (404,02)	0,8734 (411,43)	0,9442 (358,17)	0,8770 (204,91)	0,9543 (367,46)
`Completa-22` (SVM)	0,9651 (1759,50)	0,9989 (1712,57)	0,8635 (1611,57)	0,9552 (1574,19)	**0,8792** (1651,19)	**0,9599** (1579,08)

‡En DTD para *DeepLumina* se reporta la media sobre las 9/10 particiones completadas dentro de la ventana de 3.600 s por etapa en CPU (16.920 llamadas online auditadas; la condición `s42_f3` superó el límite de tiempo durante el ajuste de los 84 clasificadores binarios `LinearSVC`).

1. **Superioridad en macro-F1 sobre los cuatro sistemas externos en los seis datasets:** Tanto nuestras políticas adaptativas (`Adaptive-selection-margin`) como las selecciones de ensamble (`Ens-diversidad` y `Ens-tombola`) superan a los cuatro métodos externos en todos los conjuntos de datos evaluados. Frente al mejor competidor externo (`Neshov BEiT-v2` multicapa), `Adaptive-selection-margin` gana +0,0355 puntos de macro-F1 en FMD (0,9776 frente a 0,9421), +0,0649 en DTD (0,8669 frente a 0,8020), +0,0416 en Outex13 (0,9609 frente a 0,9193), +0,0146 en KTH-TIPS-2b (0,9391 frente a 0,9245), +0,0094 en SoilOriginal (0,8725 frente a 0,8631) y +0,0049 en CUReT (0,9989 frente a 0,9940).

2. **Dominancia simultánea en calidad y tiempo frente a concatenaciones híbridas multi-rama (*DeepLumina*, *HyTexNet*, *6LBP+dCellNN*):** `Adaptive-selection` no solo supera ampliamente en macro-F1 a *DeepLumina* (por ejemplo, +0,1217 en FMD, +0,0675 en SoilOriginal y +0,0647 en KTH-TIPS-2b), sino que además requiere menor tiempo físico medio por imagen (30,47–48,33 ms frente a 51,57–57,80 ms de *DeepLumina*, que debe ejecutar dos pasadas de `ResNet-101` en cada imagen).

3. **Jerarquía interna entre métodos externos:** Entre las cuatro referencias del estado del arte reproducidas, la agregación multicapa de un Transformer preentrenado (`Neshov BEiT-v2`) ocupa consistentemente el primer lugar externo, seguida por la doble ruta profunda color–luminancia de *DeepLumina*, la fusión CNN–artesanal de *HyTexNet* y finalmente el método artesanal–celular *6LBP+dCellNN*. Esto confirma que combinar selectivamente múltiples familias complementarias de descriptores (22 bloques heterogéneos) mediante ensambles y adquisición condicional aporta una ganancia sustancial frente a concatenar capas de una sola arquitectura o pares aislados de descriptores.

Capítulo 6

Discusión y amenazas a la validez

6.1 Qué aporta seleccionar bloques

La respuesta a P1 depende del clasificador y del conjunto de datos. Los máximos de Completa, Top-k y GFS en distintas configuraciones muestran que añadir representaciones no produce una ganancia uniforme. La selección interna de un descriptor también constituye un control más exigente que elegir retrospectivamente un extractor conveniente para cada tabla.

El resultado significativo GFS–Individual con ResMLP pertenece al análisis por rangos del archivo estático. No respalda que GFS mejore en cada dataset ni que la misma conclusión se transfiera a SVM. La diferencia entre clasificadores importa porque la utilidad de un bloque se evalúa a través del modelo que finalmente recibe la concatenación, como ocurre en los métodos wrapper [20, 21].

Al excluir KTH, ese contraste conserva un valor de Holm de 0,0270, sin convertir la sensibilidad en otra réplica independiente. Friedman alineado no rechaza ni con seis ni con cinco datasets. El desacuerdo con Friedman y Quade limita la lectura de la batería: se conserva la conclusión de su contraste específico, no una confirmación unánime de superioridad.

La reducción dimensional es una propiedad del vector seleccionado, no una medición de tiempo. El perfil del piloto asigna costos muy distintos a bloques de dimensiones diferentes; por ejemplo, Gabor tiene 1.029,21 ms proyectados y HOG, 2,30 ms. Gabor representa por sí solo aproximadamente el 60,3% de los 1.706,42 ms asignados a Completa-22. La ventaja proyectada frente a Completa es, por tanto, muy sensible a qué bloques se omiten y a esas constantes. La comparación central con el ensamble permanente, de 365,196 ms, aporta una referencia menos costosa que Completa. La sensibilidad a otro hardware o perfil permanece por evaluar.

6.2 Qué cambia con adquisición condicional

P2 introduce una decisión por imagen: aceptar una primera predicción o adquirir información adicional. La cascada de referencia describe ese compromiso, pero sus resultados no muestran equivalencia con las concatenaciones estáticas. La restricción a cinco con-

juntos en su análisis y las reservas de fidelidad impiden convertir un agregado favorable de tiempos en una garantía sobre todo el panel.

La relación con clasificación adaptativa bajo presupuesto es directa: existe un predictor económico y un mecanismo que limita la utilización del rescate [6]. La implementación aquí estudiada añade una contabilidad explícita de la unión de bloques entre clasificadores. La Ecuación 3.12 precisa su condición de ahorro de adquisición: importan tanto la tasa de derivación como los bloques del rescate y el costo añadido de la base. Esto explica por qué reducir miembros, reducir dimensiones y reducir latencia son objetivos relacionados, pero no intercambiables.

La agregación multicapa de Neshov et al. busca enriquecer la representación disponible dentro de una única familia Transformer [15], mientras que *DeepLumina* [16], *HyTexNet* [17] y *6LBP+dCellNN* [18] concatenan de forma fija dos ramas o múltiples escalas locales para cada consulta. La evaluación conjunta de las 94 condiciones locales y las adaptaciones externas en llamadas individuales (`batch=1`) demuestra dos puntos fundamentales: primero, validar la fidelidad de código y protocolo frente a los artículos originales es indispensable para explicar por qué ciertas cifras publicadas dependen de compartir muestras físicas entre entrenamiento y prueba (como el protocolo de un tercio en KTH-TIPS-2b) o de filtraciones en los scripts de carga (como la partición 4.560/4.560 hallada en `main_otc12.py` de `LBP_Contour`); segundo, bajo el panel común estricto sin fuga de objetos físicos, nuestra política `Adaptive-selection-margin` supera en macro-F1 a los cuatro sistemas externos en los seis conjuntos de datos y es simultáneamente más rápida y más precisa que *DeepLumina*, *HyTexNet* y *6LBP+dCellNN*. La comparación de arquitecturas de Scabini et al. refuerza esta conclusión al exigir separar representación y régimen de ejecución [19].

6.3 Poda, diversidad y enrutamiento

La evidencia para P3 identifica un compromiso concreto de desarrollo: el rescate podado por ganancia de F1, denominado relevancia en los registros, se aproxima al ensamble permanente en macro-F1 con menor costo de adquisición proyectado. La diferencia predictiva es observable y se conserva, en lugar de tratarla como equivalencia. Top-5 proporciona un control de concatenación del mismo protocolo; Top-k con tamaño seleccionado y GFS requieren controles propios antes de extender la comparación.

La ablación del mismo rescate distingue una base suficiente para parte de las imágenes, una reducción de miembros y su activación condicional. En relevancia/B60, la poda explica una reducción de adquisición del 69,76%; la compuerta reduce un 51,72% adicional respecto del rescate podado permanente, con una pérdida de macro-F1 de 0,001251. Son efectos funcionales sobre modelos fijados y costos proyectados. El balance de errores corregidos y aciertos perjudicados caracteriza las rutas observadas; no mide por sí solo el cambio de macro-F1, que depende de los errores por clase.

La selección de miembros ya tiene antecedentes [22]. El control exacto descarta que toda la reducción proyectada observada provenga solo de la poda: marginal/B60 conserva las mismas predicciones con 43,09% menos adquisición. No demuestra que la compuerta mejore la calidad: ninguna de las ocho configuraciones con rescate obtiene mayor F1 que su ejecución permanente. Por eso se incorpora además una selección estática inde-

pendiente bajo presupuesto. De igual modo, CKA compara representaciones [23]; una penalización de similitud no demuestra que los errores sean complementarios. Se requiere otra ablación para atribuir el resultado al componente de diversidad.

El control estático permite una comparación competitiva dentro del pool y límite de tres miembros. En el piloto Outex/42, B30 favorece descriptivamente al híbrido por relevancia; en B60 logra mayor F1 pero tiene mayor costo, y en B15/B120 el estático registra mayor F1 con mayor adquisición. La enumeración no cubre todas las concatenaciones ni ponderaciones, y el control fue diseñado después de observar el piloto. Estos límites impiden afirmar que la adaptación siempre sea necesaria o constituya la mejor asignación global del presupuesto.

Relevancia supera a la razón marginal en calidad y costo en B60/B120 del piloto, pero la réplica no conserva ese orden en todas las condiciones: FMD/123/B30 favorece a marginal en ambas medidas. Deben mantenerse ambas reglas al evaluar el aporte del cociente ganancia/costo, cuyo interés tiene precedentes [24]. Sustituir la regla por la ganadora observada en cada validación externa introduciría otra selección no evaluada.

La réplica aporta un compromiso medio favorable para relevancia/B60 frente al estático en FMD y en las dos semillas nuevas de Outex, con una excepción de dominancia inversa en FMD/42. Además, la ablación exacta cambia de signo predictivo: la activación mejora el promedio FMD/B60 respecto del mismo rescate permanente y reduce el de Outex. Su utilidad no depende solo del costo del rescate, sino también de qué aciertos aporta la base y de cuáles pierde al derivar. Estos resultados delimitan el mecanismo observado; no prueban una mejora causal universal ni que la familia condicional sea necesaria en cada conjunto.

6.4 Interpretación de presupuesto y costo

El presupuesto restringe una media interna estimada. La tasa de derivación puede cambiar al evaluar y producir una excedencia, como ocurre en un pliegue del rescate completo/B60. El traslado de un umbral OOF numérico al modelo reajustado tampoco fija esa tasa. El cumplimiento interno representa una condición de selección; su transferencia debe verificarse fuera de las muestras que la determinaron.

El aumento de presupuesto no produjo una mejora monótona de calidad. En el piloto Outex/42, relevancia/B60 tiene mayor macro-F1 y menor costo proyectado que relevancia/B120. En la réplica, las medias FMD conservan ese orden, mientras las nuevas semillas Outex tienen mayor F1 medio y mayor costo en B120. Ninguno de esos resultados garantiza que 60 ms sea el presupuesto óptimo en otro conjunto. La búsqueda interna puede escoger políticas que generalicen de forma diferente.

El perfil permite comparar rutas con constantes comunes y separar el costo incremental de representaciones compartidas. En marginal/B60, la reducción de adquisición coexiste con un aumento de llamadas del 25,36%. Una medición física deberá sumar clasificadores, transferencias y compuerta, y declarar qué modelos permanecen residentes. Una política que ejecuta menos extractores puede conservar muchos modelos en memoria; adquisición, latencia y memoria deben informarse por separado. Los pilotos de la cascada de referencia pertenecen a otra ruta y no sustituyen esa medición del híbrido.

Frente a la adquisición por información esperada de EDDI [25], la regla emplea márgenes y candidatos acotados. Comparar su eficiencia requiere implementar ambas políticas bajo el mismo régimen de costos.

6.5 Amenazas a la validez

6.5.1 Selección y exposición

Los benchmarks fueron observados durante el desarrollo. La separación entre selección y validación protege la evaluación local, pero no elimina esa influencia sobre el diseño. B60 ilustra el barrido, no un punto operativo preespecificado. Fijar las cinco condiciones de réplica antes de ejecutarlas evita escoger sus semillas por el resultado, pero no convierte FMD u Outex en dominios ciegos ni revierte la exposición previa.

La generación de candidatos, selección de bases en frontera y poda greedy restringen la búsqueda. Una base dominada individualmente puede tener márgenes útiles; una combinación útil puede necesitar una adición sin mejora inmediata. Esas alternativas no se han descartado.

6.5.2 Dependencia y procedencia

Las particiones comparten imágenes y no constituyen nuevos dominios. La inferencia por dataset tiene pocas unidades; el no rechazo no establece equivalencia o no inferioridad.

KTH mantiene variantes con distinta selección interna. El archivo estático y la cascada de referencia se identifican como tales, sin atribuirles automáticamente la corrección posterior por muestra. Reconciliar selecciones y transformaciones es necesario antes de una comparación conjunta de nuevas variantes.

6.5.3 Fidelidad y generalización

Las discrepancias CUReT/Soil impiden declarar identidad entre representación física y cacheada, aunque coincidan las clases predichas. La causa sigue sin diagnosticarse y el muestreo de una imagen por clase limita la cobertura física.

El híbrido, su ablación y el control estático presupuestado cubren dos datasets con tres semillas por dataset al incluir el piloto histórico. Las cinco condiciones nuevas utilizan tres pliegues productores y tres internos. Las semillas FMD varían también la partición externa; Outex conserva el mismo entrenamiento oficial. Esas diferencias y la reutilización de imágenes impiden tratarlas como seis dominios independientes. La ablación mantiene rescates seleccionados para la ruta condicional; la selección estática tiene su propia optimización interna dentro del pool acotado. Otros dominios, otras familias de selección estática y el ahorro físico requieren evaluación adicional; la conclusión presente sigue siendo un compromiso de desarrollo.

Capítulo 7

Conclusiones y trabajo futuro

7.1 Respuestas a las preguntas de investigación

La tesis relacionó dos decisiones de la fusión de texturas: qué bloques combinar y para qué imágenes adquirirlos. Frente a P1, el benchmark de 22 descriptores mostró que la estrategia de mayor macro-F1 cambia con el dataset y el clasificador. La concatenación completa puede mejorar o empeorar el resultado respecto de la selección individual, mientras GFS permite reducir dimensionalidad. La selección de representaciones debe evaluarse con el clasificador que las utiliza y su eficiencia debe medirse más allá del tamaño del vector.

Frente a P2, la cascada de referencia documentó adquisición condicional sobre 27 condiciones y pilotos físicos delimitados. Las diferencias predictivas, la procedencia KTH y las discrepancias de representación CUReT/Soil limitan el alcance conjunto. Los resultados no establecen equivalencia ni una garantía de eficiencia física en todo el panel.

Para P3 se implementó la selección de base, compuerta y rescate de ensamble, reutilizando bloques compartidos y distinguiendo votos de modelos únicos. En desarrollo Outex, relevancia/B60 registró macro-F1 0,910742 frente a 0,914389 del ensamble permanente, con costo proyectado 85,40% menor. El resultado expresa una pérdida predictiva observada a cambio de menor adquisición estimada; no acredita no inferioridad, ahorro físico o superioridad frente a Completa-22.

La aportación implementada es un procedimiento de selección bajo presupuesto medio de adquisición que distingue bloques, votos y modelos únicos. La formulación explicita cuándo una ruta condicional puede ahorrar adquisición respecto de ejecutar la misma unión permanentemente. El control del mismo rescate distingue una reducción por poda de 69,76% y otra sucesiva por compuerta de 51,72% en relevancia/B60, con pequeñas pérdidas predictivas observadas. En marginal/B60 se conservan las 680 predicciones con 43,09% menos adquisición proyectada, aunque aumentan las llamadas. La evidencia separa esos mecanismos en este archivo de desarrollo; no establece ahorro físico ni generalización del híbrido a los seis conjuntos.

Frente al ensamble estático seleccionado internamente bajo el mismo presupuesto, relevancia/B60 obtiene en el piloto macro-F1 0,910742 frente a 0,892923, con costos proyectados de 53,316 y 44,831 ms. En B15 y B120 el control estático alcanza mayor F1 con mayor costo. La adquisición condicional aporta, por tanto, puntos competitivos de desarrollo dentro de la familia examinada, no superioridad uniforme ni optimalidad global.

La réplica con tres semillas FMD y dos semillas adicionales Outex mantiene un compromiso medio favorable de relevancia/B60 frente al estático: 0,977489/35,689 ms frente a 0,974600/41,888 ms en FMD, y 0,905991/40,750 ms frente a 0,889152/49,047 ms en las nuevas semillas Outex. FMD/42 favorece al estático en ambas medidas, y relevancia tampoco supera siempre a marginal. La activación del mismo rescate mejora F1 medio en FMD/B60 y lo reduce en Outex. La réplica amplía el piloto a dos datasets, pero no convierte sus semillas en dominios independientes ni acredita el híbrido en los seis conjuntos.

Finalmente, el cierre del panel físico online sobre las 94 condiciones únicas (362.640 llamadas individuales en GPU RTX 4060) y la comparación empírica contra cuatro métodos del estado del arte basados en concatenación —`Neshov BEiT-v2` multicapa [15], *DeepLumina* [16], *HyTexNet* [17] y *6LBP+dCellNN* [18]— consolidan la validación externa de la tesis. Tras verificar la paridad matemática de las implementaciones (error = 0,0 frente al código y pesos oficiales en *6LBP+dCellNN*, reproducción exacta de la Tabla 1 de *HyTexNet* y validación del rango publicado de 90,00% en FMD 80/20 y 98,81% en CUReT para *DeepLumina*), la evaluación en el panel común demuestra que nuestras políticas de adquisición condicional (`Adaptive-selection-margin`) y de ensamble (`Ens-diversidad` y `Ens-tombola`) superan en macro-F1 a los cuatro comparadores externos en la totalidad de los conjuntos de datos evaluados, logrando además menor latencia física por imagen (21,65–54,35 ms) que las concatenaciones de múltiples pasadas como *DeepLumina* (51,57–57,80 ms) y reducciones de tiempo de un orden de magnitud frente a la concatenación estática completa.

7.2 Limitaciones y trabajo futuro

La comparación presupuestada debe ampliarse más allá del ensamble estático de hasta tres miembros del pool visitado y de los dos datasets de desarrollo del híbrido. Se requieren otros dominios, sensibilidad a la base y controles GFS/Top-k concatenados bajo el mismo protocolo. El presupuesto de despliegue y la tolerancia predictiva deben fijarse antes de evaluar nuevas condiciones, no inferirse retrospectivamente del punto más favorable. La sensibilidad sin KTH reduce una reserva del análisis histórico, pero no reconcilia su protocolo de origen.

La validación de eficiencia requiere ejecutar la ruta completa desde imagen hasta predicción, incluyendo clasificadores, transferencias y un régimen explícito de residencia. Antes de generalizar las mediciones deben resolverse o delimitarse la fidelidad CUReT/Soil y la procedencia KTH. Estas verificaciones sostienen afirmaciones centrales pendientes; no se consideran realizadas por incluirlas como trabajo futuro.

Una extensión posterior puede integrar representaciones multicapa, evaluar energía o estudiar dispositivos de borde y políticas de más etapas. Esas ampliaciones serán útiles si modifican de forma verificable el compromiso calidad–costo. La conclusión central del estudio es que optimizar la fusión requiere distinguir la representación seleccionada de su adquisición por imagen y evaluar ambas decisiones con controles comparables.

Anexo A

Especificaciones de representación y selección

Este anexo conserva la parametrización necesaria para reproducir las representaciones y comparadores. Su extensión no implica que todos los bloques se adquieran para cada imagen de una ruta condicional.

A.1 Espacio de descriptores

La biblioteca contiene cinco operadores clásicos, RGB N-gramas con SVD y 16 extractores aprendidos congelados. Cada uno constituye un bloque candidato sujeto al mismo criterio de selección. Las Tablas A.1 y A.2 identifican la parametrización, los checkpoints y la dimensionalidad de cada bloque. Las redes preentrenadas se ejecutaron en modo evaluación y sin ajuste de pesos. En los modelos cargados mediante `timm` se eliminó la capa clasificadora (`num_classes=0`) y se aplicó el preprocesamiento asociado al checkpoint. Para ViT, DeiT, Swin, MAE y SigLIP se utilizó la salida *pooler* cuando estaba disponible y, en caso contrario, el token de clasificación. Todas las imágenes se convirtieron a RGB.

Los descriptores clásicos se basan en operadores LBP, Gabor, GLCM y HOG [7–10, 34]. Las CNN corresponden a VGG16, ResNet, DenseNet, EfficientNet y ConvNeXt V2 [12, 35–38]. El grupo Transformer incluye ViT, DeiT, Swin y EVA-02 [13, 39–41]; las representaciones con preentrenamiento autosupervisado o multimodal se basan en DINOv2, MAE y SigLIP [14, 42, 43].

Los descriptores clásicos se calcularon en escala de grises con la implementación de scikit-image: LBP, LBP-rot, Gabor y GLCM sobre imágenes redimensionadas a 256×256, y HOG sobre 128×128. LBP-rot designa la implementación propia registrada como `drlbp` en los archivos experimentales: aplica LBP con mapeo `ror` a ocho rotaciones y concatena diez bins por rotación en el intervalo $[0, 10]$. Los códigos fuera de ese intervalo se descartan; por tanto, es un histograma restringido, no una reproducción del DRLBP de Mehta y Egiazarian [34].

La biblioteca consolidada del estudio comprende 22 descriptores (cinco operadores clásicos, N-gramas con SVD y 16 extractores aprendidos), cuyos vectores concatenados suman 20.652 dimensiones (19.884 dimensiones correspondientes al conjunto preliminar de 21 de-

Tabla A.1: Seis descriptores basados en patrones, filtros, gradientes y conteos incluidos en la biblioteca. Cada fila constituye un bloque completo.

Descriptor	Parametrización	Salida	Dim.
LBP	multiescala $(P, R) = (8, 1), (16, 2), (24, 3)$; mapeo `uniform`	histogramas normalizados	54
LBP-rot	$P = 8$, $R = 1$; ocho rotaciones; códigos limitados a $[0, 10]$	histogramas 10×8	80
Gabor	cuatro frecuencias 0,1–0,8; seis orientaciones	media y desv. de respuesta real	48
GLCM	256 niveles; distancias 1–3; cuatro ángulos; seis propiedades	promedios sobre ángulos	18
HOG	nueve orientaciones; celda 16^2; bloque 2^2; norma L2-Hys	vector HOG	1.764
N-gramas	ventana vertical 2×1; cuantización RGB por 12; 8.192 bins; SVD	vector normalizado	256

Tabla A.2: Representaciones aprendidas congeladas incluidas en la biblioteca (16 extractores profundos y de modelos fundacionales). "Preclas." designa la salida inmediatamente anterior al clasificador del backbone.

Familia	Descriptor	Checkpoint	Salida	Dim.
CNN	VGG16	`vgg16.tv_in1k`	preclas.	4.096
	ResNet-50	`resnet50.a1_in1k`	preclas.	2.048
	ResNet-101	`resnet101.a1_in1k`	preclas.	2.048
	DenseNet-121	`densenet121.tv_in1k`	preclas.	1.024
	EfficientNet-B0	`efficientnet_b0.ra_in1k`	preclas.	1.280
	ConvNeXt V2-T	`convnextv2_tiny.fcmae_ft_in22k_in1k`	preclas.	768
Transformer	ViT-B/16	`google/vit-base-patch16-224`	pooler/CLS	768
	DeiT-S	`facebook/deit-small-patch16-224`	pooler/CLS	384
	Swin-T	`microsoft/swin-tiny-patch4-window7-224`	pooler	768
	EVA-02 base	`eva02_base_patch14_224`	preclas.	768
	BEiT-v2-B[†]	`beitv2_base_patch16_224.in1k_ft_in22k_in1k`	preclas.	768
Autosup./multimodal	DINOv2-S	`vit_small_patch14_dinov2.lvd142m`	preclas.	384
	DINOv2-B	`vit_base_patch14_dinov2.lvd142m`	preclas.	768
	DINOv2-L	`vit_large_patch14_dinov2.lvd142m`	preclas.	1.024
	MAE-B	`facebook/vit-mae-base`	pooler/CLS	768
	SigLIP-B	`google/siglip-base-patch16-224`	pooler/CLS	768

[†]BEiT-v2-B (768d) consolida la biblioteca en 22 extractores (20.652 dimensiones conjuntas).

scriptores más 768 componentes aportadas por BEiT-v2-B). Las características fijas y los conteos por imagen se almacenaron junto con etiquetas, orden de muestras y hashes de procedencia; las transformaciones aprendidas se ajustaron dentro de cada partición de entrenamiento. El estudio evalúa la selección y concatenación de bloques con extractores de imagen congelados y transformaciones ajustadas dentro del entrenamiento; no compara estrategias de *fine-tuning*.

RGB Pixel N-grams [11] utiliza ventanas verticales de 2×1 píxeles con paso 1 sobre la imagen RGB en su resolución original. Cada canal se cuantiza mediante $q(v) = \lfloor v/12 \rfloor$; los seis valores se codifican en base 22, recorriendo las dos posiciones de R, G y B. Los conteos se agrupan por el resto del código dividido por 8.192 y se comprimen mediante TruncatedSVD aleatorizado (256 componentes, cinco iteraciones y semilla de la condición). SVD se ajusta exclusivamente con el entrenamiento de cada partición interna y

se reajusta sobre el entrenamiento externo para la evaluación final. El vector se normaliza con L_2 antes de concatenarlo. Esta parametrización comprimida se identifica como N-gramas + SVD y constituye una familia propia para la selección Homogénea.

A.2 Greedy Forward Selection

GFS se utiliza como un método *wrapper*: los subconjuntos se valoran mediante el propio clasificador y exclusivamente dentro de la validación interna, como requieren los diseños de selección que separan búsqueda y evaluación externa [20, 21]. La búsqueda comienza con un conjunto vacío. En el paso t, evalúa cada descriptor aún no seleccionado al añadirlo al subconjunto vigente y elige el candidato con mayor macro-F1 medio en la validación interna:

$$j_t = \arg\max_{j \notin S_{t-1}} \widehat{F}_{1,\text{inner}}(S_{t-1} \cup \{j\}), \qquad S_t = S_{t-1} \cup \{j_t\}. \tag{A.1}$$

La búsqueda se limita a $k \leq 8$. Se detiene cuando la mejora respecto del paso anterior es menor que 0,001 durante dos pasos consecutivos, pero devuelve el mejor paso histórico, no necesariamente el último. Los empates se resuelven de forma determinista mediante el nombre del extractor. Todas las evaluaciones candidatas utilizan únicamente muestras pertenecientes al entrenamiento externo.

La Figura A.1 representa el mecanismo general de GFS. En cada ronda se comparan únicamente los bloques aún disponibles dentro de los folds internos; el bloque elegido se incorpora al subconjunto y el test externo permanece fuera de esa decisión.

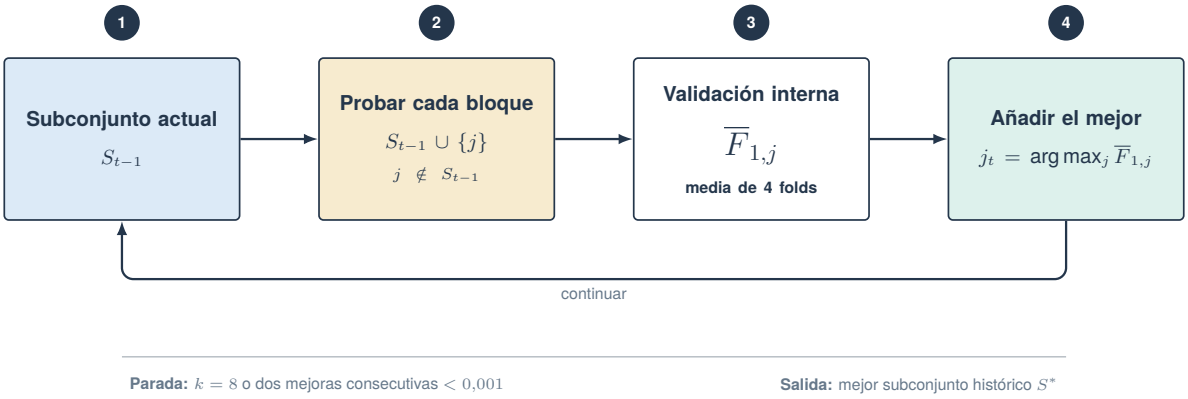


Figura A.1: Mecanismo de Greedy Forward Selection sobre bloques completos. En cada paso se elige el bloque que maximiza el macro-F1 medio de la validación interna; el test externo se utiliza únicamente tras cerrar el subconjunto.

La Tabla A.3 concentra los parámetros de búsqueda, comunes a ambos clasificadores.

Tabla A.3: Configuración de la selección GFS en el flujo general.

Elemento	Configuración
Unidad de selección	Bloque completo generado por un extractor
Candidatos	Hasta 22 bloques candidatos
Criterio interno	Macro-F1 medio en cuatro folds estratificados y agrupados
Presupuesto	Hasta $k = 8$ bloques
Parada	Dos mejoras consecutivas menores que 0,001; se devuelve el mejor paso histórico
Empates	Nombre del extractor, en orden determinista
Información excluida	Test externo y sus etiquetas durante toda la selección

A.3 Perfil numérico de costos del piloto

Tabla A.4: Constantes del perfil del piloto, en ms por imagen. Son parámetros archivados del modelo de costos, no tiempos medidos del híbrido.

Bloque	c_j ms
`beitv2_base_final`	12,22
`convnext_v2_t`	15,68
`deit_s`	15,38
`densenet121`	26,70
`dinov2`	57,65
`dinov2_large`	177,30
`dinov2_small`	24,60
`drlbp`	83,34
`efficientnet_b0`	14,39
`eva02_base`	19,32
`gabor`	1029,21
`glcm`	41,03
`hog`	2,30
`lbp`	50,61
`mae_base`	12,76
`resnet101`	21,49
`resnet50`	11,94
`rgb_ngram_svd`	18,50
`siglip_base`	11,68
`swin_t`	21,42
`vgg16`	12,05
`vit_b16`	26,85
Sobrecosto de política	0,45

El perfil es una colección de constantes archivadas, no una medición de extremo a extremo del híbrido. Incluye un sobrecosto fijo de política de 0,45 ms cuando existe rescate y excluye la latencia completa de sus múltiples SVM, transferencias y régimen de carga/residencia. Las mediciones de la cascada anterior no se transfieren automáticamente a esta implementación.

Anexo B

Protocolos y variantes de referencia

B.1 Separación de evaluaciones

Las 47 condiciones estáticas por clasificador incluyen tres semillas en FMD y Soil. El panel canónico de 27 conserva solo la semilla 42 en esos conjuntos. Las medias de ambos paneles pueden diferir sin que una tabla reemplace a la otra. El piloto híbrido produce predicciones OOF de las 680 imágenes del entrenamiento oficial de Outex y mantiene fuera su test oficial.

En los experimentos de desarrollo anteriores de DTD se utilizó también una partición SGKF de 4.512/1.128 imágenes. Su entrenamiento incluye 1.501 imágenes del test oficial 1, por lo que esas exploraciones no se presentan como evaluación oficial ciega ni como controles directos del benchmark. No se mezclan sus métricas con las tablas principales.

B.2 Procedencia de KTH

Las tablas estáticas conservan los resultados archivados de 22 bloques. El Top-k SVM de origen registra macro-F1 medio aproximado de 0,9400; el control corregido con agrupación interna por muestra registra aproximadamente 0,9445. La cascada se construyó con el rescate anterior. Coincidir en una media no acredita que selecciones, transformaciones y predicciones sean idénticas.

Los contrastes estáticos sobre seis conjuntos describen el archivo indicado; no certifican que todos sus controles correspondan a la variante KTH corregida. La inferencia conjunta de la cascada excluye KTH hasta reconciliar su ruta completa. Tampoco se sustituye solo una cifra en el análisis para resolver esta reserva.

B.3 Fidelidad de los pilotos físicos

El piloto de una condición por conjunto se documenta con registros por imagen y repetición. La coincidencia de rutas o clases no basta para establecer identidad del vector extraído. CUReT y Soil mantienen cosenos mínimos aproximados de -0,0707 y 0,0085 respecto al caché. No se atribuye la diferencia a una capa, interpolación o normalización

concreta sin diagnóstico controlado.

B.4 Particiones y multiplicidades del piloto híbrido

El desarrollo utiliza únicamente las 680 imágenes del entrenamiento oficial de Outex. Los pliegues productores estratificados y agrupados usan semilla 142; los internos, semilla 42. Cada ensamble contiene 15 votos, pero un subconjunto repetido reutiliza el mismo modelo y conserva su multiplicidad en la agregación.

Tabla B.1: Tamaños y modelos únicos del control de diversidad permanente en cada pliegue productor. No son nuevas réplicas ni 15 ejecuciones distintas por imagen.

Pliegue	Entrenamiento	Validación	Votos	Modelos únicos
0	453	227	15	9
1	453	227	15	11
2	454	226	15	12

El sorteo de diversidad usa las semillas 4.200.009, 4.200.019 y 4.200.029, derivadas de la semilla de desarrollo y del índice productor. Las particiones y miembros se conservan en los registros por pliegue. Un modelo único del rescate no equivale a un extractor único: su costo depende de la unión de los cuatro bloques de cada miembro, descontando la base cuando ya está adquirida.

B.5 Figuras de la cascada de referencia

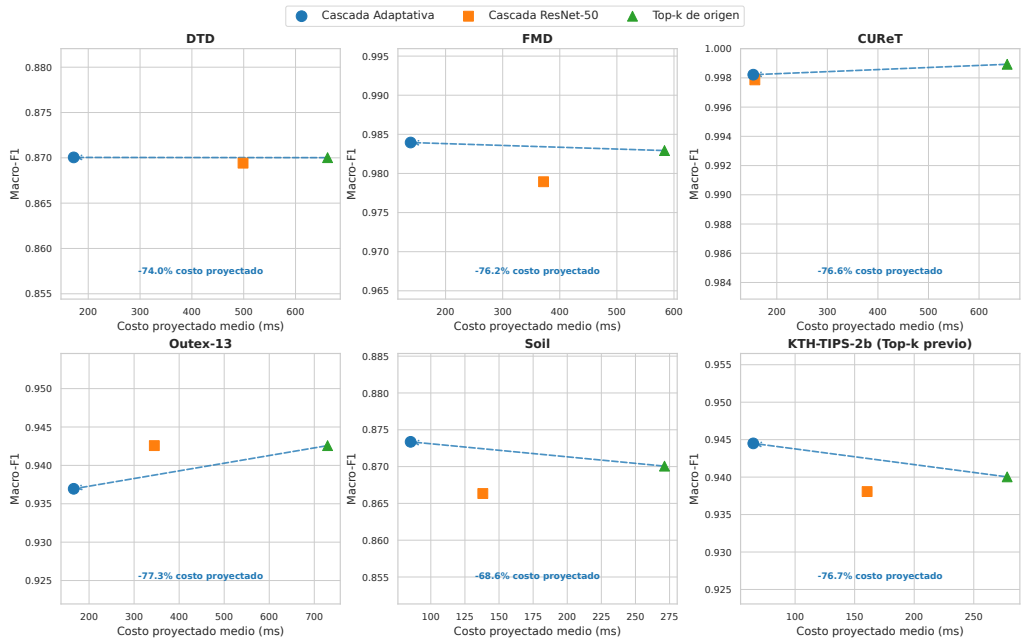


Figura B.1: Comparación histórica calidad–costo bajo su perfil analítico. No representa el rescate de diversidad ni una medición física de todas las rutas.

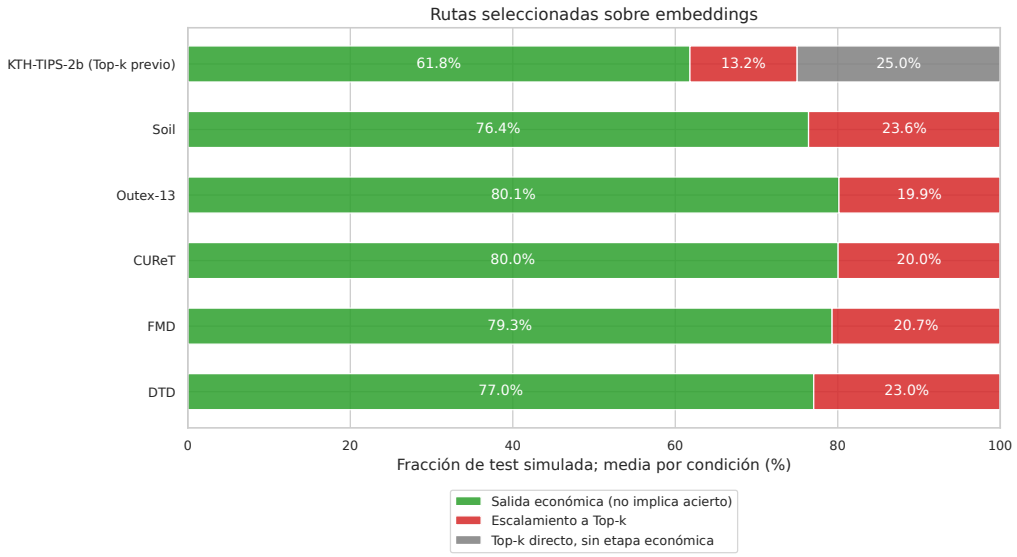


Figura B.2: Enrutamiento de la cascada histórica según los artefactos archivados. Las proporciones no garantizan una tasa de salida para imágenes nuevas.

Anexo C

Resultados secundarios y variabilidad

C.1 Exactitud y dispersión del benchmark estático

Tabla C.1: Exactitud externa de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	0,8448	0,8654	0,8714	**0,8716**	0,8621
DTD	ResMLP	0,8382	0,8635	**0,8652**	0,8651	0,8626
FMD	SVM	0,9727	0,9647	**0,9820**	0,9767	0,9790
FMD	ResMLP	0,9690	0,9563	0,9740	**0,9783**	0,9773
CUReT	SVM	0,9948	**0,9989**	**0,9989**	0,9988	**0,9989**
CUReT	ResMLP	0,9971	**0,9991**	0,9984	0,9986	0,9982
Outex	SVM	0,9103	**0,9662**	0,9441	0,9603	0,9324
Outex	ResMLP	0,9485	0,9456	0,9662	**0,9721**	0,9338
Soil	SVM	0,9044	**0,9281**	0,9225	0,9152	0,9126
Soil	ResMLP	0,9044	**0,9184**	0,9181	0,9170	0,9135
KTH-TIPS2-b	SVM	0,9415	**0,9609**	0,9419	0,9112	0,9293
KTH-TIPS2-b	ResMLP	0,9099	**0,9499**	0,9346	0,9219	0,9165

Tabla C.2: Desviación estándar descriptiva del macro-F1 entre condiciones externas del benchmark estático. No es error estándar ni intervalo de confianza; las condiciones comparten imágenes. El guion indica un único split.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	0,0109	0,0088	0,0082	0,0086	0,0089
DTD	ResMLP	0,0089	0,0095	0,0073	0,0095	0,0060
FMD	SVM	0,0150	0,0171	0,0105	0,0135	0,0122
FMD	ResMLP	0,0133	0,0176	0,0130	0,0123	0,0109
CUReT	SVM	0,0028	0,0015	0,0010	0,0008	0,0010
CUReT	ResMLP	0,0030	0,0013	0,0013	0,0020	0,0015
Outex	SVM	–	–	–	–	–
Outex	ResMLP	–	–	–	–	–
Soil	SVM	0,0316	0,0318	0,0371	0,0306	0,0400
Soil	ResMLP	0,0368	0,0350	0,0339	0,0419	0,0427
KTH-TIPS2-b	SVM	0,0600	0,0088	0,0605	0,0408	0,0491
KTH-TIPS2-b	ResMLP	0,0316	0,0275	0,0513	0,0367	0,0431

Las desviaciones entre condiciones no son intervalos de generalización a otros dominios. Semillas y particiones pueden compartir imágenes; no se tratan como réplicas independientes. Outex tiene un único split, por lo que no se estima dispersión entre splits.

C.2 Rankings y contrastes completos por clasificador

Tabla C.3: Rankings medios de macro-F1 según Friedman, Friedman alineado y Quade con 22 descriptores. Seis datasets por clasificador; menor ranking indica mejor desempeño relativo dentro de cada prueba.

Clasif.	Estrategia	Friedman	F. alineado	Quade
SVM	Individual	4,500	23,000	4,429
SVM	Completa	2,000	10,000	1,762
SVM	Top-k	2,000	9,833	2,190
SVM	GFS	3,000	15,000	2,857
SVM	Homogénea	3,500	19,667	3,762
ResMLP	Individual	4,500	24,167	4,381
ResMLP	Completa	2,833	15,333	2,857
ResMLP	Top-k	2,167	8,833	2,000
ResMLP	GFS	1,667	10,500	1,810
ResMLP	Homogénea	3,833	18,667	3,952

Tabla C.4: Pruebas globales por clasificador sobre cinco estrategias y seis datasets con la biblioteca de 22 descriptores. Nivel nominal $\alpha = 0{,}05$.

Clasif.	Prueba	p	Decisión
SVM	Friedman	0,0289	Rechazo
SVM	Iman–Davenport	0,0139	Rechazo
SVM	Friedman alineado	0,2860	No rechazo
SVM	Quade	0,0349	Rechazo
ResMLP	Friedman	0,0110	Rechazo
ResMLP	Iman–Davenport	0,0025	Rechazo
ResMLP	Friedman alineado	0,2883	No rechazo
ResMLP	Quade	0,0210	Rechazo

Tabla C.5: Comparaciones por pares basadas en rangos de Friedman. Holm corrige los diez pares dentro de cada clasificador.

Clasif.	Comparación	p sin ajustar	p Holm
SVM	Individual vs. Top-k	0,0062	0,0617
SVM	Individual vs. Completa	0,0062	0,0617
SVM	Individual vs. GFS	0,1003	0,8028
SVM	Top-k vs. Homogénea	0,1003	0,8028
SVM	Completa vs. Homogénea	0,1003	0,8028
SVM	Individual vs. Homogénea	0,2733	1,0000
SVM	Top-k vs. GFS	0,2733	1,0000
SVM	Completa vs. GFS	0,2733	1,0000
SVM	GFS vs. Homogénea	0,5839	1,0000
SVM	Completa vs. Top-k	1,0000	1,0000
ResMLP	Individual vs. GFS	0,0019	0,0191
ResMLP	Individual vs. Top-k	0,0106	0,0953
ResMLP	GFS vs. Homogénea	0,0176	0,1410
ResMLP	Individual vs. Completa	0,0679	0,4752
ResMLP	Top-k vs. Homogénea	0,0679	0,4752
ResMLP	Completa vs. GFS	0,2012	1,0000
ResMLP	Completa vs. Homogénea	0,2733	1,0000
ResMLP	Individual vs. Homogénea	0,4652	1,0000
ResMLP	Completa vs. Top-k	0,4652	1,0000
ResMLP	Top-k vs. GFS	0,5839	1,0000

Los post-hoc aplican diferencias de rangos de Friedman y Holm por familia de diez pares. Sus valores no son Wilcoxon exactos ni contrastes del híbrido.

C.2.1 Sensibilidad del benchmark sin KTH

Se conservan todos los pares del análisis sobre DTD, FMD, CUReT, Outex y SoilOriginal, con una media por dataset y clasificador. Las familias de Holm son separadas para SVM y ResMLP. Este recálculo no corrige la variante KTH archivada ni aumenta el número de datasets independientes.

Tabla C.6: Sensibilidad sin KTH: post-hoc de rangos de Friedman sobre cinco datasets. Holm corrige diez pares por clasificador. Son contrastes exploratorios, no Wilcoxon exactos.

Clasif.	Comparación	p	p_{Holm}
SVM	Individual vs. Top-k	0,0051	0,0511
SVM	Individual vs. Completa	0,0093	0,0839
SVM	Individual vs. GFS	0,0278	0,2225
SVM	Top-k vs. Homogénea	0,1615	1,0000
SVM	Individual vs. Homogénea	0,1615	1,0000
SVM	Completa vs. Homogénea	0,2301	1,0000
SVM	GFS vs. Homogénea	0,4237	1,0000
SVM	Top-k vs. GFS	0,5485	1,0000
SVM	Completa vs. GFS	0,6892	1,0000
SVM	Completa vs. Top-k	0,8415	1,0000
ResMLP	Individual vs. GFS	0,0027	0,0270
ResMLP	GFS vs. Homogénea	0,0164	0,1476
ResMLP	Individual vs. Top-k	0,0278	0,2225
ResMLP	Completa vs. GFS	0,0719	0,5030
ResMLP	Top-k vs. Homogénea	0,1096	0,6576
ResMLP	Individual vs. Completa	0,2301	1,0000
ResMLP	Completa vs. Top-k	0,3173	1,0000
ResMLP	Top-k vs. GFS	0,4237	1,0000
ResMLP	Individual vs. Homogénea	0,5485	1,0000
ResMLP	Completa vs. Homogénea	0,5485	1,0000

C.2.2 Control emparejado de N-gramas

El pool corregido conserva candidatos estáticos, sorteos, particiones y scores comunes al ofrecer versiones con y sin N-gramas. En marginal/B120, permitir color y reseleccionar cambia 0,900563/97,245 ms a 0,906690/83,772 ms. Cambia la ruta: no es una ablación de ruta fija. El rescate de diversidad utiliza otro pool, por lo que sus diferencias no se atribuyen únicamente al color.

C.3 Barrido del control de poda y compuerta

La Tabla C.7 conserva las doce configuraciones, incluidas las cuatro sin rescate. Se calcula macro-F1 sobre las 680 predicciones reunidas; los costos se ponderan por imagen. Las comparaciones comparten imágenes y no constituyen doce datasets ni réplicas independientes.

Tabla C.7: Barrido completo del control de rescate fijo en desarrollo Outex. F1 es macro-F1 OOF; C es adquisición media proyectada en ms. Permanente utiliza el mismo rescate que la política condicional, sin reselección estática.

Rescate	B	F1 base	F1 perm.	F1 cond.	C perm.	C cond.
Completo	15	0,858056	0,858056	0,858056	12,220	12,220
Completo	30	0,854129	0,854129	0,854129	20,485	20,485
Completo	60	0,859848	0,914389	0,891759	365,196	57,839
Completo	120	0,852780	0,914389	0,908603	365,196	104,660
Podado marginal	15	0,858056	0,858056	0,858056	12,220	12,220
Podado marginal	30	0,858056	0,905034	0,893488	98,344	25,394
Podado marginal	60	0,820226	0,905140	0,905140	97,282	55,365
Podado marginal	120	0,823601	0,913072	0,908781	251,028	84,018
Podado relevancia	15	0,858056	0,858056	0,858056	12,220	12,220
Podado relevancia	30	0,858056	0,905034	0,893488	98,344	25,394
Podado relevancia	60	0,840378	0,911993	0,910742	110,421	53,316
Podado relevancia	120	0,822836	0,913895	0,909396	229,836	78,938

La base es la seleccionada en cada política. El rescate permanente conserva exactamente miembros y multiplicidades, omite una base innecesaria y no se reoptimiza para el presupuesto indicado. La ruta forzada, no mostrada en este barrido, tiene las mismas predicciones del rescate permanente y conserva base y sobrecosto de política; se distingue en la Tabla 5.8. Los cuatro casos sin rescate mantienen la base en todas las vistas.

C.4 Réplica del rescate por condición y regla

La réplica conserva cinco condiciones nuevas: FMD/42, FMD/123, FMD/2026, Outex/123 y Outex/2026. Outex/42 permanece en las tablas del piloto y no integra las medias nuevas. Las Tablas C.8 y C.9 mantienen los presupuestos completos y las referencias del mismo protocolo de desarrollo. No se escoge una regla por su F1 de validación productora.

Tabla C.8: Barrido de la réplica por dataset/semilla: macro-F1 / costo proyectado (ms). Las tres reglas híbridas y el control estático mantienen los cuatro presupuestos. Las filas comparten imágenes; no representan dominios independientes.

Condición	B	Completo	Marginal	Relevancia	Estático
FMD/42	15	0,970082 / 11,680	0,970082 / 11,680	0,970082 / 11,680	0,970082 / 11,680
FMD/42	30	0,970082 / 11,680	0,972549 / 19,343	0,972543 / 19,915	0,970082 / 11,680
FMD/42	60	0,975026 / 37,423	0,976279 / 35,411	0,977506 / 38,282	0,978772 / 35,078
FMD/42	120	0,980012 / 63,318	0,976279 / 49,068	0,976262 / 61,387	0,977528 / 95,181
FMD/123	15	0,968721 / 11,680	0,968721 / 11,680	0,968721 / 11,680	0,968721 / 11,680
FMD/123	30	0,968721 / 11,680	0,975051 / 15,770	0,973800 / 17,771	0,965017 / 16,894
FMD/123	60	0,972554 / 45,396	0,974987 / 35,516	0,974987 / 35,869	0,975028 / 52,565
FMD/123	120	0,971325 / 64,937	0,974987 / 35,516	0,974987 / 35,869	0,978770 / 100,779
FMD/2026	15	0,971229 / 11,680	0,971229 / 11,680	0,971229 / 11,680	0,971229 / 11,680
FMD/2026	30	0,971229 / 11,680	0,977512 / 17,812	0,977512 / 17,812	0,971229 / 15,758
FMD/2026	60	0,976270 / 28,804	0,978724 / 27,758	0,979974 / 32,917	0,969999 / 38,020
FMD/2026	120	0,976270 / 28,804	0,978731 / 38,353	0,979974 / 43,512	0,974948 / 106,826
Outex/123	15	0,859336 / 12,220	0,859336 / 12,220	0,859336 / 12,220	0,863699 / 13,756
Outex/123	30	0,862149 / 20,467	0,902291 / 25,902	0,902291 / 25,902	0,866167 / 25,829
Outex/123	60	0,882609 / 47,852	0,908180 / 41,548	0,911087 / 39,233	0,888012 / 54,531
Outex/123	120	0,913572 / 98,437	0,909208 / 59,907	0,904064 / 75,565	0,900579 / 113,288
Outex/2026	15	0,866570 / 12,220	0,866570 / 12,220	0,866570 / 12,220	0,869584 / 12,988
Outex/2026	30	0,856203 / 20,467	0,888810 / 22,546	0,888810 / 22,546	0,882948 / 26,149
Outex/2026	60	0,880431 / 48,802	0,907518 / 45,307	0,900894 / 42,267	0,890292 / 43,563
Outex/2026	120	0,905178 / 100,718	0,912713 / 85,802	0,912582 / 79,164	0,910586 / 105,505

Tabla C.9: Referencias del mismo desarrollo productor. Top-3/4/5 tienen tamaño fijo y no equivalen al Top-k heredado de GFS del benchmark. Costos proyectados, no latencias físicas.

Condición	Referencia	Macro-F1	Costo ms
FMD/42	Individual interno	0,970082	11,680
FMD/42	Top-3 fijo	0,977535	141,376
FMD/42	Top-4 fijo	0,978777	265,950
FMD/42	Top-5 fijo	0,976253	290,550
FMD/42	Completa-22	0,961310	1706,420
FMD/42	Diversidad permanente	0,978777	359,751
FMD/123	Individual interno	0,968721	11,680
FMD/123	Top-3 fijo	0,971305	130,345
FMD/123	Top-4 fijo	0,975044	214,986
FMD/123	Top-5 fijo	0,971339	286,418
FMD/123	Completa-22	0,953807	1706,420
FMD/123	Diversidad permanente	0,967593	387,321
FMD/2026	Individual interno	0,971229	11,680
FMD/2026	Top-3 fijo	0,976280	141,376
FMD/2026	Top-4 fijo	0,978785	265,950
FMD/2026	Top-5 fijo	0,977530	290,550
FMD/2026	Completa-22	0,969995	1706,420
FMD/2026	Diversidad permanente	0,975059	347,062
Outex/123	Individual interno	0,860527	86,608
Outex/123	Top-3 fijo	0,902588	225,153
Outex/123	Top-4 fijo	0,900695	256,615
Outex/123	Top-5 fijo	0,897444	275,698
Outex/123	Completa-22	0,922741	1706,420
Outex/123	Diversidad permanente	0,909076	384,654
Outex/2026	Individual interno	0,879569	177,300
Outex/2026	Top-3 fijo	0,891325	255,417
Outex/2026	Top-4 fijo	0,897518	271,770
Outex/2026	Top-5 fijo	0,897968	288,837
Outex/2026	Completa-22	0,917259	1706,420
Outex/2026	Diversidad permanente	0,910605	356,496

C.4.1 Activación del mismo rescate en la réplica

La Tabla C.10 compara las mismas políticas con su rescate permanente, conservando miembros y puntuaciones. Las medias se calculan primero por condición y luego entre semillas del mismo dataset. En los casos sin rescate ambas vistas son la base. Las diferencias de calidad pueden ser positivas o negativas; no se traslada a estas condiciones la conclusión de ausencia de mejora de F1 del piloto Outex/42. El archivo de análisis conserva además las sesenta filas individuales por condición, regla y presupuesto.

Tabla C.10: Mismo rescate permanente frente a condicional en la réplica: macro-F1 / costo proyectado (ms), media de tres semillas FMD y dos Outex. La referencia permanente conserva los miembros seleccionados para la ruta condicional y no se reoptimiza bajo B. Incluye los casos sin rescate.

Dataset	Regla	B	Permanente	Condicional
FMD	Completo	15	0,970011 / 11,680	0,970011 / 11,680
FMD	Completo	30	0,970011 / 11,680	0,970011 / 11,680
FMD	Completo	60	0,972561 / 286,449	0,974617 / 37,207
FMD	Completo	120	0,973809 / 325,955	0,975869 / 52,353
FMD	Marginal	15	0,970011 / 11,680	0,970011 / 11,680
FMD	Marginal	30	0,972549 / 79,357	0,975037 / 17,642
FMD	Marginal	60	0,973370 / 249,391	0,976663 / 32,895
FMD	Marginal	120	0,973370 / 244,231	0,976666 / 40,979
FMD	Relevancia	15	0,970011 / 11,680	0,970011 / 11,680
FMD	Relevancia	30	0,972552 / 88,127	0,974618 / 18,499
FMD	Relevancia	60	0,974596 / 281,061	0,977489 / 35,689
FMD	Relevancia	120	0,974598 / 279,669	0,977074 / 46,923
Outex	Completo	15	0,862953 / 12,220	0,862953 / 12,220
Outex	Completo	30	0,859176 / 20,467	0,859176 / 20,467
Outex	Completo	60	0,909840 / 370,575	0,881520 / 48,327
Outex	Completo	120	0,909840 / 370,575	0,909375 / 99,577
Outex	Marginal	15	0,862953 / 12,220	0,862953 / 12,220
Outex	Marginal	30	0,904744 / 97,145	0,895551 / 24,224
Outex	Marginal	60	0,917058 / 152,408	0,907849 / 43,427
Outex	Marginal	120	0,910992 / 158,374	0,910960 / 72,854
Outex	Relevancia	15	0,862953 / 12,220	0,862953 / 12,220
Outex	Relevancia	30	0,904744 / 97,145	0,895551 / 24,224
Outex	Relevancia	60	0,912135 / 134,273	0,905991 / 40,750
Outex	Relevancia	120	0,909442 / 202,008	0,908323 / 77,365

C.5 Alcance de las exploraciones secundarias

Las exploraciones de proyecciones, residuos y políticas de más etapas pertenecen al desarrollo del proyecto. No se les atribuye aquí una pérdida general frente a concatenación, ni se usa la falta de un resultado reconciliado para refutar una familia metodológica. Solo un contraste con particiones, selección y medición compatibles permitiría esa conclusión.

Los registros de desarrollo conservan variantes con distintos protocolos y estimandos. Las tablas de este manuscrito incluyen resultados con fuentes identificadas y separan las comparaciones no reconciliadas. Así se evita atribuir a una misma evaluación cifras procedentes de diseños distintos.

Anexo D

Reproducibilidad y disponibilidad

D.1 Materiales, procedencia y acceso

El paquete organiza manifiestos, decisiones, puntuaciones, predicciones y scripts. La procedencia se identifica mediante commit y hashes, incluidos los cambios locales. La implementación se desarrolla en el repositorio del proyecto; al reproducir el estudio deben contrastarse los registros locales con la versión publicada.

Los manifiestos identifican las muestras de las seis colecciones del Capítulo 4. La disponibilidad y redistribución de imágenes, embeddings y pesos dependen de sus proveedores. Los archivos auxiliares locales no se presumen incluidos en la versión pública.

D.2 Comprobaciones registradas y alcance

La verificación del 25 de octubre de 2026 recalcula 147 métricas de desarrollo, comprueba 470 filas estáticas y reproduce 36 decisiones del híbrido con sus 13 resultados. Ese corte registró 83 pruebas de software aprobadas. La réplica del 26 de octubre añade cinco condiciones auditadas, con 60 selecciones estáticas, 180 decisiones de enrutamiento y 170 resultados de políticas recalculados; su verificación de software registró 94 pruebas aprobadas. Los índices, decisiones y puntuaciones permiten comprobar selección y aritmética; reproducir independientemente requiere repetir extracción y entrenamiento con las configuraciones indicadas.

El benchmark histórico conserva 27 archivos de predicciones y 31.984 observaciones de test acumuladas, no necesariamente imágenes únicas. Las particiones sin índices guardados mantienen una reserva de trazabilidad. El piloto híbrido conserva 680 predicciones por política y se distingue de esas 27 condiciones.

El control de poda y compuerta verifica 31 hashes y las predicciones de rescate de 36 decisiones contra las puntuaciones originales. Sus 8.160 filas corresponden a doce vistas de las mismas 680 imágenes, no a imágenes adicionales. Las tablas se reconstruyen mediante `scripts/build_p0_thesis_tables.py` desde los registros P0, con hashes de entradas y salidas, sin reentrenar ni modificar predicciones.

Las comprobaciones desde caché y las pruebas de software no estiman desempeño en

imágenes nuevas ni sustituyen extracción y entrenamiento independientes. La medición física requiere fidelidad de representación y un régimen de ejecución explícito.

D.3 Reconstrucción mínima y límites de entrega

Se reconstruyeron las dos tablas P0 en una carpeta aislada con diez archivos: el generador, cinco registros del análisis y cuatro del piloto de origen. El resultado fue byte-idéntico, utilizando el mismo entorno Python; no se presenta como instalación independiente ni reproducción de extracción. La receta, dependencias, entradas y hashes completos se documentan en `docs/fsc_tex/REPRODUCCION_MINIMA_MESA_2026-10-25.md` dentro del repositorio.

El control estático nuevo conserva sus doce decisiones antes de evaluación, las puntuaciones de validación y una predicción por imagen y presupuesto. Se comprobaron las doce selecciones, el costo de cada unión y la correspondencia entre puntuaciones y clases. La sensibilidad KTH conserva matrices de entrada, salidas SCI2S y comprobaciones numéricas de Friedman y Holm. Estos registros separan la reconstrucción aritmética del entrenamiento y la extracción.

En la réplica, los tres controles estáticos FMD fallaron por una comprobación heredada que exigía 680 imágenes en lugar de las 800 de desarrollo. Se conservan los intentos originales y se recuperaron solo esas etapas en directorios nuevos, adaptando la validación al tamaño de entrenamiento. Las decisiones recuperadas son byte-idénticas a las congeladas antes del fallo. No se modificaron las particiones, el selector ni los parámetros, ni se repitieron el pool, el ensamble o el híbrido. El registro de autorización y los hashes distinguen recuperación de ejecución original.

Las tablas de la réplica se generan con `scripts/build_replication_thesis_tables.py` desde los resultados auditados en `results/analysis/mesa_replication_20261026`. El generador verifica las fuentes ligadas por hashes y conserva la procedencia de cuatro tablas en `paper/generated_replication/provenance.json`. Su reconstrucción no ejecuta modelos ni añade contrastes estadísticos. La auditoría comprueba además la exclusión de test y la separación de grupos y transformaciones.

Para SoilOriginal se verificaron nuevamente el archivo de la versión 1 y los hashes de las 1.140 imágenes admitidas. El SHA-256 del archivo comienza por `a4ae6ce5f918`; el manifiesto y el registro de reproducción conservan el valor completo. Se utilizan las rutas de las fuentes recuperadas, no los placeholders históricos. Los grupos de dependencia por nombre son conservadores y no acreditan que se conozca toda relación física entre imágenes.

El paquete de trabajo contiene rutas absolutas históricas y archivos auxiliares no necesariamente publicados. La entrega pública completa requiere resolver su portabilidad, disponibilidad y condiciones de redistribución. Reproducir desde RGB exige además los pesos exactos, preprocesamiento y capa de cada extractor del Anexo A. Estas comprobaciones no incluyen esa reextracción ni una medición física del híbrido.

Declaraciones

Financiación

Los autores declaran que no hubo financiación externa para este trabajo.

Conflictos de interés

Los autores declaran que no existen conflictos de interés.

Datos y consideraciones éticas

El estudio utiliza colecciones de imágenes preexistentes y no incorpora reclutamiento ni intervención sobre participantes. La disponibilidad de datos, código y registros se describe en el Anexo D. El acceso y la eventual redistribución de imágenes, características y pesos están sujetos a las condiciones de sus proveedores.

Asistencia en la revisión

Se utilizó asistencia de inteligencia artificial en esta revisión editorial y en la generación de scripts de presentación de resultados. Esa asistencia no se considera fuente científica ni evidencia de validez experimental. Los resultados se vinculan con sus archivos de procedencia y se distinguen las verificaciones automáticas de una reproducción independiente.

Referencias

[1] Li Liu, Jie Chen, Paul Fieguth, Guoying Zhao, Rama Chellappa, and Matti Pietik"ainen. From BoW to CNN: Two decades of texture representation for texture classification. *International Journal of Computer Vision (IJCV)*, 127:74–109, 2019. doi: 10.1007/s11263-018-1125-z.

[2] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, Sammy Mohamed, and Andrea Vedaldi. Describing textures in the wild. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3606–3613, 06 2014. doi: 10.1109/CVPR.2014.461.

[3] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, and Andrea Vedaldi. Deep filter banks for texture recognition, description, and segmentation. *International Journal of Computer Vision (IJCV)*, 118(1):65–94, 01 2016. doi: 10.1007/s11263-015-0872-3.

[4] Paul Viola and Michael Jones. Rapid object detection using a boosted cascade of simple features. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 1, pages I–511. IEEE, 2001. doi: 10.1109/CVPR.2001.990517.

[5] Yizeng Han, Gao Huang, Shiji Song, Le Yang, Honghui Wang, and Yulin Wang. Dynamic neural networks: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 44(11):7436–7456, 2021. doi: 10.1109/TPAMI.2021.3117837.

[6] Feng Nan and Venkatesh Saligrama. Adaptive classification for prediction under a budget. In *Advances in Neural Information Processing Systems*, volume 30, 2017. URL `https://proceedings.neurips.cc/paper_files/paper/2017/hash/d9ff90f4000eacd3a6c9cb27f78994cf-Abstract.html`.

[7] Timo Ojala, Matti Pietikäinen, and Topi Mäenpää. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 24(7):971–987, 07 2002. doi: 10.1109/TPAMI.2002.1017623.

[8] Robert M. Haralick. Statistical and structural approaches to texture. *Proceedings of the IEEE*, 67(5):786–804, 05 1979. doi: 10.1109/PROC.1979.11328.

[9] Anil K. Jain and Farshid Farrokhnia. Unsupervised texture segmentation using Gabor filters. *Pattern Recognition*, 24(12):1167–1186, 1991. doi: 10.1016/0031-3203(91)90143-S.

[10] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893. IEEE, 06 2005. doi: 10.1109/CVPR.2005.177.

[11] Fátima Belén Paiva Pavón, María Cristina Orué Gil, José Luis Vázquez Noguera,

Helena Gómez-Adorno, and Valentín Calzada-Ledesma. Rgb pixel n-grams: A texture descriptor. *Signal Processing: Image Communication*, 118:117028, 2023. doi: 10.1016/j.image.2023.117028.

[12] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 06 2016. doi: 10.1109/CVPR.2016.90.

[13] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 05 2021. URL `https://openreview.net/forum?id=YicbFdNTTy`. International Conference on Learning Representations (ICLR).

[14] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research (TMLR)*, 07 2024. URL `https://arxiv.org/abs/2304.07193`.

[15] Nikolay Neshov, Krasimir Tonchev, Ivaylo Bozhilov, Radostina Petkova, and Agata Manolova. Improving texture recognition via multi-layer feature aggregation from pre-trained vision architectures. *Electronics*, 14(23):4779, 2025. doi: 10.3390/electronics14234779.

[16] P. Simon and V. Uma. DeepLumina: A method based on deep features and luminance information for color texture classification. *Computational Intelligence and Neuroscience*, 2022:9510987, 2022. doi: 10.1155/2022/9510987.

[17] Deepak Gupta, Ankit Mishra, and Pradeep Shrivastava. HyTexNet: A hybrid deep and handcrafted texture representation network for material and texture classification. *Knowledge-Based Systems*, page 115482, 2026. doi: 10.1016/j.knosys.2026.115482.

[18] Liang Chang, Xiaoping Ji, and Zexuan Zhu. Multi-scale local binary pattern fused with dynamic cellular neural network contour for texture classification. *Expert Systems with Applications*, 238:122100, 2024. doi: 10.1016/j.eswa.2023.122100.

[19] Leonardo Scabini, Arthur Sacilotti, Kamil M. Zielinski, Lucas C. Ribas, Bernard De Baets, and Odemir M. Bruno. A comparative survey of vision transformers for feature extraction in texture analysis. *Journal of Imaging*, 11(9):304, 2025. doi: 10.3390/jimaging11090304.

[20] Ron Kohavi and George H. John. Wrappers for feature subset selection. *Artificial Intelligence*, 97(1–2):273–324, 1997. doi: 10.1016/S0004-3702(97)00043-X.

[21] Isabelle Guyon and André Elisseeff. An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182, 2003. URL `https://www.jmlr.org/papers/v3/guyon03a.html`.

[22] Rich Caruana, Alexandru Niculescu-Mizil, Geoff Crew, and Alex Ksikes. Ensemble selection from libraries of models. In *Proceedings of the 21st International Conference*

on Machine Learning, 2004. doi: 10.1145/1015330.1015432. URL https://www.cs.cornell.edu/~alexn/papers/shotgun.icml04.revised.rev2.pdf.

[23] Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey Hinton. Similarity of neural network representations revisited. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3519–3529, 2019. URL https://proceedings.mlr.press/v97/kornblith19a.html.

[24] Zhixiang Xu, Kilian Q. Weinberger, and Olivier Chapelle. The greedy miser: Learning under test-time budgets. In *Proceedings of the 29th International Conference on Machine Learning*, 2012. URL https://icml.cc/2012/papers/592.pdf.

[25] Chao Ma, Sebastian Tschiatschek, Konstantina Palla, José Miguel Hernández-Lobato, Sebastian Nowozin, and Cheng Zhang. EDDI: Efficient dynamic discovery of high-value information with partial VAE. In *International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 4234–4243. PMLR, 2019. URL https://proceedings.mlr.press/v97/ma19c.html.

[26] Surat Teerapittayanon, Bradley McDanel, and H. T. Kung. Branchynet: Fast inference via early exiting from deep neural networks. In *23rd International Conference on Pattern Recognition (ICPR)*, pages 2464–2469. IEEE, 2016. doi: 10.1109/ICPR.2016.7900006.

[27] Lavanya Sharan, Ce Liu, Ruth Rosenholtz, and Edward H. Adelson. Recognizing materials using perceptually inspired features. *International Journal of Computer Vision (IJCV)*, 103(3):348–371, 07 2013. doi: 10.1007/s11263-013-0609-0.

[28] Timo Ojala, Topi Mäenpää, Matti Pietikäinen, Jaakko Viertola, Juha Kyllönen, and Sami Huovinen. Outex—new framework for empirical evaluation of texture analysis algorithms. In *Proceedings of the 16th International Conference on Pattern Recognition*, volume 1, pages 701–706. IEEE, 2002. doi: 10.1109/ICPR.2002.1044854.

[29] Manik Varma and Andrew Zisserman. Texture classification: Are filter banks necessary? In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 2, pages 691–698. IEEE, 2003. URL https://www.robots.ox.ac.uk/~vgg/publications/2003/Varma03/varma03.pdf.

[30] Hugo Touvron, Piotr Bojanowski, Mathilde Caron, Matthieu Cord, Alaaeldin El-Nouby, Edouard Grave, Gautier Izacard, Armand Joulin, Gabriel Synnaeve, Jakob Verbeek, and Hervé Jégou. ResMLP: Feedforward networks for image classification with data-efficient training. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 45(4):5314–5321, 04 2023. doi: 10.1109/TPAMI.2022.3206148.

[31] Janez Demšar. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30, 2006.

[32] Joaquín Derrac, Salvador García, Daniel Molina, and Francisco Herrera. A practical tutorial on the use of nonparametric statistical tests as a methodology for comparing evolutionary and swarm intelligence algorithms. *Swarm and Evolutionary Computation*, 1(1):3–18, 2011. doi: 10.1016/j.swevo.2011.02.002.

[33] Salvador García and Francisco Herrera. An extension on "statistical comparisons of classifiers over multiple data sets" for all pairwise comparisons. *Journal of Machine Learning Research (JMLR)*, 9(89):2677–2694, 2008. URL https://jmlr.org/papers/v9/garcia08a.html.

[34] Rakesh Mehta and Karen Egiazarian. Dominant rotated local binary patterns (DRLBP) for texture classification. *Pattern Recognition Letters*, 71:16–22, 02 2016. doi: 10.1016/j.patrec.2015.11.019.

[35] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition, 2015. URL `https://arxiv.org/abs/1409.1556`. International Conference on Learning Representations (ICLR).

[36] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2261–2269. IEEE, 07 2017. doi: 10.1109/CVPR.2017.243. URL `https://openaccess.thecvf.com/content_cvpr_2017/html/Huang_Densely_Connected_Convolutional_CVPR_2017_paper.html`.

[37] Mingxing Tan and Quoc Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 6105–6114. PMLR, 06 2019. URL `https://proceedings.mlr.press/v97/tan19a.html`.

[38] Sanghyun Woo, Shoubhik Debnath, Ronghang Hu, Xinlei Chen, Zhuang Liu, In So Kweon, and Saining Xie. Convnext v2: Co-designing and scaling convnets with masked autoencoders. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16133–16142, 06 2023. doi: 10.1109/CVPR52729.2023.01548.

[39] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 10347–10357. PMLR, 07 2021. URL `https://proceedings.mlr.press/v139/touvron21a.html`.

[40] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 10012–10022, 10 2021. doi: 10.1109/ICCV48922.2021.00986.

[41] Yuxin Fang, Quan Sun, Xinggang Wang, Tiejun Huang, Xinlong Wang, and Yue Cao. Eva-02: A visual representation for neon genesis. *Image and Vision Computing*, 149: 105171, 09 2024. doi: 10.1016/j.imavis.2024.105171.

[42] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16000–16009. IEEE, 06 2022. doi: 10.1109/CVPR52688.2022.01553.

[43] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 11941–11952. IEEE, 10 2023. doi: 10.1109/ICCV51070.2023.01100.