

Concatenación sistemática de descriptores visuales clásicos y modernos para clasificación de texturas

Evaluación anidada de estrategias de concatenación de 21 descriptores

Carlos Ayala

Joaquín Delgado

Septiembre 2026

Universidad Nacional de Asunción

Facultad Politécnica

Concatenación sistemática de descriptores visuales clásicos y modernos para clasificación de texturas

Evaluación anidada de estrategias de concatenación de 21 descriptores

**Carlos Ayala
Joaquín Delgado**

Tutor: José Vázquez

Septiembre 2026

Agradecimientos

A nuestro tutor, José Vázquez, por su guía y paciencia.
A la Facultad Politécnica de la UNA, por el espacio y los recursos.
A nuestras familias, por el apoyo incondicional.

Resumen

Este trabajo evalúa la concatenación de descriptores heterogéneos para clasificar texturas. Se comparan cinco estrategias: Individual, Completa, Top- k , Greedy Forward Selection (GFS) y Homogénea. La biblioteca evaluada reúne 21 descriptores sobre DTD, FMD, CURET y Outex con SVM lineal y ResMLP. La selección se realiza dentro del entrenamiento y el desempeño se mide mediante macro-F1 y exactitud en 56 condiciones externas en total. GFS obtiene mayor macro-F1 medio que Individual en las ocho configuraciones dataset-clasificador, pero el método con mayor desempeño varía entre dominios y clasificadores. Con un bloque por dataset, Friedman ($p = 0,1074$) y Quade ($p = 0,0705$) no rechazan la hipótesis global, y ninguna comparación por pares resulta significativa tras Holm a $\alpha = 0,05$. GFS reduce la dimensión media entre 71,7% y 85,4% respecto de la concatenación completa. Los resultados respaldan evaluar la composición y el costo dimensional según el dominio, sin establecer una estrategia universalmente superior.

Palabras clave: clasificación de texturas, concatenación de descriptores, selección de bloques, GFS, evaluación anidada.

Abstract

This thesis compares five descriptor selection and concatenation strategies using 21 descriptors. The complete evaluation covers DTD, FMD, CURET and Outex with linear SVM and a residual MLP, using 56 external conditions. GFS obtains higher mean macro-F1 than the internally selected individual descriptor in all eight dataset-classifier configurations. With one block per dataset, Friedman ($p=0.1074$) and Quade ($p=0.0705$) do not reject their global null hypotheses; no pairwise comparison is significant after Holm adjustment at 0.05. These results support evaluating concatenation by domain, performance and representation size, without establishing universal superiority.

Keywords: texture classification, descriptor concatenation, block selection, GFS, nested evaluation.

Contenido

1	Introducción	5
2	Trabajos relacionados	7
2.1	Representaciones de textura	7
2.2	Concatenación y selección de bloques	7
3	Método de concatenación y selección de descriptores	9
3.1	Representación conjunta y pregunta de estudio	9
3.2	Estrategias comparadas	10
3.3	Espacio de descriptores	11
3.4	Greedy Forward Selection	12
3.5	Conjuntos de datos y control de integridad	14
3.6	Clasificadores	14
3.7	Configuración experimental y protocolo anidado	15
3.8	Análisis estadístico	15
4	Resultados del estudio anidado	16
4.1	Resultados principales: desempeño y descriptor individual	16
4.2	Rankings y comparaciones estadísticas	17
5	Discusión	20
5.1	Limitaciones	20
6	Conclusión	22

Capítulo 1

Introducción

La clasificación de texturas depende de señales locales, distribuciones espaciales y respuestas en frecuencia que cambian con el dominio, la escala, la iluminación y el punto de vista [1–3]. Ninguna representación captura necesariamente todas esas variaciones. Los descriptores clásicos resumen propiedades diseñadas, como microestructuras, coocurrencias y gradientes [4–6]; las redes convolucionales, los Transformers y los modelos autosupervisados producen características aprendidas con arquitecturas y objetivos de preentrenamiento diferentes [7–11]. Esta diversidad crea una oportunidad para combinar representaciones, pero también introduce redundancia, escalas incompatibles y un aumento considerable de dimensionalidad.

La concatenación conserva la información de varios extractores y delega al clasificador la decisión sobre sus coordenadas. Agregaciones locales, Fisher vectors, bancos de filtros profundos y capas de codificación aprendida han mostrado que combinar respuestas puede mejorar el reconocimiento de texturas [2, 12, 13]. Sin embargo, una mejora de la representación conjunta no demuestra que todos sus bloques sean necesarios ni que la complementariedad explique por sí sola el resultado. El mismo efecto puede aparecer al aumentar la dimensión o al reunir descriptores que ya son fuertes de manera individual.

Las arquitecturas de fusión y las combinaciones de representaciones motivan distinguir tres factores en la evaluación: calidad individual, cantidad de variables y composición del subconjunto. La distinción adquiere especial importancia en una biblioteca que reúne descriptores clásicos, CNN, Transformers y representaciones autosupervisadas o multimodales. La pregunta de estudio es *cómo cambian el desempeño externo y la dimensionalidad al concatenar descriptores, frente a seleccionar uno individual, y qué aporta elegir la composición de esa concatenación*.

Para responder esta pregunta se evaluaron 21 descriptores sobre DTD, FMD, CURET y Outex con SVM lineal y ResMLP. El mismo protocolo anidado compara cinco estrategias: Individual, Completa, Top- k , GFS y Homogénea. La comparación considera macro-F1 y exactitud, junto con la dimensión de las representaciones. Se completaron 28 condiciones externas por clasificador; cada una incluye las cinco estrategias sobre la misma biblioteca de 21 descriptores.

El trabajo aporta una comparación reproducible de estrategias de concatenación bajo particiones comunes, una evaluación no paramétrica entre datasets y una comparación del desempeño y la dimensionalidad de los subconjuntos seleccionados. GFS y Top- k

son procedimientos para elegir qué bloques concatenar dentro de esta comparación. El propósito es caracterizar las ganancias y los costos observados de combinar bloques, sin introducir un nuevo algoritmo de selección. La evidencia se interpreta atendiendo tanto a las diferencias observadas como a la incertidumbre estadística.

La tesis se organiza en seis capítulos: introducción, antecedentes, metodología, resultados, discusión y conclusión. El estudio anidado con cuatro datasets constituye la referencia actual. Los experimentos exploratorios previos se conservan en los materiales del proyecto y no se mezclan con sus contrastes estadísticos.

Capítulo 2

Trabajos relacionados

2.1 Representaciones de textura

Los descriptores de textura resumen señales distintas de una misma imagen: microestructuras (LBP), coocurrencias, orientación de gradientes y patrones en frecuencia [4–6, 14]. Las representaciones aprendidas introducen sesgos adicionales derivados de arquitecturas convolucionales, Transformers y objetivos de preentrenamiento supervisado, autosupervisado o multimodal [7–11, 15–18]. Por ello, ningún extractor debe suponerse universalmente suficiente: vectores con distinto origen pueden contener información redundante, pero también señales complementarias aprovechables por un clasificador conjunto. Esta complementariedad, y no la comparación aislada entre arquitecturas, motiva la composición de bloques del presente estudio.

2.2 Concatenación y selección de bloques

La fusión de características combina información antes de la decisión final del clasificador. Una estrategia directa consiste en concatenar los vectores extraídos de una misma imagen. A diferencia de la fusión de decisiones, esta operación conserva explícitamente las coordenadas de cada representación y permite entrenar un único clasificador sobre el espacio conjunto. Su sencillez constituye una ventaja experimental: permite estudiar el efecto de combinar descriptores sin introducir un módulo de fusión altamente parametrizado. No obstante, el vector resultante crece con cada extractor incorporado y puede acumular escalas incompatibles, variables redundantes y dimensiones poco informativas.

Los Fisher vectors mostraron que la agregación de descriptores locales puede producir representaciones de alto rendimiento [12]; en texturas, los bancos de filtros profundos combinaron activaciones convolucionales con agregación estadística [2] y DeepTEN integró una capa de codificación residual dentro de una arquitectura profunda [13]. Estos antecedentes muestran que reunir señales distintas puede mejorar la representación, pero no determinan si todos los componentes son necesarios cuando la biblioteca contiene extractores heterogéneos y congelados.

Los antecedentes citados motivan evaluar si una búsqueda secuencial supera a reunir los descriptores individualmente más fuertes bajo el mismo número de bloques. Por ello, este

estudio compara esas políticas bajo las mismas particiones y separa la selección de la evaluación externa, como recomiendan los diseños wrapper y la evaluación anidada [19, 20]. El foco no está en proponer otro extractor ni en atribuir el resultado a una arquitectura particular, sino en evaluar la *concatenación de descriptores como problema de selección de bloques*, comparando su desempeño externo y dimensionalidad. Igualar el número de bloques no iguala las dimensiones ni permite aislar causalmente la complementariedad.

Capítulo 3

Método de concatenación y selección de descriptores

3.1 Representación conjunta y pregunta de estudio

El estudio evalúa la concatenación como un problema de selección de bloques. Cada extractor transforma una imagen x_i en un vector $\mathbf{z}_{ij} \in \mathbb{R}^{d_j}$, donde j identifica el descriptor y d_j su dimensionalidad. Para un subconjunto S de extractores, la representación conjunta se define como

$$\mathbf{z}_{i,S} = \parallel \frac{\mathbf{z}_{ij}}{\max(\|\mathbf{z}_{ij}\|_2, 10^{-12})}, \quad (3.1)$$

donde $\parallel$ denota concatenación. La normalización L_2 se aplica por descriptor y por muestra antes de unir los bloques, para evitar que la escala de un extractor determine por sí sola la contribución al clasificador.

La Figura 3.1 muestra cómo una misma imagen produce representaciones diferentes. Un descriptor resume patrones, relaciones entre intensidades o activaciones aprendidas en un vector. Después de normalizar cada bloque, se conserva un descriptor individual o se concatenan los bloques seleccionados. La dimensión conjunta es $d_S = \sum_{j \in S} d_j$.




Figura 3.1: Extracción y concatenación de descriptores. La misma imagen de DTD se representa mediante cinco ejemplos: patrones locales (LBP), respuestas de filtros (Gabor), coocurrencias (GLCM), una red convolucional (ResNet) y secuencias RGB (N-gramas). Las transformaciones internas se muestran esquemáticamente; no representan mapas de importancia por píxel. Cada rama produce un bloque normalizado que puede utilizarse individualmente o concatenarse con otros. El ejemplo de tres bloques ilustra la unión de coordenadas; cada política determina el subconjunto admisible.

3.2 Estrategias comparadas

Las cinco estrategias responden a decisiones sobre la representación que recibe el clasificador. Individual establece el desempeño de un solo bloque; Completa evalúa la unión de toda la biblioteca; Top- k y GFS eligen subconjuntos; Homogénea restringe la procedencia de los bloques a una familia. Se utilizan las mismas denominaciones en método, resultados y estadística:

1. **Individual:** descriptor con mayor macro-F1 medio en validación interna.
2. **Completa:** concatenación de todos los bloques de la biblioteca evaluada.
3. **Top- k :** concatenación de los k descriptores mejor posicionados por su macro-F1 individual interno; k se toma del subconjunto GFS de la misma condición.
4. **GFS:** subconjunto devuelto por la selección secuencial de bloques.
5. **Homogénea:** mejor resultado interno de GFS restringido a una familia, con un límite de bloques no mayor que el subconjunto GFS heterogéneo.

Top- k controla la composición bajo el mismo número de bloques que GFS, aunque las dimensiones pueden diferir. No constituye una política independiente de elección de k . Homogénea permite estudiar el efecto de restringir la biblioteca a una familia. Todos los comparadores se seleccionan antes de evaluar el test. Los controles aleatorios y las variantes de presupuesto se conservan como análisis auxiliares en los materiales del proyecto.

3.3 Espacio de descriptores

La biblioteca contiene 21 descriptores, agrupados según el tipo de representación. Cada uno constituye un bloque candidato sujeto al mismo criterio de selección. Las Tablas 3.1 y 3.2 identifican la parametrización, los checkpoints y la dimensionalidad de cada bloque. Las redes preentrenadas se ejecutaron en modo evaluación y sin ajuste de pesos. En los modelos cargados mediante `timm` se eliminó la capa clasificadora (`num_classes=0`) y se aplicó el preprocesamiento asociado al checkpoint. Para ViT, DeiT, Swin, MAE y SigLIP se utilizó la salida *pooler* cuando estaba disponible y, en caso contrario, el token de clasificación. Todas las imágenes se convirtieron a RGB.

Los descriptores clásicos se basan en operadores LBP, Gabor, GLCM y HOG [4–6, 14, 21]. Las CNN corresponden a VGG16, ResNet, DenseNet, EfficientNet y ConvNeXt V2 [7, 8, 22–24]. El grupo Transformer incluye ViT, DeiT, Swin y EVA-02 [9, 10, 25, 26]; las representaciones con preentrenamiento autosupervisado o multimodal se basan en DINOv2, MAE y SigLIP [11, 16, 18].

Tabla 3.1: Seis descriptores basados en patrones, filtros, gradientes y conteos incluidos en la biblioteca. Cada fila constituye un bloque completo.

Descriptor	Parametrización	Salida	Dim.
LBP	multiescala $(P, R) = (8, 1), (16, 2), (24, 3)$; mapeo uniforme invariante a rotación (riu2)	histogramas normalizados	54
LBP-rot	$P = 8, R = 1$; ocho rotaciones; códigos limitados a $[0, 10]$	histogramas 10×8	80
Gabor	cuatro frecuencias 0,1–0,8; seis orientaciones	media y desv. de respuesta real	48
GLCM	256 niveles; distancias 1–3; cuatro ángulos; seis propiedades	promedios sobre ángulos	18
HOG	nueve orientaciones; celda 16^2 ; bloque 2^2 ; norma L2-Hys	vector HOG	1.764
N-gramas	ventana vertical 2×1 ; cuantización RGB por 12; 8.192 bins; SVD	vector normalizado	256

Los descriptores clásicos se calcularon en escala de grises con la implementación de `scikit-image`: LBP, LBP-rot, Gabor y GLCM sobre imágenes redimensionadas a 256×256 , y HOG sobre 128×128 . LBP-rot designa la implementación propia registrada como `dr1bp` en los archivos experimentales: aplica LBP con mapeo `ror` a ocho rotaciones y concatena diez bins por rotación en el intervalo $[0, 10]$. Los códigos fuera de ese intervalo se descartan; por tanto, es un histograma restringido, no una reproducción del DRLBP de Mehta y Egiazarian [14]. Los 21 vectores concatenados suman 19.884 dimensiones. Las características fijas y los conteos por imagen se almacenaron junto con etiquetas, orden de muestras y hashes de procedencia; las transformaciones aprendidas se ajustaron dentro de cada partición de entrenamiento. El estudio evalúa la selección y concatenación

Tabla 3.2: Quince representaciones aprendidas congeladas incluidas en la biblioteca. “Preclas.” designa la salida inmediatamente anterior al clasificador del backbone.

Familia	Descriptor	Checkpoint	Salida	Dim.
CNN	VGG16	<code>vgg16.tv_in1k</code>	preclas.	4.096
	ResNet-50	<code>resnet50.a1_in1k</code>	preclas.	2.048
	ResNet-101	<code>resnet101.a1_in1k</code>	preclas.	2.048
	DenseNet-121	<code>densenet121.tv_in1k</code>	preclas.	1.024
	EfficientNet-B0	<code>efficientnet_b0.ra_in1k</code>	preclas.	1.280
	ConvNeXt V2-T	<code>convnextv2_tiny.fcmae_ft_in22k_in1k</code>	preclas.	768
Transformer	ViT-B/16	<code>google/vit-base-patch16-224</code>	pooler/CLS	768
	DeiT-S	<code>facebook/deit-small-patch16-224</code>	pooler/CLS	384
	Swin-T	<code>microsoft/swin-tiny-patch4-window7-224</code>	pooler	768
	EVA-02 base	<code>eva02_base_patch14_224</code>	preclas.	768
Autosup./multimodal	DINOv2-S	<code>vit_small_patch14_dinov2.lvd142m</code>	preclas.	384
	DINOv2-B	<code>vit_base_patch14_dinov2.lvd142m</code>	preclas.	768
	DINOv2-L	<code>vit_large_patch14_dinov2.lvd142m</code>	preclas.	1.024
	MAE-B	<code>facebook/vit-mae-base</code>	pooler/CLS	768
	SigLIP-B	<code>google/siglip-base-patch16-224</code>	pooler/CLS	768

de bloques con extractores de imagen congelados y transformaciones ajustadas dentro del entrenamiento; no compara estrategias de *fine-tuning*.

RGB Pixel N-grams [27] utiliza ventanas verticales de 2×1 píxeles con paso 1 sobre la imagen RGB en su resolución original. Cada canal se cuantiza mediante $q(v) = \lfloor v/12 \rfloor$; los seis valores se codifican en base 22, recorriendo las dos posiciones de R, G y B. Los conteos se agrupan por el resto del código dividido por 8.192 y se comprimen mediante TruncatedSVD aleatorizado (256 componentes, cinco iteraciones y semilla de la condición). SVD se ajusta exclusivamente con el entrenamiento de cada partición interna y se reajusta sobre el entrenamiento externo para la evaluación final. El vector se normaliza con L_2 antes de concatenarlo. Esta parametrización comprimida se identifica como N-gramas + SVD y constituye una familia propia para la selección Homogénea.

3.4 Greedy Forward Selection

GFS se utiliza como un método *wrapper*: los subconjuntos se valoran mediante el propio clasificador y exclusivamente dentro de la validación interna, como requieren los diseños de selección que separan búsqueda y evaluación externa [19, 20]. La búsqueda comienza con un conjunto vacío. En el paso t , evalúa cada descriptor aún no seleccionado al añadirlo al subconjunto vigente y elige el candidato con mayor macro-F1 medio en la validación interna:

$$j_t = \arg \max_{j \notin S_{t-1}} \hat{F}_{1,\text{inner}}(S_{t-1} \cup \{j\}), \quad S_t = S_{t-1} \cup \{j_t\}. \quad (3.2)$$

La búsqueda se limita a $k \leq 8$. Se detiene cuando la mejora respecto del paso anterior es menor que 0,001 durante dos pasos consecutivos, pero devuelve el mejor paso histórico, no necesariamente el último. Los empates se resuelven de forma determinista mediante el nombre del extractor. Todas las evaluaciones candidatas utilizan únicamente muestras pertenecientes al entrenamiento externo.

La Figura 3.2 representa el mecanismo general de GFS. En cada ronda se comparan

únicamente los bloques aún disponibles dentro de los folds internos; el bloque elegido se incorpora al subconjunto y el test externo permanece fuera de esa decisión.




Figura 3.2: Mecanismo de Greedy Forward Selection sobre bloques completos. En cada paso se elige el bloque que maximiza el macro-F1 medio de la validación interna; el test externo se utiliza únicamente tras cerrar el subconjunto.

La Tabla 3.3 concentra los parámetros de búsqueda, comunes a ambos clasificadores.

Tabla 3.3: Configuración de la selección GFS en el flujo general.

Elemento	Configuración
Unidad de selección	Bloque completo generado por un extractor
Candidatos	21 bloques
Criterio interno	Macro-F1 medio en cuatro folds estratificados y agrupados
Presupuesto	Hasta $k = 8$ bloques
Parada	Dos mejoras consecutivas menores que 0,001; se devuelve el mejor paso histórico
Empates	Nombre del extractor, en orden determinista
Información excluida	Test externo y sus etiquetas durante toda la selección

3.5 Conjuntos de datos y control de integridad

Antes del análisis se construyó un manifiesto por dataset y se verificaron etiquetas, orden de muestras, dimensiones, valores finitos y grupos de dependencia. Se utilizaron DTD, FMD, CURET y Outex. Sus particiones se describen a continuación; los cuatro datasets integran el análisis estadístico principal.

DTD contiene 5.640 imágenes de texturas en condiciones no controladas y proporciona diez particiones oficiales de entrenamiento, validación y prueba [1]. En cada partición se unieron entrenamiento y validación para ejecutar la selección interna, mientras que el test oficial se reservó para una única evaluación. Los duplicados byte-idénticos que cruzaban roles fueron retirados del conjunto de entrenamiento, conservando intacta la evaluación.

FMD reúne 1.000 fotografías de diez categorías de materiales [28]. Las características fijas y los conteos por imagen se obtuvieron desde las imágenes oficiales en un orden canónico. Cada imagen presentó un hash único y se utilizó como unidad de agrupación. La evaluación externa empleó cinco folds estratificados y agrupados, repetidos con semillas 42, 123 y 2026.

Outex contiene 1.360 BMP RGB de 128×128 píxeles, organizados en 68 clases balanceadas. La auditoría verificó archivos legibles, IDs continuos 000000–001359, ausencia de duplicados y la partición oficial de 680 imágenes de entrenamiento y 680 de prueba, con diez muestras de cada clase en cada lado [29]. Todos los bloques respetan el orden de las 1.360 muestras del manifiesto oficial. Este es el único conjunto Outex utilizado en los resultados del artículo.

Para CURET se utilizó la distribución gris recortada de 61 materiales, con 92 condiciones compartidas por clase [30]. Cada condición constituye un grupo para impedir que la misma configuración de adquisición aparezca a ambos lados de una partición. Se definieron dos mitades complementarias deterministas de 46 condiciones: A para selección y entrenamiento con B como test, y la dirección inversa. Esta asignación reproduce de manera transparente el tamaño 46/46 publicado, pero no se presenta como el split histórico exacto. Debido a que las dos direcciones son complementarias y dependientes, sus resultados se interpretarán descriptivamente.

3.6 Clasificadores

Se emplearon dos clasificadores con sesgos diferentes. La SVM lineal se implementa con `LinearSVC` de `scikit-learn`: $C = 1$, ponderación balanceada por clase, pérdida *squared hinge*, regularización L_2 , esquema uno-contra-el-resto, tolerancia 10^{-4} y un máximo de 10.000 iteraciones.

Se denomina ResMLP a la MLP residual implementada para este estudio sobre vectores de características; no es una reproducción del modelo de imágenes del mismo nombre [31]. Proyecta la entrada a 256 unidades y aplica tres bloques residuales, normalización de capa, activaciones GELU, *dropout* de 0,1 y una salida multiclase. Se entrena con entropía cruzada y AdamW, tasa de aprendizaje 10^{-3} , decaimiento de pesos 10^{-4} , lotes de 256 muestras y un máximo de 100 épocas. La parada se basa en la pérdida media de entrenamiento: tras diez épocas sin una disminución mayor que 10^{-4} , se detiene y

restaura el mejor estado registrado. No utiliza el test ni una validación adicional para elegir la época. Las semillas se fijan para NumPy y PyTorch; cuando está disponible, la red se ejecuta en GPU.

3.7 Configuración experimental y protocolo anidado

La selección interna utiliza cuatro folds estratificados y agrupados. En DTD se ejecuta dentro de la unión *train+val* de cada split oficial; en FMD dentro del entrenamiento de cada uno de los 15 folds externos; y en CURET dentro de la mitad de 46 condiciones asignada al entrenamiento. En Outex, las cinco estrategias restringen los cuatro folds internos a las 680 imágenes del entrenamiento oficial. Después de seleccionar el subconjunto y los comparadores, cada modelo se ajusta con todo el entrenamiento externo y se evalúa una sola vez en el test correspondiente. Se verifica programáticamente que ningún grupo aparezca en entrenamiento y prueba.

3.8 Análisis estadístico

El análisis utiliza rankings de Friedman y Quade, contrastes globales y comparaciones por pares con ajuste de Holm, siguiendo una organización empleada en clasificación de texturas [27]. Los cálculos se realizaron con los paquetes Java ControlTest y MultipleTest distribuidos con el tutorial de pruebas no paramétricas [32].

La exactitud es la proporción de imágenes clasificadas correctamente. Macro-F1 promedia el F1 de las C clases con igual peso: $\text{macro-F1} = C^{-1} \sum_{c=1}^C 2TP_c / (2TP_c + FP_c + FN_c)$, donde TP_c , FP_c y FN_c son los verdaderos positivos, falsos positivos y falsos negativos de la clase c . Esta media evita que la contribución de una clase dependa directamente de su número de muestras.

Macro-F1 es la métrica primaria. Para cada dataset se promedian primero las condiciones externas de cada clasificador y después los dos clasificadores con igual peso. Así se obtienen cuatro bloques, uno por dataset, y cinco estrategias. No se tratan las particiones repetidas ni los dos clasificadores de una misma base como problemas independientes. Se adopta $\alpha = 0,05$ y Holm se aplica a la familia de diez pares posibles mediante comparaciones de rangos basadas en Friedman; estos valores no son contrastes post hoc de Quade. Se reportan todas las comparaciones, incluidas las que no rechazan la hipótesis nula. Los valores ajustados se acotan a 1 para su presentación.

La exactitud se reporta como métrica descriptiva secundaria sobre las mismas condiciones. La media y la desviación estándar entre particiones describen la variación observada, pero no convierten las particiones dependientes en réplicas independientes. La ausencia de significancia no demuestra equivalencia entre estrategias.

Capítulo 4

Resultados del estudio anidado

4.1 Resultados principales: desempeño y descriptor individual

La Tabla 4.1 compara las cinco estrategias con la biblioteca de 21 descriptores. Individual corresponde a una política de selección interna: el descriptor elegido puede cambiar entre particiones. El panel B identifica esos descriptores y sus frecuencias, evitando atribuir la media a un único extractor cuando hubo varios. La Tabla 4.2 presenta la exactitud bajo el mismo protocolo.

Tabla 4.1: Macro-F1 externo de las cinco estrategias con la biblioteca de 21 descriptores. Media y desviación estándar entre particiones; Outex tiene un único split. El máximo de cada fila se destaca sin implicar significancia estadística.

Panel A: macro-F1 externo						
Dataset	Clasif.	Individual	Completa	Top- k	GFS	Homogénea
DTD	SVM	0,8426 $\pm$ 0,0109	0,8629 $\pm$ 0,0080	0,8684 $\pm$ 0,0080	0,8694 $\pm$ 0,0096	0,8606 $\pm$ 0,0086
DTD	ResMLP	0,8373 $\pm$ 0,0089	0,8608 $\pm$ 0,0100	0,8648 $\pm$ 0,0084	0,8660 $\pm$ 0,0095	0,8611 $\pm$ 0,0060
FMD	SVM	0,9726 $\pm$ 0,0150	0,9644 $\pm$ 0,0174	0,9820 $\pm$ 0,0105	0,9766 $\pm$ 0,0135	0,9789 $\pm$ 0,0122
FMD	ResMLP	0,9690 $\pm$ 0,0133	0,9518 $\pm$ 0,0203	0,9753 $\pm$ 0,0140	0,9783 $\pm$ 0,0123	0,9773 $\pm$ 0,0109
CUReT	SVM	0,9948 $\pm$ 0,0028	0,9989 $\pm$ 0,0015	0,9989 $\pm$ 0,0010	0,9988 $\pm$ 0,0008	0,9989 $\pm$ 0,0010
CUReT	ResMLP	0,9971 $\pm$ 0,0030	0,9993 $\pm$ 0,0010	0,9986 $\pm$ 0,0015	0,9980 $\pm$ 0,0013	0,9982 $\pm$ 0,0015
Outex	SVM	0,9066	0,9674	0,9441	0,9610	0,9307
Outex	ResMLP	0,9476	0,9537	0,9607	0,9715	0,9306

Panel B: descriptor Individual seleccionado		
Dataset	Clasificador	Descriptor (frecuencia)
DTD	SVM	SigLIP-B (8/10); DINOv2-L (2/10)
DTD	ResMLP	SigLIP-B (10/10)
FMD	SVM	SigLIP-B (15/15)
FMD	ResMLP	SigLIP-B (15/15)
CUReT	SVM	DINOv2-L (2/2)
CUReT	ResMLP	DINOv2-S (1/2); DINOv2-L (1/2)
Outex	SVM	DINOv2-L (1/1)
Outex	ResMLP	N-gramas + SVD (1/1)

Frecuencias de selección interna; cuando cambia el descriptor, la media del panel A reúne esas elecciones.

Tabla 4.2: Exactitud externa de las cinco estrategias con la biblioteca de 21 descriptores. Media y desviación estándar entre particiones; Outex tiene un único split. El máximo de cada fila se destaca sin implicar significancia estadística.

Dataset	Clasif.	Individual	Completa	Top- k	GFS	Homogénea
DTD	SVM	0,8448 $\pm$ 0,0106	0,8644 $\pm$ 0,0075	0,8697 $\pm$ 0,0077	0,8707 $\pm$ 0,0094	0,8623 $\pm$ 0,0083
DTD	ResMLP	0,8382 $\pm$ 0,0085	0,8624 $\pm$ 0,0094	0,8660 $\pm$ 0,0084	0,8670 $\pm$ 0,0091	0,8626 $\pm$ 0,0056
FMD	SVM	0,9727 $\pm$ 0,0150	0,9643 $\pm$ 0,0174	0,9820 $\pm$ 0,0105	0,9767 $\pm$ 0,0135	0,9790 $\pm$ 0,0121
FMD	ResMLP	0,9690 $\pm$ 0,0133	0,9517 $\pm$ 0,0204	0,9753 $\pm$ 0,0139	0,9783 $\pm$ 0,0122	0,9773 $\pm$ 0,0108
CUReT	SVM	0,9948 $\pm$ 0,0028	0,9989 $\pm$ 0,0015	0,9989 $\pm$ 0,0010	0,9988 $\pm$ 0,0008	0,9989 $\pm$ 0,0010
CUReT	ResMLP	0,9971 $\pm$ 0,0030	0,9993 $\pm$ 0,0010	0,9986 $\pm$ 0,0015	0,9980 $\pm$ 0,0013	0,9982 $\pm$ 0,0015
Outex	SVM	0,9103	0,9676	0,9456	0,9618	0,9324
Outex	ResMLP	0,9485	0,9544	0,9618	0,9721	0,9338

Tabla 4.3: Dimensión media de las representaciones por dataset y clasificador. Se cuentan coordenadas del vector de entrada, con los mismos subconjuntos usados para medir macro-F1 y exactitud.

Dataset	Clasif.	Individual	Completa	Top- k	GFS	Homogénea
DTD	SVM	819,2	19884,0	4851,2	5589,8	2572,8
DTD	ResMLP	768,0	19884,0	4544,0	4613,2	2598,4
FMD	SVM	768,0	19884,0	2969,6	2909,3	2338,1
FMD	ResMLP	768,0	19884,0	3404,8	3077,5	2218,7
CUReT	SVM	1024,0	19884,0	3328,0	4402,0	2944,0
CUReT	ResMLP	704,0	19884,0	2304,0	3520,0	1856,0
Outex	SVM	1024,0	19884,0	7040,0	5632,0	3712,0
Outex	ResMLP	256,0	19884,0	6016,0	3346,0	2176,0

Las medias pueden ser fraccionarias porque el subconjunto seleccionado cambia entre particiones. La dimensión no equivale a tiempo de extracción ni a memoria total de ejecución.

GFS obtiene mayor macro-F1 medio que Individual en las ocho configuraciones, pero el método con mayor desempeño depende del dataset. Completa alcanza los mayores valores en CUReT y en Outex con SVM; GFS obtiene el mayor valor en Outex con ResMLP. En DTD destaca GFS, mientras que en FMD destacan Top- k con SVM y GFS con ResMLP. Esta comparación describe las medias externas y no implica que cada diferencia sea estadísticamente significativa.

La Tabla 4.3 permite contrastar el desempeño con el tamaño de la representación en las cinco estrategias. La dimensión media de GFS por configuración dataset-clasificador se sitúa entre 2.909,3 y 5.632 componentes, una reducción de entre 71,7% y 85,4% respecto de los 19.884 de Completa. Este rango compara las ocho medias, no los extremos de las particiones individuales. La disminución corresponde al vector almacenado y utilizado por el clasificador. No se midió una reducción proporcional de latencia o memoria de extremo a extremo.

4.2 Rankings y comparaciones estadísticas

Las Tablas 4.4 y 4.5 presentan los rankings y los contrastes de la biblioteca de 21 descriptores. En Friedman, Top- k obtiene el menor ranking medio (2,00), seguido por GFS (2,25) y Completa (2,75). En Quade, el menor ranking corresponde a GFS (1,70), seguido por Top- k (2,00). Sin embargo, Friedman ($p = 0,1074$) y Quade ($p = 0,0705$) no rechazan

sus hipótesis globales al nivel adoptado.

Tabla 4.4: Rankings medios según Friedman y Quade para macro-F1. Análisis principal con un bloque por dataset y biblioteca de 21 descriptores. Menor ranking indica mejor desempeño relativo.

Estrategia	Friedman	Quade
Individual	4,750	4,800
Completa	2,750	2,800
Top- k	2,000	2,200
GFS	2,250	1,700
Homogénea	3,250	3,500

Tabla 4.5: Contrastes globales del análisis principal de macro-F1, con cuatro datasets y cinco estrategias (21 descriptores). Distribución de referencia y grados de libertad entre paréntesis.

Prueba	Distribución (gl)	Estadístico	p	Decisión ($\alpha = 0,05$)
Friedman	$\chi^2(4)$	7,6000	0,1074	No rechazo
Quade	$F(4, 12)$	2,8632	0,0705	No rechazo

Tabla 4.6: Valores p ajustados mediante Holm para las diez comparaciones de macro-F1 entre estrategias (21 descriptores; cuatro datasets). Ninguna comparación rechaza a $\alpha = 0,05$.

Estrategia	Individual	Completa	Top- k	GFS	Homogénea
Individual	—	0,5891	0,1391	0,2281	1,0000
Completa	—	—	1,0000	1,0000	1,0000
Top- k	—	—	—	1,0000	1,0000
GFS	—	—	—	—	1,0000
Homogénea	—	—	—	—	—

Se presentan como información complementaria: Friedman no rechazó la hipótesis global. Los valores ajustados que el programa imprime por encima de 1 se acotan a 1; los originales se conservan.

Tabla 4.7: Comparaciones de cada estrategia combinada frente a Individual con 21 descriptores. Diferencia media de macro-F1 entre datasets y valores p de las comparaciones basadas en rangos de Friedman, ajustados con Holm.

Comparación	Δ macro-F1	Datasets a favor	p_{Holm}	Significativa
GFS vs. Individual	0,0190	4/4	0,2281	No
Top- k vs. Individual	0,0156	4/4	0,1391	No
Completa vs. Individual	0,0114	3/4	0,5891	No
Homogénea vs. Individual	0,0086	4/4	1,0000	No

Se promedian primero las condiciones de cada clasificador y luego ambos clasificadores por dataset. Holm conserva la familia de diez pares; mostrar estos cuatro contrastes no reduce la corrección. Nivel $\alpha = 0,05$.

La Tabla 4.7 detalla las cuatro comparaciones de interés frente a Individual e incluye su diferencia media de macro-F1. La Tabla 4.6 conserva las diez comparaciones como información complementaria, sin un rechazo global previo. Frente a Individual, los valores ajustados con Holm son 0,1391 para Top- k , 0,2281 para GFS, 0,5891 para Completa

y 1,0000 para Homogénea. Ninguno es menor que 0,05. Como magnitud descriptiva, las diferencias absolutas de macro-F1 de GFS frente a Individual, promediando ambos clasificadores, son 0,0277 en DTD, 0,0066 en FMD, 0,0024 en CURET y 0,0392 en Outex. Por tanto, el mejor orden descriptivo de las estrategias combinadas no demuestra una superioridad general entre datasets.

Como sensibilidad se conservó también la matriz de ocho filas dataset-clasificador. En ella, GFS y Top- k frente a Individual obtienen $p_{\text{Holm}} = 0,0157$ cada uno. Esas filas comparten datasets y su dependencia impide sustituir el resultado principal por ese rechazo. Los procedimientos adicionales y sus salidas originales se conservan en los materiales de reproducibilidad. Las matrices y las salidas Java corresponden a las 56 condiciones completas de la biblioteca.

Capítulo 5

Discusión

La comparación muestra que concatenar descriptores puede mejorar el desempeño respecto de elegir un único bloque, pero el beneficio depende de la composición y del dominio. En DTD y FMD, seleccionar un subconjunto ofrece resultados competitivos frente a utilizar toda la biblioteca. En CURET, Completa alcanza los mayores valores; en Outex, la mejor estrategia depende del clasificador: Completa con SVM y GFS con ResMLP. La concatenación completa mejora descriptivamente frente a Individual en tres de los cuatro datasets al promediar los clasificadores, pero pierde desempeño en FMD. Seleccionar bloques ofrece una alternativa de menor dimensión, cuyo resultado depende de su composición. Este patrón es compatible con distintas combinaciones de información complementaria y redundante; el diseño no mide directamente esa redundancia ni identifica un mecanismo causal.

Las pruebas de Friedman, Quade y Holm moderan la interpretación de las ventajas descriptivas de la biblioteca de 21 descriptores. Con cuatro datasets no se obtuvo evidencia suficiente para afirmar una superioridad global. Esto no demuestra igualdad de rendimiento; delimita lo que sostienen los contrastes realizados.

5.1 Limitaciones

GFS es una búsqueda local y no garantiza el subconjunto óptimo. Top- k hereda su presupuesto de bloques, por lo que compara composiciones bajo un k compartido. Individual se elige internamente y no representa al descriptor con mejor resultado a posteriori en el test. Las particiones de DTD y FMD reutilizan imágenes, CURET presenta dos direcciones complementarias y Outex tiene una sola partición. El número de datasets limita la precisión y la generalización de la inferencia multibase. No se realizó un cálculo de tamaño muestral a priori ni se presentan intervalos de confianza de generalización a nuevos datasets. Las desviaciones entre particiones describen la variabilidad observada; no estiman esa incertidumbre tratando folds dependientes como réplicas independientes.

Los descriptores clásicos se calcularon sobre escala de grises, mientras las redes y RGB Pixel N-grams utilizan RGB; en CURET las imágenes de origen son grises. Además, los corpus de preentrenamiento de los modelos podrían solaparse con imágenes de los benchmarks; ese solapamiento no fue auditado. El agrupamiento de conteos y la reducción de dimensión pueden perder información. El histograma restringido de LBP-rot

también descarta códigos; la comparación incluye esa implementación específica y no permite extraer conclusiones sobre el DRLBP original. Los resultados dependen de la parametrización especificada. No se dispone de mediciones homogéneas de latencia y memoria para atribuir ahorro de cómputo a la reducción dimensional.

Capítulo 6

Conclusión

Este trabajo estudió la concatenación de descriptores como una elección entre representaciones individuales, completas y seleccionadas. La evaluación completa reunió 21 descriptores, cuatro datasets y dos clasificadores bajo un protocolo que separa selección interna y evaluación externa. Las cinco estrategias se compararon mediante macro-F1 y exactitud, con rankings de Friedman y Quade y comparaciones por pares ajustadas mediante Holm.

Los resultados muestran beneficios descriptivos de combinar representaciones y reducciones dimensionales al seleccionar subconjuntos. Ninguna estrategia obtiene el mayor desempeño en todos los dominios. Los contrastes principales entre cuatro datasets no permiten afirmar una superioridad estadística general de GFS, Top- k , Completa o Homogénea frente a Individual.

La elección de una representación debe considerar el desempeño externo y la dimensionalidad bajo un protocolo común. Como siguientes pasos se plantea ampliar la diversidad de datasets, estudiar el efecto de la normalización y medir de forma homogénea el costo de extracción y clasificación.

Referencias

- [1] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, Sammy Mohamed, and Andrea Vedaldi. Describing textures in the wild. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3606–3613, 06 2014. doi: 10.1109/CVPR.2014.461.
- [2] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, and Andrea Vedaldi. Deep filter banks for texture recognition, description, and segmentation. *International Journal of Computer Vision (IJCV)*, 118(1):65–94, 01 2016. doi: 10.1007/s11263-015-0872-3.
- [3] Li Liu, Jie Chen, Paul Fieguth, Guoying Zhao, Rama Chellappa, and Matti Pietikäinen. From BoW to CNN: Two decades of texture representation for texture classification. *International Journal of Computer Vision (IJCV)*, 127:74–109, 2019. doi: 10.1007/s11263-018-1125-z.
- [4] Timo Ojala, Matti Pietikäinen, and Topi Mäenpää. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 24(7):971–987, 07 2002. doi: 10.1109/TPAMI.2002.1017623.
- [5] Robert M. Haralick. Statistical and structural approaches to texture. *Proceedings of the IEEE*, 67(5):786–804, 05 1979. doi: 10.1109/PROC.1979.11328.
- [6] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893. IEEE, 06 2005. doi: 10.1109/CVPR.2005.177.
- [7] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 06 2016. doi: 10.1109/CVPR.2016.90.
- [8] Mingxing Tan and Quoc Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 6105–6114. PMLR, 06 2019. URL <https://proceedings.mlr.press/v97/tan19a.html>.
- [9] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 05 2021. URL <https://openreview.net/forum?id=YicbFdNTTy>. International Conference on Learning Representations (ICLR).

- [10] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 10012–10022, 10 2021. doi: 10.1109/ICCV48922.2021.00986.
- [11] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research (TMLR)*, 07 2024. URL <https://arxiv.org/abs/2304.07193>.
- [12] Jorge Sánchez, Florent Perronnin, Thomas Mensink, and Jakob Verbeek. Image classification with the fisher vector: Theory and practice. *International Journal of Computer Vision (IJCV)*, 105(3):222–245, 12 2013. doi: 10.1007/s11263-013-0636-x.
- [13] Hang Zhang, Jia Xue, and Kristin Dana. Deep TEN: Texture encoding network. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2896–2905. IEEE, 07 2017. doi: 10.1109/CVPR.2017.309.
- [14] Rakesh Mehta and Karen Egiazarian. Dominant rotated local binary patterns (DRLBP) for texture classification. *Pattern Recognition Letters*, 71:16–22, 02 2016. doi: 10.1016/j.patrec.2015.11.019.
- [15] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 9650–9660, 10 2021. doi: 10.1109/ICCV48922.2021.00951.
- [16] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16000–16009. IEEE, 06 2022. doi: 10.1109/CVPR52688.2022.01553.
- [17] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763. PMLR, 07 2021. URL <https://proceedings.mlr.press/v139/radford21a.html>.
- [18] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 11941–11952. IEEE, 10 2023. doi: 10.1109/ICCV51070.2023.01100.
- [19] Ron Kohavi and George H. John. Wrappers for feature subset selection. *Artificial Intelligence*, 97(1–2):273–324, 1997. doi: 10.1016/S0004-3702(97)00043-X.

- [20] Isabelle Guyon and André Elisseeff. An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182, 2003. URL <https://www.jmlr.org/papers/v3/guyon03a.html>.
- [21] Anil K. Jain and Farshid Farrokhnia. Unsupervised texture segmentation using Gabor filters. *Pattern Recognition*, 24(12):1167–1186, 1991. doi: 10.1016/0031-3203(91)90143-S.
- [22] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition, 2015. URL <https://arxiv.org/abs/1409.1556>. International Conference on Learning Representations (ICLR).
- [23] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2261–2269. IEEE, 07 2017. doi: 10.1109/CVPR.2017.243. URL https://openaccess.thecvf.com/content_cvpr_2017/html/Huang_Densely_Connected_Convolutional_CVPR_2017_paper.html.
- [24] Sanghyun Woo, Shoubhik Debnath, Ronghang Hu, Xinlei Chen, Zhuang Liu, In So Kweon, and Saining Xie. Convnext v2: Co-designing and scaling convnets with masked autoencoders. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16133–16142, 06 2023. doi: 10.1109/CVPR52729.2023.01548.
- [25] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 10347–10357. PMLR, 07 2021. URL <https://proceedings.mlr.press/v139/touvron21a.html>.
- [26] Yuxin Fang, Quan Sun, Xinggang Wang, Tiejun Huang, Xinlong Wang, and Yue Cao. Eva-02: A visual representation for neon genesis. *Image and Vision Computing*, 149: 105171, 09 2024. doi: 10.1016/j.imavis.2024.105171.
- [27] Fátima Belén Paiva Pavón, María Cristina Orué Gil, José Luis Vázquez Noguera, Helena Gómez-Adorno, and Valentín Calzada-Ledesma. Rgb pixel n-grams: A texture descriptor. *Signal Processing: Image Communication*, 118:117028, 2023. doi: 10.1016/j.image.2023.117028.
- [28] Lavanya Sharan, Ce Liu, Ruth Rosenholtz, and Edward H. Adelson. Recognizing materials using perceptually inspired features. *International Journal of Computer Vision (IJCV)*, 103(3):348–371, 07 2013. doi: 10.1007/s11263-013-0609-0.
- [29] Timo Ojala, Topi Mäenpää, Matti Pietikäinen, Jaakko Viertola, Juha Kyllönen, and Sami Huovinen. Outex—new framework for empirical evaluation of texture analysis algorithms. In *Proceedings of the 16th International Conference on Pattern Recognition*, volume 1, pages 701–706. IEEE, 2002. doi: 10.1109/ICPR.2002.1044854.
- [30] Manik Varma and Andrew Zisserman. Texture classification: Are filter banks necessary? In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 2, pages 691–698. IEEE, 2003. URL <https://www.robots.ox.ac.uk/~vgg/publications/2003/Varma03/varma03.pdf>.

- [31] Hugo Touvron, Piotr Bojanowski, Mathilde Caron, Matthieu Cord, Alaaeldin El-Nouby, Edouard Grave, Gautier Izacard, Armand Joulin, Gabriel Synnaeve, Jakob Verbeek, and Hervé Jégou. ResMLP: Feedforward networks for image classification with data-efficient training. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 45(4):5314–5321, 04 2023. doi: 10.1109/TPAMI.2022.3206148.
- [32] Joaquín Derrac, Salvador García, Daniel Molina, and Francisco Herrera. A practical tutorial on the use of nonparametric statistical tests as a methodology for comparing evolutionary and swarm intelligence algorithms. *Swarm and Evolutionary Computation*, 1(1):3–18, 2011. doi: 10.1016/j.swevo.2011.02.002.