Universidad Nacional de Asunción

Facultad Politécnica

Concatenación Top-k de descriptores para clasificar texturas: comparación del uso directo y la activación por margen

Carlos Ayala
Joaquín Delgado

Tutor: José Vázquez

Noviembre de 2026

Agradecimientos

A nuestro tutor, José Vázquez, por acompañar la formulación del problema y la revisión del trabajo. A la Facultad Politécnica de la Universidad Nacional de Asunción, y a nuestras familias por su apoyo.

Resumen

La concatenación de descriptores permite combinar información para clasificar texturas, pero aumenta la representación y el trabajo de extracción. Esta tesis evalúa dos decisiones: qué bloques concatenar mediante un ranking Top-k, y cuándo ejecutar esa concatenación mediante el margen de un clasificador base. Se estudian seis datasets, SVM lineal y una MLP residual sobre características, distinguiendo bibliotecas de 21 bloques sin N-gramas y la biblioteca consolidada de 22.

El barrido exploratorio de uno a 21 bloques contiene 47 condiciones por tamaño y clasificador. Con SVM, Top-4 registra macro-F1 medio equiponderado por dataset de 0,936554, frente al máximo descriptivo de 0,936764 en $k = 10$, utilizando aproximadamente 15,42 % de las dimensiones del barrido. Con ResMLP, el máximo aparece en $k = 5$. El resultado identifica una alternativa compacta, no un tamaño óptimo universal. Los controles con N-gramas y otras selecciones muestran que relevancia individual y complementariedad no son equivalentes.

La comparación directa/por margen reconstruye 27 condiciones SVM y verifica el mismo rescate Top-k en las imágenes derivadas. La política registra macro-F1 medio 0,983953 frente a 0,982926 del uso directo en FMD, y 0,936950 frente a 0,942574 en Outex. Los costos por componentes proyectan menor adquisición; los pilotos físicos tienen un alcance delimitado y reservas de representación. Las comparaciones externas utilizan adaptaciones identificadas y mantienen DeepLumina bajo revisión por no convergencia y cobertura incompleta.

La evidencia es exploratoria y conserva exposición previa a benchmarks, dependencia entre particiones y diferencias entre archivos. Se concluye que una concatenación pequeña puede ofrecer un compromiso útil y que su activación por margen debe evaluarse frente al mismo uso directo, contabilizando la base y separando dimensión, adquisición proyectada y latencia física.

Palabras clave: clasificación de texturas, concatenación de descriptores, Top-k, margen, N-gramas, adquisición condicional.

Abstract

Descriptor concatenation combines information for texture classification but increases representation size and extraction work. This thesis examines which blocks to concatenate using a Top-k ranking and when to execute that concatenation using the margin of a base classifier. Six datasets, a linear SVM and a residual feature MLP are studied, distinguishing a 21-block library without N-grams from the consolidated 22-block library.

An exploratory sweep from one to 21 blocks includes 47 conditions per size and classifier. For SVM, Top-4 achieves dataset-balanced mean macro-F1 0.936554, compared with the descriptive maximum 0.936764 at $k = 10$, using approximately 15.42 % of the sweep's feature dimensions. The ResMLP maximum occurs at $k = 5$. This identifies a compact alternative rather than a universally optimal size. Controls with N-grams and other selection methods show that individual relevance and complementarity are different properties.

The direct-versus-margin comparison reconstructs 27 SVM conditions and verifies that escalated predictions use the same Top-k rescue. Mean macro-F1 is 0.983953 versus 0.982926 for direct use on FMD, and 0.936950 versus 0.942574 on Outex. Component profiles project lower acquisition costs; physical pilots have limited scope and unresolved representation reservations. External comparisons use identified adaptations, retaining DeepLumina's nonconvergence and incomplete coverage.

The evidence remains exploratory, with prior benchmark exposure, dependent partitions and differences between archives. A small concatenation can provide a useful trade-off, while margin-based activation must be compared with the same direct predictor, accounting for the base and separating feature dimensions, projected acquisition and physical latency.

Keywords: texture classification, descriptor concatenation, Top-k, margin, N-grams, conditional acquisition.

Siglas y notación

Top-k	Concatenación de los primeros k bloques de un ranking interno
Top-4	Caso de tamaño fijo $k = 4$, no cuatro identidades universales
OOF	Predicciones fuera de pliegue del entrenamiento
GFS	Selección secuencial hacia delante de bloques
SVD	Descomposición en valores singulares truncada
SVM	Máquina de vectores de soporte
ResMLP	MLP residual sobre características
S_k, h_k	Bloques seleccionados y clasificador de su concatenación
h_b, m_b, τ	Clasificador base, margen y umbral
$\widehat{r}$	Fracción de imágenes derivadas al rescate
c_j, C_{inc}	Costo por bloque y adquisición incremental
P1, P2	Preguntas de selección Top-k y uso directo/por margen
CKA	Similitud entre representaciones, usada en estudios complementarios

Contenido

Resumen **ii**

Abstract **iii**

Siglas y notación **iv**

1 Introducción **1**

1.1 Problema de investigación 1

1.2 Recorrido: Top-k directo y versión optimizada 1

1.3 Objetivo general 2

1.4 Objetivos específicos 2

1.5 Preguntas y alcance 2

1.6 Aportes y organización 3

2 Antecedentes y trabajos relacionados **4**

2.1 Representaciones para clasificar texturas 4

2.2 Concatenación y selección de bloques 4

2.3 Métodos de literatura utilizados como comparación 5

2.4 Activación condicional y margen 6

2.5 Criterio para comparar con un paper 6

3 Concatenación Top-k y activación por margen **7**

3.1 Bloques y bibliotecas de características 7

3.1.1 Ejemplo concreto: de cuatro vectores a una clase 7

3.2 Ranking individual y construcción de Top-k 8

3.3 Barrido de tamaños y origen del caso Top-4 9

3.4 Controles de concatenación y papel de N-gramas 9

3.5 Uso directo y versión optimizada por margen 9

3.6 Cómo se aprenden la base y el umbral 10

3.7 Costo incremental y medición física 11

4 Diseño experimental 12

4.1 Recorrido de las pruebas hasta Top-4 y su optimización 12
4.2 Experimentos y unidades de análisis 13
4.3 Colecciones y particiones 14
4.4 Clasificadores y transformaciones 14
4.5 Cómo se comparan los prefijos y las bibliotecas 15
4.6 Contraste del mismo Top-k directo y por margen 15
4.7 Métricas y costos 16
4.8 Comparadores externos y controles estadísticos 16
4.9 Reglas de cierre y reproducibilidad 17

5 Resultados experimentales 18

5.1 P1: del descriptor individual a la concatenación 18
5.2 Barrido de k y justificación del caso Top-4 19
5.2.1 Por qué estudiar cuatro: ganancia frente a crecimiento del vector 20
5.3 Qué aportan N-gramas y las ampliaciones de biblioteca 21
5.4 Comparación externa de Top-4 en llamadas online 23
5.5 P2: optimización mediante activación por margen 24
5.6 Adquisición proyectada y pilotos físicos 25
5.7 Síntesis de evidencia 27

6 Discusión 28

6.1 Qué justifica estudiar Top-4 28
6.2 Relevancia individual y complementariedad 28
6.3 Cuándo tiene sentido la activación por margen 29
6.4 Qué permite afirmar el tiempo medido 29
6.5 Interpretación de la comparación con papers 29
6.6 Amenazas a la validez y alcance 30
6.7 Implicación para el diseño de un clasificador 30

7 Conclusiones y trabajo futuro 31

7.1 Respuesta a las preguntas de investigación 31
7.2 Contribución y límites del cierre 32
7.3 Trabajo futuro delimitado 32

A Especificaciones de representación y selección **33**
A.1 Espacio de descriptores 33
A.2 Greedy Forward Selection 35
A.3 Perfil numérico de costos del piloto 36

B Protocolos y variantes de referencia **37**
B.1 Separación de evaluaciones 37
B.2 Procedencia de KTH 37
B.3 Fidelidad de los pilotos físicos 37
B.4 Particiones y multiplicidades del piloto híbrido 38
B.5 Figuras de la cascada de referencia 38

C Resultados secundarios y variabilidad **40**
C.1 Exactitud y dispersión del benchmark estático 40
C.2 Rankings y contrastes completos por clasificador 41
C.2.1 Sensibilidad del benchmark sin KTH 42
C.3 N-gramas con ResMLP y ampliación de biblioteca 43
C.3.1 N-gramas en el estudio complementario de rescate 44
C.4 Barrido del control de poda y compuerta 44
C.5 Réplica del rescate por condición y regla 44
C.5.1 Activación del mismo rescate en la réplica 47
C.6 Alcance de las exploraciones secundarias 47

D Reproducibilidad y disponibilidad **48**
D.1 Fuentes y versiones 48
D.2 Reconstrucción sin ejecutar modelos 48
D.3 Datos, pesos y portabilidad 49
D.4 Compilación y alcance de la entrega 49

Declaraciones **50**

E Estudios complementarios de rescate de ensamble **51**
E.1 Bloques, miembros y política de adquisición 51
E.2 Generación del ensamble de subconjuntos 52
E.3 Puntuaciones y agregación 52
E.4 Base y compuerta 53

E.5 Costo compartido y presupuesto 53
E.5.1 Interpretación del costo de adquisición 53
E.6 Selección completa y poda del rescate 54
E.7 Referencias estáticas y cascada de comparación 57
E.8 Piloto de rescate de ensamble 57
E.8.1 Ablación del mismo rescate con y sin compuerta 58
E.8.2 Control estático bajo presupuesto 58
E.8.3 Réplica en FMD y semillas adicionales 59
E.9 Resultados del rescate de ensamble en desarrollo Outex 59
E.9.1 Separación de poda y activación condicional 61
E.9.2 Comparación con selección estática bajo presupuesto 62
E.10 Réplica del rescate en dos datasets 63

Lista de figuras

3.1 Construcción de una concatenación Top-k. Evaluar varios tamaños externos es una exploración; escoger uno después de observarlos no constituye selección interna de ese tamaño. 8

3.2 Clasificación por margen. La ruta directa de comparación ejecuta h_k sin base. La condición de margen no utiliza la etiqueta verdadera de la imagen nueva. 10

5.1 Calidad y ganancia marginal al aumentar el número de descriptores. . . . 20

5.2 Barrido de tamaños en los seis datasets. 22

5.3 Comparación por dataset del uso directo y por margen: calidad a la izquierda y adquisición proyectada a la derecha. La diagonal indica igualdad de la magnitud; el panel de costo no es un cronometraje físico nuevo. KTH conserva su reserva. 26

A.1 Mecanismo de Greedy Forward Selection sobre bloques completos. En cada paso se elige el bloque que maximiza el macro-F1 medio de la validación interna; el test externo se utiliza únicamente tras cerrar el subconjunto. . 35

B.1 Comparación histórica calidad–costo bajo su perfil analítico. No representa el rescate de diversidad ni una medición física de todas las rutas. 38

B.2 Enrutamiento de la cascada histórica según los artefactos archivados. Las proporciones no garantizan una tasa de salida para imágenes nuevas. . . 39

E.1 Construcción de la política y especificación de su ejecución. La selección usa entrenamiento; la compuerta utiliza el margen de cada imagen, no su etiqueta. En el piloto las rutas se reconstruyen con puntuaciones guardadas y costos proyectados; no se cronometra esta ruta completa desde RGB. . 56

E.2 Políticas del piloto Outex y controles del mismo protocolo. Se muestran los cuatro presupuestos de cada variante, incluidos puntos coincidentes. El eje horizontal es costo proyectado en escala logarítmica, no latencia física; las líneas no representan una frontera óptima. 60

Lista de tablas

2.1 Nivel de combinación y relación con la comparación propuesta. 5

4.1 Cobertura de los bloques experimentales utilizados en la tesis. 13

5.1 Macro-F1 externo de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial. . . . 18

5.2 Dimensión media de las representaciones usadas en la evaluación externa con 22 descriptores. 19

5.3 Barrido exploratorio ampliado: medias equiponderadas de seis datasets, con 47 condiciones por tamaño y clasificador. 19

5.4 Top-4 y concatenaciones completas en el archivo exploratorio (SVM). . . 21

5.5 Top-4 y concatenaciones completas en el archivo exploratorio (ResMLP). 21

5.6 Comparación completa con SVM: medias con 20 frente a 21 bloques, incluyendo RGB Pixel N-grams + SVD. Mismas 28 condiciones externas: DTD (10), FMD (15), CUReT (2) y Outex (1). La selección se repite dentro del entrenamiento. 22

5.7 Macro-F1 de Top-4/SVM y adaptaciones externas en el panel online auditado. 23

5.8 Latencia media observada por imagen (ms) de las mismas llamadas que sustentan la tabla de macro-F1. 23

5.9 Uso directo y activación por margen del mismo Top-k: auditoría de las 27 condiciones guardadas, SVM. 24

5.10 Condiciones donde el rescate coincide con el Top-4 del barrido, SVM. . . 25

5.11 Costos de extracción proyectados de las rutas históricas. No son latencias online por dataset. 25

5.12 Piloto físico histórico, una condición por dataset. Modelos residentes e imágenes decodificadas; una imagen por clase y tres repeticiones pareadas. 26

A.1 Seis descriptores basados en patrones, filtros, gradientes y conteos incluidos en la biblioteca. Cada fila constituye un bloque completo. 34

A.2 Representaciones aprendidas congeladas incluidas en la biblioteca (16 extractores profundos y de modelos fundacionales). “Preclas.” designa la salida inmediatamente anterior al clasificador del backbone. 34

A.3 Configuración de la selección GFS en el flujo general. 36

A.4 Constantes del perfil del piloto, en ms por imagen. Son parámetros archivados del modelo de costos, no tiempos medidos del híbrido. 36

B.1 Tamaños y modelos únicos del control de diversidad permanente en cada pliegue productor. No son nuevas réplicas ni 15 ejecuciones distintas por imagen. 38

C.1 Exactitud externa de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial. . . . 40

C.2 Desviación estándar descriptiva del macro-F1 entre condiciones externas del benchmark estático. No es error estándar ni intervalo de confianza; las condiciones comparten imágenes. El guion indica un único split. 40

C.3 Rankings medios de macro-F1 según Friedman, Friedman alineado y Quade con 22 descriptores. Seis datasets por clasificador; menor ranking indica mejor desempeño relativo dentro de cada prueba. 41

C.4 Pruebas globales por clasificador sobre cinco estrategias y seis datasets con la biblioteca de 22 descriptores. Nivel nominal $\alpha = 0{,}05$. 41

C.5 Comparaciones por pares basadas en rangos de Friedman. Holm corrige los diez pares dentro de cada clasificador. 42

C.6 Sensibilidad del benchmark estático a excluir KTH archivado: seis datasets originales frente a los cinco restantes. Valores p SCI2S por clasificador; no son evaluaciones del híbrido. 42

C.7 Sensibilidad sin KTH: post-hoc de rangos de Friedman sobre cinco datasets. Holm corrige diez pares por clasificador. Son contrastes exploratorios, no Wilcoxon exactos. 43

C.8 Comparación completa con ResMLP: medias con 20 frente a 21 bloques, incluyendo RGB Pixel N-grams + SVD. Mismas 28 condiciones externas: DTD (10), FMD (15), CUReT (2) y Outex (1). La selección se repite dentro del entrenamiento. 43

C.9 Barrido completo del control de rescate fijo en desarrollo Outex. F1 es macro-F1 OOF; C es adquisición media proyectada en ms. Permanente utiliza el mismo rescate que la política condicional, sin reselección estática. 44

C.10 Barrido de la réplica por dataset/semilla: macro-F1 / costo proyectado (ms). Las tres reglas híbridas y el control estático mantienen los cuatro presupuestos. Las filas comparten imágenes; no representan dominios independientes. 45

C.11 Referencias del mismo desarrollo productor. Top-3/4/5 tienen tamaño fijo y no equivalen al Top-k heredado de GFS del benchmark. Costos proyectados, no latencias físicas. 46

C.12 Mismo rescate permanente frente a condicional en la réplica: macro-F1 / costo proyectado (ms), media de tres semillas FMD y dos Outex. La referencia permanente conserva los miembros seleccionados para la ruta condicional y no se reoptimiza bajo B. Incluye los casos sin rescate. . . . 47

E.1 Procedimiento de selección dentro de un entrenamiento productor. La validación productora no interviene en estos pasos. 55

E.2 Especificación de inferencia de la política seleccionada. El piloto la evalúa sobre puntuaciones guardadas; la ejecución física completa del híbrido no ha sido medida. 55

E.3 Controles del mismo piloto Outex: macro-F1 OOF sobre 680 imágenes de entrenamiento oficial y costo medio proyectado, no latencia física. 60

E.4 Piloto híbrido de Outex: macro-F1 OOF de desarrollo y costo proyectado. B es el presupuesto de selección en ms; los costos no son latencias físicas. 61

E.5 Control de poda y compuerta en relevancia/B60. Macro-F1 OOF sobre las mismas 680 imágenes; costo medio de adquisición proyectado y llamadas a clasificadores únicos por imagen. No son tiempos físicos. 62

E.6 Control estático optimizado dentro del pool visitado, con hasta tres miembros, frente al híbrido por relevancia bajo el mismo presupuesto. Macro-F1 OOF de desarrollo sobre 680 imágenes; C es adquisición media proyectada en ms. Δ es híbrido menos estático. 63

E.7 Réplica de desarrollo: media entre semillas nuevas de macro-F1 / costo proyectado (ms). El número entre paréntesis es el de semillas, no datasets independientes. B restringe el costo interno medio; no es el costo medido. Outex/42 no integra estas medias. 63

Capítulo 1

Introducción

1.1 Problema de investigación

Una imagen de textura puede describirse por la distribución de intensidades, la organización de patrones locales, las relaciones espaciales o las características aprendidas por una red. Estas representaciones responden de manera diferente a cambios de iluminación, escala y punto de vista. En consecuencia, un descriptor con buen rendimiento individual no necesariamente contiene toda la información útil para clasificar una superficie [1, 2].

La concatenación permite reunir varios vectores en una única representación y entrenar un clasificador sobre ella. Sin embargo, incorporar más descriptores aumenta la dimensión y exige ejecutar más extractores. Además, la información añadida puede ser redundante o modificar desfavorablemente el ajuste del clasificador. Por ello, la decisión no consiste únicamente en combinar representaciones, sino en determinar cuáles y cuántas conviene utilizar.

Esta tesis estudia una regla sencilla: ordenar los descriptores según su desempeño individual dentro del entrenamiento y concatenar los primeros k. A esta estrategia se la denomina Top-k. El estudio compara sus prefijos con la concatenación completa y con otros criterios de selección. Top-4 es un caso de tamaño fijo de especial interés por el compromiso observado entre calidad y dimensión; no se presupone que sea el mejor tamaño para todo conjunto de datos.

Una segunda decisión surge durante la clasificación. Aunque se haya seleccionado una concatenación útil, no todas las imágenes necesariamente requieren adquirir sus bloques. Una primera etapa puede resolver una parte de las consultas y utilizar el margen de sus puntuaciones para decidir si ejecutar el Top-k. La comparación relevante mantiene fijo ese Top-k: utilizarlo directamente o activarlo según la decisión de una base. La adquisición condicional tiene antecedentes y se evalúa aquí como una aplicación concreta a una biblioteca heterogénea de texturas [3, 4].

1.2 Recorrido: Top-k directo y versión optimizada

El argumento experimental tiene dos etapas. Primero se construye Top-k, se estudia por qué seleccionar pocos descriptores puede resultar más conveniente que concatenarlos

todos y se compara su desempeño con otros métodos. Después se toma esa concatenación como referencia y se optimiza su ejecución mediante la activación por margen: una base atiende cada imagen y el Top-k se calcula solo cuando la regla aprendida lo requiere. La versión optimizada constituye la segunda parte central del trabajo. Su evaluación debe mostrar cuánto costo evita y qué calidad conserva o pierde frente al uso directo del mismo Top-k.

1.3 Objetivo general

Evaluar la concatenación Top-k de descriptores para clasificar texturas y comparar su uso directo con su activación por margen, distinguiendo calidad predictiva, dimensión de representación, costo de adquisición y latencia física.

1.4 Objetivos específicos

1. Caracterizar la biblioteca de descriptores y el procedimiento de ranking y concatenación, incluyendo el tratamiento de RGB Pixel N-grams y sus transformaciones aprendidas.
2. Examinar el efecto de k, explicar el origen experimental del caso Top-4 y contrastarlo con descriptores individuales, concatenaciones completas y selecciones alternativas.
3. Comparar los resultados con implementaciones adaptadas de métodos de literatura, identificando diferencias de representación, protocolo y métrica.
4. Evaluar el mismo Top-k como ruta directa y como rescate activado por margen, incluyendo el costo de la base y la reutilización de bloques.
5. Delimitar qué conclusiones respaldan los registros guardados, los pilotos físicos y las comparaciones entre conjuntos, conservando las excepciones y reservas de procedencia.

1.5 Preguntas y alcance

El trabajo se organiza alrededor de dos preguntas:

P1. £Qué compromiso de desempeño y representación permite la concatenación Top-k, y qué evidencia justifica estudiar Top-4 frente a otras concatenaciones y N-gramas?

P2. £Cómo cambia ese compromiso al utilizar directamente el Top-k o activarlo mediante el margen de una primera etapa?

Se utilizan DTD, FMD, CUReT, Outex-TC-00013, SoilOriginal y KTH-TIPS-2b. El estudio estático incluye SVM lineal y una MLP residual sobre características. La comparación histórica directa/por margen utiliza SVM y 27 condiciones; sus tamaños Top-k proceden

de controles archivados y no son siempre cuatro. El barrido ampliado de tamaños contiene 47 condiciones por clasificador y tamaño. El número de condiciones no se interpreta como número de datasets independientes.

La biblioteca consolidada contiene 22 bloques, mientras que el barrido principal de k utiliza 21 sin N-gramas. Se identifican también las bibliotecas intermedias con N-gramas y sin BEiT-v2. Estas diferencias forman parte del diseño y no se ocultan bajo el nombre genérico de concatenación completa.

El estudio es exploratorio: resultados externos observados influyeron en decisiones posteriores, incluida la atención prestada a $k = 4$. La separación interna de entrenamiento y prueba evita ciertas fugas dentro de cada ejecución, pero no convierte todo el proceso de investigación en una confirmación ciega. Tampoco se identifica una disminución dimensional con una reducción proporcional del tiempo.

1.6 Aportes y organización

La contribución empírica consiste en documentar el recorrido desde la selección individual hasta una concatenación compacta, examinar sus límites y evaluar cuándo conviene adquirirla por imagen. Se aporta trazabilidad entre reglas, particiones, predicciones, costos y llamadas físicas. No se presenta el ranking Top-k ni una compuerta por margen como principios inéditos, ni se exige superioridad universal para considerar informativo el resultado.

Los Capítulos 2 y 3 presentan antecedentes y método; el Capítulo 4, el diseño. Los resultados siguen el mismo orden: construcción y comparación de Top-k, N-gramas y literatura, y finalmente uso directo/por margen. La discusión y las conclusiones responden P1 y P2. Los ensambles y la poda desarrollados durante el proyecto se conservan como estudios complementarios en el Anexo E, sin atribuirles la identidad del rescate Top-k.

Capítulo 2

Antecedentes y trabajos relacionados

2.1 Representaciones para clasificar texturas

Los descriptores clásicos resumen regularidades locales mediante histogramas, filtros, gradientes o estadísticas de coocurrencia. LBP codifica comparaciones vecinales; Gabor caracteriza respuestas a frecuencia y orientación; GLCM resume relaciones entre niveles de intensidad, y HOG organiza orientaciones de gradiente [5–8]. Cada familia destaca propiedades diferentes de la imagen. La invariancia buscada y el tamaño de su salida dependen de la implementación.

Las redes preentrenadas ofrecen otra fuente de características. CNN como ResNet y DenseNet, y modelos basados en atención como ViT, generan vectores que pueden utilizarse sin ajustar el backbone a la colección de texturas [9–11]. Un clasificador sobre esos vectores permite separar extracción y aprendizaje de la tarea. No obstante, una representación entrenada con otro dominio puede conservar información semántica o de forma que no coincide con la textura que se quiere distinguir.

RGB Pixel N-grams representa secuencias de píxeles de color mediante conteos [12]. Su interés en este trabajo es aportar información cromática y local a representaciones de otras familias. La implementación evaluada comprime sus conteos mediante SVD ajustada dentro del entrenamiento. Esa variante se denomina N-gramas+SVD y no se identifica automáticamente con todas las configuraciones ni los porcentajes del artículo original.

2.2 Concatenación y selección de bloques

La concatenación es una fusión a nivel de características: reúne los vectores antes de entrenar el clasificador. Un ensamble, en cambio, combina decisiones o puntuaciones de varios clasificadores. Aunque un miembro de un ensamble pueda recibir una concatenación, ambas operaciones resuelven decisiones distintas.

Seleccionar los primeros k descriptores de un ranking individual ofrece una referencia de baja complejidad conceptual. El ranking estima relevancia individual; no mide necesariamente la complementariedad condicionada a los bloques que ya están presentes. Un descriptor que no ocupa una posición alta puede añadir información útil a otro subcon-

junto.

Los métodos *wrapper* evalúan subconjuntos mediante el clasificador que los utilizará [13, 14]. GFS construye el conjunto de manera secuencial, añadiendo bloques según un criterio interno. Frente al ranking Top-k, esto examina más directamente la composición, pero exige más ajustes. La comparación debe informar por separado el número de bloques, la dimensión, el costo de selección y la inferencia.

Una selección realizada dentro del entrenamiento no justifica volver a elegir k mirando los resultados externos y describir esa elección como previa. El análisis de curvas externas es útil para explorar; su función y exposición deben declararse.

2.3 Métodos de literatura utilizados como comparación

Neshov et al. extraen características de varios niveles de una arquitectura preentrenada y las concatenan antes de una MLP [15]. El trabajo permite estudiar agregación entre capas, mientras que nuestro Top-k selecciona bloques de extractores diferentes. Las dos operaciones pueden relacionarse, pero no tienen el mismo costo ni la misma unidad de selección.

DeepLumina reúne características profundas obtenidas a partir de información RGB y de luminancia [16]. HyTexNet combina una codificación local guiada por percentiles con características profundas [17]. El método de Chang et al. fusiona LBP multiescala y contornos producidos por CellNN [18]. Estos casos representan formas concretas de concatenar información complementaria. Las dimensiones, checkpoints y cabezas utilizados en nuestras adaptaciones se identifican en las recetas del proyecto.

Scabini et al. comparan extractores basados en Vision Transformers y consideran eficiencia junto con calidad [19]. En el proyecto también existen mediciones derivadas de procesamiento por lotes. Su tiempo amortizado por imagen no se intercambia con la latencia individual de una consulta.

Tabla 2.1: Nivel de combinación y relación con la comparación propuesta.

Estrategia	Información combinada	Decisión que se estudia
Top-k	Bloques mejor valorados internamente	Qué bloques y cuántos
GFS	Bloques añadidos según utilidad conjunta	Composición del subconjunto
Neshov	Características de varias capas	Agregación dentro de arquitectura
DeepLumina	Características RGB/luminancia	Complementariedad cromática
HyTexNet / CellNN	Características profundas y patrones locales	Fusión de representaciones
Cascada por margen	Base y concatenación Top-k	Para qué imágenes adquirirla

2.4 Activación condicional y margen

Las cascadas distribuyen trabajo según decisiones intermedias [20]. La clasificación adaptativa bajo presupuesto incorpora una compuerta para limitar el uso de modelos costosos [3]. En sistemas con extractores independientes, el costo depende también de qué bloques puede reutilizar la segunda etapa.

El margen entre las dos mayores puntuaciones permite ordenar consultas según la separación que produce un clasificador. No es, por sí mismo, una probabilidad calibrada de acierto ni una garantía de que un rescate vaya a corregir el caso. La compuerta puede conservar aciertos de la base o evitar errores del Top-k, pero también descartar una segunda etapa que habría sido útil.

Otros enfoques incorporan costo de extracción durante el aprendizaje o adquieren características por información esperada [21, 22]. Las salidas tempranas dentro de redes reutilizan activaciones de una misma arquitectura [4, 23]. La tesis no reproduce todas estas familias; estudia una regla de dos etapas con margen y una concatenación fijada.

2.5 Criterio para comparar con un paper

Se distinguen tres alcances: una reproducción fiel requiere verificar el pipeline y protocolo; una aproximación conserva parte del diseño con supuestos explícitos; una adaptación permite comparar una receta en nuestro panel común. Coincidir en un porcentaje o reproducir una ecuación aislada no acredita identidad de datos, pesos, selección y evaluación.

La evaluación empírica utiliza macro-F1, accuracy y tiempos identificados por llamada. Los porcentajes publicados bajo otros repartos se usan como contexto. Para contrastar implementaciones se emparejan muestras y condiciones cuando la evidencia lo permite. Una referencia incompleta o cuyo ajuste exige revisión no se convierte en una media validada por omitir la condición fallida.

Capítulo 3

Concatenación Top-k y activación por margen

3.1 Bloques y bibliotecas de características

Sea $\mathcal{B}$ una biblioteca de descriptores. El extractor j transforma la imagen x en un vector $\phi_j(x) \in \mathbb{R}^{d_j}$. La unidad seleccionada es el bloque completo, no cada coordenada. Las características fijas se normalizan por imagen antes de la concatenación:

$$z_j(x) = \frac{\phi_j(x)}{\max(\|\phi_j(x)\|_2, 10^{-12})}, \qquad z_S(x) = \Big\|_{j \in S} z_j(x), \qquad d_S = \sum_{j \in S} d_j. \tag{3.1}$$

La concatenación no asigna por sí sola pesos de decisión: estos se aprenden al ajustar el clasificador sobre z_S. La normalización impide identificar automáticamente una mayor norma bruta con mayor importancia.

3.1.1 Ejemplo concreto: de cuatro vectores a una clase

En el archivo FMD/SVM, semilla 42 y pliegue externo 0, el prefijo de cuatro bloques es SigLIP-base (768 valores), DINOv2-large (1.024), EVA02-base (768) y DINOv2-base (768). Para una misma imagen se obtienen esos cuatro vectores, se normaliza cada uno con la Ecuación 3.1 y se colocan consecutivamente:

$$z_{S_4}(x) = [z_{\text{SigLIP}}(x) \| z_{\text{DINO L}}(x) \| z_{\text{EVA02}}(x) \| z_{\text{DINO B}}(x)] \in \mathbb{R}^{3328}. \tag{3.2}$$

Las filas de los cuatro bloques deben representar la misma imagen. Un único SVM se ajusta con estos vectores de 3.328 coordenadas y las etiquetas del entrenamiento. Para una imagen nueva se construye el vector en el mismo orden y el SVM entrega la clase de textura. La concatenación une características; el clasificador aprende cómo utilizarlas. Este ejemplo identifica una condición real, sin convertir sus cuatro nombres en una selección universal para todos los datasets.

El proyecto contiene bibliotecas relacionadas, pero diferentes. Sea $\mathcal{B}_{20}$ la biblioteca previa sin N-gramas ni el bloque final BEiT-v2. La incorporación de cada uno genera dos bibliotecas de 21 bloques:

$$\mathcal{B}_{21}^{Ng} = \mathcal{B}_{20} \cup \{Ng\}, \quad \mathcal{B}_{21}^{B} = \mathcal{B}_{20} \cup \{\text{BEiT}\}, \quad \mathcal{B}_{22} = \mathcal{B}_{20} \cup \{Ng, \text{BEiT}\}. \tag{3.3}$$

El barrido de tamaños utiliza 21 bloques sin N-gramas. Por tanto, su prefijo $k = 21$ no es la concatenación completa de 22. Las etiquetas de carpetas históricas no sustituyen esta identificación de candidatos.

La biblioteca consolidada reúne operadores clásicos, N-gramas y representaciones aprendidas congeladas. El Anexo A conserva parámetros y dimensiones. La SVD de N-gramas se aprende en cada entrenamiento pertinente; no se ajusta una proyección con todas las imágenes antes de separar prueba.

3.2 Ranking individual y construcción de Top-k

Para una partición externa, T contiene el entrenamiento y V la evaluación. Dentro de T, los pliegues T_ℓ^{fit}, T_ℓ^{val} respetan los grupos de dependencia. Cada descriptor se puntúa individualmente con el clasificador que se estudiará:

$$a_j = \frac{1}{L}\sum_{\ell=1}^{L} F_{1,\text{macro}}\Big(y_{T_\ell^{val}}, f_{j,\ell}(z_j(T_\ell^{val}))\Big)\,. \tag{3.4}$$

Se ordenan los bloques por a_j decreciente. En el barrido, los empates se resuelven por nombre. El prefijo de tamaño k es

$$S_k = \{j_{(1)}, \ldots, j_{(k)}\}, \qquad h_k = \text{Ajustar}\Big(z_{S_k}(T), y_T\Big). \tag{3.5}$$

Una vez fijado S_k, se reajusta el clasificador con todo T y se evalúa en V. El ranking puede cambiar entre datasets, clasificadores y particiones. Top-4 fija el número de bloques, no cuatro identidades universales.

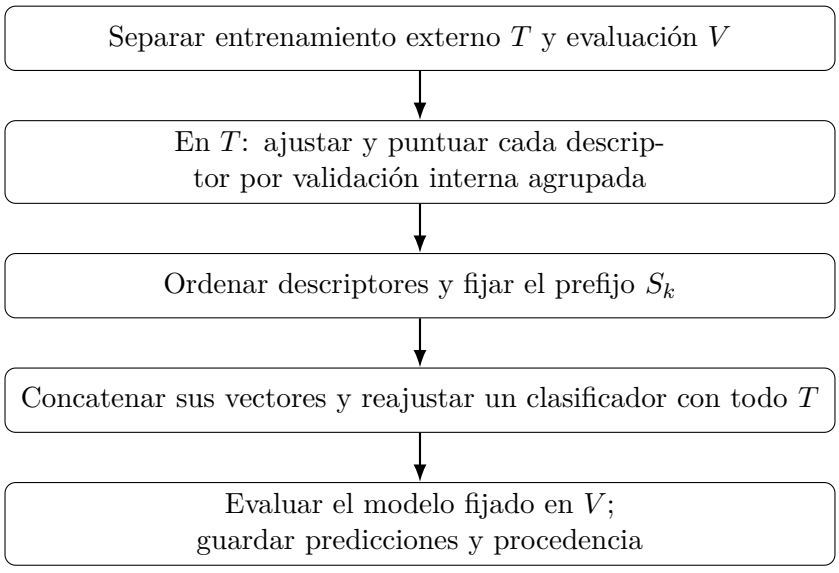


Figura 3.1: Construcción de una concatenación Top-k. Evaluar varios tamaños externos es una exploración; escoger uno después de observarlos no constituye selección interna de ese tamaño.

3.3 Barrido de tamaños y origen del caso Top-4

El barrido ejecuta los prefijos $k = 1, \ldots, 21$ del mismo orden interno. Cada punto permite examinar la relación entre calidad y representación. Se conserva también el descriptor añadido y el tamaño de la concatenación.

Hay dos controles distintos. En Top-4 se fija $k = 4$. En el Top-k histórico de igual tamaño que GFS, k se hereda del GFS archivado para esa condición y después se eligen los primeros bloques del ranking individual. Este control compara composiciones a un tamaño vinculado al otro procedimiento; no debe utilizarse para afirmar que cuatro fue el tamaño elegido en todas las condiciones.

La atención a Top-4 surgió al observar una región de la curva con buen compromiso de calidad y dimensión. Esa elección es exploratoria. Los máximos por dataset o clasificador son descripciones del barrido, no tamaños elegidos ciegamente para despliegue. La evaluación de Top-4 conserva también los casos en que tamaños mayores o la biblioteca completa obtienen mejor macro-F1.

3.4 Controles de concatenación y papel de N-gramas

El mejor individual se selecciona dentro del entrenamiento. Completa utiliza todos los bloques de la biblioteca identificada. GFS valora adiciones conjuntas y devuelve el mejor paso según su regla interna; la selección homogénea compara familias. Los ensambles de tómbola y diversidad combinan decisiones de varios miembros y se utilizan como controles complementarios.

El aporte de N-gramas se examina mediante versiones emparejadas de la biblioteca y el procedimiento de selección. Añadirlo a Completa mantiene el resto de los bloques; ofrecerlo a GFS o Top-k puede cambiar el subconjunto y su tamaño. Esta última comparación mide el efecto de ampliar la biblioteca y reseleccionar, no una ablación con todos los demás componentes fijos.

Un buen ranking individual no garantiza complementariedad: que N-gramas no aparezca entre los cuatro primeros no demuestra que añadirlo al Top-4 sea inútil. Si no existe ese control específico bajo el mismo protocolo, no se sustituye por otra comparación.

3.5 Uso directo y versión optimizada por margen

La optimización estudiada en esta segunda etapa modifica cuándo se ejecuta la concatenación seleccionada. Conserva el clasificador Top-k como rescate y añade una decisión de adquisición por imagen. Por ello se evalúa frente a su propio uso directo, además de las comparaciones estáticas de la primera etapa.

La ruta directa calcula $z_{S_k}(x)$ y devuelve $h_k(x)$ para todas las imágenes. No necesita ejecutar un clasificador base adicional.

La ruta condicional incorpora una base h_b, un bloque base b y un umbral τ. Para SVM multiclase, el margen es la diferencia entre las dos mayores puntuaciones de su función

de decisión:

$$m_b(x) = s_{b,(1)}(x) - s_{b,(2)}(x). \tag{3.6}$$

En clasificación binaria, la implementación utiliza el valor absoluto de la función de decisión. El margen no es una probabilidad calibrada.

La implementación histórica de esta cascada usa la regla

$$h_{\text{margen}}(x) = \begin{cases} h_b(x), & m_b(x) > \tau, \\ h_k(x), & m_b(x) \leq \tau. \end{cases} \tag{3.7}$$

Cuando se activa el rescate, su predicción reemplaza a la base. No se añade un voto ni se entrenan pesos de mezcla diferentes para la ruta directa y la condicional.

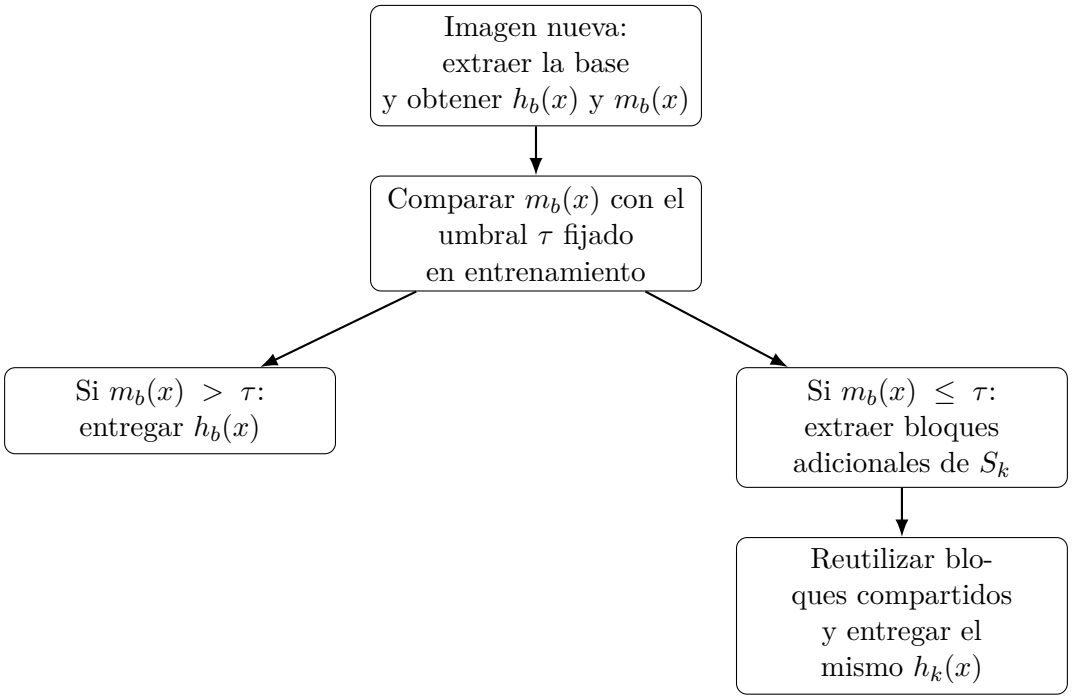


Figura 3.2: Clasificación por margen. La ruta directa de comparación ejecuta h_k sin base. La condición de margen no utiliza la etiqueta verdadera de la imagen nueva.

3.6 Cómo se aprenden la base y el umbral

El umbral se obtiene de márgenes fuera de pliegue del entrenamiento externo. Para cada base candidata se consideran cuantiles $q \in \{0,25; 0,50; 0,75\}$, utilizando la notación decimal de esos valores. El cuantil produce un umbral numérico y permite estimar la fracción derivada dentro del entrenamiento.

La variante de base seleccionada compara ResNet-50, SigLIP, BEiT-v2 y ConvNeXt V2-T cuando existen bloque y costo registrado. Entre las rutas cuyo macro-F1 interno está al menos en el valor Top-k menos 0,005, se selecciona el menor costo proyectado. El uso directo siempre es candidato. Los empates favorecen la ruta directa y después ResNet-50. Esta tolerancia es una decisión exploratoria del proyecto, no una garantía poblacional de no inferioridad.

Finalmente se reajustan los modelos seleccionados con todo el entrenamiento externo y se conserva el umbral numérico. El porcentaje de imágenes nuevas que activa el rescate puede ser distinto del cuantil nominal. No se recalcula el umbral utilizando etiquetas ni márgenes de todo el test.

3.7 Costo incremental y medición física

Sean c_j los tiempos por extractor del perfil de componentes. El costo directo y el costo incremental del rescate son

$$C_{\mathrm{dir}} = \sum_{j \in S_k} c_j, \qquad C_{\mathrm{inc}} = \sum_{j \in S_k \setminus \{b\}} c_j. \tag{3.8}$$

La base se reutiliza únicamente si su representación coincide con el bloque que necesita h_k. El perfil histórico aproxima la adquisición media por

$$\widehat{C}_{\mathrm{margen}} = c_b + \widehat{r}\, C_{\mathrm{inc}}, \tag{3.9}$$

donde $\widehat{r}$ es la fracción interna derivada. Su condición de ahorro proyectado es $c_b + \widehat{r} C_{\mathrm{inc}} < C_{\mathrm{dir}}$. Si la base cuesta más que la representación directa, la salida condicional puede no ser conveniente.

Esta ecuación corresponde al perfil de extracción histórico; no incorpora automáticamente todos los clasificadores, transferencias o sobrecostos de la compuerta. La latencia física debe cronometrar la ruta ejecutada y declarar si incluye decodificación, carga de pesos y calentamiento. Para un sistema residente, la ruta condicional suma base, compuerta y, cuando corresponda, extracción incremental y clasificador Top-k. La comparación directa omite la base.

La compacidad del vector, la extracción de bloques, el tiempo de selección, el entrenamiento y la latencia por consulta son magnitudes distintas. El diseño experimental y los resultados mantienen separadas sus unidades.

Capítulo 4

Diseño experimental

4.1 Recorrido de las pruebas hasta Top-4 y su optimización

El estudio avanzó por una secuencia de preguntas. Los pasos siguientes reconstruyen ese recorrido experimental; los registros ampliados y las bibliotecas correspondientes se identifican después para evitar tratarlos como una única corrida.

1. **Establecer referencias individuales.** Se evaluaron los descriptores por separado y se calculó un ranking mediante validación interna del entrenamiento. Esto permite conocer qué representación funciona bien sola y definir el punto de partida de una selección.

2. **Probar la concatenación completa.** Se entrenó un clasificador con todos los bloques de la biblioteca de cada corte. La comparación con Individual permitió examinar si añadir toda la información disponible compensa su mayor dimensión.

3. **Comparar maneras de elegir bloques.** GFS construye combinaciones valorando las adiciones; Homogénea restringe familias; el control Top-k toma los primeros del ranking con el mismo número de bloques que el GFS de esa condición. Este control separa la cantidad seleccionada de la composición.

4. **Recorrer todos los tamaños.** Un solo tamaño heredado no explica cuántos descriptores hacen falta. El barrido pasó a evaluar los 21 prefijos del ranking. El registro inicial SVM contenía 27 condiciones con semilla 42; los CSV ampliados contienen 47 por tamaño y clasificador, incluyendo ResMLP y más semillas FMD/Soil. La tesis utiliza la cobertura ampliada en sus curvas principales.

5. **Examinar el aporte marginal.** Se compararon la calidad y la dimensión al pasar de uno a dos, tres, cuatro y más bloques. La zona de buen rendimiento con pocos bloques motivó prestar atención a Top-4. El máximo observado y las pérdidas por dataset se conservan, en lugar de imponer cuatro como ganador de todas las curvas.

6. **Examinar alternativas y ampliaciones.** Los archivos exploratorios también incluyen reglas internas para elegir k, SFFS y selecciones aleatorias; su cobertura

no es la del barrido ampliado. Las comparaciones emparejadas con N-gramas estudian qué cambia al ampliar la biblioteca. Estos estudios contextualizan la elección sencilla por ranking, sin atribuirles una validación ciega de $k = 4$.

7. **Contrastar con métodos externos.** Se comparó Top-4 con adaptaciones de métodos de literatura y se midieron predicción y tiempo de las mismas llamadas. Se conservaron por separado porcentajes publicados, recetas adaptadas y resultados locales.

8. **Optimizar cuándo ejecutar Top-k.** Se tomó el uso directo como referencia y se estudió una base que activa el mismo rescate según su margen. Esta segunda parte compara calidad y adquisición por imagen, y utiliza los pilotos físicos dentro de su alcance.

La elección de Top-4 fue posterior a observar resultados del barrido. El ranking interno y la decisión exploratoria sobre un tamaño global son decisiones distintas. La secuencia documenta cómo surgió la opción compacta, sin presentarla como una regla derivada antes de ver toda la evidencia.

4.2 Experimentos y unidades de análisis

La evaluación reúne tres archivos con funciones distintas. El barrido permite estudiar k; el benchmark de selección compara estrategias sobre una biblioteca consolidada; la cascada contrasta el mismo Top-k directo y por margen. Un cuarto archivo físico permite describir las llamadas de Top-4 y de los comparadores externos. Sus cifras no se mezclan para construir una media nueva.

Tabla 4.1: Cobertura de los bloques experimentales utilizados en la tesis.

Conjunto	Barrido por k/clasif.	Estático por clasif.	Directo/margen SVM
DTD	10	10	10
FMD	15	15	5
CUReT	2	2	2
Outex13	1	1	1
SoilOriginal	15	15	5
KTH-TIPS2b	4	4	4
Total	47	47	27

El barrido contiene 21 tamaños por clasificador: 987 filas SVM y 987 ResMLP. Cada tamaño conserva las mismas 47 condiciones de su clasificador. Las 27 condiciones de cascada utilizan solo la semilla 42 en FMD y Soil, frente a tres semillas en los archivos ampliados. Las particiones oficiales DTD, las mitades complementarias de CUReT y las semillas repetidas comparten imágenes; sus condiciones no son réplicas independientes.

El panel online previo incluye cinco estrategias locales y dos clasificadores sobre 94 condiciones. La tesis extrae la evidencia de Top-4 de ese panel y la mantiene separada de sus otras políticas. Las 362.640 llamadas primarias del panel completo no son 362.640 llamadas de Top-4 ni una nueva medición del sistema directo/por margen.

4.3 Colecciones y particiones

Se utilizaron manifiestos para comprobar etiquetas, orden, dimensiones y valores finitos de los vectores. Los hashes y grupos permiten detectar duplicados y separar unidades relacionadas. La existencia de una separación externa dentro de una corrida no elimina la exposición de sus resultados durante el desarrollo.

DTD contiene 47 clases y diez particiones oficiales [24]. El estudio estático selecciona dentro de la unión de entrenamiento y validación de cada partición; la prueba de esa ejecución permanece fuera del ajuste. Los duplicados byte-idénticos que cruzaban roles se retiraron del entrenamiento. La reserva física de una condición del panel online se conserva en su documentación y no se interpreta como una validación nueva de todas las representaciones.

FMD contiene 1.000 imágenes y diez categorías [25]. Se usan cinco pliegues estratificados y agrupados con semillas 42, 123 y 2026. Cada imagen se identifica mediante un hash; la cascada utiliza los cinco pliegues de la semilla 42.

CUReT se basa en la distribución gris recortada de 61 materiales y 92 condiciones por clase [26]. Se fijaron dos mitades de 46 condiciones y ambas direcciones de entrenamiento/prueba. Las condiciones de adquisición se agrupan para no cruzar una misma configuración. Este reparto no identifica el subconjunto histórico exacto de cada paper y sus direcciones son dependientes.

Outex-TC-00013 contiene 1.360 imágenes de 68 clases y una partición oficial de 680/680 [27]. Se comprobaron imágenes RGB legibles, IDs y ausencia de duplicados exactos. Existe una alerta de correspondencia de filas y bloques de características cuyo rastreo se conserva como reserva; la enmienda DeiT del panel no se atribuye automáticamente a todos los archivos históricos.

SoilOriginal utiliza solo imágenes originales de la versión 1 de la colección *Comprehensive Soil Classification Datasets*. Tras deduplicación exacta se conservaron 1.140 imágenes, siete clases y 962 grupos conservadores por familia de nombre dentro de clase. No existe un split oficial utilizado en esta evaluación. Se aplican cinco pliegues agrupados y tres semillas en el archivo ampliado; la cascada conserva la semilla 42.

KTH-TIPS2b tiene 11 clases y cuatro muestras físicas por clase. El estudio mantiene cuatro particiones invertidas, con tres muestras para entrenar y una para probar. Algunos controles históricos difieren en agrupación interna y procedencia de representaciones. No se sustituye una media por la de otro control para dar por reconciliada toda la ruta. KTH se muestra descriptivamente y se excluye del contraste conjunto histórico de la cascada. Las aproximaciones al reparto de un tercio de algunos papers, con 44 muestras físicas compartidas entre entrenamiento y prueba, son otra evaluación y no se mezclan con este panel.

4.4 Clasificadores y transformaciones

La SVM lineal utiliza `LinearSVC`, $C = 1$, clases balanceadas, pérdida *squared hinge*, regularización L_2, uno-contra-el-resto y la receta registrada de tolerancia e iteraciones. El código conserva los parámetros y el estado del ajuste. Los avisos de convergencia se

informan; no se cambia el solver retrospectivamente para recuperar una cifra deseada.

ResMLP es una MLP residual sobre vectores, no una reproducción de una arquitectura homónima que recibe imágenes. Proyecta a 256 unidades y utiliza tres bloques residuales, normalización de capa, GELU y *dropout* de 0,1. Se ajusta con AdamW y la parada registrada sobre pérdida de entrenamiento. No se elige una época mediante el test.

La búsqueda interna utiliza pliegues estratificados y agrupados, limitada por disponibilidad de grupos. Las redes de extracción permanecen congeladas. Las transformaciones aprendidas, como SVD, se ajustan con el entrenamiento del pliegue correspondiente. Cuando se cambia la biblioteca o el clasificador, la selección se repite dentro de su protocolo; no se reutiliza un ranking de otro modelo como si fuera una nueva selección interna.

4.5 Cómo se comparan los prefijos y las bibliotecas

En cada condición del barrido se mantiene un ranking y se evalúan sus prefijos de uno a 21 bloques. Se comprueba cobertura íntegra para cada k, ausencia de duplicados de dataset/semilla/pliegue/tamaño y correspondencia con los resúmenes guardados. Esta evaluación no incluye N-gramas.

El estudio de N-gramas utiliza sus bibliotecas emparejadas y condiciones comunes. Las tablas de 20 frente a 21 bloques corresponden a un corte anterior a la incorporación final de BEiT-v2. Las tablas consolidadas de 22 y el barrido sin N-gramas responden a otro corte. La comparación no utiliza los nombres de las carpetas como prueba de identidad de bibliotecas.

Las medias principales se calculan dentro de cada dataset y luego se equiponderan los seis datasets:

$$\overline{F} = \frac{1}{D} \sum_{d=1}^{D} \left(\frac{1}{n_d} \sum_{r=1}^{n_d} F_{d,r} \right). \tag{4.1}$$

Este estimando difiere de reunir todas las predicciones y calcular un único F1. Las tablas indican cuando muestran una media por condición, un valor por llamada o un promedio OOF reunido.

4.6 Contraste del mismo Top-k directo y por margen

Cada condición conserva el subconjunto Top-k archivado, ajusta su clasificador con el entrenamiento externo y utiliza ese mismo resultado como referencia de la ruta condicional. La selección de base y umbral usa únicamente sus predicciones internas fuera de pliegue. Se conserva la alternativa Top-k directo si la cascada no resulta elegida.

Para la revisión final se reconstruyeron las métricas de las 27 condiciones desde sus JSON de predicción. Se verificaron identidad de dataset/protocolo, unicidad de índices dentro de cada prueba, longitud de arrays, macro-F1, fracción activada, bloques del rescate y hash del archivo de origen. Para cada imagen derivada se exigió que la predicción condicional coincidiera con la del Top-k directo. Esta comprobación atribuye las diferencias a conservar la base en las otras imágenes, y no a utilizar otro rescate.

La auditoría cubre 31.984 observaciones externas, no ese número de imágenes independientes. Reconstruye las decisiones guardadas sin volver a ajustar modelos. La coincidencia con el registro es una prueba de consistencia del archivo, no una reproducción independiente desde RGB.

4.7 Métricas y costos

Para C clases se usa

$$F_{1,\text{macro}} = \frac{1}{C}\sum_{c=1}^{C}\frac{2TP_c}{2TP_c + FP_c + FN_c}, \qquad \text{accuracy} = \frac{1}{n}\sum_{i=1}^{n}\mathbb{I}[\widehat{y}_i = y_i]. \tag{4.2}$$

Se aplica la convención registrada de valor cero ante denominador nulo. Un aumento de accuracy no implica necesariamente el mismo cambio de macro-F1.

Se informan también bloques, dimensión, tiempo de selección y ajuste, fracción derivada y costo incremental. Un porcentaje de dimensiones se refiere a su biblioteca de comparación. Un porcentaje de adquisición se refiere al modelo analítico de componentes. Ninguno se denomina automáticamente ahorro de latencia.

Los perfiles históricos de adquisición se midieron con imágenes de entrenamiento y se trasladaron como proxies entre dominios. El piloto físico de la cascada utiliza una condición por dataset, una imagen por clase y tres repeticiones pareadas, con modelos residentes e imágenes decodificadas. Sus 612 parejas corresponden a 204 imágenes. No se presentan como toda la prueba externa de cada dataset ni como latencia de arranque en frío.

El panel online posterior conserva predicción y tiempo de cada llamada batch1. Los tiempos de métodos diferentes proceden de fechas/estados de hardware distintos y tienen alcance descriptivo. Los tiempos amortizados de lotes de 32 pertenecen a otro régimen y no se incorporan a esas tablas.

4.8 Comparadores externos y controles estadísticos

Se utilizan las adaptaciones Neshov BEiTv2+MLP, HyTexNet y 6LBP+dCellNN con 47 condiciones completas cada una. DeepLumina mantiene 46 condiciones terminadas, avisos de no convergencia en todas y una condición DTD interrumpida. La tabla DTD no tiene una media completa de ese método. El protocolo aproximado Neshov FMD 10 por 10 es una comprobación separada, no el panel común.

Los contrastes agregados por dataset se separan por clasificador y familia de comparación. Friedman y los post-hoc archivados comparan las estrategias de su benchmark; no prueban que Top-4 fijo sea el mejor tamaño del barrido. En la cascada se mantiene la sensibilidad que excluye KTH. El no rechazo no demuestra equivalencia ni no inferioridad [28, 29].

4.9 Reglas de cierre y reproducibilidad

Toda condición nueva requiere congelar receta, versiones, pesos, semillas, partición y presupuesto antes de medir. Se conserva un benchmark GPU, CPU a dos hilos y lock global, sin ajuste o extracción concurrente con el cronometraje. No se repiten paneles cerrados para sustituir resultados desfavorables. Los fallos científicos mantienen evidencia y revisión, sin omisión de casos ni cambios silenciosos de método.

La actualización de este manuscrito añade auditorías y tablas reconstruidas; no ejecuta un nuevo barrido ni afirma una nueva campaña física. Los estudios de ensamble, poda y réplicas OOF permanecen en los anexos con su propio alcance.

Capítulo 5

Resultados experimentales

Los resultados responden primero cómo se construye y se compara Top-k, y después qué cambia al activarlo por margen. Se conservan separados el archivo de características, el panel online y los pilotos físicos. Las tablas generadas para esta revisión se vinculan con 124 fuentes mediante hashes y no añaden ajustes ni mediciones.

5.1 P1: del descriptor individual a la concatenación

El benchmark consolidado compara Individual, Completa, Top-k, GFS y Homogénea sobre seis datasets y dos clasificadores. Individual designa la mejor alternativa seleccionada internamente, no el máximo externo de todos los descriptores. El Top-k de esta primera tabla hereda su tamaño del control GFS; su nombre no significa Top-4 fijo.

Tabla 5.1: Macro-F1 externo de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	0,8426	0,8639	0,8700	**0,8703**	0,8604
DTD	ResMLP	0,8373	0,8620	**0,8643**	0,8639	0,8611
FMD	SVM	0,9726	0,9647	**0,9820**	0,9766	0,9789
FMD	ResMLP	0,9690	0,9564	0,9740	**0,9783**	0,9773
CUReT	SVM	0,9948	**0,9989**	**0,9989**	0,9988	0,9989
CUReT	ResMLP	0,9971	**0,9991**	0,9984	0,9986	0,9982
Outex	SVM	0,9066	**0,9656**	0,9426	0,9589	0,9307
Outex	ResMLP	0,9476	0,9416	0,9652	**0,9715**	0,9306
Soil	SVM	0,8578	**0,8816**	0,8776	0,8671	0,8670
Soil	ResMLP	0,8533	0,8649	0,8685	**0,8691**	0,8629
KTH-TIPS2-b	SVM	0,9396	**0,9601**	0,9400	0,9052	0,9271
KTH-TIPS2-b	ResMLP	0,9061	**0,9487**	0,9322	0,9201	0,9127

Tabla 5.2: Dimensión media de las representaciones usadas en la evaluación externa con 22 descriptores.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	819,2	20652,0	4480,0	5390,4	2496,0
DTD	ResMLP	768,0	20652,0	4211,2	4626,4	2598,4
FMD	SVM	768,0	20652,0	2969,6	2687,5	2338,1
FMD	ResMLP	768,0	20652,0	3404,8	3077,5	2218,7
CUReT	SVM	1024,0	20652,0	3328,0	4402,0	2944,0
CUReT	ResMLP	704,0	20652,0	2176,0	2880,0	1856,0
Outex	SVM	1024,0	20652,0	7808,0	6784,0	3712,0
Outex	ResMLP	256,0	20652,0	6016,0	3346,0	2176,0
Soil	SVM	768,0	20652,0	4898,1	3709,9	2184,5
Soil	ResMLP	768,0	20652,0	5529,6	4415,6	2235,7
KTH-TIPS2-b	SVM	832,0	20652,0	1280,0	960,0	960,0
KTH-TIPS2-b	ResMLP	672,0	20652,0	1600,0	1440,0	928,0

Completa tiene siempre 20.652 coordenadas; las otras estrategias pueden elegir subconjuntos distintos entre particiones.

Las medias muestran que una concatenación puede mejorar al mejor individual seleccionado, pero añadir indiscriminadamente bloques también puede empeorar. En FMD/SVM, Completa registra aproximadamente 0,9647, frente a 0,9726 de Individual y 0,9820 del Top-k del control. En Outex/SVM, en cambio, Completa alcanza aproximadamente 0,9656. Las diferencias entre datasets impiden definir una regla uniforme a partir del número de bloques.

La dimensión seleccionada y la calidad se reportan conjuntamente. La reducción de entrada al clasificador es informativa para almacenamiento y ajuste, pero no determina qué extractores dominan el tiempo de una consulta. Los contrastes del benchmark estático y su sensibilidad sin KTH se conservan en el Anexo C. Su alcance no se extiende a los tamaños fijos nuevos por un cambio de etiqueta.

5.2 Barrido de k y justificación del caso Top-4

La reconstrucción del barrido verifica 47 condiciones para cada tamaño de uno a 21 y cada clasificador. Las Tablas 5.3–5.5 y la Figura 5.1 describen ese archivo ampliado. El README inicial del barrido corresponde a menos condiciones y no sustituye sus CSV ampliados.

Tabla 5.3: Barrido exploratorio ampliado: medias equiponderadas de seis datasets, con 47 condiciones por tamaño y clasificador.

k	Macro-F1 SVM	Macro-F1 ResMLP	% dimensiones SVM
1	0,917448	0,917119	4,28
2	0,929892	0,932352	8,37
3	0,933921	0,933727	11,70
4	0,936554	0,933077	15,42
5	0,934857	0,935195	19,02
10	0,936764	0,933165	45,17
21	0,935616	0,929877	100,00

La referencia dimensional son los 21 bloques del barrido, sin N-gramas. El máximo observado no es un tamaño óptimo confirmado.

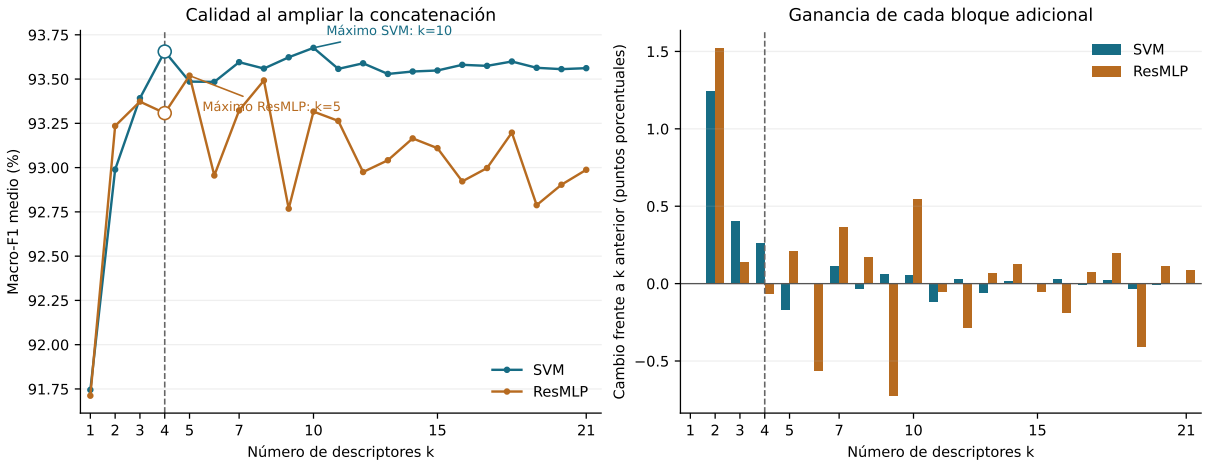


Figura 5.1: Calidad al aumentar el número de descriptores y ganancia de cada bloque adicional. Los círculos abiertos y la línea vertical señalan Top-4. Cada punto promedia primero dentro del dataset y después entre datasets. Una barra negativa indica pérdida al añadir ese bloque. Se muestran todos los tamaños, incluidos los máximos posteriores a cuatro.

Con SVM, Top-4 obtiene 0,936554 y el máximo descriptivo aparece en $k = 10$, con 0,936764. La diferencia es 0,000210 de macro-F1, mientras el porcentaje dimensional medio es aproximadamente 15,42 para cuatro bloques y 45,17 para diez, respecto a 21. Esto identifica una alternativa compacta cercana al máximo observado, no una prueba de equivalencia.

Con ResMLP, Top-4 registra 0,933077 y el máximo del barrido aparece en $k = 5$, con 0,935195. Por tanto, la elección de cuatro no maximiza todas las curvas. Tampoco puede reducirse la decisión al promedio global: la composición y la respuesta a k dependen del dataset y del clasificador.

5.2.1 Por qué estudiar cuatro: ganancia frente a crecimiento del vector

El eje horizontal representa el número de descriptores concatenados. Se trata de una curva de desempeño frente al tamaño de la representación; el número de imágenes de entrenamiento y las épocas no varían en ese eje. Para explicar la contribución incremental se calcula

$$g_k = 100\,[\overline{F}(k) - \overline{F}(k-1)], \qquad k = 2, \ldots, 21, \tag{5.1}$$

en puntos porcentuales de macro-F1. La Figura 5.1 muestra cada incremento, incluidos los negativos.

Con SVM, pasar de uno a cuatro bloques aumenta el macro-F1 medio de 0,917448 a 0,936554: una ganancia de 1,911 puntos porcentuales. Pasar de cuatro al máximo observado en diez aporta solo 0,021 puntos adicionales, mientras la dimensión media relativa aumenta de 15,42 a 45,17 %. Cuatro concentra aproximadamente el 98,91 % de la mejora observada entre uno y el máximo del barrido. Esta proporción describe la ganancia de F1, no el porcentaje de imágenes clasificadas correctamente ni un intervalo de equivalencia.

Así, Top-4 resulta una elección compacta con buena calidad media y una regla de tamaño

fácil de explicar. Después de cuatro se observan ocho pasos negativos y nueve positivos con SVM: el rendimiento fluctúa, en lugar de disminuir siempre. Con ResMLP, cinco aporta 0,212 puntos más que cuatro. La conclusión sustentada es que las ganancias posteriores pueden ser pequeñas frente al crecimiento de representación; identificar un mejor compromiso exige declarar qué calidad y costo se priorizan.

Tabla 5.4: Top-4 y concatenaciones completas en el archivo exploratorio (SVM).

Dataset	Cond.	Top-4	21 sin Ng	22 con Ng	Δ a 22
DTD	10	0,8689	0,8657	0,8639	0,0050
FMD	15	0,9823	0,9638	0,9647	0,0176
CUReT	2	0,9986	0,9991	0,9989	-0,0004
Outex-13	1	0,9288	0,9618	0,9656	-0,0368
Soil	15	0,8864	0,8738	0,8816	0,0048
KTH-TIPS2b	4	0,9544	0,9496	0,9601	-0,0057

Top-4 selecciona cuatro bloques de la biblioteca sin N-gramas. Los resultados KTH conservan su variante archivada. Esta tabla no es el panel online.

Tabla 5.5: Top-4 y concatenaciones completas en el archivo exploratorio (ResMLP).

Dataset	Cond.	Top-4	21 sin Ng	22 con Ng	Δ a 22
DTD	10	0,8612	0,8640	0,8620	-0,0007
FMD	15	0,9800	0,9591	0,9564	0,0236
CUReT	2	0,9984	0,9989	0,9991	-0,0007
Outex-13	1	0,9357	0,9476	0,9416	-0,0059
Soil	15	0,8662	0,8616	0,8649	0,0013
KTH-TIPS2b	4	0,9570	0,9481	0,9487	0,0083

Top-4 selecciona cuatro bloques de la biblioteca sin N-gramas. Los resultados KTH conservan su variante archivada. Esta tabla no es el panel online.

En FMD, cuatro es el máximo medio del barrido para ambos clasificadores y supera a concatenar toda la biblioteca. En Soil, cuatro también maximiza la curva SVM; con ResMLP el máximo aparece en ocho. Outex constituye una excepción relevante: la representación completa conserva una ventaja de calidad frente a cuatro. CUReT se encuentra cerca del techo de la métrica, donde diferencias pequeñas merecen una interpretación prudente. Los resultados KTH de este archivo conservan su variante histórica y no se utilizan para borrar la reserva de otra evaluación.

5.3 Qué aportan N-gramas y las ampliaciones de biblioteca

Las tablas previas distinguen 21 bloques sin N-gramas de la biblioteca de 22. El control histórico emparejado de 20 frente a 21 con N-gramas examina otra ampliación, anterior a BEiT-v2. Se conserva en la Tabla 5.6 para SVM y en el Anexo C para ResMLP.

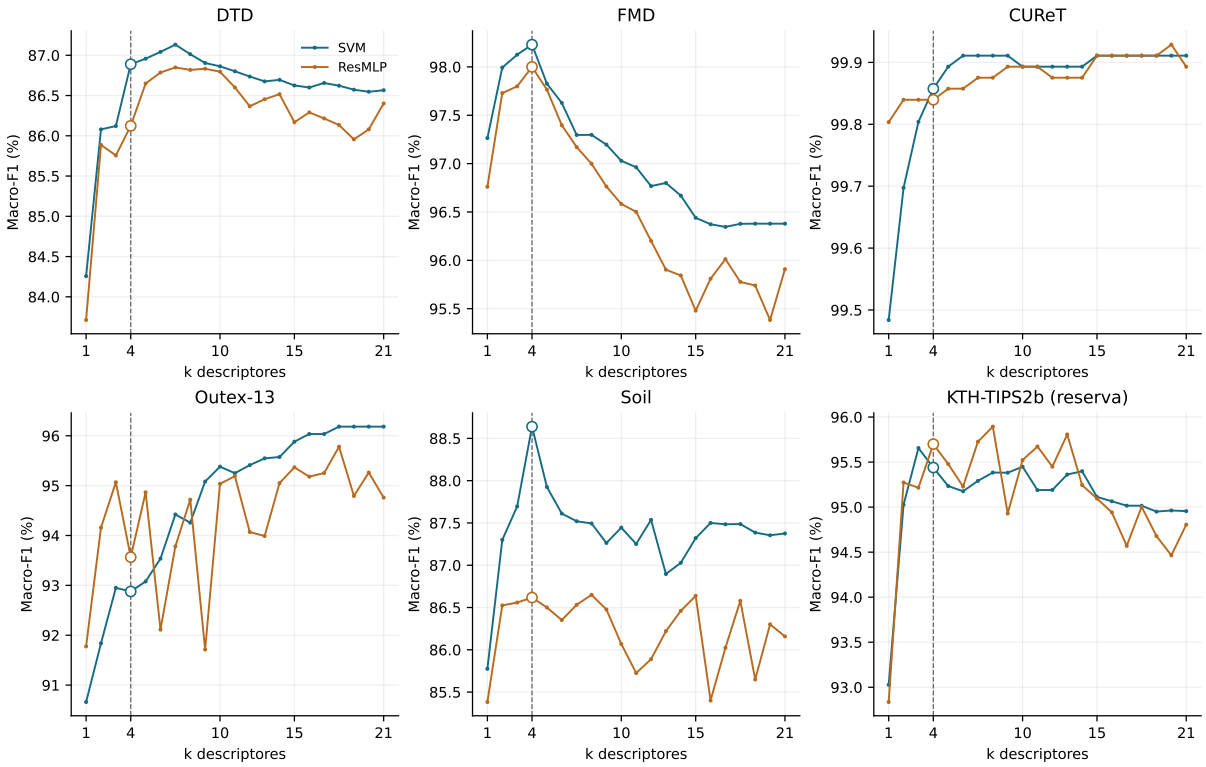


Figura 5.2: Barrido de tamaños en los seis datasets. Cada panel muestra SVM y ResMLP con medias de las condiciones del dataset. La línea vertical y los círculos abiertos señalan cuatro. Las escalas verticales se ajustan por panel para mostrar las variaciones; KTH mantiene su reserva de procedencia.

Tabla 5.6: Comparación completa con SVM: medias con 20 frente a 21 bloques, incluyendo RGB Pixel N-grams + SVD. Mismas 28 condiciones externas: DTD (10), FMD (15), CUReT (2) y Outex (1). La selección se repite dentro del entrenamiento.

Dataset	Estrategia	F1 (20)	F1 (21)	Δ F1	Exactitud (21)
DTD	Individual	0,8426	0,8426	0,0000 ± 0,0000	0,8448
DTD	Completa	0,8648	0,8629	−0,0019 ± 0,0026	0,8644
DTD	Top-k	0,8684	0,8684	0,0000 ± 0,0000	0,8697
DTD	GFS	0,8694	0,8694	0,0000 ± 0,0000	0,8707
DTD	Homogénea	0,8606	0,8606	0,0000 ± 0,0000	0,8623
FMD	Individual	0,9726	0,9726	0,0000 ± 0,0000	0,9727
FMD	Completa	0,9644	0,9644	0,0000 ± 0,0033	0,9643
FMD	Top-k	0,9820	0,9820	0,0000 ± 0,0000	0,9820
FMD	GFS	0,9766	0,9766	0,0000 ± 0,0000	0,9767
FMD	Homogénea	0,9789	0,9789	0,0000 ± 0,0000	0,9790
CUReT	Individual	0,9948	0,9948	0,0000 ± 0,0000	0,9948
CUReT	Completa	0,9991	0,9989	−0,0002 ± 0,0002	0,9989
CUReT	Top-k	0,9989	0,9989	0,0000 ± 0,0000	0,9989
CUReT	GFS	0,9988	0,9988	0,0000 ± 0,0000	0,9988
CUReT	Homogénea	0,9989	0,9989	0,0000 ± 0,0000	0,9989
Outex	Individual	0,9066	0,9066	0,0000	0,9103
Outex	Completa	0,9572	0,9674	0,0102	0,9676
Outex	Top-k	0,9503	0,9441	−0,0062	0,9456
Outex	GFS	0,9426	0,9610	0,0184	0,9618
Outex	Homogénea	0,9307	0,9307	0,0000	0,9324

F1 designa macro-F1. Δ es la media de las diferencias pareadas (21 menos 20), acompañada de su desviación estándar cuando hay más de una partición; no es un intervalo de confianza ni una prueba de significancia.

En ese control, añadir N-gramas a Completa en Outex cambia el macro-F1 de aproximadamente 0,9572 a 0,9674. La ampliación también puede cambiar qué subconjunto elige GFS o el Top-k de tamaño heredado. En DTD, Completa no mejora con la incorporación del bloque. El aporte no es uniforme y el resultado de una ampliación no se extrapola a todas las bibliotecas.

El ranking individual y la complementariedad responden preguntas distintas. La ausencia de N-gramas entre cuatro bloques mejor puntuados individualmente no demuestra que su combinación con ellos no sea útil. La tesis no presenta como ejecutado un control Top-4 más N-gramas que no tenga evidencia emparejada y cobertura identificada.

5.4 Comparación externa de Top-4 en llamadas online

Las Tablas 5.7 y 5.8 extraen Top-4/SVM del panel físico auditado y lo comparan con las adaptaciones externas sobre las mismas imágenes de cada condición. Las métricas de cada método se reconstruyeron con predicción y tiempo de las mismas llamadas. No se reutiliza aquí el F1 del barrido histórico con un tiempo medido después.

Tabla 5.7: Macro-F1 de Top-4/SVM y adaptaciones externas en el panel online auditado.

Dataset	Top-4	Neshov	HyTex	CellNN	DeepLumina
DTD	0,8689	0,8020	0,6242	0,2162	incompleto
FMD	0,9823	0,9421	0,7414	0,2477	0,8559†
CUReT	0,9986	0,9940	0,9831	0,6934	0,9881†
Outex-13	0,9288	0,9193	0,8927	0,6356	0,9073†
Soil	0,8594	0,8631	0,7880	0,3550	0,8050†
KTH-TIPS2b	0,9544	0,9245	0,8259	0,5750	0,8744†

† DeepLumina conserva avisos de no convergencia; DTD no tiene media completa. Los tiempos de métodos distintos provienen de fechas/estados de hardware diferentes y son descriptivos. KTH y DTD conservan sus reservas físicas/protocolares.

Tabla 5.8: Latencia media observada por imagen (ms) de las mismas llamadas que sustentan la tabla de macro-F1.

Dataset	Top-4	Neshov	HyTex	CellNN	DeepLumina
DTD	333,98	16,79	33,51	31,52	incompleto
FMD	268,96	16,89	31,18	29,66	53,33†
CUReT	270,69	14,27	32,41	31,02	53,00†
Outex-13	265,38	14,61	29,04	29,91	53,54†
Soil	70,98	19,17	33,11	32,98	57,80†
KTH-TIPS2b	260,38	16,48	30,98	31,94	51,57†

† DeepLumina conserva avisos de no convergencia; DTD no tiene media completa. Los tiempos de métodos distintos provienen de fechas/estados de hardware diferentes y son descriptivos. KTH y DTD conservan sus reservas físicas/protocolares.

En FMD, Top-4 alcanza aproximadamente 0,98230 frente a 0,94213 de la adaptación Neshov con MLP. Requiere más tiempo en las mediciones observadas. En Soil, Top-4 queda en 0,85940 frente a 0,86310 de Neshov, y su media temporal es mayor. Este caso desfavorable se conserva. Las mediciones de fechas distintas describen el archivo disponible y no identifican por sí solas una ventaja temporal causal.

Los valores Top-4 del panel online no se presentan como reproducción exacta de toda fila del barrido. Por ejemplo, Soil/SVM registra aproximadamente 0,88639 en el archivo de tamaños y 0,85940 en este panel. La discrepancia entre archivos requiere trazabilidad de selección, representación y ajuste; no se atribuye a una causa no demostrada ni se escoge el mayor número para una tabla final. Las conclusiones del barrido y las comparaciones por llamadas se mantienen dentro de sus archivos.

DeepLumina conserva una reserva científica: las 46 condiciones terminadas contienen avisos de no convergencia y la inspección de modelos encontró 1.653 de 2.441 clasificadores binarios en el límite de iteraciones. DTD contiene nueve de diez condiciones terminadas y no se informa una media completa. La existencia de predicciones no convierte esos ajustes en una réplica validada.

La aproximación separada Neshov FMD de 100 condiciones y 10.000 llamadas registra accuracy 94,22 %, frente a 96,7 % publicado. La diferencia no se oculta ni se transforma en un cambio de receta para forzar coincidencia. Se trata de una aproximación con diferencias de partición y entorno. Los porcentajes de otros artículos se interpretan de igual modo según sus protocolos.

5.5 P2: optimización mediante activación por margen

La auditoría reconstruye 27 condiciones SVM y 31.984 observaciones de prueba a partir de las predicciones guardadas. Verifica que, en todas las imágenes derivadas, el resultado condicional es el del mismo Top-k directo. Los tamaños del rescate van de uno a ocho: cinco condiciones usan cuatro. Son una evaluación de Top-k por condición, no 27 experimentos Top-4 fijo.

Tabla 5.9: Uso directo y activación por margen del mismo Top-k: auditoría de las 27 condiciones guardadas, SVM.

Dataset	k observados	Directo F1	Margen F1	Δ F1	Rescate %
DTD	4/5/6/7/8	0,8700	0,8700	0,0000	23,0
FMD	3/4/5	0,9829	0,9840	0,0010	20,7
CUReT	4/5	0,9989	0,9982	-0,0007	20,0
Outex-13	8	0,9426	0,9369	-0,0056	19,9
Soil	3/5/6/7/8	0,8701	0,8734	0,0033	23,6
KTH-TIPS2b	1/2	0,9400	0,9445	0,0045	38,2

Se conserva el Top-k específico de cada condición; k no es siempre cuatro. KTH mantiene la reserva de procedencia y no integra inferencia conjunta. La tasa incluye Top-k directo cuando esa fue la ruta seleccionada.

Se identificaron además las cinco condiciones cuyo rescate tiene cuatro bloques y coincide exactamente con el subconjunto Top-4 del barrido de esa partición. La Tabla 5.10 conserva sus aumentos, pérdidas y empates. El subconjunto se define por identidad de bloques y tamaño, no por favorecer la activación. No representa cobertura Top-4 por margen en los seis datasets.

Se selecciona cascada en 26 condiciones y uso directo en una. Las bases de las rutas condicionales son SigLIP en veinte condiciones, BEiT-v2 en cinco y ResNet-50 en una.

Tabla 5.10: Condiciones donde el rescate coincide con el Top-4 del barrido, SVM.

Condición	Directo F1	Margen F1	Δ F1	Rescate %
DTD / split 10	0,860440	0,864968	0,004529	24,47
DTD / split 8	0,854571	0,853492	-0,001079	22,34
FMD / fold 2	0,984994	0,984994	0,000000	17,00
FMD / fold 3	1,000000	1,000000	0,000000	19,50
CUReT / A a B	0,998218	0,996792	-0,001426	22,45

Subconjunto definido por k=4 y coincidencia de bloques, no por signo del resultado. Son cinco condiciones de tres datasets; no una evaluación Top-4 por margen completa en seis datasets.

Estas elecciones provienen del criterio interno identificado en el método; no se escoge una base por el mayor F1 externo.

En FMD, el uso directo registra macro-F1 medio 0,982926 y la política por margen 0,983953. En Outex, la política condicional baja de 0,942574 a 0,936950. CUReT presenta una pérdida pequeña; DTD queda muy próximo en promedio. Soil y el KTH histórico muestran aumentos. La compuerta no produce una mejora uniforme.

La ruta condicional puede superar a Top-k porque conserva la predicción base en las imágenes que no deriva. Top-k directo no es un techo matemático de esa combinación. Del mismo modo, un margen alto puede conservar un error que la segunda etapa habría corregido. La auditoría guarda ambos conteos, junto con los cambios de clase.

5.6 Adquisición proyectada y pilotos físicos

Tabla 5.11: Costos de extracción proyectados de las rutas históricas. No son latencias online por dataset.

Dataset	Directo (ms)	Margen (ms)	Reducción %
DTD	661,82	171,95	74,0
FMD	583,42	138,74	76,2
CUReT	655,64	153,45	76,6
Outex-13	729,48	165,90	77,3
Soil	271,28	85,20	68,6
KTH-TIPS2b	278,05	64,89	76,7

Cociente de medias por dataset; perfiles históricos por componente. No incluye una nueva medición física ni valida las discrepancias de representación.

Los costos por componentes proyectan reducciones en las rutas seleccionadas. Esa selección utiliza costos y predicciones internas; la fracción efectivamente derivada al evaluar puede cambiar. Las cifras no incluyen automáticamente todos los elementos del sistema y no se denominan ahorro online de cada prueba externa.

El piloto reúne 204 imágenes y 612 parejas, no 612 imágenes independientes. Los tiempos observados favorecen la ruta condicional en esas condiciones. Sin embargo, CUReT y Soil mantienen discrepancias entre los vectores físicos y cacheados; sus cosenos mínimos fueron aproximadamente -0,0707 y 0,0085. Coincidir en clase o ruta no demuestra identidad de representación. Los tiempos no cierran esa reserva ni acreditan reducción general en los seis conjuntos.

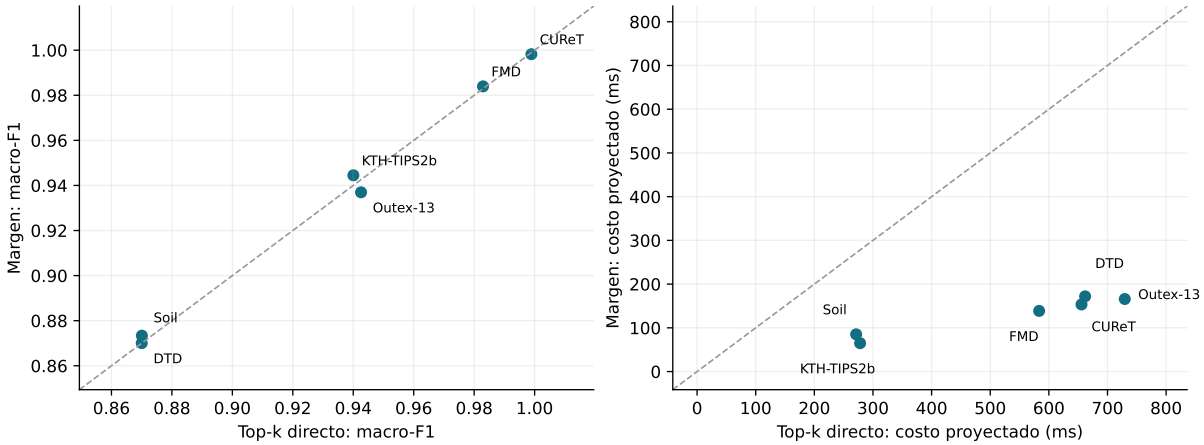


Figura 5.3: Comparación por dataset del uso directo y por margen: calidad a la izquierda y adquisición proyectada a la derecha. La diagonal indica igualdad de la magnitud; el panel de costo no es un cronometraje físico nuevo. KTH conserva su reserva.

Tabla 5.12: Piloto físico histórico, una condición por dataset. Modelos residentes e imágenes decodificadas; una imagen por clase y tres repeticiones pareadas.

Dataset	Imágenes	Pares	Margen ms	Directo ms	Reserva
DTD	47	141	90,57	295,55	alcance del piloto
FMD	10	30	13,01	208,08	alcance del piloto
CUReT	61	183	92,52	270,60	representación
Outex13	68	204	111,47	354,31	alcance del piloto
Soil	7	21	41,99	109,10	representación
KTH-TIPS2b	11	33	46,08	188,33	variante histórica

El control físico KTH con salida directa justa documentó también que una cascada puede ser más lenta cuando Top-k ya es barato. La posibilidad de elegir uso directo forma parte de la decisión estudiada, no constituye un caso que se deba omitir.

5.7 Síntesis de evidencia

P1 queda respaldada por un barrido amplio y por comparaciones que identifican tanto ventajas de compactar como pérdidas frente a representaciones mayores. P2 dispone de una comparación por predicciones del mismo Top-k, costos analíticos y pilotos físicos delimitados. La cobertura completa de las predicciones no convierte automáticamente los costos en latencias físicas completas.

Los experimentos de ensamble y poda permiten otras preguntas y se conservan en el Anexo E. No se utilizan sus porcentajes de ahorro para atribuir un resultado al Top-k directo/por margen del cuerpo principal.

Capítulo 6

Discusión

6.1 Qué justifica estudiar Top-4

El barrido muestra una mejora importante al pasar de una representación individual a concatenaciones pequeñas. Después aparece una región de variaciones menores, sin una ganancia monótona al añadir bloques. Con SVM, cuatro se encuentra cerca del máximo medio observado con una fracción reducida de dimensiones. Esto justifica estudiarlo como un compromiso práctico y explicable.

La conclusión no es que cuatro constituya una constante óptima de la clasificación de texturas. Con ResMLP, el máximo descriptivo del barrido aparece en cinco. Outex se beneficia de una representación mayor; otras colecciones tienen márgenes pequeños de mejora o se aproximan al techo de la métrica. El promedio global no reemplaza estas diferencias.

El origen de la elección también importa. Top-4 se destacó después de observar curvas externas, aunque los rankings de cada corrida se calcularan dentro del entrenamiento. Esa cronología permite una conclusión exploratoria sobre el archivo y una hipótesis para otra evaluación; no demuestra selección ciega de k.

6.2 Relevancia individual y complementariedad

Top-k ordena descriptores por cómo funcionan solos. Una concatenación, sin embargo, utiliza la información conjunta. Dos bloques individualmente fuertes pueden ser redundantes, y un bloque menos destacado puede corregir una limitación común de los primeros.

N-gramas es relevante para interpretar esa diferencia. Su información cromática y local puede cambiar una concatenación aunque no encabece el ranking individual. Los controles con/sin el bloque muestran beneficios en algunos casos y pérdidas en otros. La explicación no debe reducirse a que una familia sea intrínsecamente superior: cambian biblioteca, combinación, clasificador y dominio.

GFS permite examinar adiciones condicionadas al subconjunto, pero tiene una búsqueda más costosa y tampoco garantiza un óptimo global. El control que hereda su tamaño ayuda a separar composición y cantidad, siempre que se mantenga identificado como otra

regla. Los ensambles permiten agregar decisiones, pero su ventaja no demuestra una mejora de la concatenación de un único vector.

6.3 Cuándo tiene sentido la activación por margen

La ruta condicional es útil si la base resuelve una proporción suficiente de consultas y el costo incremental evitado compensa su propio costo. No basta con que la base sea nominalmente pequeña; debe compararse con los bloques concretos del Top-k. Si la concatenación seleccionada ya es rápida, ejecutar una base adicional puede perjudicar el tiempo.

La compuerta conserva dos posibles beneficios: evitar adquirir información innecesaria y mantener aciertos de la base que Top-k no comparte. También introduce dos riesgos: descartar un rescate útil y ejecutar un rescate que empeora la predicción. Por eso, una fracción baja de derivación no basta para evaluar el método; se requieren calidad y costo en las mismas rutas.

La tolerancia interna de 0,005 limita el conjunto de candidatos del procedimiento registrado. No garantiza una pérdida externa menor a ese valor, ni tiene por sí sola el significado de una prueba de no inferioridad. El traslado del umbral al modelo reajustado puede cambiar la escala de márgenes y la tasa de rescate.

6.4 Qué permite afirmar el tiempo medido

La dimensión del vector es una propiedad de la representación. La latencia depende de extractores, hardware, preprocesamiento, residencia, transferencia y clasificadores. Cuatro bloques pueden incluir redes costosas; una representación de más coordenadas puede provenir de un extractor económico. No corresponde convertir el 15 % de dimensiones de un punto en un 85 % de ahorro temporal.

Los perfiles analíticos sirven para comparar candidatos bajo constantes comunes y seleccionar antes de evaluar. Los pilotos físicos comprueban comportamiento de una implementación y de una muestra de imágenes. El panel online posterior permite asociar F1 y tiempo de cada llamada, pero sus diferencias entre fechas no son un experimento pareado simultáneo de todos los métodos.

Las discrepancias de representación de CUReT y Soil impiden cerrar el vínculo entre algunos embeddings y la ejecución física. La identidad de predicciones no resuelve esa diferencia. Se necesita una reconciliación de capa, transformación, checkpoint y muestras antes de extender el alcance, no una explicación causal elegida a partir de una coincidencia parcial.

6.5 Interpretación de la comparación con papers

La tabla externa responde cómo se comportaron adaptaciones en el panel local. No demuestra que nuestras recetas reproduzcan íntegramente los artículos ni que las cifras

publicadas sean incorrectas. El protocolo aproximado Neshov, por ejemplo, conserva una diferencia observada de accuracy respecto del porcentaje publicado.

DeepLumina exige una reserva adicional de ajuste. No conocer el impacto de la no convergencia sobre F1 impide atribuir toda una diferencia a la calidad de su idea de concatenación. Una tabla con datos disponibles puede ser informativa si mantiene esa condición y la cobertura incompleta, pero no debe utilizarse como prueba definitiva de superioridad sobre el método del paper.

Top-4 también presenta pérdidas: Soil frente a Neshov en el panel online es un ejemplo. La selección de un método exige decidir qué calidad y costo son aceptables para una aplicación; una clasificación global de ganadores ocultaría ese compromiso.

6.6 Amenazas a la validez y alcance

La primera amenaza es la exposición acumulada a benchmarks durante el desarrollo. Separar pliegues sigue siendo necesario, pero no elimina la influencia de resultados anteriores sobre nuevas decisiones. Las bibliotecas intermedias y los distintos regímenes de medición constituyen otra fuente de confusión si no se identifican.

La segunda es la dependencia: semillas, particiones y repeticiones físicas reutilizan imágenes. Aumentar su número no equivale a incorporar nuevos dominios. Las desviaciones entre pliegues no son intervalos de generalización universal; el no rechazo estadístico no acredita igualdad.

La tercera es la conciliación entre archivos. El barrido, el benchmark estático y el panel online no se intercambian automáticamente. Las diferencias Top-4 de Soil y las variantes KTH requieren trazabilidad adicional antes de atribuir identidad de modelo y representación. Esta tesis conserva los archivos y no selecciona entre cifras según cuál favorece la hipótesis.

Finalmente, faltan controles específicos para algunas preguntas secundarias, como Top-4 más N-gramas bajo determinadas bibliotecas y una campaña física íntegra del mismo Top-k directo/condicional con todas sus representaciones reconciliadas. Su ausencia limita esas afirmaciones, pero no invalida la comparación descriptiva que sí dispone de predicciones y procedencia.

6.7 Implicación para el diseño de un clasificador

El recorrido permite plantear una decisión ordenada: elegir primero una biblioteca y un clasificador, evaluar la representación pequeña frente a referencias y solo después estudiar si una base aporta ventaja de adquisición. Esa secuencia evita introducir una compuerta para compensar una concatenación que no fue comparada adecuadamente.

La contribución de la tesis es documentar ese recorrido con sus resultados y límites. No depende de que Top-4 gane todos los datasets, de que el margen siempre mejore F1 o de que se igualen porcentajes publicados.

Capítulo 7

Conclusiones y trabajo futuro

7.1 Respuesta a las preguntas de investigación

Esta tesis estudió primero la construcción y el uso directo de la concatenación Top-k de descriptores para clasificar texturas y después la optimización de su ejecución mediante activación por margen. Ambas etapas forman parte del aporte: seleccionar una representación útil y decidir para qué imágenes compensa adquirirla.

Para P1, el barrido de uno a 21 bloques, con 47 condiciones por tamaño y clasificador, mostró que aumentar la representación no mejora uniformemente el macro-F1. Top-4/SVM alcanzó una media equiponderada por dataset de 0,936554, frente al máximo descriptivo de 0,936764 en $k = 10$, utilizando aproximadamente 15,42 % de las dimensiones de la biblioteca sin N-gramas. Con ResMLP, el máximo observado correspondió a cinco. Los datos respaldan estudiar Top-4 como alternativa compacta, no declararlo óptimo universal ni equivalente estadísticamente al máximo.

La comparación por dataset conserva situaciones donde concatenar más información resulta útil. N-gramas mostró que relevancia individual y complementariedad no son intercambiables. Sus variantes con SVD y las bibliotecas intermedias deben identificarse para no atribuir a la selección un efecto producido por cambiar los candidatos. Las adaptaciones de papers ofrecen contexto empírico, con diferencias de receta y reservas explícitas.

Para P2, se reconstruyeron 27 condiciones SVM con el mismo Top-k directo y como rescate condicional. En todas las imágenes derivadas, la predicción condicional coincide con la del rescate fijado. La ruta por margen puede conservar o mejorar calidad al evitar ciertas decisiones de Top-k, pero también puede perder aciertos. FMD mostró un aumento medio de macro-F1 y Outex una disminución. Sus tamaños no son siempre cuatro y la evidencia no se presenta como 27 comparaciones de Top-4 fijo.

Los costos por componentes proyectan menor adquisición en las rutas elegidas; los pilotos físicos aportan observaciones favorables de tiempo en condiciones delimitadas. Las discrepancias de representación, las variantes KTH y el alcance de los cronometrajes impiden concluir ahorro físico universal o equivalencia predictiva. La complejidad del vector y la latencia son magnitudes que deben medirse por separado.

7.2 Contribución y límites del cierre

El aporte consiste en un estudio trazable de selección, concatenación y adquisición por imagen: identifica cómo se obtiene el subconjunto, qué evidencia motiva un tamaño compacto y cuándo se utiliza una primera etapa para decidir su ejecución. Se conservan tanto mejoras como pérdidas y se separan archivos históricos, llamadas online y experimentos complementarios.

Las comparaciones externas no se presentan como reproducción fiel de todos los porcentajes publicados. DeepLumina permanece bajo revisión por no convergencia e incompletitud DTD. Las discrepancias entre archivos Top-4 tampoco se resuelven escogiendo la cifra más favorable. Las conclusiones son las de una investigación exploratoria con evidencia localizada, no las de una confirmación ciega de superioridad.

7.3 Trabajo futuro delimitado

Las prioridades son conciliar las variantes pendientes de representación y procedencia; completar controles específicos de complementariedad con N-gramas; y medir de manera pareada el sistema directo/por margen bajo un régimen físico explícito. Toda condición nueva deberá fijar receta y criterio antes de evaluar, conservando los datos ya observados como tales.

También es pertinente examinar bases y tamaños seleccionados con otros dominios de evaluación. Una compuerta más compleja o un rescate de ensamble constituye otra hipótesis y requiere controles propios. El estudio aquí presentado muestra que la pregunta útil no es cuántos descriptores se pueden concatenar, sino qué combinación aporta calidad y para qué imágenes compensa adquirirla.

Anexo A

Especificaciones de representación y selección

Este anexo conserva la parametrización necesaria para reproducir las representaciones y comparadores. Su extensión no implica que todos los bloques se adquieran para cada imagen de una ruta condicional.

La biblioteca de 21 bloques del barrido excluye N-gramas y tiene 20.396 dimensiones nominales. No es la biblioteca intermedia de 21 con N-gramas y sin BEiT-v2, de 19.884 dimensiones. La biblioteca consolidada de 22 suma 20.652. Se conserva esta distinción al interpretar los porcentajes de compacidad.

A.1 Espacio de descriptores

La biblioteca contiene cinco operadores clásicos, RGB N-gramas con SVD y 16 extractores aprendidos congelados. Cada uno constituye un bloque candidato sujeto al mismo criterio de selección. Las Tablas A.1 y A.2 identifican la parametrización, los checkpoints y la dimensionalidad de cada bloque. Las redes preentrenadas se ejecutaron en modo evaluación y sin ajuste de pesos. En los modelos cargados mediante `timm` se eliminó la capa clasificadora (`num_classes=0`) y se aplicó el preprocesamiento asociado al checkpoint. Para ViT, DeiT, Swin, MAE y SigLIP se utilizó la salida *pooler* cuando estaba disponible y, en caso contrario, el token de clasificación. Todas las imágenes se convirtieron a RGB.

Los descriptores clásicos se basan en operadores LBP, Gabor, GLCM y HOG [5–8, 30]. Las CNN corresponden a VGG16, ResNet, DenseNet, EfficientNet y ConvNeXt V2 [9, 10, 31–33]. El grupo Transformer incluye ViT, DeiT, Swin y EVA-02 [11, 34–36]; las representaciones con preentrenamiento autosupervisado o multimodal se basan en DINOv2, MAE y SigLIP [37–39].

Los descriptores clásicos se calcularon en escala de grises con la implementación de scikit-image: LBP, LBP-rot, Gabor y GLCM sobre imágenes redimensionadas a 256×256, y HOG sobre 128×128. LBP-rot designa la implementación propia registrada como `drlbp` en los archivos experimentales: aplica LBP con mapeo `ror` a ocho rotaciones y concatena diez bins por rotación en el intervalo $[0, 10]$. Los códigos fuera de ese intervalo se descartan; por tanto, es un histograma restringido, no una reproducción del DRLBP

Tabla A.1: Seis descriptores basados en patrones, filtros, gradientes y conteos incluidos en la biblioteca. Cada fila constituye un bloque completo.

Descriptor	Parametrización	Salida	Dim.
LBP	multiescala $(P, R) = (8, 1), (16, 2), (24, 3)$; mapeo `uniform`	histogramas normalizados	54
LBP-rot	$P = 8$, $R = 1$; ocho rotaciones; códigos limitados a $[0, 10]$	histogramas 10×8	80
Gabor	cuatro frecuencias 0,1–0,8; seis orientaciones	media y desv. de respuesta real	48
GLCM	256 niveles; distancias 1–3; cuatro ángulos; seis propiedades	promedios sobre ángulos	18
HOG	nueve orientaciones; celda 16^2; bloque 2^2; norma L2-Hys	vector HOG	1.764
N-gramas	ventana vertical 2×1; cuantización RGB por 12; 8.192 bins; SVD	vector normalizado	256

Tabla A.2: Representaciones aprendidas congeladas incluidas en la biblioteca (16 extractores profundos y de modelos fundacionales). "Preclas." designa la salida inmediatamente anterior al clasificador del backbone.

Familia	Descriptor	Checkpoint	Salida	Dim.
CNN	VGG16	`vgg16.tv_in1k`	preclas.	4.096
	ResNet-50	`resnet50.a1_in1k`	preclas.	2.048
	ResNet-101	`resnet101.a1_in1k`	preclas.	2.048
	DenseNet-121	`densenet121.tv_in1k`	preclas.	1.024
	EfficientNet-B0	`efficientnet_b0.ra_in1k`	preclas.	1.280
	ConvNeXt V2-T	`convnextv2_tiny.fcmae_ft_in22k_in1k`	preclas.	768
Transformer	ViT-B/16	`google/vit-base-patch16-224`	pooler/CLS	768
	DeiT-S	`facebook/deit-small-patch16-224`	pooler/CLS	384
	Swin-T	`microsoft/swin-tiny-patch4-window7-224`	pooler	768
	EVA-02 base	`eva02_base_patch14_224`	preclas.	768
	BEiT-v2-B[†]	`beitv2_base_patch16_224.in1k_ft_in22k_in1k`	preclas.	768
Autosup./multimodal	DINOv2-S	`vit_small_patch14_dinov2.lvd142m`	preclas.	384
	DINOv2-B	`vit_base_patch14_dinov2.lvd142m`	preclas.	768
	DINOv2-L	`vit_large_patch14_dinov2.lvd142m`	preclas.	1.024
	MAE-B	`facebook/vit-mae-base`	pooler/CLS	768
	SigLIP-B	`google/siglip-base-patch16-224`	pooler/CLS	768

[†]BEiT-v2-B (768d) consolida la biblioteca en 22 extractores (20.652 dimensiones conjuntas).

de Mehta y Egiazarian [30].

La biblioteca consolidada del estudio comprende 22 descriptores (cinco operadores clásicos, N-gramas con SVD y 16 extractores aprendidos), cuyos vectores concatenados suman 20.652 dimensiones (19.884 dimensiones correspondientes al conjunto preliminar de 21 descriptores más 768 componentes aportadas por BEiT-v2-B). Las características fijas y los conteos por imagen se almacenaron junto con etiquetas, orden de muestras y hashes de procedencia; las transformaciones aprendidas se ajustaron dentro de cada partición de entrenamiento. El estudio evalúa la selección y concatenación de bloques con extractores de imagen congelados y transformaciones ajustadas dentro del entrenamiento; no compara estrategias de *fine-tuning*.

RGB Pixel N-grams [12] utiliza ventanas verticales de 2×1 píxeles con paso 1 sobre la imagen RGB en su resolución original. Cada canal se cuantiza mediante $q(v) = \lfloor v/12 \rfloor$;

los seis valores se codifican en base 22, recorriendo las dos posiciones de R, G y B. Los conteos se agrupan por el resto del código dividido por 8.192 y se comprimen mediante TruncatedSVD aleatorizado (256 componentes, cinco iteraciones y semilla de la condición). SVD se ajusta exclusivamente con el entrenamiento de cada partición interna y se reajusta sobre el entrenamiento externo para la evaluación final. El vector se normaliza con L_2 antes de concatenarlo. Esta parametrización comprimida se identifica como N-gramas + SVD y constituye una familia propia para la selección Homogénea.

A.2 Greedy Forward Selection

GFS se utiliza como un método *wrapper*: los subconjuntos se valoran mediante el propio clasificador y exclusivamente dentro de la validación interna, como requieren los diseños de selección que separan búsqueda y evaluación externa [13, 14]. La búsqueda comienza con un conjunto vacío. En el paso t, evalúa cada descriptor aún no seleccionado al añadirlo al subconjunto vigente y elige el candidato con mayor macro-F1 medio en la validación interna:

$$j_t = \arg\max_{j \notin S_{t-1}} \widehat{F}_{1,\text{inner}}(S_{t-1} \cup \{j\}), \qquad S_t = S_{t-1} \cup \{j_t\}. \tag{A.1}$$

La búsqueda se limita a $k \leq 8$. Se detiene cuando la mejora respecto del paso anterior es menor que 0,001 durante dos pasos consecutivos, pero devuelve el mejor paso histórico, no necesariamente el último. Los empates se resuelven de forma determinista mediante el nombre del extractor. Todas las evaluaciones candidatas utilizan únicamente muestras pertenecientes al entrenamiento externo.

La Figura A.1 representa el mecanismo general de GFS. En cada ronda se comparan únicamente los bloques aún disponibles dentro de los folds internos; el bloque elegido se incorpora al subconjunto y el test externo permanece fuera de esa decisión.

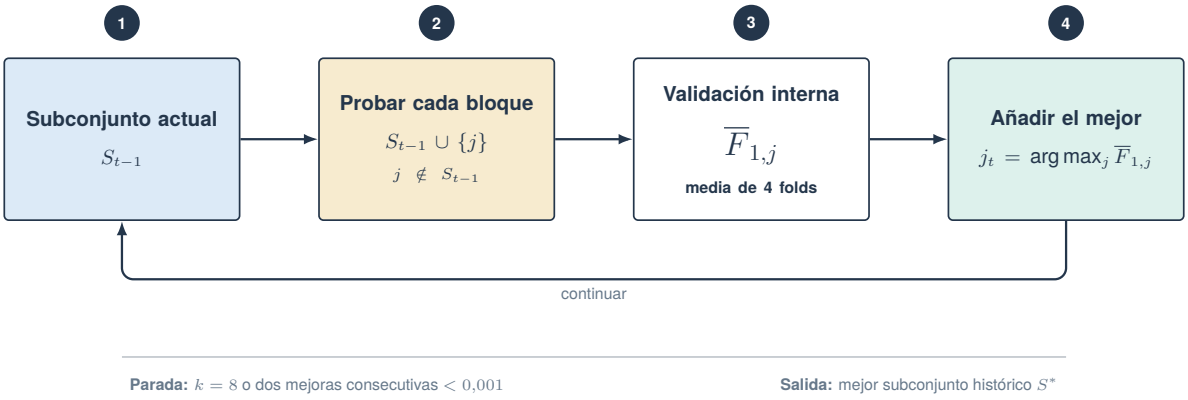


Figura A.1: Mecanismo de Greedy Forward Selection sobre bloques completos. En cada paso se elige el bloque que maximiza el macro-F1 medio de la validación interna; el test externo se utiliza únicamente tras cerrar el subconjunto.

La Tabla A.3 concentra los parámetros de búsqueda, comunes a ambos clasificadores.

Tabla A.3: Configuración de la selección GFS en el flujo general.

Elemento	Configuración
Unidad de selección	Bloque completo generado por un extractor
Candidatos	Hasta 22 bloques candidatos
Criterio interno	Macro-F1 medio en cuatro folds estratificados y agrupados
Presupuesto	Hasta $k = 8$ bloques
Parada	Dos mejoras consecutivas menores que 0,001; se devuelve el mejor paso histórico
Empates	Nombre del extractor, en orden determinista
Información excluida	Test externo y sus etiquetas durante toda la selección

A.3 Perfil numérico de costos del piloto

Tabla A.4: Constantes del perfil del piloto, en ms por imagen. Son parámetros archivados del modelo de costos, no tiempos medidos del híbrido.

Bloque	c_j ms
`beitv2_base_final`	12,22
`convnext_v2_t`	15,68
`deit_s`	15,38
`densenet121`	26,70
`dinov2`	57,65
`dinov2_large`	177,30
`dinov2_small`	24,60
`drlbp`	83,34
`efficientnet_b0`	14,39
`eva02_base`	19,32
`gabor`	1029,21
`glcm`	41,03
`hog`	2,30
`lbp`	50,61
`mae_base`	12,76
`resnet101`	21,49
`resnet50`	11,94
`rgb_ngram_svd`	18,50
`siglip_base`	11,68
`swin_t`	21,42
`vgg16`	12,05
`vit_b16`	26,85
Sobrecosto de política	0,45

El perfil es una colección de constantes archivadas, no una medición de extremo a extremo del híbrido. Incluye un sobrecosto fijo de política de 0,45 ms cuando existe rescate y excluye la latencia completa de sus múltiples SVM, transferencias y régimen de carga/residencia. Las mediciones de la cascada anterior no se transfieren automáticamente a esta implementación.

Anexo B

Protocolos y variantes de referencia

B.1 Separación de evaluaciones

Las 47 condiciones estáticas por clasificador incluyen tres semillas en FMD y Soil. El panel canónico de 27 conserva solo la semilla 42 en esos conjuntos. Las medias de ambos paneles pueden diferir sin que una tabla reemplace a la otra. El piloto híbrido produce predicciones OOF de las 680 imágenes del entrenamiento oficial de Outex y mantiene fuera su test oficial.

En los experimentos de desarrollo anteriores de DTD se utilizó también una partición SGKF de 4.512/1.128 imágenes. Su entrenamiento incluye 1.501 imágenes del test oficial 1, por lo que esas exploraciones no se presentan como evaluación oficial ciega ni como controles directos del benchmark. No se mezclan sus métricas con las tablas principales.

B.2 Procedencia de KTH

Las tablas estáticas conservan los resultados archivados de 22 bloques. El Top-k SVM de origen registra macro-F1 medio aproximado de 0,9400; el control corregido con agrupación interna por muestra registra aproximadamente 0,9445. La cascada se construyó con el rescate anterior. Coincidir en una media no acredita que selecciones, transformaciones y predicciones sean idénticas.

Los contrastes estáticos sobre seis conjuntos describen el archivo indicado; no certifican que todos sus controles correspondan a la variante KTH corregida. La inferencia conjunta de la cascada excluye KTH hasta reconciliar su ruta completa. Tampoco se sustituye solo una cifra en el análisis para resolver esta reserva.

B.3 Fidelidad de los pilotos físicos

El piloto de una condición por conjunto se documenta con registros por imagen y repetición. La coincidencia de rutas o clases no basta para establecer identidad del vector extraído. CUReT y Soil mantienen cosenos mínimos aproximados de -0,0707 y 0,0085 respecto al caché. No se atribuye la diferencia a una capa, interpolación o normalización

concreta sin diagnóstico controlado.

B.4 Particiones y multiplicidades del piloto híbrido

El desarrollo utiliza únicamente las 680 imágenes del entrenamiento oficial de Outex. Los pliegues productores estratificados y agrupados usan semilla 142; los internos, semilla 42. Cada ensamble contiene 15 votos, pero un subconjunto repetido reutiliza el mismo modelo y conserva su multiplicidad en la agregación.

Tabla B.1: Tamaños y modelos únicos del control de diversidad permanente en cada pliegue productor. No son nuevas réplicas ni 15 ejecuciones distintas por imagen.

Pliegue	Entrenamiento	Validación	Votos	Modelos únicos
0	453	227	15	9
1	453	227	15	11
2	454	226	15	12

El sorteo de diversidad usa las semillas 4.200.009, 4.200.019 y 4.200.029, derivadas de la semilla de desarrollo y del índice productor. Las particiones y miembros se conservan en los registros por pliegue. Un modelo único del rescate no equivale a un extractor único: su costo depende de la unión de los cuatro bloques de cada miembro, descontando la base cuando ya está adquirida.

B.5 Figuras de la cascada de referencia

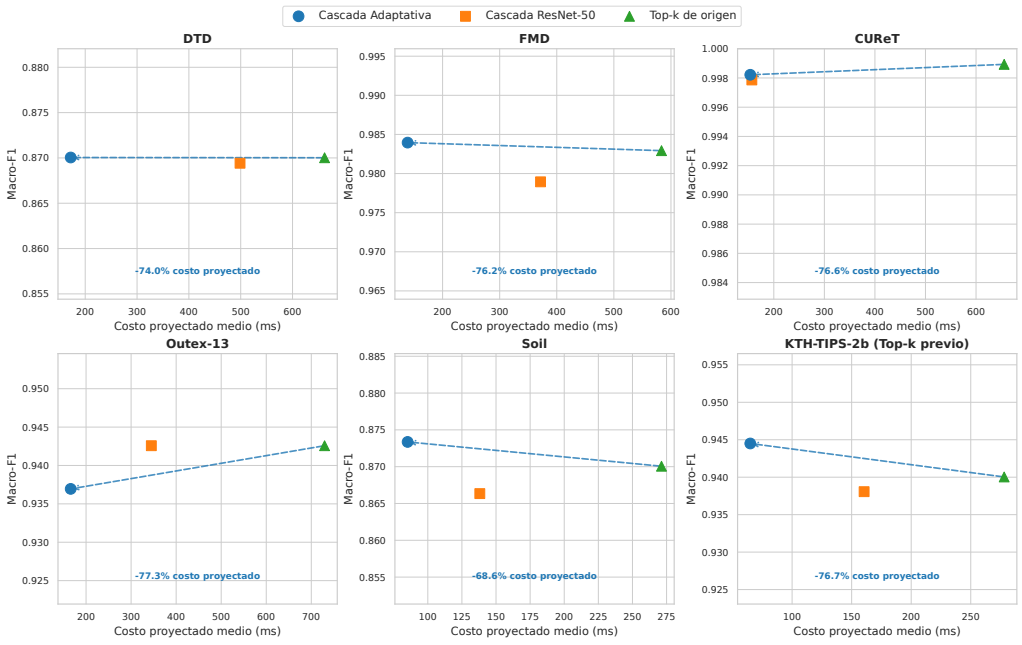


Figura B.1: Comparación histórica calidad–costo bajo su perfil analítico. No representa el rescate de diversidad ni una medición física de todas las rutas.

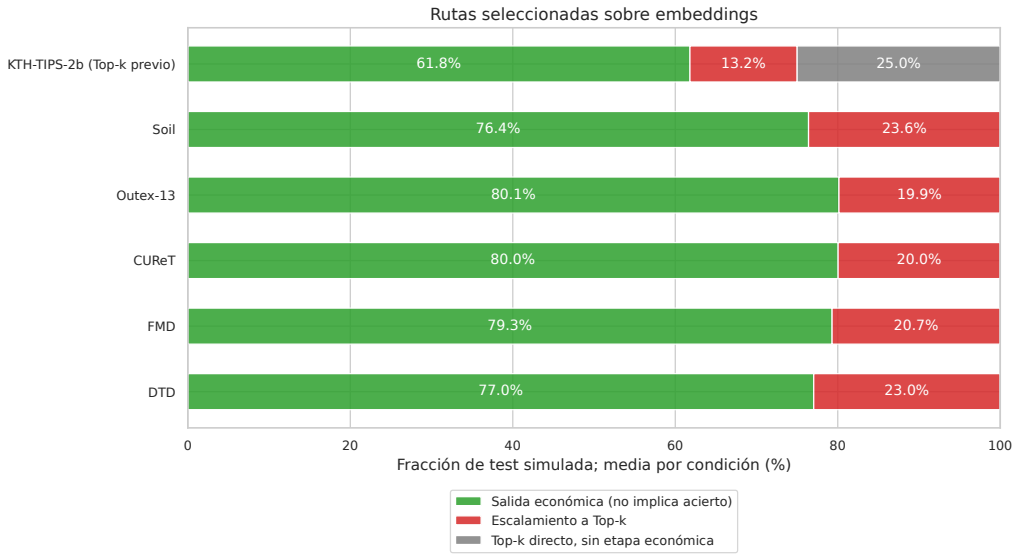


Figura B.2: Enrutamiento de la cascada histórica según los artefactos archivados. Las proporciones no garantizan una tasa de salida para imágenes nuevas.

Anexo C

Resultados secundarios y variabilidad

C.1 Exactitud y dispersión del benchmark estático

Tabla C.1: Exactitud externa de cinco estrategias con la biblioteca común de 22 descriptores, incluidos RGB N-gramas + SVD y BEiTv2-B. Se muestran medias entre condiciones externas; Outex tiene un único split oficial.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	0,8448	0,8654	0,8714	**0,8716**	0,8621
DTD	ResMLP	0,8382	0,8635	**0,8652**	0,8651	0,8626
FMD	SVM	0,9727	0,9647	**0,9820**	0,9767	0,9790
FMD	ResMLP	0,9690	0,9563	0,9740	**0,9783**	0,9773
CUReT	SVM	0,9948	**0,9989**	**0,9989**	0,9988	**0,9989**
CUReT	ResMLP	0,9971	**0,9991**	0,9984	0,9986	0,9982
Outex	SVM	0,9103	**0,9662**	0,9441	0,9603	0,9324
Outex	ResMLP	0,9485	0,9456	0,9662	**0,9721**	0,9338
Soil	SVM	0,9044	**0,9281**	0,9225	0,9152	0,9126
Soil	ResMLP	0,9044	**0,9184**	0,9181	0,9170	0,9135
KTH-TIPS2-b	SVM	0,9415	**0,9609**	0,9419	0,9112	0,9293
KTH-TIPS2-b	ResMLP	0,9099	**0,9499**	0,9346	0,9219	0,9165

Tabla C.2: Desviación estándar descriptiva del macro-F1 entre condiciones externas del benchmark estático. No es error estándar ni intervalo de confianza; las condiciones comparten imágenes. El guion indica un único split.

Dataset	Clasif.	Individual	Completa	Top-k	GFS	Homogénea
DTD	SVM	0,0109	0,0088	0,0082	0,0086	0,0089
DTD	ResMLP	0,0089	0,0095	0,0073	0,0095	0,0060
FMD	SVM	0,0150	0,0171	0,0105	0,0135	0,0122
FMD	ResMLP	0,0133	0,0176	0,0130	0,0123	0,0109
CUReT	SVM	0,0028	0,0015	0,0010	0,0008	0,0010
CUReT	ResMLP	0,0030	0,0013	0,0013	0,0020	0,0015
Outex	SVM	–	–	–	–	–
Outex	ResMLP	–	–	–	–	–
Soil	SVM	0,0316	0,0318	0,0371	0,0306	0,0400
Soil	ResMLP	0,0368	0,0350	0,0339	0,0419	0,0427
KTH-TIPS2-b	SVM	0,0600	0,0088	0,0605	0,0408	0,0491
KTH-TIPS2-b	ResMLP	0,0316	0,0275	0,0513	0,0367	0,0431

Las desviaciones entre condiciones no son intervalos de generalización a otros dominios. Semillas y particiones pueden compartir imágenes; no se tratan como réplicas independientes. Outex tiene un único split, por lo que no se estima dispersión entre splits.

C.2 Rankings y contrastes completos por clasificador

Tabla C.3: Rankings medios de macro-F1 según Friedman, Friedman alineado y Quade con 22 descriptores. Seis datasets por clasificador; menor ranking indica mejor desempeño relativo dentro de cada prueba.

Clasif.	Estrategia	Friedman	F. alineado	Quade
SVM	Individual	4,500	23,000	4,429
SVM	Completa	2,000	10,000	1,762
SVM	Top-k	2,000	9,833	2,190
SVM	GFS	3,000	15,000	2,857
SVM	Homogénea	3,500	19,667	3,762
ResMLP	Individual	4,500	24,167	4,381
ResMLP	Completa	2,833	15,333	2,857
ResMLP	Top-k	2,167	8,833	2,000
ResMLP	GFS	1,667	10,500	1,810
ResMLP	Homogénea	3,833	18,667	3,952

Tabla C.4: Pruebas globales por clasificador sobre cinco estrategias y seis datasets con la biblioteca de 22 descriptores. Nivel nominal $\alpha = 0{,}05$.

Clasif.	Prueba	p	Decisión
SVM	Friedman	0,0289	Rechazo
SVM	Iman–Davenport	0,0139	Rechazo
SVM	Friedman alineado	0,2860	No rechazo
SVM	Quade	0,0349	Rechazo
ResMLP	Friedman	0,0110	Rechazo
ResMLP	Iman–Davenport	0,0025	Rechazo
ResMLP	Friedman alineado	0,2883	No rechazo
ResMLP	Quade	0,0210	Rechazo

Tabla C.5: Comparaciones por pares basadas en rangos de Friedman. Holm corrige los diez pares dentro de cada clasificador.

Clasif.	Comparación	p sin ajustar	p Holm
SVM	Individual vs. Top-k	0,0062	0,0617
SVM	Individual vs. Completa	0,0062	0,0617
SVM	Individual vs. GFS	0,1003	0,8028
SVM	Top-k vs. Homogénea	0,1003	0,8028
SVM	Completa vs. Homogénea	0,1003	0,8028
SVM	Individual vs. Homogénea	0,2733	1,0000
SVM	Top-k vs. GFS	0,2733	1,0000
SVM	Completa vs. GFS	0,2733	1,0000
SVM	GFS vs. Homogénea	0,5839	1,0000
SVM	Completa vs. Top-k	1,0000	1,0000
ResMLP	Individual vs. GFS	0,0019	0,0191
ResMLP	Individual vs. Top-k	0,0106	0,0953
ResMLP	GFS vs. Homogénea	0,0176	0,1410
ResMLP	Individual vs. Completa	0,0679	0,4752
ResMLP	Top-k vs. Homogénea	0,0679	0,4752
ResMLP	Completa vs. GFS	0,2012	1,0000
ResMLP	Completa vs. Homogénea	0,2733	1,0000
ResMLP	Individual vs. Homogénea	0,4652	1,0000
ResMLP	Completa vs. Top-k	0,4652	1,0000
ResMLP	Top-k vs. GFS	0,5839	1,0000

Los post-hoc aplican diferencias de rangos de Friedman y Holm por familia de diez pares. Sus valores no son Wilcoxon exactos ni contrastes del híbrido.

C.2.1 Sensibilidad del benchmark sin KTH

Se conservan todos los pares del análisis sobre DTD, FMD, CUReT, Outex y SoilOriginal, con una media por dataset y clasificador. Las familias de Holm son separadas para SVM y ResMLP. Este recálculo no corrige la variante KTH archivada ni aumenta el número de datasets independientes.

Tabla C.6: Sensibilidad del benchmark estático a excluir KTH archivado: seis datasets originales frente a los cinco restantes. Valores p SCI2S por clasificador; no son evaluaciones del híbrido.

Clasif.	N	Friedman	Iman–D.	F. alineado	Quade
SVM	6	0,0289	0,0139	0,2860	0,0349
SVM	5	0,0342	0,0145	0,3901	0,0203
ResMLP	6	0,0110	0,0025	0,2883	0,0210
ResMLP	5	0,0199	0,0051	0,3955	0,0157

Tabla C.7: Sensibilidad sin KTH: post-hoc de rangos de Friedman sobre cinco datasets. Holm corrige diez pares por clasificador. Son contrastes exploratorios, no Wilcoxon exactos.

Clasif.	Comparación	p	p_{Holm}
SVM	Individual vs. Top-k	0,0051	0,0511
SVM	Individual vs. Completa	0,0093	0,0839
SVM	Individual vs. GFS	0,0278	0,2225
SVM	Top-k vs. Homogénea	0,1615	1,0000
SVM	Individual vs. Homogénea	0,1615	1,0000
SVM	Completa vs. Homogénea	0,2301	1,0000
SVM	GFS vs. Homogénea	0,4237	1,0000
SVM	Top-k vs. GFS	0,5485	1,0000
SVM	Completa vs. GFS	0,6892	1,0000
SVM	Completa vs. Top-k	0,8415	1,0000
ResMLP	Individual vs. GFS	0,0027	0,0270
ResMLP	GFS vs. Homogénea	0,0164	0,1476
ResMLP	Individual vs. Top-k	0,0278	0,2225
ResMLP	Completa vs. GFS	0,0719	0,5030
ResMLP	Top-k vs. Homogénea	0,1096	0,6576
ResMLP	Individual vs. Completa	0,2301	1,0000
ResMLP	Completa vs. Top-k	0,3173	1,0000
ResMLP	Top-k vs. GFS	0,4237	1,0000
ResMLP	Individual vs. Homogénea	0,5485	1,0000
ResMLP	Completa vs. Homogénea	0,5485	1,0000

C.3 N-gramas con ResMLP y ampliación de biblioteca

Tabla C.8: Comparación completa con ResMLP: medias con 20 frente a 21 bloques, incluyendo RGB Pixel N-grams + SVD. Mismas 28 condiciones externas: DTD (10), FMD (15), CUReT (2) y Outex (1). La selección se repite dentro del entrenamiento.

Dataset	Estrategia	F1 (20)	F1 (21)	Δ F1	Exactitud (21)
DTD	Individual	0,8373	0,8373	0,0000 ± 0,0000	0,8382
DTD	Completa	0,8602	0,8608	0,0006 ± 0,0026	0,8624
DTD	Top-k	0,8662	0,8648	−0,0014 ± 0,0045	0,8660
DTD	GFS	0,8668	0,8660	−0,0009 ± 0,0028	0,8670
DTD	Homogénea	0,8611	0,8611	0,0000 ± 0,0000	0,8626
FMD	Individual	0,9690	0,9690	0,0000 ± 0,0000	0,9690
FMD	Completa	0,9575	0,9518	−0,0056 ± 0,0067	0,9517
FMD	Top-k	0,9770	0,9753	−0,0017 ± 0,0077	0,9753
FMD	GFS	0,9783	0,9783	0,0000 ± 0,0000	0,9783
FMD	Homogénea	0,9773	0,9773	0,0000 ± 0,0000	0,9773
CUReT	Individual	0,9971	0,9971	0,0000 ± 0,0000	0,9971
CUReT	Completa	0,9988	0,9993	0,0005 ± 0,0008	0,9993
CUReT	Top-k	0,9970	0,9986	0,0016 ± 0,0023	0,9986
CUReT	GFS	0,9980	0,9980	0,0000 ± 0,0000	0,9980
CUReT	Homogénea	0,9982	0,9982	0,0000 ± 0,0000	0,9982
Outex	Individual	0,9178	0,9476	0,0298	0,9485
Outex	Completa	0,9542	0,9537	−0,0005	0,9544
Outex	Top-k	0,9419	0,9607	0,0188	0,9618
Outex	GFS	0,9423	0,9715	0,0292	0,9721
Outex	Homogénea	0,9306	0,9306	0,0000	0,9338

F1 designa macro-F1. Δ es la media de las diferencias pareadas (21 menos 20), acompañada de su desviación estándar cuando hay más de una partición; no es un intervalo de confianza ni una prueba de significancia.

Esta comparación conserva la biblioteca de 20 frente a 21 con N-gramas de su corte histórico; no equivale al barrido sin N-gramas de 21 ni a una prueba de Top-4 más N-gramas.

C.3.1 N-gramas en el estudio complementario de rescate

El pool corregido conserva candidatos estáticos, sorteos, particiones y scores comunes al ofrecer versiones con y sin N-gramas. En marginal/B120, permitir color y reseleccionar cambia 0,900563/97,245 ms a 0,906690/83,772 ms. Cambia la ruta: no es una ablación de ruta fija. El rescate de diversidad utiliza otro pool, por lo que sus diferencias no se atribuyen únicamente al color.

C.4 Barrido del control de poda y compuerta

La Tabla C.9 conserva las doce configuraciones, incluidas las cuatro sin rescate. Se calcula macro-F1 sobre las 680 predicciones reunidas; los costos se ponderan por imagen. Las comparaciones comparten imágenes y no constituyen doce datasets ni réplicas independientes.

Tabla C.9: Barrido completo del control de rescate fijo en desarrollo Outex. F1 es macro-F1 OOF; C es adquisición media proyectada en ms. Permanente utiliza el mismo rescate que la política condicional, sin reselección estática.

Rescate	B	F1 base	F1 perm.	F1 cond.	C perm.	C cond.
Completo	15	0,858056	0,858056	0,858056	12,220	12,220
Completo	30	0,854129	0,854129	0,854129	20,485	20,485
Completo	60	0,859848	0,914389	0,891759	365,196	57,839
Completo	120	0,852780	0,914389	0,908603	365,196	104,660
Podado marginal	15	0,858056	0,858056	0,858056	12,220	12,220
Podado marginal	30	0,858056	0,905034	0,893488	98,344	25,394
Podado marginal	60	0,820226	0,905140	0,905140	97,282	55,365
Podado marginal	120	0,823601	0,913072	0,908781	251,028	84,018
Podado relevancia	15	0,858056	0,858056	0,858056	12,220	12,220
Podado relevancia	30	0,858056	0,905034	0,893488	98,344	25,394
Podado relevancia	60	0,840378	0,911993	0,910742	110,421	53,316
Podado relevancia	120	0,822836	0,913895	0,909396	229,836	78,938

La base es la seleccionada en cada política. El rescate permanente conserva exactamente miembros y multiplicidades, omite una base innecesaria y no se reoptimiza para el presupuesto indicado. La ruta forzada, no mostrada en este barrido, tiene las mismas predicciones del rescate permanente y conserva base y sobrecosto de política; se distingue en la Tabla E.5. Los cuatro casos sin rescate mantienen la base en todas las vistas.

C.5 Réplica del rescate por condición y regla

La réplica conserva cinco condiciones nuevas: FMD/42, FMD/123, FMD/2026, Outex/123 y Outex/2026. Outex/42 permanece en las tablas del piloto y no integra las

medias nuevas. Las Tablas C.10 y C.11 mantienen los presupuestos completos y las referencias del mismo protocolo de desarrollo. No se escoge una regla por su F1 de validación productora.

Tabla C.10: Barrido de la réplica por dataset/semilla: macro-F1 / costo proyectado (ms). Las tres reglas híbridas y el control estático mantienen los cuatro presupuestos. Las filas comparten imágenes; no representan dominios independientes.

Condición	B	Completo	Marginal	Relevancia	Estático
FMD/42	15	0,970082 / 11,680	0,970082 / 11,680	0,970082 / 11,680	0,970082 / 11,680
FMD/42	30	0,970082 / 11,680	0,972549 / 19,343	0,972543 / 19,915	0,970082 / 11,680
FMD/42	60	0,975026 / 37,423	0,976279 / 35,411	0,977506 / 38,282	0,978772 / 35,078
FMD/42	120	0,980012 / 63,318	0,976279 / 49,068	0,976262 / 61,387	0,977528 / 95,181
FMD/123	15	0,968721 / 11,680	0,968721 / 11,680	0,968721 / 11,680	0,968721 / 11,680
FMD/123	30	0,968721 / 11,680	0,975051 / 15,770	0,973800 / 17,771	0,965017 / 16,894
FMD/123	60	0,972554 / 45,396	0,974987 / 35,516	0,974987 / 35,869	0,975028 / 52,565
FMD/123	120	0,971325 / 64,937	0,974987 / 35,516	0,974987 / 35,869	0,978770 / 100,779
FMD/2026	15	0,971229 / 11,680	0,971229 / 11,680	0,971229 / 11,680	0,971229 / 11,680
FMD/2026	30	0,971229 / 11,680	0,977512 / 17,812	0,977512 / 17,812	0,971229 / 15,758
FMD/2026	60	0,976270 / 28,804	0,978724 / 27,758	0,979974 / 32,917	0,969999 / 38,020
FMD/2026	120	0,976270 / 28,804	0,978731 / 38,353	0,979974 / 43,512	0,974948 / 106,826
Outex/123	15	0,859336 / 12,220	0,859336 / 12,220	0,859336 / 12,220	0,863699 / 13,756
Outex/123	30	0,862149 / 20,467	0,902291 / 25,902	0,902291 / 25,902	0,866167 / 25,829
Outex/123	60	0,882609 / 47,852	0,908180 / 41,548	0,911087 / 39,233	0,888012 / 54,531
Outex/123	120	0,913572 / 98,437	0,909208 / 59,907	0,904064 / 75,565	0,900579 / 113,288
Outex/2026	15	0,866570 / 12,220	0,866570 / 12,220	0,866570 / 12,220	0,869584 / 12,988
Outex/2026	30	0,856203 / 20,467	0,888810 / 22,546	0,888810 / 22,546	0,882948 / 26,149
Outex/2026	60	0,880431 / 48,802	0,907518 / 45,307	0,900894 / 42,267	0,890292 / 43,563
Outex/2026	120	0,905178 / 100,718	0,912713 / 85,802	0,912582 / 79,164	0,910586 / 105,505

Tabla C.11: Referencias del mismo desarrollo productor. Top-3/4/5 tienen tamaño fijo y no equivalen al Top-k heredado de GFS del benchmark. Costos proyectados, no latencias físicas.

Condición	Referencia	Macro-F1	Costo ms
FMD/42	Individual interno	0,970082	11,680
FMD/42	Top-3 fijo	0,977535	141,376
FMD/42	Top-4 fijo	0,978777	265,950
FMD/42	Top-5 fijo	0,976253	290,550
FMD/42	Completa-22	0,961310	1706,420
FMD/42	Diversidad permanente	0,978777	359,751
FMD/123	Individual interno	0,968721	11,680
FMD/123	Top-3 fijo	0,971305	130,345
FMD/123	Top-4 fijo	0,975044	214,986
FMD/123	Top-5 fijo	0,971339	286,418
FMD/123	Completa-22	0,953807	1706,420
FMD/123	Diversidad permanente	0,967593	387,321
FMD/2026	Individual interno	0,971229	11,680
FMD/2026	Top-3 fijo	0,976280	141,376
FMD/2026	Top-4 fijo	0,978785	265,950
FMD/2026	Top-5 fijo	0,977530	290,550
FMD/2026	Completa-22	0,969995	1706,420
FMD/2026	Diversidad permanente	0,975059	347,062
Outex/123	Individual interno	0,860527	86,608
Outex/123	Top-3 fijo	0,902588	225,153
Outex/123	Top-4 fijo	0,900695	256,615
Outex/123	Top-5 fijo	0,897444	275,698
Outex/123	Completa-22	0,922741	1706,420
Outex/123	Diversidad permanente	0,909076	384,654
Outex/2026	Individual interno	0,879569	177,300
Outex/2026	Top-3 fijo	0,891325	255,417
Outex/2026	Top-4 fijo	0,897518	271,770
Outex/2026	Top-5 fijo	0,897968	288,837
Outex/2026	Completa-22	0,917259	1706,420
Outex/2026	Diversidad permanente	0,910605	356,496

C.5.1 Activación del mismo rescate en la réplica

La Tabla C.12 compara las mismas políticas con su rescate permanente, conservando miembros y puntuaciones. Las medias se calculan primero por condición y luego entre semillas del mismo dataset. En los casos sin rescate ambas vistas son la base. Las diferencias de calidad pueden ser positivas o negativas; no se traslada a estas condiciones la conclusión de ausencia de mejora de F1 del piloto Outex/42. El archivo de análisis conserva además las sesenta filas individuales por condición, regla y presupuesto.

Tabla C.12: Mismo rescate permanente frente a condicional en la réplica: macro-F1 / costo proyectado (ms), media de tres semillas FMD y dos Outex. La referencia permanente conserva los miembros seleccionados para la ruta condicional y no se reoptimiza bajo B. Incluye los casos sin rescate.

Dataset	Regla	B	Permanente	Condicional
FMD	Completo	15	0,970011 / 11,680	0,970011 / 11,680
FMD	Completo	30	0,970011 / 11,680	0,970011 / 11,680
FMD	Completo	60	0,972561 / 286,449	0,974617 / 37,207
FMD	Completo	120	0,973809 / 325,955	0,975869 / 52,353
FMD	Marginal	15	0,970011 / 11,680	0,970011 / 11,680
FMD	Marginal	30	0,972549 / 79,357	0,975037 / 17,642
FMD	Marginal	60	0,973370 / 249,391	0,976663 / 32,895
FMD	Marginal	120	0,973370 / 244,231	0,976666 / 40,979
FMD	Relevancia	15	0,970011 / 11,680	0,970011 / 11,680
FMD	Relevancia	30	0,972552 / 88,127	0,974618 / 18,499
FMD	Relevancia	60	0,974596 / 281,061	0,977489 / 35,689
FMD	Relevancia	120	0,974598 / 279,669	0,977074 / 46,923
Outex	Completo	15	0,862953 / 12,220	0,862953 / 12,220
Outex	Completo	30	0,859176 / 20,467	0,859176 / 20,467
Outex	Completo	60	0,909840 / 370,575	0,881520 / 48,327
Outex	Completo	120	0,909840 / 370,575	0,909375 / 99,577
Outex	Marginal	15	0,862953 / 12,220	0,862953 / 12,220
Outex	Marginal	30	0,904744 / 97,145	0,895551 / 24,224
Outex	Marginal	60	0,917058 / 152,408	0,907849 / 43,427
Outex	Marginal	120	0,910992 / 158,374	0,910960 / 72,854
Outex	Relevancia	15	0,862953 / 12,220	0,862953 / 12,220
Outex	Relevancia	30	0,904744 / 97,145	0,895551 / 24,224
Outex	Relevancia	60	0,912135 / 134,273	0,905991 / 40,750
Outex	Relevancia	120	0,909442 / 202,008	0,908323 / 77,365

C.6 Alcance de las exploraciones secundarias

Las exploraciones de proyecciones, residuos y políticas de más etapas pertenecen al desarrollo del proyecto. No se les atribuye aquí una pérdida general frente a concatenación, ni se usa la falta de un resultado reconciliado para refutar una familia metodológica. Solo un contraste con particiones, selección y medición compatibles permitiría esa conclusión.

Los registros de desarrollo conservan variantes con distintos protocolos y estimandos. Las tablas de este manuscrito incluyen resultados con fuentes identificadas y separan las comparaciones no reconciliadas. Así se evita atribuir a una misma evaluación cifras procedentes de diseños distintos.

Anexo D

Reproducibilidad y disponibilidad

D.1 Fuentes y versiones

El proyecto organiza código, manifiestos, decisiones de selección, predicciones y registros físicos. El código se conserva en el repositorio público del proyecto. Un commit y los cambios locales deben identificarse al reproducir una versión; la existencia de un archivo público no demuestra que incluya pesos, imágenes y entornos locales.

La revisión del 13 de noviembre reconstruye las curvas de tamaño y la comparación directa/por margen mediante `scripts/build_topk_margin_thesis_20261113.py`. Sus salidas están en `results/analysis/topk_margin_rewrite_20261113_v1/` y las tablas y figuras del manuscrito en `paper/generated_topk_margin/`. El resumen registra 124 fuentes ligadas por SHA-256, la cobertura y la ausencia de nuevos fits, predicciones o tiempos.

El barrido se reconstruye desde seis CSV por clasificador. La auditoría de cascada utiliza los 27 resultados, sus decisiones pretest, predicciones y archivos Top-k de origen. El panel externo procede de `results/analysis/reconciliation_full_panel_20261104_v1/`. Las referencias bibliográficas corregidas se contrastaron con los metadatos del DOI y se registraron en `reference_metadata.json` del directorio de auditoría.

Las figuras de ganancias y por dataset (252 puntos) se reconstruyen con `scripts/build_topk_progression_20261113.py`. Los cinco rescates con los bloques Top-4 del barrido se verifican con `scripts/audit_top4_margin_subset_20261113.py`. Ambos leen resultados existentes y conservan fuentes y hashes.

D.2 Reconstrucción sin ejecutar modelos

El siguiente comando utiliza salidas nuevas y rechaza sobreescribir el directorio de auditoría:

```
OMP_NUM_THREADS=2 OPENBLAS_NUM_THREADS=2 MKL_NUM_THREADS=2 \
.venv-confirmatory/bin/python \
scripts/build_topk_margin_thesis_20261113.py \
  --audit results/analysis/topk_margin_rebuild_v1 \
  --generated output/topk_margin_rebuild
```

La reconstrucción recalcula agregados y métricas guardadas; no reextrae imágenes ni reentrena. Sus tablas no deben confundirse con una nueva validación física. El directorio generado alternativo permite comparar resultados sin alterar los utilizados por el manuscrito.

Las pruebas de software verifican cobertura, integridad de fuentes y correspondencia entre predicciones derivadas y el mismo rescate. Las verificaciones de cortes anteriores, incluidas las auditorías del rescate de ensamble, se conservan con sus fechas. No se suman conteos de tests históricos para afirmar que toda la versión actual fue validada en una ejecución única.

D.3 Datos, pesos y portabilidad

La disponibilidad y redistribución de imágenes, embeddings y pesos dependen de sus proveedores. El archivo público no incluye necesariamente los datasets, las características cacheadas o los modelos entrenados. Reproducir desde RGB exige checkpoints, capa y preprocesamiento de cada bloque, y ajustar las transformaciones aprendidas exclusivamente en el entrenamiento correspondiente.

Los nombres de diez artefactos CUReT se normalizaron sustituyendo dos puntos por doble guion bajo para permitir su descarga en Windows. El contenido y los identificadores de protocolo internos permanecieron iguales. Los generadores y lectores se actualizaron; las rutas absolutas históricas dentro de registros se interpretan con su mapeo, no como autorización para modificar resultados sellados.

Para Soil se conserva el archivo de la versión auditada y los manifiestos con los hashes de las 1.140 imágenes. Las agrupaciones por nombre son conservadoras y no acreditan conocer toda dependencia física. Las reservas KTH, Outex, CUReT/Soil y DeepLumina forman parte de los materiales y no desaparecen al empaquetar el PDF.

D.4 Compilación y alcance de la entrega

La fuente principal es `paper/tesis.tex`, con siete capítulos y anexos. Las tablas históricas y las nuevas están incluidas por rutas explícitas. La bibliografía activa se encuentra en `paper/articulo/borrador_profesor/references.bib`. La compilación local utiliza Tectonic o un flujo LaTeX/BibTeX compatible; el registro de construcción identifica el resultado entregado.

Una compilación correcta y una auditoría de predicciones no constituyen aprobación académica ni certifican identidad completa de todos los pipelines físicos. La entrega distingue el manuscrito escrito de las comprobaciones científicas que continúan abiertas.

Declaraciones

Financiación

Los autores declaran que no hubo financiación externa para este trabajo.

Conflictos de interés

Los autores declaran que no existen conflictos de interés.

Datos y consideraciones éticas

El estudio utiliza colecciones de imágenes preexistentes y no incorpora reclutamiento ni intervención sobre participantes. La disponibilidad de datos, código y registros se describe en el Anexo D. El acceso y la eventual redistribución de imágenes, características y pesos están sujetos a las condiciones de sus proveedores.

Asistencia en la revisión

Se utilizó asistencia de inteligencia artificial para reorganizar y redactar este borrador, revisar la argumentación y construir scripts de auditoría y presentación de resultados. Esa asistencia no se considera autora, fuente científica ni evidencia de validez experimental. Las afirmaciones y referencias deben ser revisadas por los autores, quienes conservan la responsabilidad de la entrega. Los resultados se vinculan con sus archivos de procedencia y se distinguen las verificaciones automáticas de una reproducción independiente.

Anexo E

Estudios complementarios de rescate de ensamble

Este anexo conserva el estudio de ensambles y poda desarrollado durante el proyecto. Su rescate contiene varios clasificadores sobre subconjuntos y no equivale a ejecutar la misma concatenación Top-k del cuerpo principal. Sus resultados OOF, presupuestos y réplicas no se atribuyen automáticamente a la comparación directa/por margen de esta tesis. Se preservan como evidencia complementaria, incluidos los casos desfavorables y las reservas de costo proyectado.

E.1 Bloques, miembros y política de adquisición

Sea $\mathcal{B} = \{1, \ldots, M\}$ una biblioteca de extractores congelados. El bloque j transforma una imagen x_i en $\mathbf{z}_{ij} \in \mathbb{R}^{d_j}$. Para un subconjunto $S \subseteq \mathcal{B}$, se utiliza

$$\mathbf{z}_{i,S} = \Big\|_{j \in S} \frac{\mathbf{z}_{ij}}{\max(\|\mathbf{z}_{ij}\|_2, 10^{-12})}, \qquad d_S = \sum_{j \in S} d_j. \tag{E.1}$$

Cada miembro f_S es una SVM entrenada sobre una concatenación de bloques; distintos votos pueden corresponder al mismo modelo. Una política $\pi = (b, E, \tau)$ consta de un bloque base b, una lista de miembros de rescate E y un umbral τ. El ensamble completo puede contener miembros repetidos con efecto en el voto, aunque cada modelo único se ejecute una sola vez.

La biblioteca comprende 22 bloques y 20.652 dimensiones nominales. Los descriptores fijos se almacenan por imagen, mientras que la proyección SVD de N-gramas se aprende con el entrenamiento del ajuste pertinente. Los detalles de extracción, checkpoints y dimensiones se conservan en el Anexo A. La selección actúa sobre bloques completos, no sobre coordenadas individuales.

Se denomina entrenamiento productor al conjunto utilizado para construir candidatos, seleccionar la política y reajustar los modelos. Dentro de él se obtienen predicciones OOF internas para la selección. La validación productora permanece fuera de esas decisiones y evalúa la política elegida. El Capítulo 4 detalla ambos niveles de partición.

E.2 Generación del ensamble de subconjuntos

Se construye un ensamble de 15 miembros, cada uno con cuatro bloques. La relevancia R_j se obtiene normalizando a_j, la media aritmética del macro-F1 individual entre los pliegues internos:

$$R_j = \frac{a_j - a_{\min}}{a_{\max} - a_{\min}}, \tag{E.2}$$

con denominador uno cuando todos los valores coinciden. La frontera de bases y las ganancias de poda, en cambio, usan macro-F1 sobre las predicciones OOF internas reunidas. Ambas agregaciones pueden producir ordenamientos diferentes. La similitud entre dos matrices de características centradas por columna, X e Y, se calcula mediante CKA lineal [40]:

$$\mathrm{CKA}(X, Y) = \frac{\|Y^\top X\|_F^2}{\|X^\top X\|_F \, \|Y^\top Y\|_F}. \tag{E.3}$$

Si el denominador es cero, la implementación devuelve cero. Se usa únicamente el entrenamiento productor, es decir, las imágenes disponibles para construir y seleccionar la ruta antes de evaluar su pliegue de validación.

Dado el conjunto parcial S, la utilidad de un candidato es

$$u_j(S) = R_j - \lambda \, |S|^{-1} \sum_{\ell \in S} \mathrm{CKA}(j, \ell); \qquad u_j(\varnothing) = R_j. \tag{E.4}$$

Los candidatos se ordenan por utilidad decreciente y nombre en caso de empate. Si quedan n candidatos y $r_j = 1$ identifica el mejor, el sorteo utiliza

$$p(j \mid S) = \frac{(n - r_j + 1)^\beta}{\sum_{\ell=1}^{n} \ell^\beta}. \tag{E.5}$$

Cada bloque elegido se retira del sorteo del mismo miembro. Entre miembros sí pueden repetirse subconjuntos. En el piloto se fijaron $\beta = 8$ y $\lambda = 0{,}25$, procedentes de la configuración archivada del ensamble. No se presentan como hiperparámetros óptimos universales.

E.3 Puntuaciones y agregación

Cada SVM produce un vector de puntuaciones $s_S(x) \in \mathbb{R}^C$, con el mismo orden de clases. Su escala σ_S es la desviación estándar poblacional de todas las puntuaciones de sus imágenes de entrenamiento, agrupando filas y clases. Se fija en uno si no es positiva o finita. La puntuación normalizada es

$$\widetilde{s}_S(x) = s_S(x)/\sigma_S, \qquad \widehat{y}_E(x) = \arg\max_c \frac{1}{|E|} \sum_{S \in E} \widetilde{s}_{S,c}(x). \tag{E.6}$$

La escala permanece congelada en validación; no se recalcula con el lote evaluado. Esta operación no convierte las puntuaciones en probabilidades calibradas. Los miembros repetidos conservan su multiplicidad en la suma del ensamble completo. El rescate podado, en cambio, usa pesos uniformes sobre modelos únicos seleccionados.

E.4 Base y compuerta

Las bases candidatas pertenecen a la frontera no dominada de macro-F1 individual interno y costo proyectado. Una base se excluye si otra no es peor en calidad ni costo y la mejora estrictamente en al menos uno. Es una restricción del espacio de búsqueda: no demuestra que una base dominada individualmente carezca de utilidad para enrutamiento.

El margen de la base es la diferencia entre sus dos puntuaciones más altas:

$$m_b(x) = \widetilde{s}_{b,(1)}(x) - \widetilde{s}_{b,(2)}(x). \tag{E.7}$$

Para cada base se consideran cuantiles $q \in \{0{,}1; 0{,}25; 0{,}5\}$ de márgenes OOF internos. Un umbral $\tau_{b,q}$ define la regla

$$\widehat{y}_\pi(x) = \begin{cases} \widehat{y}_b(x), & E = \varnothing \text{ o } m_b(x) \geq \tau_{b,q}, \\ \widehat{y}_E(x), & m_b(x) < \tau_{b,q}. \end{cases} \tag{E.8}$$

Cuando se activa el rescate, su predicción reemplaza a la base; esta no se añade como voto adicional. El margen ordena las muestras para esta regla de parada, pero no es una probabilidad de acierto. Tras reajustar la base con todo el entrenamiento productor, su escala se vuelve a estimar únicamente con ese entrenamiento y se conserva el valor numérico del umbral OOF. No se recalcula el cuantil con la validación productora. Por ello, el cuantil seleccionado no fija una fracción exacta de derivación al evaluar.

E.5 Costo compartido y presupuesto

Sea $U(E)$ la unión de bloques de los miembros y c_j el costo por extractor del perfil fijado. Para la fracción interna derivada $\widehat{r}$, se estima

$$\widehat{C}(b, E) = \begin{cases} c_b, & E = \varnothing, \\ c_b + c_{\text{pol}} + \widehat{r} \displaystyle\sum_{j \in U(E) \setminus \{b\}} c_j, & E \neq \varnothing. \end{cases} \tag{E.9}$$

Los bloques compartidos se contabilizan una vez y la representación base se reutiliza. El piloto fija $c_{\text{pol}} = 0{,}45$ ms como sobrecosto del perfil. Este valor no constituye un cronometraje de todos los clasificadores del híbrido. El Anexo A registra las constantes utilizadas.

Los presupuestos $B \in \{15, 30, 60, 120\}$ ms restringen la media proyectada de selección, no el costo de cada imagen ni una media futura. La fracción derivada puede cambiar al evaluar. También se registra el número esperado de llamadas:

$$\widehat{L} = 1 + \widehat{r}\,|\,\text{unique}(E)|. \tag{E.10}$$

Menos llamadas no implica por sí solo una reducción física proporcional.

E.5.1 Interpretación del costo de adquisición

Para una política no vacía, sea $A_{b,E} = \sum_{j \in U(E) \setminus \{b\}} c_j$ el costo adicional del rescate. El modelo por imagen es

$$C_\pi(x) = c_b + c_{\text{pol}} + \mathbb{I}[m_b(x) < \tau]\, A_{b,E}. \tag{E.11}$$

La media de esta expresión da la Ecuación E.9. El sobrecosto fijo se aplica a todas las imágenes cuando existe rescate, no solo a las derivadas.

Una referencia que extrae permanentemente la misma unión tiene costo de adquisición $C_E = \sum_{j \in U(E)} c_j$, sin incluir latencia de clasificadores. Si $A_{b,E} > 0$, la política condicional reduce ese costo estimado únicamente cuando

$$\widehat{r} < \frac{C_E - c_b - c_{\text{pol}}}{A_{b,E}}. \tag{E.12}$$

La condición muestra dos efectos distintos: podar puede reducir $U(E)$ y enrutar puede reducir $\widehat{r}$. Una base fuera de la unión añade un costo que debe compensarse; el umbral también puede derivar demasiadas imágenes para que la adquisición resulte ventajosa. Esta identidad del modelo de costos no es una garantía de latencia física. Además, comparar un rescate podado condicional con un ensamble completo permanente cambia ambos mecanismos, por lo que no aísla el aporte de la compuerta.

E.6 Selección completa y poda del rescate

Sea $\mathcal{P}_B$ la familia restringida de políticas visitadas a partir de las bases candidatas, los cuantiles y la búsqueda de rescates para el presupuesto B. Se selecciona

$$\widehat{\pi}_B \in \operatorname*{arg\,max}_{\pi \in \mathcal{P}_B :\, \widehat{C}(\pi) \le B} \widehat{F}_{1,\text{OOF}}(\pi), \tag{E.13}$$

donde el macro-F1 se calcula sobre las puntuaciones internas reunidas. El desempate favorece menor costo, menos miembros y, finalmente, los identificadores deterministas de la implementación. La optimalidad se refiere solo a los puntos visitados en $\mathcal{P}_B$; no a todos los subconjuntos posibles. Si ninguna base cabe en el presupuesto, la configuración se registra como inviable.

El criterio operativo de este estudio es maximizar calidad interna dentro de un presupuesto de adquisición fijado, no aceptar una pérdida de F1 elegida después de observar validación. Al evaluar se informan conjuntamente ΔF_1, costo y cumplimiento del presupuesto frente a controles factibles para el mismo B. Una política domina descriptivamente a otra si no empeora ninguna de las dos magnitudes y mejora al menos una; de otro modo se conserva el compromiso, sin agregarlo en una puntuación arbitraria. No se escoge un presupuesto de despliegue ni se establece un margen retrospectivo de no inferioridad. Una excedencia en validación se registra como incumplimiento observado, aunque la selección interna fuera factible.

El rescate completo compara la base sola con los 15 votos para cada base, cuantil y presupuesto factibles. La poda empieza sin miembros y añade hasta tres modelos únicos del mismo ensamble. Cada adición debe mejorar el macro-F1 interno de la ruta y cumplir $\widehat{C} \le B$. Se comparan dos méritos:

$$h_{\text{rel}} = \Delta F_1, \qquad h_{\text{marg}} = \Delta F_1 / \Delta \widehat{C}. \tag{E.14}$$

Aquí ΔF_1 es el cambio de macro-F1 de la ruta completa sobre las imágenes internas reunidas, manteniendo base y umbral; no el F1 aislado del candidato ni el F1 de las imágenes derivadas solamente. $\Delta \widehat{C}$ es la diferencia de costo de adquisición al añadir ese

miembro a los ya elegidos. El primer criterio se denomina *relevancia* en los registros, pero su mérito es la ganancia de macro-F1 de la ruta, no la relevancia individual R_j usada para generar el ensamble. Solo se aceptan ganancias mayores que 10^{-12}. En el criterio marginal, una ganancia positiva con costo incremental no mayor que 10^{-12} tiene prioridad sobre razones finitas; el criterio de relevancia ordena por ganancia sin utilizar ese cociente. Los desempates consideran ganancia, costo y nombre del miembro. Se conserva el mejor punto interno visitado, incluida base sola.

Esta es una búsqueda heurística sobre candidatos generados, no una solución global del problema combinatorio. La relevancia y la razón marginal usan el mismo pool, bases y cuantiles; cambiar ese pool constituiría otra comparación.

Tabla E.1: Procedimiento de selección dentro de un entrenamiento productor. La validación productora no interviene en estos pasos.

1. Recibir entrenamiento productor, biblioteca, grupos, semilla y perfil de costos.
2. Calcular ranking individual y CKA; generar 15 subconjuntos de cuatro bloques.
3. Obtener puntuaciones OOF internas de bases y miembros, ajustando SVD y escalas dentro de cada ajuste pertinente.
4. Construir la frontera de bases; para cada presupuesto y cuantil, evaluar base sola y rescate completo o la secuencia de poda.
5. Conservar la política de mayor macro-F1 interno bajo el presupuesto y los desempates especificados.
6. Reajustar los modelos necesarios con el entrenamiento productor; congelar escalas y umbral. Guardar selección e índices antes de evaluar la validación productora.

Tabla E.2: Especificación de inferencia de la política seleccionada. El piloto la evalúa sobre puntuaciones guardadas; la ejecución física completa del híbrido no ha sido medida.

1. Extraer y normalizar la base; calcular su predicción y margen.
2. Si no hay rescate o el margen es al menos el umbral, devolver la predicción base.
3. En otro caso, adquirir $U(E) \setminus \{b\}$, reutilizando cada bloque ya disponible.
4. Evaluar cada modelo único del rescate; agregar puntuaciones con sus escalas y multiplicidades fijadas. Devolver la clase de mayor puntuación.

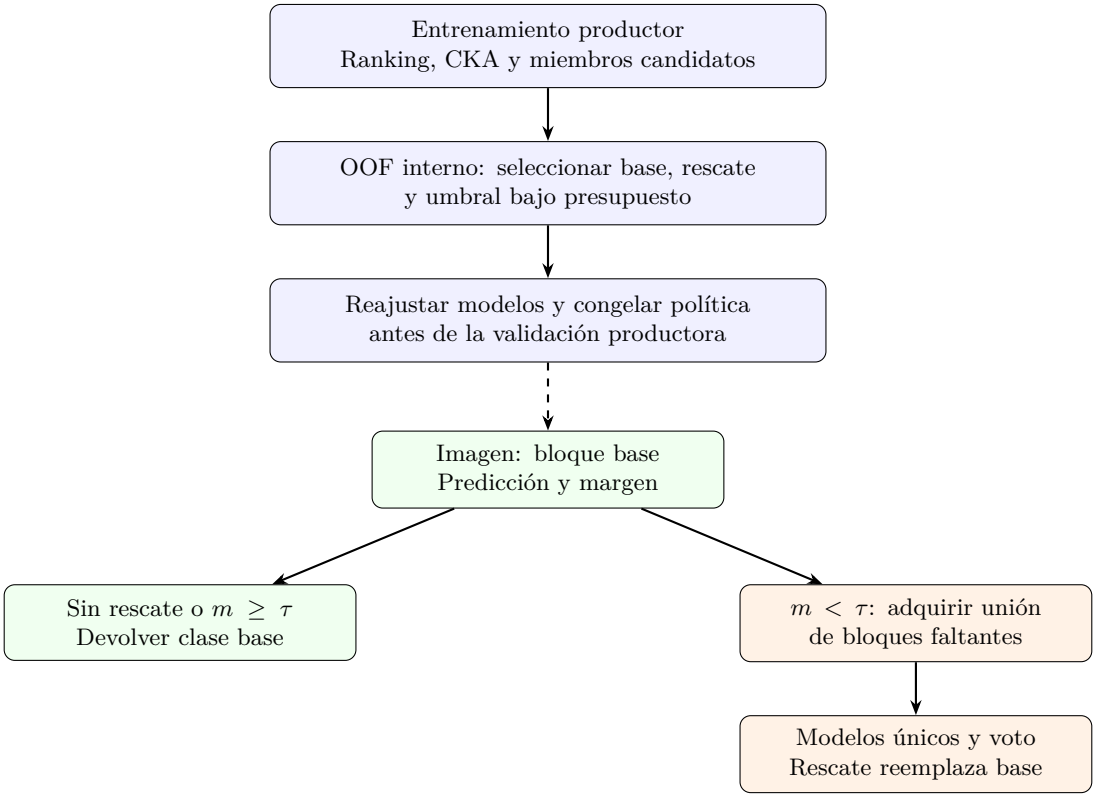


Figura E.1: Construcción de la política y especificación de su ejecución. La selección usa entrenamiento; la compuerta utiliza el margen de cada imagen, no su etiqueta. En el piloto las rutas se reconstruyen con puntuaciones guardadas y costos proyectados; no se cronometra esta ruta completa desde RGB.

E.7 Referencias estáticas y cascada de comparación

Las estrategias estáticas son: Individual, mejor descriptor interno; Completa, los 22 bloques; GFS, selección secuencial; Top-k, los primeros del ranking individual con k heredado de GFS; y Homogénea, GFS restringido a una familia con el límite de tamaño del GFS heterogéneo. Top-k controla composición bajo igual número de bloques, no una elección independiente de k.

GFS inicia vacío y añade el bloque que maximiza macro-F1 interno, hasta ocho bloques. Se detiene tras dos mejoras consecutivas menores que 0,001 y devuelve el mejor paso visitado. Sus detalles y esquema se conservan en el Anexo A.

La cascada de referencia usa una base y una concatenación Top-k archivada como rescate. Su compuerta deriva si $m(x) \leq \tau$, mientras el híbrido usa $m(x) < \tau$. El umbral se seleccionó entre cuantiles 0,25/0,50/0,75 minimizando costo bajo tolerancia interna de F1 de 0,005. La ruta Top-k no se reconstruyó dentro de cada pliegue productor OOF; esta dependencia se mantiene como límite de esa referencia. Si ninguna ruta cumple, se elige Top-k directo.

En la referencia se consideraron ResNet-50, SigLIP, BEiT-v2 y ConvNeXt V2; KTH utilizó solo ResNet-50 y BEiT-v2. No se confunde este conjunto acotado de bases con la frontera individual del híbrido.

E.8 Piloto de rescate de ensamble

Sea D_{dev} el entrenamiento oficial de Outex. Cada pliegue productor h lo divide en entrenamiento T_h y validación V_h, sin grupos compartidos. A su vez, T_h se divide en tres pliegues internos. Se distinguen cuatro operaciones:

1. Construir el ranking, calcular CKA y generar los subconjuntos utilizando T_h.
2. Reunir puntuaciones OOF internas de las imágenes de T_h y seleccionar base, umbral y rescate mediante la Ecuación E.13.
3. Reajustar los modelos elegidos con T_h, estimar sus escalas y conservar el umbral numérico seleccionado.
4. Predecir las imágenes de V_h sin modificar la política a partir de sus etiquetas.

Al reunir las tres validaciones V_h se obtienen las 680 predicciones OOF de desarrollo, una por imagen y política. Esas predicciones son distintas de las puntuaciones OOF internas que guiaron la selección.

La biblioteca de candidatos se construye a nivel de T_h; no se genera de nuevo dentro de cada pliegue interno. Las puntuaciones internas, por tanto, sirven como criterio de selección dentro de una búsqueda adaptada a T_h, no como evaluación independiente del procedimiento completo. La evaluación productora conserva separadas las imágenes de V_h. La semilla de partición productora es 142 y la interna, 42; el Anexo B registra tamaños y multiplicidades.

El piloto reutiliza puntuaciones de validación productora de los miembros del control de diversidad previamente auditado. Se ajustaron las puntuaciones internas faltantes y las bases necesarias, comprobando igualdad de particiones y procedencia. Los parámetros del ensamble, presupuestos y cuantiles se fijaron desde la configuración de desarrollo; no son una preespecificación ciega de toda la investigación.

Los controles del mismo piloto incluyen mejor individual interno, Top-3/4/5, Completa-22 y ensamble de diversidad permanente. Top-3/4/5 son tamaños fijos; no equivalen al Top-k del benchmark que hereda k de GFS. Se añadió un ensamble estático seleccionado bajo cada presupuesto, definido a continuación; no se dispone de GFS concatenado reajustado para este protocolo.

E.8.1 Ablación del mismo rescate con y sin compuerta

Se reconstruyeron cuatro vistas de cada una de las doce políticas a partir de puntuaciones y predicciones de validación productora guardadas: base sola, mismo rescate permanente, ruta forzada y ruta condicional. Se conservaron los miembros, multiplicidades, pesos, escalas, modelos y particiones; no se reentrenó ni se utilizó el test oficial. La base de cada vista es la elegida para esa política, no el mejor individual global.

El rescate permanente predice todas las imágenes con los miembros fijados y contabiliza únicamente la unión $U(E)$, sin extraer una base innecesaria. La ruta forzada conserva además la base y el sobrecosto de política, pero activa el mismo rescate en todas las imágenes. Ambas producen las mismas clases; la segunda tiene otra contabilidad de costo y llamadas. La vista condicional conserva la decisión archivada de la compuerta. Si el rescate es vacío, las cuatro vistas se reducen a la base; esos casos no aportan evidencia sobre enrutamiento.

El contraste entre rescate permanente y condicional aísla la activación para los modelos fijados en este archivo de desarrollo. No evalúa el mejor rescate estático posible: sus miembros fueron seleccionados conjuntamente con la compuerta. Las doce configuraciones reutilizan las mismas 680 imágenes y son dependientes. Se informan cambios predictivos, costos y llamadas, sin atribuirles significancia confirmatoria ni equivalencia poblacional.

E.8.2 Control estático bajo presupuesto

En cada entrenamiento productor se reúnen los 22 clasificadores individuales y los modelos únicos del ensamble de diversidad, con las puntuaciones OOF internas guardadas. Se enumeran todos los ensambles de uno a tres miembros únicos de ese pool, con igual peso y sin repetición. Para cada presupuesto 15, 30, 60 y 120 ms se elige el mayor macro-F1 interno cuya unión de bloques sea factible. Los desempates favorecen menor costo, menos modelos y orden léxico. No se añade una base ni una compuerta al costo del control permanente.

Las doce decisiones se guardaron antes de calcular sus predicciones de validación productora. Se reutilizaron nueve modelos disponibles y se reajustaron nueve con la misma receta SVM y el mismo entrenamiento productor. La enumeración es exhaustiva dentro de ese pool y límite de tres miembros, no sobre todas las concatenaciones o pondera-

ciones posibles. Se conservan los mismos pliegues y constantes del híbrido; el control no sustituye una ejecución GFS bajo presupuesto.

Este análisis se diseñó después de conocer el piloto y P0. Su regla se fijó antes de obtener las nuevas predicciones, pero no constituye una preinscripción ciega. Se conserva todo el barrido y no se usa el test oficial ni se reajusta el híbrido a partir del resultado del control.

E.8.3 Réplica en FMD y semillas adicionales

La réplica conserva la biblioteca de 22 bloques, SVM, tres pliegues productores y tres internos, presupuestos 15/30/60/120 ms y cuantiles 0,10/0,25/0,50. Mantiene cinco sorteos de candidatos de tamaño cuatro, hasta tres miembros podados y el ensamble de quince votos con $\beta = 8$ y $\lambda = 0{,}25$. No se modificaron estos parámetros a partir de sus resultados. Las cinco condiciones y los comandos se fijaron antes de ejecutar la cola, después de conocer el piloto; no constituyen una preinscripción ciega de la investigación.

En FMD se reserva el pliegue externo 0 de la partición estratificada y agrupada de cada semilla 42, 123 y 2026: 800 imágenes forman D_{dev} y las 200 restantes quedan excluidas. En Outex se mantiene el entrenamiento oficial de 680 imágenes y se añaden las semillas 123 y 2026, sin evaluar las 680 imágenes de test. El piloto Outex/42 se conserva por separado. Las semillas alteran particiones, sorteos y transformaciones; no aíslan solamente el efecto de la inicialización. La partición productora usa semilla $s + 100$ y la interna, s.

Cada condición evalúa referencias individuales, Top-3/4/5, Completa-22, ensambles permanentes, las tres reglas híbridas y el rival estático bajo presupuesto. La vista P0 vuelve a aplicar permanentemente exactamente el rescate seleccionado, sin reoptimizarlo. La cobertura se audita por imagen, grupo y transformación, manteniendo el test externo excluido. El perfil de costos es el mismo del piloto Outex, no una medición nueva de extracción en FMD. Las reglas completas y el detalle por semilla se conservan en el Anexo C.5.

E.9 Resultados del rescate de ensamble en desarrollo Outex

El piloto usa las 680 imágenes del entrenamiento oficial de Outex, semilla 42, tres folds productores y tres internos. El test oficial no fue evaluado. La Tabla E.4 muestra todas sus políticas; no se comparan directamente con el F1 de test de la Tabla 5.9.

Tabla E.3: Controles del mismo piloto Outex: macro-F1 OOF sobre 680 imágenes de entrenamiento oficial y costo medio proyectado, no latencia física.

Control	Macro-F1	Costo proyectado ms
Individual interno	0,871642	177,300
Top-3	0,882967	236,862
Top-4	0,884244	256,272
Top-5	0,900824	288,435
Completa-22	0,913957	1706,420
Diversidad15 permanente	0,914389	365,196

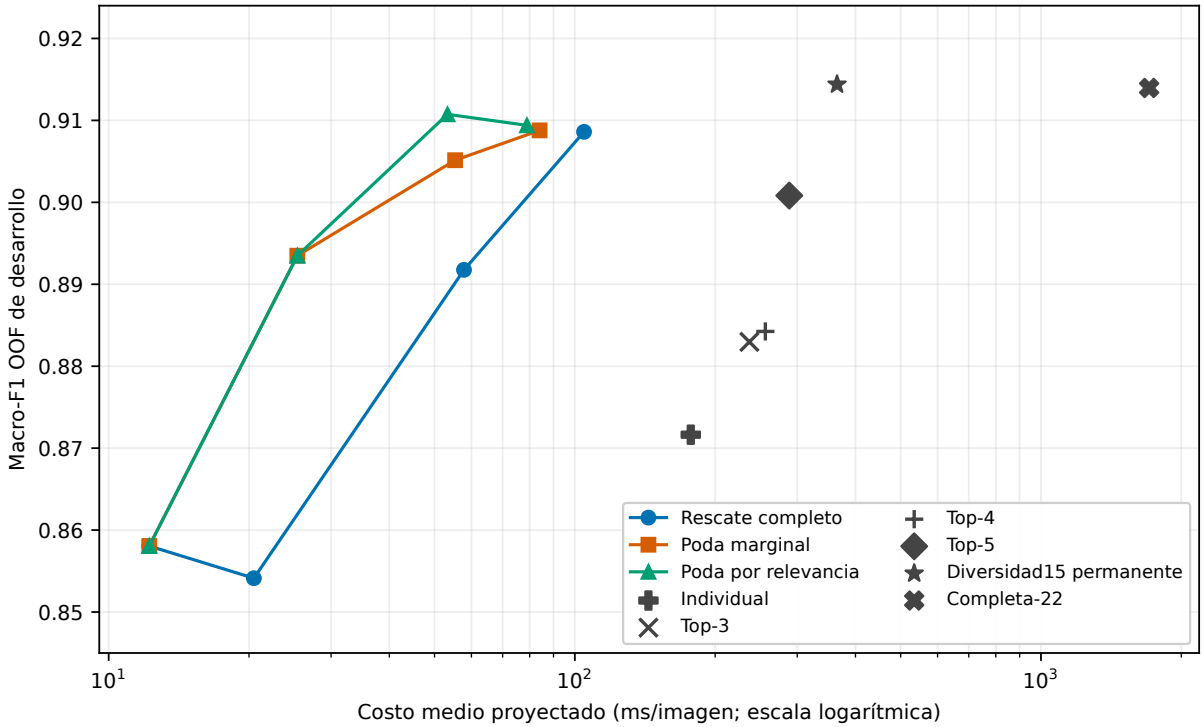


Figura E.2: Políticas del piloto Outex y controles del mismo protocolo. Se muestran los cuatro presupuestos de cada variante, incluidos puntos coincidentes. El eje horizontal es costo proyectado en escala logarítmica, no latencia física; las líneas no representan una frontera óptima.

Tabla E.4: Piloto híbrido de Outex: macro-F1 OOF de desarrollo y costo proyectado. B es el presupuesto de selección en ms; los costos no son latencias físicas.

Ruta	B	Macro-F1	Costo proyectado ms
Diversidad15 permanente	–	0,914389	365,196
Completo como rescate	15	0,858056	12,220
Podado marginal	15	0,858056	12,220
Podado relevancia	15	0,858056	12,220
Completo como rescate	30	0,854129	20,485
Podado marginal	30	0,893488	25,394
Podado relevancia	30	0,893488	25,394
Completo como rescate	60	0,891759	57,839
Podado marginal	60	0,905140	55,365
Podado relevancia	60	0,910742	53,316
Completo como rescate	120	0,908603	104,660
Podado marginal	120	0,908781	84,018
Podado relevancia	120	0,909396	78,938

El punto podado por relevancia/B60 obtiene 0,910742, frente a 0,914389 de diversidad permanente, con 85,40% menos costo estimado y una diferencia de F1 de −0,003646 (aproximadamente −0,365 puntos porcentuales). Top-5 obtiene 0,900824/288,435 ms y Completa-22 0,913957/1706,420 ms. El híbrido supera numéricamente Top-5, pero no a Completa ni al ensamble permanente en calidad. B60 es un punto observado dentro del barrido de desarrollo, no un presupuesto validado de forma independiente después de su selección.

Ese punto deriva 278/680 imágenes: corrige 52 errores de las bases y perjudica cinco aciertos. El saldo de 47 aciertos adicionales describe exactitud, no una diferencia de macro-F1, que depende de la distribución de errores por clase. Sus bases son DINOv2-small, BEiT-v2-final y VGG16, con dos, dos y un modelos de rescate únicos. Las llamadas medias son 1,654 frente a 10,665 del ensamble permanente. El resto de las imágenes sale por la base; el Anexo B aclara la diferencia entre votos y modelos ejecutados.

A presupuesto 15 se elige base sola; el rescate completo/B30 tampoco se activa. Relevancia supera a marginal en calidad y costo en los puntos de 60 y 120 ms. Los 36 presupuestos internos se cumplen, pero completo/B60/fold1 registra 70,019604 ms proyectados en validación frente a 59,602804 internos. Se conservan esa excedencia y la falta de monotonía del F1 con el presupuesto.

La Tabla E.3 y la Figura E.2 permiten comparar referencias sin trasladar cifras de test externo. El primer control siguiente mantiene fijo el rescate; el segundo lo compara con una selección estática propia bajo presupuesto. GFS concatenado sigue sin evaluarse en este protocolo. El análisis emparejado de N-gramas se conserva como evidencia secundaria en el Anexo C.

E.9.1 Separación de poda y activación condicional

La Tabla E.5 descompone el punto relevancia/B60 con el control de la Sección E.8.1. Son las mismas 680 imágenes y los mismos modelos del piloto; el recálculo no constituye otra evaluación independiente.

Tabla E.5: Control de poda y compuerta en relevancia/B60. Macro-F1 OOF sobre las mismas 680 imágenes; costo medio de adquisición proyectado y llamadas a clasificadores únicos por imagen. No son tiempos físicos.

Vista	Macro-F1	Costo ms	Llamadas
Ensamble completo permanente	0,914389	365,196	10,665
Mismo rescate podado permanente	0,911993	110,421	1,668
Mismo rescate, ruta forzada	0,911993	110,871	2,668
Ruta condicional	0,910742	53,316	1,654

La poda cambia el ensamble permanente de 0,914389/365,196 ms a 0,911993/110,421 ms: reduce la adquisición proyectada en 69,76%, con ΔF1 = −0,002395. Activar condicionalmente ese mismo rescate reduce otros 51,72% respecto de su ejecución permanente, hasta 53,316 ms, con ΔF1 = −0,001251. Las reducciones se aplican sucesivamente y no se suman; el descenso total frente al ensamble completo es 85,40%. La ruta forzada retiene la base y tiene costo 110,871 ms; se distingue de la referencia permanente eficiente, que omite ese trabajo.

Frente al mismo rescate permanente, la compuerta cambia tres clases predichas: corrige una y perjudica dos. La exactitud pasa de 0,914706 a 0,913235. Es un contraste distinto del balance de 52 errores corregidos y cinco aciertos perjudicados frente a las bases. Las llamadas medias apenas disminuyen un 0,79% respecto del rescate podado permanente, de 1,668 a 1,654. La gran reducción de llamadas frente al ensamble completo corresponde principalmente a la poda, no a la compuerta.

En marginal/B60, las 680 predicciones condicionales coinciden exactamente con las del mismo rescate permanente: macro-F1 0,905140 y exactitud 0,907353. Su costo proyectado pasa de 97,282 a 55,365 ms, una reducción de 43,09%. Sin embargo, las llamadas aumentan de 1,334 a 1,672, un 25,36%, porque la ruta también calcula la base. Menor adquisición proyectada puede coexistir con más evaluaciones de clasificadores; la coincidencia de clases en estas imágenes no prueba equivalencia poblacional.

El barrido completo, incluida la base sola, se presenta en la Tabla C.9. En ocho configuraciones existe rescate: la compuerta reduce F1 en siete y conserva las predicciones en marginal/B60; no mejora F1 en ninguna. Las otras cuatro se reducen a la base. Los rescates permanentes de ambos criterios en B60 superan 60 ms proyectados, mientras sus rutas condicionales quedan por debajo en la media reunida. Esto no descarta una alternativa estática distinta que cumpla el mismo presupuesto. La excedencia del rescate completo/B60 en un pliegue sigue vigente. Para esta ablación no se calcularon valores p ni se midió latencia física.

E.9.2 Comparación con selección estática bajo presupuesto

El control de la Sección E.8.2 cumple su presupuesto en las doce combinaciones de pliegue y presupuesto. Los pools contienen 31, 33 y 34 candidatos. En B60 se examinan 617 combinaciones factibles por pliegue; en B120, entre 1.287 y 1.701. La elección usa únicamente macro-F1 OOF interno. La Tabla E.6 conserva los cuatro presupuestos frente a relevancia, sin recomendar uno retrospectivamente.

Tabla E.6: Control estático optimizado dentro del pool visitado, con hasta tres miembros, frente al híbrido por relevancia bajo el mismo presupuesto. Macro-F1 OOF de desarrollo sobre 680 imágenes; C es adquisición media proyectada en ms. Δ es híbrido menos estático.

B	F1 estático	C estático	F1 híbrido	C híbrido	ΔF1
15	0,859690	13,752	0,858056	12,220	-0,001634
30	0,861264	28,463	0,893488	25,394	0,032225
60	0,892923	44,831	0,910742	53,316	0,017819
120	0,909612	103,040	0,909396	78,938	-0,000216

En B30, el híbrido por relevancia tiene mayor F1 observado y menor costo proyectado que el control: 0,893488/25,394 ms frente a 0,861264/28,463 ms. En B60 obtiene 0,910742 frente a 0,892923, pero también adquiere más información estimada: 53,316 frente a 44,831 ms. Ambos cumplen 60 ms en la media reunida; no son puntos de idéntico costo.

En B15, el estático tiene mayor F1 (0,859690 frente a 0,858056) y mayor costo (13,752 frente a 12,220 ms). En B120 también obtiene mayor F1 (0,909612 frente a 0,909396) con mayor costo (103,040 frente a 78,938 ms). Por tanto, la comparación no muestra superioridad uniforme de la adquisición condicional. La ventaja predictiva observada dentro de B60 corresponde a este pool, semilla y protocolo de desarrollo; no establece optimalidad global, significancia entre dominios ni aceleración física.

E.10 Réplica del rescate en dos datasets

Las cinco condiciones nuevas de la Sección E.8.3 completaron sus etapas y la auditoría de índices, selecciones y predicciones. Las medias de la Tabla E.7 no incluyen el piloto Outex/42: resumen tres semillas FMD y dos semillas Outex. Se conserva relevancia como referencia de la discusión del piloto, sin cambiar la regla para escoger retrospectivamente el mejor resultado de cada fila. Las tres reglas completas y las referencias emparejadas figuran en las Tablas C.10 y C.11.

Tabla E.7: Réplica de desarrollo: media entre semillas nuevas de macro-F1 / costo proyectado (ms). El número entre paréntesis es el de semillas, no datasets independientes. B restringe el costo interno medio; no es el costo medido. Outex/42 no integra estas medias.

Dataset	B	Híbrido relevancia	Estático presupuestado
FMD (3)	15	0,970011 / 11,680	0,970011 / 11,680
FMD (3)	30	0,974618 / 18,499	0,968776 / 14,777
FMD (3)	60	0,977489 / 35,689	0,974600 / 41,888
FMD (3)	120	0,977074 / 46,923	0,977082 / 100,929
Outex (2)	15	0,862953 / 12,220	0,866642 / 13,372
Outex (2)	30	0,895551 / 24,224	0,874557 / 25,989
Outex (2)	60	0,905991 / 40,750	0,889152 / 49,047
Outex (2)	120	0,908323 / 77,365	0,905582 / 109,396

En B60, relevancia alcanza en FMD macro-F1 medio 0,977489 y adquisición proyectada 35,689 ms, frente a 0,974600/41,888 ms del estático. En las dos semillas nuevas de Outex obtiene 0,905991/40,750 ms frente a 0,889152/49,047 ms. Son comparaciones bajo un

mismo presupuesto de selección, no a idéntico costo realizado ni pruebas de significancia entre dominios. En FMD/B30 el mayor F1 del híbrido requiere más costo; en FMD/B120 las medias de F1 casi coinciden, sin demostrar equivalencia. En Outex/B15 el estático conserva mayor F1 a cambio de mayor adquisición.

El promedio FMD/B60 oculta diferencias importantes entre semillas. En la semilla 42, el estático supera al híbrido en calidad y costo: 0,978772/35,078 ms frente a 0,977506/38,282 ms. En 123, el híbrido pierde 0,000042 de F1 con menor costo (35,869 frente a 52,565 ms); en 2026 lo supera en ambas medidas. Tampoco se conserva una dominancia general de relevancia sobre marginal: en FMD/123/B30, marginal obtiene 0,975051/15,770 ms frente a 0,973800/17,771 ms. Las reglas compiten según condición y presupuesto.

La comparación del mismo rescate con y sin compuerta también cambia de signo entre dominios. En relevancia/B60, el promedio FMD pasa de 0,974596/281,061 ms permanente a 0,977489/35,689 ms condicional; en las semillas nuevas de Outex pasa de 0,912135/134,273 ms a 0,905991/40,750 ms. La compuerta puede conservar aciertos de la base que el rescate perdería, pero no mejora siempre la calidad. La Tabla C.12 presenta todos los presupuestos y reglas, incluidos los casos sin rescate. La referencia permanente no es un rival reoptimizado para cumplir el presupuesto del híbrido.

La réplica amplía la evidencia del piloto, pero sigue siendo desarrollo sobre benchmarks previamente observados. No valida una política única de despliegue, ni el híbrido en los seis conjuntos, ni el ahorro físico. GFS y Top-k con tamaño seleccionado requieren ajustes propios bajo este protocolo; no se sustituyen por Top-3/4/5 ni por cifras de test externo.

Referencias

[1] Li Liu, Jie Chen, Paul Fieguth, Guoying Zhao, Rama Chellappa, and Matti Pietik"ainen. From BoW to CNN: Two decades of texture representation for texture classification. *International Journal of Computer Vision (IJCV)*, 127:74–109, 2019. doi: 10.1007/s11263-018-1125-z.

[2] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, and Andrea Vedaldi. Deep filter banks for texture recognition, description, and segmentation. *International Journal of Computer Vision (IJCV)*, 118(1):65–94, 01 2016. doi: 10.1007/s11263-015-0872-3.

[3] Feng Nan and Venkatesh Saligrama. Adaptive classification for prediction under a budget. In *Advances in Neural Information Processing Systems*, volume 30, 2017. URL `https://proceedings.neurips.cc/paper_files/paper/2017/hash/d9ff90f4000eacd3a6c9cb27f78994cf-Abstract.html`.

[4] Yizeng Han, Gao Huang, Shiji Song, Le Yang, Honghui Wang, and Yulin Wang. Dynamic neural networks: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 44(11):7436–7456, 2021. doi: 10.1109/TPAMI.2021.3117837.

[5] Timo Ojala, Matti Pietikäinen, and Topi Mäenpää. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 24(7):971–987, 07 2002. doi: 10.1109/TPAMI.2002.1017623.

[6] Anil K. Jain and Farshid Farrokhnia. Unsupervised texture segmentation using Gabor filters. *Pattern Recognition*, 24(12):1167–1186, 1991. doi: 10.1016/0031-3203(91)90143-S.

[7] Robert M. Haralick. Statistical and structural approaches to texture. *Proceedings of the IEEE*, 67(5):786–804, 05 1979. doi: 10.1109/PROC.1979.11328.

[8] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893. IEEE, 06 2005. doi: 10.1109/CVPR.2005.177.

[9] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 06 2016. doi: 10.1109/CVPR.2016.90.

[10] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2261–2269. IEEE, 07 2017. doi: 10.1109/CVPR.2017.243. URL `https://openaccess.thecvf.com/content_cvpr_2017/html/Huang_Densely_Connected_Convolutional_CVPR_2017_paper.html`.

[11] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua

Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 05 2021. URL https://openreview.net/forum?id=YicbFdNTTy. International Conference on Learning Representations (ICLR).

[12] Fátima Belén Paiva Pavón, María Cristina Orué Gil, José Luis Vázquez Noguera, Helena Gómez-Adorno, and Valentín Calzada-Ledesma. Rgb pixel n-grams: A texture descriptor. *Signal Processing: Image Communication*, 118:117028, 2023. doi: 10.1016/j.image.2023.117028.

[13] Ron Kohavi and George H. John. Wrappers for feature subset selection. *Artificial Intelligence*, 97(1–2):273–324, 1997. doi: 10.1016/S0004-3702(97)00043-X.

[14] Isabelle Guyon and André Elisseeff. An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182, 2003. URL https://www.jmlr.org/papers/v3/guyon03a.html.

[15] Nikolay Neshov, Krasimir Tonchev, Ivaylo Bozhilov, Radostina Petkova, and Agata Manolova. Improving texture recognition via multi-layer feature aggregation from pre-trained vision architectures. *Electronics*, 14(23):4779, 2025. doi: 10.3390/electronics14234779.

[16] A. Philomina Simon and B. V. Uma. DeepLumina: A method based on deep features and luminance information for color texture classification. *Computational Intelligence and Neuroscience*, 2022:9510987, 2022. doi: 10.1155/2022/9510987.

[17] Vandana Gupta, Ashish Mishra, and Nishant Shrivastava. HyTexNet: Percentile-guided local encoding and deep feature fusion for enhanced texture classification. *Knowledge-Based Systems*, 338:115482, 2026. doi: 10.1016/j.knosys.2026.115482.

[18] Mingzhe Chang, Luping Ji, and Jiewen Zhu. Multi-scale LBP fusion with the contours from deep CellNNs for texture classification. *Expert Systems with Applications*, 238:122100, 2024. doi: 10.1016/j.eswa.2023.122100.

[19] Leonardo Scabini, Arthur Sacilotti, Kamil M. Zielinski, Lucas C. Ribas, Bernard De Baets, and Odemir M. Bruno. A comparative survey of vision transformers for feature extraction in texture analysis. *Journal of Imaging*, 11(9):304, 2025. doi: 10.3390/jimaging11090304.

[20] Paul Viola and Michael Jones. Rapid object detection using a boosted cascade of simple features. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 1, pages I–511. IEEE, 2001. doi: 10.1109/CVPR.2001.990517.

[21] Zhixiang Xu, Kilian Q. Weinberger, and Olivier Chapelle. The greedy miser: Learning under test-time budgets. In *Proceedings of the 29th International Conference on Machine Learning*, 2012. URL https://icml.cc/2012/papers/592.pdf.

[22] Chao Ma, Sebastian Tschiatschek, Konstantina Palla, José Miguel Hernández-Lobato, Sebastian Nowozin, and Cheng Zhang. EDDI: Efficient dynamic discovery of high-value information with partial VAE. In *International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 4234–4243. PMLR, 2019. URL https://proceedings.mlr.press/v97/ma19c.html.

[23] Surat Teerapittayanon, Bradley McDanel, and H. T. Kung. Branchynet: Fast inference via early exiting from deep neural networks. In *23rd International*

Conference on Pattern Recognition (ICPR), pages 2464–2469. IEEE, 2016. doi: 10.1109/ICPR.2016.7900006.

[24] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, Sammy Mohamed, and Andrea Vedaldi. Describing textures in the wild. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3606–3613, 06 2014. doi: 10.1109/CVPR.2014.461.

[25] Lavanya Sharan, Ce Liu, Ruth Rosenholtz, and Edward H. Adelson. Recognizing materials using perceptually inspired features. *International Journal of Computer Vision (IJCV)*, 103(3):348–371, 07 2013. doi: 10.1007/s11263-013-0609-0.

[26] Manik Varma and Andrew Zisserman. Texture classification: Are filter banks necessary? In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 2, pages 691–698. IEEE, 2003. URL `https://www.robots.ox.ac.uk/~vgg/publications/2003/Varma03/varma03.pdf`.

[27] Timo Ojala, Topi Mäenpää, Matti Pietikäinen, Jaakko Viertola, Juha Kyllönen, and Sami Huovinen. Outex—new framework for empirical evaluation of texture analysis algorithms. In *Proceedings of the 16th International Conference on Pattern Recognition*, volume 1, pages 701–706. IEEE, 2002. doi: 10.1109/ICPR.2002.1044854.

[28] Janez Demšar. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30, 2006.

[29] Salvador García and Francisco Herrera. An extension on "statistical comparisons of classifiers over multiple data sets" for all pairwise comparisons. *Journal of Machine Learning Research (JMLR)*, 9(89):2677–2694, 2008. URL `https://jmlr.org/papers/v9/garcia08a.html`.

[30] Rakesh Mehta and Karen Egiazarian. Dominant rotated local binary patterns (DRLBP) for texture classification. *Pattern Recognition Letters*, 71:16–22, 02 2016. doi: 10.1016/j.patrec.2015.11.019.

[31] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition, 2015. URL `https://arxiv.org/abs/1409.1556`. International Conference on Learning Representations (ICLR).

[32] Mingxing Tan and Quoc Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 6105–6114. PMLR, 06 2019. URL `https://proceedings.mlr.press/v97/tan19a.html`.

[33] Sanghyun Woo, Shoubhik Debnath, Ronghang Hu, Xinlei Chen, Zhuang Liu, In So Kweon, and Saining Xie. Convnext v2: Co-designing and scaling convnets with masked autoencoders. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16133–16142, 06 2023. doi: 10.1109/CVPR52729.2023.01548.

[34] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *International Conference on Machine Learning (ICML)*, volume 139 of *Proceedings of Machine Learning Research*, pages 10347–10357. PMLR, 07 2021. URL `https://proceedings.mlr.press/v139/touvron21a.html`.

[35] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted

windows. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 10012–10022, 10 2021. doi: 10.1109/ICCV48922.2021.00986.

[36] Yuxin Fang, Quan Sun, Xinggang Wang, Tiejun Huang, Xinlong Wang, and Yue Cao. Eva-02: A visual representation for neon genesis. *Image and Vision Computing*, 149: 105171, 09 2024. doi: 10.1016/j.imavis.2024.105171.

[37] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research (TMLR)*, 07 2024. URL `https://arxiv.org/abs/2304.07193`.

[38] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16000–16009. IEEE, 06 2022. doi: 10.1109/CVPR52688.2022.01553.

[39] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 11941–11952. IEEE, 10 2023. doi: 10.1109/ICCV51070.2023.01100.

[40] Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey Hinton. Similarity of neural network representations revisited. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 3519–3529, 2019. URL `https://proceedings.mlr.press/v97/kornblith19a.html`.